

队伍编号	MCB2400837
赛道	A

台风的分类与预测

摘要

台风作为一种极端气象现象，对沿海地区的安全和经济活动构成了严重威胁。随着全球气候变化的加剧，台风的频率和强度可能会发生变化，这使得准确预测其路径、强度及其对环境影响的能力显得尤为重要。台风的形成和发展受多种气象因素的影响，包括气温、气压、洋流和风场等，这些因素的复杂相互作用使得台风的研究充满挑战。近年来，借助大数据和机器学习技术，研究人员在台风路径预测和影响因素分析方面取得了显著进展。然而，现有的研究仍然面临数据维度不一致、特征提取不足以及模型鲁棒性等问题，限制了其实际应用效果。因此，系统性地研究台风的分类、路径预测及其登陆后衰减特征，不仅可以提升对台风行为模式的理解，还能为灾害预警和应对策略的制定提供有力支持。

本次赛题围绕台风分类、路径预测和登陆后风速与降水量衰减的需求展开。研究团队首先针对台风分类评价，利用多个权威数据集及中国气象局获取的气象数据，提取台风的时序观测数据，并转化为一致性的17个特征向量，以确保后续建模时特征维度统一。团队采用层次聚类算法构建分类树状图，识别具有相似特征的台风类别，共计分类21类，并对每个类别进行了命名，具体结果见表4.6-4.7。同时，团队使用循环神经网络（RNN）捕捉台风路径的短期和长期特征，预测2024年7月及9月的分类情况，结果也见表4.8。通过分析夏季与秋季台风的特征差异发现，夏季台风受低气压和西南季风影响，路径复杂，易深入内陆。秋季气压较高、气压梯度增大，受东北季风影响，台风多在沿海转向偏东北，路径较稳定，影响范围较小。此外，研究发现随着全球气候变暖，秋季台风的行径路径呈现出与夏季台风行径路径相似的趋势。这一发现为进一步理解台风行为模式及其气候变化影响提供了重要依据。

其次，在台风路径预测方面，研究团队探索气温、气压、洋流和风场等多重因素对路径的影响，以预测2024年9月13日至17日第13号台风贝碧嘉的中心位置。为提高预测精度，团队选择了发生时期相近、强度相似和中心位置相近的历史台风数据作为训练样本。由于台风生命周期和数据记录频率差异，团队采用步长为2天的滑动窗口法将每条台风数据划分为多个训练样本，从而详细刻画不同发展阶段。最终提取了147个时序特征，包括经度、纬度、风速、气压和气温等，并利用长短期记忆网络（LSTM）算法进行逐步预测，结果见表5.2。为评估模型准确性，团队采用动态时间规整（DTW）算法计算预测路径与实际路径的差异，DTW距离为8.8774，表明预测路径与实际路径相似性较高；地理位移误差为 0.4035° ，显示预测点与真实点的空间偏差小，模型的路径预测效果良好。这一研究为理解台风路径的动态变化提供了重要依据。

最后，针对台风登陆后风速和降水量的衰减预测，研究团队分析台风中心风速和降水量与登陆距离的关系，在问题二的特征基础上，继续采用步长为4天的滑动窗口法，以每日14时的台风数据进行特征扩充，共扩充54个时序特征。并结合LSTM与多重注意力机制，逐步预测风速和降水量的动态变化。研究还分析影响预测结果的关键气象指标，为有效应对台风灾害提供数据支持。模型通过LSTM与多重注意力机制，成功捕捉了台风贝碧嘉登陆后的风速与降水变化趋势。误差分析和DTW对比结果表明，模型在台风衰减趋势的预测上表现良好。

关键词：分类评价；系统聚类；RNN；路径预测；LSTM；DTW；多重注意力机制

目 录

一、问题重述	1
1.1 问题背景	1
1.2 目标任务	1
二、模型假设及符号	2
2.1 模型假设	2
2.2 主要的符号说明	2
三、问题分析	3
3.1 针对问题一	3
3.2 针对问题二	4
3.3 针对问题三	5
四、问题一模型的建立与求解	6
4.1 数据预处理	6
4.1.1 数据来源	6
4.1.2 数据过滤	7
4.1.3 数据清洗与缺失值处理	8
4.1.4 数据整合	9
4.2 特征提取	11
4.2.1 原始数据局限与特征提取的必要性	11
4.2.2 搭建特征空间	11
4.2.3 关键特征的提取	12
4.3 基于层次聚类的分类模型	13
4.3.1 特征选择与数据标准化处理	13
4.3.2 层次聚类模型的构建	13
4.3.3 模型参数与阈值设置	14
4.3.4 台风路径类型划分	14
4.3.5 模型评估	15
4.3.6 结果展示与分析	16
4.4 基于循环神经网络的台风数据分类评价	16
4.4.1 模型选择与架构	16
4.4.2 模型训练与验证	17
4.4.3 分类规则与评估	17
4.5 夏台风与秋台风的对比分析	17
4.5.1 结果展示	17
4.5.2 差异分析	18
4.5.3 结果应用与分析	18
五、问题二模型的建立与求解	19
5.1 台风的数据融合	19
5.1.1 台风数据筛选	19
5.1.2 台风数据融合	19
5.2 数据预处理	20

5.3 搭建特征空间	20
5.3.1 滑动窗口的建立	20
5.3.2 指标的选取	22
5.4 基于 LSTM 的路径预测模型	24
5.4.1 训练集与测试集的构建	24
5.4.2 LSTM 模型的实施	24
5.4.3 预测结果与分析	25
5.4.4 问题二小结	26
六、 问题三模型的建立与求解	28
6.1 台风数据融合	28
6.1.1 数据筛选	28
6.1.2 数据融合	29
6.2 搭建特征空间	30
6.3 基于 LSTM+多重注意力机制的预测模型	31
6.3.1 滑动窗口处理数据	31
6.3.2 模型的实施	32
6.3.3 预测结果分析	32
6.4.4 问题三小结	33
七、模型的评价与推广	34
7.1 模型评价	34
7.2 模型推广	34
八、参考文献	35
九、附录	36

一、问题重述

1.1 问题背景

台风是全球范围内破坏力最强的自然灾害之一，尤其在夏秋季节，常伴随强风、暴雨、风暴潮等极端天气，对沿海地区的经济和社会发展造成严重影响。台风的形成通常依赖于海洋温度、气压系统和地球自转偏向力等气象因素。当海洋表面温度上升时，水汽蒸发形成低压气旋，并在地转偏向力的作用下旋转并发展成台风，特别是西北太平洋地区，台风活动频繁，路径复杂，常呈现出西进型、转向型、迷走型等多种模式。

然而，近年来全球气候变暖，海洋表面温度上升，台风的频率和强度发生了显著变化，路径预测的难度也随之增加。2024 年第 13 号台风贝碧嘉便是这一现象的典型案例。贝碧嘉的初期路径预测显示它将影响浙江沿海，然而在逼近浙江时，台风发生转向，未登陆台州，最终路径偏向了其他区域。这次预测偏差引发了防灾资源的调度浪费，给多个地区带来误判的风险。

这次台风的路径变化强调了台风分类与预测中大数据技术的必要性。通过历史气象数据、海洋温度、风速、气压等多源数据，结合动态时间规整算法（DTW）等技术，可以更加精确地预测台风的路径和强度，从而提高预警的准确性。大数据技术在这一背景下显得尤为关键，能够通过机器学习和数据挖掘对台风特征进行多维度分析，提升预测模型的科学性和时效性。

大数据驱动的台风研究和预测对现代社会有着重要现实意义：

①提高台风预测的准确性：基于历史数据和先进算法，如动态时间规整（DTW）和深度学习，可以更准确地预测台风路径和强度，降低误差，帮助决策者做出及时反应。

②防灾减灾的提前部署：准确的台风路径预测能帮助政府和救援机构提前部署防灾措施，减少因预测不准确带来的资源浪费及潜在损失。

③促进经济和基础设施的规划：台风预测对物流、能源和建筑等行业有着重要的决策支撑，帮助优化资源调配，减少经济损失。

基于大数据分析的台风分类与预测能够更好地应对气候变化背景下的复杂气象系统，有效提高预测的科学性和社会响应能力，助力防灾减灾与可持续发展。

1.2 目标任务

本次研究主要针对台风的分类与路径预测问题，结合大数据分析技术，通过数据建模与算法优化，解决赛题提出的三个问题：

问题 1：分析台风特征参数与气象因素的关系，构建台风分类评价模型，明确台风类别划分标准。预测 2024 年 7 月和 9 月的台风类别及其途经省份，并区别夏台风与秋台风。

问题 2：利用动态时间规整算法（DTW），结合气温、气压、季风等因素，建立台风路径预测模型，并以 2024 年第 13 号台风贝碧嘉为例进行路径对比分析。

问题 3：根据台风登陆后的强度衰减，建立降水量和风速变化模型，验证并分析 2024 年第 13 号台风的数据。

二、模型假设及符号

2.1 模型假设

为了简化台风路径预测与分类模型的建立，在不影响模型精度的前提下，团队做出以下假设：

（1）假设台风路径中的观测点与台风中心的距离在 **500 公里**内，并且观测点的日期记录与台风中心的日期为**同一天**，则可以认为该观测点的气象数据能够较好地反映台风在该位置的气象特征。

（2）假设台风主要影响的范围为**季风区**。

（3）假设**海表温度**是反映海洋整体温度最有效的变量。

（4）假设海表温度的**测量深度为 2 米**，足以反映海洋表层的热状态。

（5）假设**月度海表温度的变化幅度较小**，用**当月 2 米深度**的海表温度值来**代表该月所有**台风期间的海表温度情况。

（6）假设台风的实际路径为曲线，但由于观测数据仅包含两个经纬度坐标点，且时间间隔较短（每 6 小时记录一次），为简化计算，**假设两点间的台风路径为直线**。

2.2 主要的符号说明

符号	意义
T	台风强度
M	季风影响参数
P	气压(pa)
SST	海表温度(°C)
V	最大风速(m/s)
C_t	台风类别
R_t	台风路径
RH	相对湿度
lat	纬度
lon	经度

三、问题分析

3.1 针对问题一

问题一以台风分类评价为基础，重点探讨台风特征参数（如强度、等级、风速等）与气温、气压、季风等气象因素的关系。**研究依托赛题组提供的多个权威数据集，以及从中国气象局爬取的气象数据**，获取台风路径、气温、降水、风速和海洋环境等完整信息，用于涵盖台风生成和移动过程中的重要特征。由于台风生命周期和持续时间各异，刻画台风的记录数据条数不一致，这会导致后续建模时维度不统一。因此，**为确保特征维度一致，需要对海量数据进行特征提取**，将台风的时序观测数据转化为一致性的特征向量，以便后续的分类评价模型能够有效处理这些数据。

在构建台风分类评价模型中，研究团队将**考虑多个分类视角，包括台风季节、方向和具体路径等**，搭建可以刻画这些分类视角的关键气象指标，如使用哈弗塞恩公式计算台风路径点之间的空间地理距离、气温最大变化率、气压最大变化率和路径转向角等。在此基础上，**团队选择层次聚类算法**。这种方法可以通过树状图直观地展示不同类别的分层关系，有助于识别具有相似特征的台风类别。算法采用完全链接法逐步合并特征相似的台风样本。这一过程最终形成分类树状图，揭示出台风类别的自然分布，从而为后续研究和应对策略提供数据支持。

为了深入构建台风的分类评价模型，在特征提取和层次聚类结果的基础上，**研究团队选择使用循环神经网络（RNN）来捕捉台风路径的短期和长期特征**。基于历史台风特征数据，训练这些模型学习不同类别台风的特征模式，从而在 2024 年 7 月和 9 月的台风特征基础上，对其分类预测，并列出各类别台风的途径省份。最终，基于模型的分类结果，研究团队需要分析夏季（6-8 月）与秋季（9-11 月）台风的特征差异，包括气温、台风强度、路径模式和降水等方面，以全面理解不同气象背景和海洋环境对台风行为模式的影响。**具体流程图见图 3.1。**



图 3.1 问题一模型流程图

3.2 针对问题二

针对台风路径预测需求，研究团队将探索气温、气压、洋流和风场等多重因素对台风路径的影响，以预测 2024 年 9 月 13 日至 17 日第 13 号台风贝碧嘉每天 14 时的中心位置。为了更精准地预测台风趋势，团队选择了发生时期相近、强度相似和中心位置相近的历史台风数据作为训练样本。同时，由于台风的生命周期和数据记录频率差异，导致数据记录数不一致，传统模型难以处理。为提高模型的鲁棒性，团队采用滑动窗口法，通过固定台风时长，将每条台风数据划分为多个训练样品，从而详细刻画台风的

不同发展阶段。团队基于已知的贝碧嘉在 9 月 10 日 14 时至 9 月 12 日 14 时的数据，将滑动窗口长度设置为两天，以 6 小时为时间间隔，整合 8 组台风记录数据形成一组台风数据，从而有效捕捉台风路径的短期变化特征。此外，选择经度、纬度、风速、气压和气温等核心气象指标，结合差值、对数变换、平方变换和比率等方法进一步挖掘数据中的时序变化特征，增强模型的预测能力。

由于台风路径的变化复杂且受多种因素影响，长短期记忆网络（Long Short-Term Memory, LSTM）算法能够处理长时间依赖问题，从而适合处理台风路径的时序预测。研究团队利用滑动窗口法截取的时序特征作为输入层，将后一天的台风特征设为输出层，以此训练 LSTM 算法。通过学习台风路径的动态变化，模型能够逐步预测下一时间段的经纬度、气温、气压和风速等关键特征，构建了一个完整的路径预测模型。

为了评估预测路径的准确性，研究团队将模型预测的路径与第 13 号台风贝碧嘉的实际路径进行对比，并使用动态时间规整（Dynamic Time Warping ,DTW）算法来衡量两条时间序列之间的差异。这种比较有助于分析模型在路径预测中的误差分布，并揭示台风路径预测中的关键影响因素。具体流程图见图 3.2。




图 3.2 问题二模型流程图

3.3 针对问题三

针对台风登陆后风速和降水量衰减的预测需求，研究团队重点分析台风中心风速和降水量如何随着距离登陆点的增加而逐渐减弱。以 2024 年 9 月 16 日至 18 日第 13 号台风贝碧嘉为例，团队将建立风速与降水量的衰减关系模型，并通过实际数据进行分析。为准确刻画台风的降水量和中心风速，**团队挑选了发生时期相近、生命周期相似、登陆点相近的历史台风数据作为模型训练样本。**与问题二的预测方式类似，团队继续采用滑动窗口的特征提取方法，逐步预测接下来几天的降水量和风速数据。

与问题二不同的是，由于台风的降水量目前仅有按天统计的数据，团队将**提取台风登陆后四天每天 14 时的观测数据特征输入训练模型，以学习台风随着登陆距离增加而衰减的动态变化规律。**团队在问题二的特征基础上，丰富了台风中心与登陆点的距离、与台风降水量和风速关系密切的核心气象指标，包括台风中心风速、气温、距离登陆的距离，以及台风中心以 100 公里、200 公里、300 公里为半径的降水量等。这些特征全面反映了台风的降水量和风速变化，以及降水量与距台风中心距离的关系。

考虑到 LSTM 在处理长序列时可能面临的困难，尤其是早期信息的遗忘，**研究将 LSTM 与多重注意力机制相结合，使模型既能学习台风衰减的时序特征，又能聚焦于影响风速和降水量变化的关键特征。**最终，模型将逐步预测下一时间段的风速和降水量，从而模拟台风在行进过程中的衰减情况。

通过分析预测结果的时间序列趋势，包括风速和降水量的变化模式，团队还将识别和分析影响预测结果的关键气象指标，例如气温、气压、洋流和风场的变化对风速和降水量的影响及降水量与距台风中心距离的关系。**具体流程图见图 3.3。**




图 3.3 问题三模型流程图

四、问题一模型的建立与求解

4.1 数据预处理

4.1.1 数据来源

本研究依托多个权威数据集，以获取台风路径、气象参数和海洋环境等方面的完整信息。不同数据集包含多样化的变量类型，如气温、降水、风速等，涵盖了台风生成和移动过程中的重要特征。具体数据来源如下：

（1）中国近海台风路径集合(1945–2023 年)

该数据集由海洋科学大数据中心提供，大部分以 6 小时为时间步长记录，包含了台风的起始时间、结束时间、观测时间、经纬度、台风等级、风速、气压、移动方向和速度等关键指标。利用这一数据集可以支持台风路径预测和强度分类的历史数据分析，确保路径模型的准确性和科学性。

表 4.1 中国近海台风路径集合数据

台风编号	中文名称	英文名称	起始时间	结束时间	当前时间	经度	纬度	台风强度	台风等级	风速	气压	移动方向	移送速率
201820	西马仑	Cimaron	2018-08-18T20:00	2018-08-24T14:00	2018-08-23T08:00	135.2	30.1	强台风(STY)	14	45	950	北西北	40
			2018-08-18T20:00	2018-08-24T14:00	2018-08-23T14:00	134.3	31.7	强台风(STY)	14	42	955	北	45
			2018-08-18T20:00	2018-08-24T14:00	2018-08-23T17:00	134.5	32.6	强台风(STY)	14	42	955	北	51

（2）海洋温度数据 (air. 2m. gauss)

由 Ocean and Climate 平台提供，记录了全球海洋表面 2 米深度的气温变化，是台风生成和强度变化的重要影响因素。海表温度能够直接影响台风的能量获取和强度变化，尤其在台风途经海域时至关重要。通过这一数据集，我们能够更好地捕捉台风的热量来源，为路径预测和强度评估提供关键气象支持。

表 4.2 海洋温度数据

时间	经度	纬度	海表 2m 温度
2018-08-18	88.542	65.625	273.6
2018-08-18	82.8508	101.25	273.425
2018-08-18	77.1394	127.5	274.15

（3）降水量数据集

来源于中国气象局热带气旋资料中心，记录了多个观测站点在台风路径中的逐日降水量。降水量是台风强度和路径预测的关键变量，对台风降雨影响、路径复杂性和强度变化的精确分析至关重要。

表 4.3 降水量数据集

热带气旋序列号	热带气旋数	观测点编号	最高降雨强度的次数	最大小时降水量(单位:毫米)	首次最大降雨强度开始和结束时间
201824	1800	57993	1	0.3	201808251800-201808251900
201824	1800	58362	1	0.8	201808250700-201808250800
201824	1800	58457	1	6.6	201808251200-201808251300

(4) 2012-2024 年我国观测站点的逐日气象指标

为保证研究中台风路径与强度预测的准确性，团队通过 python 爬虫技术，从美国国家海洋和大气管理局（NOAA）的数据库中，收集了 2012 年至 2024 年间中国各地级市气象观测站点的逐日气象数据。该数据集涵盖了每天各站点的降水量、气温和露点温度等关键气象指标。

表 4.4 2012-2024 年我国观测站点的逐日气象指标

站点编号	站点名称	日期	纬度	经度	气温	露点温度	降水量
45032099999	TA KWU LING, CH	2018/8/22	22.5333333	114.15	81.7	77.5	0.02
45032099999	TA KWU LING, CH	2018/8/23	22.5333333	114.15	81.6	78.1	2.74
45032099999	TA KWU LING, CH	2018/8/24	22.5333333	114.15	84.7	79.1	0.51

4.1.2 数据过滤

为了提高数据的相关性和模型预测的精度，我们对部分无关或无效的数据进行了剔除。以下是数据剔除的具体规则：

(1) 远海台风数据过滤

远海台风通常不会对大陆区域产生直接影响，因此在数据预处理时设定距离中国大陆沿海线超过 500 公里的台风为“远海台风”，并将其过滤掉。

图 4.1 展示了这一筛选的效果：初始数据包含 6327 条记录（左侧），经过筛选后，数据条目减少至 5635 条（右侧），从而提高了数据对大陆影响的相关性。

id	Chinesename	type	starttime	endtime	id	Chinesename	type	starttime	endtime
201520	科罗旺	远海	2015-09-16 02:00:00	2015-09-20 20:00:00	201317	桃芝	登陆	2013-09-02 02:00:00	2013-09-04 08:00:00
201520	科罗旺	远海	2015-09-16 02:00:00	2015-09-20 20:00:00	201317	桃芝	登陆	2013-09-02 02:00:00	2013-09-04 08:00:00
201520	科罗旺	远海	2015-09-16 02:00:00	2015-09-20 20:00:00	201317	桃芝	登陆	2013-09-02 02:00:00	2013-09-04 08:00:00
201520	科罗旺	远海	2015-09-16 02:00:00	2015-09-20 20:00:00	201317	桃芝	登陆	2013-09-02 02:00:00	2013-09-04 08:00:00
201520	科罗旺	远海	2015-09-16 02:00:00	2015-09-20 20:00:00	201317	桃芝	登陆	2013-09-02 02:00:00	2013-09-04 08:00:00
201521	杜鹃	登陆	2015-09-23 02:00:00	2015-09-29 17:00:00	201317	桃芝	登陆	2013-09-02 02:00:00	2013-09-04 08:00:00
201521	杜鹃	登陆	2015-09-23 02:00:00	2015-09-29 17:00:00	201317	桃芝	登陆	2013-09-02 02:00:00	2013-09-04 08:00:00
201521	杜鹃	登陆	2015-09-23 02:00:00	2015-09-29 17:00:00	201317	桃芝	登陆	2013-09-02 02:00:00	2013-09-04 08:00:00
201521	杜鹃	登陆	2015-09-23 02:00:00	2015-09-29 17:00:00	201317	桃芝	登陆	2013-09-02 02:00:00	2013-09-04 08:00:00
201521	杜鹃	登陆	2015-09-23 02:00:00	2015-09-29 17:00:00	201317	桃芝	登陆	2013-09-02 02:00:00	2013-09-04 08:00:00
201521	杜鹃	登陆	2015-09-23 02:00:00	2015-09-29 17:00:00	201317	桃芝	登陆	2013-09-02 02:00:00	2013-09-04 08:00:00

图 4.1 远海台风数据过滤前后对比

(2) 降水量数据过滤与最大降雨量替换

在降水量数据处理过程中，我们执行了以下两个主要步骤：

①降水量过滤：对于距离台风中心超过 400 公里的降水观测点，将其降水量设置为 0，以排除非台风引起的降水干扰，减少噪音，提高模型精度。见图 4.2。

PRCP	humidity	LATITUDE_B	LONGITUDE	DISTANCE	PRCP	humidity	LATITUDE_B	LONGITUDE	DISTANCE
5.81	12.32	16.833333	112.333333	531.891	0	12.32	16.833333	112.333333	531.891
5.81	12.32	16.833333	112.333333	498.128	0	12.32	16.833333	112.333333	498.128
5.81	12.32	16.833333	112.333333	474.87	0	12.32	16.833333	112.333333	474.87
5.81	12.32	16.833333	112.333333	464.415	0	12.32	16.833333	112.333333	464.415
5.81	12.32	16.833333	112.333333	453.969	0	12.32	16.833333	112.333333	453.969

图 4.2 降水量数据过滤与最大降雨量替换

图 4.2 降水量数据处理前后对比

②最大降雨量替换：在完成“0 值”处理后，从“最大小时降雨量数据”中提取每个台风的最大降雨量时段，并与总表中的观测时间匹配。匹配到的记录将其降雨量替换为相应的**最大降雨量**数据，确保数据的代表性。

（3）时间无效数据剔除

为确保数据准确性，我们删除了中国近海台风路径集合中**观测时间早于台风起始时间**的记录。此类记录通常反映背景气象条件，与台风活动无关。清除这些数据后，数据集仅保留与台风实际生成和发展的相关信息。

starttime	endtime	nowtime	longitude
2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 05:00:00	123.3
2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 08:00:00	122.3
2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 11:00:00	121.4
2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 14:00:00	120.7
2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 17:00:00	119.9
2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 20:00:00	119
2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 23:00:00	118.3
2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-03 02:00:00	117.2
2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-03 05:00:00	116
2018-06-05 08:00:00	2018-06-09 05:00:00	2018-06-02 14:00:00	111.3

图 4.3 台风观测时间早于起始时间的数据

（4）数据时效性筛选

近年来，**全球气候变化**尤其明显，特别是**海表温度的持续上升**对台风生成与强度的影响显著。图 4.3 反映了近 80 年来特定海域 7、8 月平均海表温度的变化趋势，显示出温度整体呈上升趋势，特别是在近十年内多次达到峰值。这种变化为台风的生成和增强提供了更多能量支持^[1]。因此，我们团队选择**近十年（2013-2022 年）**的数据不仅能够更好地反映当前气候变化对台风的影响，还能提升模型的时效性，使预测结果更加符合实际。




图 4.4 1940-2023 年 7 月平均海表温度变化趋势图（经度=137.5° E，纬度=25.5° N，深度=1m）

4.1.3 数据清洗与缺失值处理

（1）数据清洗

在数据筛选完成后，我们首先对数据中的异常值进行了清洗，确保模型输入数据的准确性。具体的清洗步骤包括：

①**降水量（PRCP）异常处理**：在降水量数据中，部分记录出现了无效的高值（如 99.99）。我们使用线性插值法对这些异常值进行了修正，以保持数据的连续性和平滑性。见图 4.5。

TEMP	PRCP	humidity	LATITUDE_B		temp	PRCP	humidity	latitude_B
27	99.99	8.53	32.5		27	10.24	8.53	32.5
27	99.99	8.53	32.5		27	10.24	8.53	32.5
27	99.99	8.53	32.5		27	10.24	8.53	32.5
27	99.99	8.53	32.5		27	10.24	8.53	32.5
27	99.99	8.53	32.5		27	4.746667	8.53	32.5
27	99.99	8.53	32.5		27	4.103333	8.53	32.5
27	99.99	8.53	32.5		27	0.4575	8.53	32.5
27	99.99	8.53	32.5		27	0.395	8.53	32.5

图 4.5 降水量异常值处理前后对比

②**统一温度单位**：为了确保数据的一致性，我们统一将不同数据源中的所有温度数据单位转换为摄氏度：

开尔文转摄氏度公式： $T_{Celsius} = T_{Kelvin} - 273.15$

华氏度转摄氏度公式： $T_{Celsius} = \frac{5}{9}(T_{Fahrenheit} - 32)$

通过这些转换，如图 4.6，我们确保了温度数据的标准化处理，从而避免了不同温度单位对模型训练的影响。

id	temp	humidity	prcp	air		id	temp	humidity	prcp	air
201317	53.4	7.47	0.08	300.33		201317	25.22	9.27	0.04	27.33
201317	53.4	7.47	0.08	300.33		201317	25.22	9.27	0.04	27.33
201317	53.4	7.47	0.08	299.65		201317	25.22	9.27	0.04	26.65
201317	53.4	7.47	0.08	299.65		201317	25.22	9.27	0.04	26.65
201317	53.4	7.47	0.08	299.65		201317	25.22	9.27	0.04	26.65
201317	53.4	7.47	0.08	299.65		201317	25.06	7.67	0	26.65

图 4.6 温度单位统一前后对比

(2) 缺失值处理

在数据清洗完成后，我们对数据中的缺失值进行了处理，以确保数据的完整性和一致性。这一步对于后续模型的稳定性至关重要。具体步骤如下：

①**均值填充法**：对于少量随机缺失的气象数据，我们采用均值填充法。即使用同一区域、相邻时间段内的平均值填补缺失值。这种方法能够保持数据的完整性，避免因缺失值造成的数据不连续问题。

②**线性插值法**：对于时间序列数据中连续缺失的部分，采用线性插值法进行填补。通过计算缺失点前后时间点的数据，推算出合理的缺失值，确保数据的平滑性与一致性。

4.1.4 数据整合

数据整合是本研究关键步骤之一，旨在通过台风编号和时间戳等将多个数据源中的不同气象变量合并为统一的数据集。具体步骤如下：

(1) 温度数据的整合

温度数据来自两个主要来源：**2012-2024 年我国观测站点的逐日气象指标**（用于陆地气温）和**海洋温度数据**（air.2m.gauss）（用于海洋气温）。在数据整合过程中，根据台风中心与观测站的距离，动态选择最适合的温度数据：

为判断台风中心点相对于陆地和海洋的接近性，我们使用**哈弗赛恩公式**（Haversine Formula）计算台风中心点到最近陆地与海洋观测点的最短距离，分别记录为 DISTANCE_B（距离陆地）和 DISTANCE_C（距离海洋）。

哈弗赛恩公式如下：

d = 2r \cdot \arcsin(\sqrt{\sin^2(\frac{\Delta \phi}{2}) + \cos(\phi_1) \cdot \cos(\phi_2) \cdot \sin^2(\frac{\Delta \mu}{2})})

其中， ϕ 和 μ 分别为台风中心和观测点的纬度和经度， r 为地球半径。

当台风中心位置距离海洋观测点更近（即 `DISTANCE_C` 较小）时，选用海表 2 米深度的温度数据 `air` 作为该位置的温度值；当台风中心位置距离陆地观测站更近（即 `DISTANCE_B` 较小）时，则使用陆地观测站的温度数据 `TEMP` 作为该位置的温度值。图 4.7 展示了原始数据中的陆地与海洋温度，以及台风中心点与最近陆地和海洋观测点之间的距离。

TEMP	PRCP	humidity	LATITUDE_B	LONGITUDE_B	DISTANCE_B	air	LATITUDE_C	LONGITUDE_C	DISTANCE_C
91.4	0	2573353.64	35.66667	-117.83333	5883.177035	299.65	33.3328	176.25	52.153276
91.4	0	2573353.64	35.66667	-117.83333	5874.597929	299.65	33.3328	176.25	58.373913
94.1	0	2366802.38	35.66667	-117.83333	5857.433946	299.55	33.3328	176.25	72.789219
94.1	0	2366802.38	35.66667	-117.83333	5836.13448	299.55	33.3328	176.25	94.34528
53.402	0.08	7.47	52.783333	103.683333	3424.387129	300.33	25.7139	125.625	113.103245
53.402	0.08	7.47	52.783333	103.683333	3424.387129	300.33	25.7139	125.625	113.103245
53.402	0.08	7.47	52.783333	103.683333	3429.944643	300.33	25.7139	125.625	93.239608
53.402	0.08	7.47	52.783333	103.683333	3428.625386	300.33	25.7139	125.625	99.316513
53.402	0.08	7.47	52.783333	103.683333	3417.430627	299.65	27.6186	125.625	91.325822

图 4.7 温度数据整合前的记录状态

经过筛选和整合处理，最终将选择的温度值统一存入 `TEMP` 列中，如图 4.8 所示。这一步骤确保了所有位置的温度数据都经过合理选择，为后续分析提供了可靠的数据支撑。

longitude	latitude	province	strength	level	windvelocity	pressure	direction	movevelocity	TEMP	PRCP
129	17.1	Bicol	热带低压(TD) 7	15		1001	北东北	5	29.65	0
129	17.5	Bicol	热带低压(TD) 7	15		1001	北东北	5	29.7	0
129.6	17.3	Bicol	热带风暴(TS) 8	18		1000	北东北	14	29.7	0
129.7	17.5	Bicol	热带风暴(TS) 8	18		1000	北东北	15	29.7	0
130.1	17.9	Bicol	热带风暴(TS) 8	18		998	北东北	15	29.3	0
130.2	18.6	Bicol	热带风暴(TS) 8	18		998	北东北	15	29.3	0
131	19.3	Okinawa	热带风暴(TS) 8	20		995	东北	10	28.9	0

图 4.8 温度数据整合后的记录状态

(2) 降水量数据的整合

降水量数据选取了两个来源：2012-2024 年我国观测站点的逐日气象指标和降水量数据集。优先选择降水量数据集中的最大降水值。如果该数据集中没有所需的记录，则使用逐日气象指标中的降水量数据。通过这种方式，确保了台风期间降水量的准确反映。

(3) 湿度的计算

湿度数据并未直接提供，为了计算台风中的相对湿度（Relative Humidity, RH），我们使用了基于露点温度（dewp）和实际气温（temp）的计算公式。该公式如下：

RH = \frac{6.11 \times 10^{\frac{7.5 \times \text{dewp}}{237.3 + \text{dewp}}}}{6.11 \times 10^{\frac{7.5 \times \text{temp}}{237.3 + \text{temp}}}}

通过这种方式，我们能够准确计算出各个时间点的湿度值。

(4) 台风路径与气象数据的融合

以台风编号、时间戳作为主键，将中国近海台风路径集合数据与其他数据集进行匹配和合并，生成了一个包含完整气象信息的数据集。见图 4.9，表格展示了台风编号、名称、时间、经纬度、强度、风速、气压、移动速度和方向等核心指标的整合结果。

id	Chinesename	Englishname	starttime	endtime	nowtime	longitude	latitude		
201317	桃芝	Toraji	2013-09-02 02:00:00	2013-09-04 08:00:00	2013-09-02 02:00:00	124.700000	26.300000		
201317	桃芝	Toraji	2013-09-02 02:00:00	2013-09-04 08:00:00	2013-09-02 05:00:00	124.700000	26.300000		
201317	桃芝	Toraji	2013-09-02 02:00:00	2013-09-04 08:00:00	2013-09-02 08:00:00	125.300000	26.500000		
201317	桃芝	Toraji	2013-09-02 02:00:00	2013-09-04 08:00:00	2013-09-02 09:00:00	125.500000	26.600000		
201317	桃芝	Toraji	2013-09-02 02:00:00	2013-09-04 08:00:00	2013-09-02 10:00:00	125.700000	26.800000		
province	strength	level	windvelocity	pressure	direction	movevelocity	TEMP	PRCP	humidity
Okinawa	热带风暴(TS)	8	18.00	1000.00	东北	9.00	11.89	0.08	7.47
Okinawa	热带风暴(TS)	8	18.00	998.00	东北	9.00	11.89	0.08	7.47
Okinawa	热带风暴(TS)	8	18.00	998.00	东北	10.00	11.89	0.08	7.47
Okinawa	热带风暴(TS)	8	20.00	995.00	东北	10.00	11.89	0.08	7.47
Okinawa	热带风暴(TS)	8	20.00	995.00	东北	10.00	11.89	0.08	7.47

图 4.9 数据整合后的数据集展示

4.2 特征提取

4.2.1 原始数据局限与特征提取的必要性

(1) 原始数据局限性

在台风路径预测中，直接使用**原始数据存在诸多挑战**，主要原因是台风的**持续时间不一致**，导致每个台风的**观测记录数量不同**。台风路径数据通常每隔六小时记录一次，但由于台风的**生命周期差异大**，记录的时间点数量会有所不同。例如，某个台风可能有 20 条记录，而另一个台风可能只有 10 条。这种数据不一致性在后续分析中产生了以下几方面的问题：

①**输入数据维度不一致**：机器学习模型通常要求输入数据维度相同。台风生命周期不同，观测记录的数量不同，导致无法统一输入模型，影响训练效果。

②**路径比较复杂化**：台风持续时间不同，直接比较其路径存在困难。例如，一个台风持续 48 小时，另一个持续 72 小时，路径时序数据无法对齐，难以准确地进行分析和预测。

因此，为了**应对原始数据在时序长度和数据维度上的不一致问题**，我们采用**特征工程方法**，将台风的时序数据转换为具有一致性特征的向量，以保证输入数据的统一性和模型的预测能力。

(2) 特征提取的必要性

特征工程的核心任务在于从原始数据中**提取出对台风分类和路径预测起关键作用的变量**，通过规范化处理，将台风的时序观测数据**转化为同维度的特征向量**，确保模型能够处理格式一致的数据。特征提取在此过程中的作用不可或缺。

首先，通过**统一时间步的特征提取**，可以生成维度一致的特征向量，使模型训练变得可行。其次，**特征提取能够有效捕捉台风路径中的关键变化模式**，例如通过差值、对数和平方等变换来**突出变量的短期变化和趋势**，增强模型在复杂气象条件下的预测能力。

此外，特征提取还具备**降维和减少计算复杂度的优势**。在保留路径预测关键特征的前提下，特征提取**有效降低了数据冗余**，缩短了模型训练时间，减小了过拟合风险。这一过程使模型在不同台风样本上获得**一致性更好的预测表现**，提高了台风路径预测的**准确性**。

4.2.2 搭建特征空间

在台风路径预测的**特征空间构建**过程中，**气温、气压和季风**等关键气象因素对台风路径的变化和强度有着直接影响。因此，针对这三方面的**特征提取**，可以为模型提供全面的预测输入^[2]。具体包括以下几个方面：

(1) 从气温角度

气温，尤其是**海表温度**，对台风的形成和路径有重要影响。**热带气旋**需要**高温的海水**来提供能量，海温的变化也直接影响台风的**强度和行进方向**。因此，团队提取了**气温的最大变化率**，以便衡量在台风生命期内**温度的波动幅度**。此特征不仅捕捉到了台风所处环境的热力变化，也反映了台风可能经历的**强度调整过程**。

(2) 从气压角度

气压是衡量台风强度的核心指标之一，**气压越低**通常意味着**台风越强**。为了捕捉气压对台风路径的影响，团队提取了**气压最大变化率**，这一特征体现了气压在台风生命周期中的**剧烈变化速率**。气压的大幅波动往往伴随着台风强度的变化，这种变化不仅影响台风的路径方向，还会影响路径的曲折程度。

路径曲度与气压关系：通过计算**台风实际路径长度与直线距离的比率**，我们能够更好地量化气压变化对路径曲度的影响。**气压的急剧变化**通常意味着台风可能经历了**强烈的路径转向和风速变化**。此特征不仅有助于模型理解**气压与路径偏移**的关系，还能揭示台风在**高强度阶段的路径行为模式**。

(3) 从季风角度

季风是影响台风路径的主要**大气动力**之一，**强季风气流**会将台风引导至特定方向。因此，团队通过**多个方向角的特征提取**（如 4.1 方向角至 4.4 方向角）来捕捉季风对台风路径的引导作用。这些**方向角特征**测量了台风路径的**转向趋势和变化率**，反映了季风对台风路径的**分阶段影响**。

一阶纬度和经度方差：台风在受到季风引导时，其路径的**纬度和经度变化**会表现出特定的波动模式。通过提取一阶纬度和经度方差，我们能够**反映路径波动的幅度**，揭示季风在不同阶段对台风路径的**调节作用**。例如，季风引导下的路径偏移会使台风朝特定方向转向，而经纬度方差能够反映这种变化的**累积效应**。

通过以上特征的提取，我们能够在**气温、气压和季风**的多重影响下**构建具有代表性的特征空间**。这种特征空间为**台风路径的聚类分析和分类模型**提供了**标准化的输入数据**，增强了模型在不同台风样本上的**泛化能力**。

4.2.3 关键特征的提取

基于**台风路径、强度及相关气象因素**的分析，本研究提取了具有代表性的**关键特征**，如表 4.1 所示，以便更好地支持路径预测和分类模型的构建：

表 4.5 台风特征参数、定义及其计算公式

特征	定义	公式
最大转向角	台风每段路径相对起始角度的最大偏转角度，衡量台风路径的突然转折情况。	$\theta = \arccos(\frac{\overrightarrow{AA} \cdot \overrightarrow{BB}}{ \overrightarrow{AA} \cdot \overrightarrow{BB} })$
路径转角波动	台风路径方向变化的波动性，即转向角的方差，反映台风路径的曲折程度。	$S^2 = \frac{\sum_{i=1}^n (\theta_i - \theta)^2}{n}$
气温最大变化率	（陆地的近地面气温，海洋的近海面气温）最大变化率	$\text{Max}(\frac{\Delta T}{\Delta t})$
气压最大变化率	台风生命周期内气压的最大变化速率，反映台风强度变化。	$\text{Max}(\frac{\Delta P}{\Delta t})$
路径长度与直线距离的比率	台风实际路径长度与起点到终点的直线距离之比，反映台风路径的曲折程度。	$\frac{s}{S}$
最大降雨量	台风生命期内观测到的最大降雨量，反映了台风携带的水汽含量。	$\text{Max}(R_i)$

最大湿度	台风生命周期内的最大湿度，衡量水汽含量对台风强度的影响。	$\text{Max}(RH_i)$
最大风速	台风过程中观测到的最大风速，反映台风强度	$\text{Max}(v_i)$
生命周期时长	台风从生成到消失的总持续时间，衡量台风的生命周期长度。	$T_{\text{末}} - T_{\text{初}}$
一阶纬度平方和	台风在每个观测时间点的纬度变化量的平方和，反映纬度的变化幅度对台风路径的影响。	$\sum_{i=1}^n (\Delta LAT_i)^2$
一阶经度平方和	台风在每个观测时间点的经度变化量的平方和，反映经度的变化幅度对台风路径的影响。	$\sum_{i=1}^n (\Delta LON_i)^2$
平均航向角	台风路径上每段轨迹的航向角度的平均值，衡量台风路径的整体方向趋势。	$\theta_{avg} = \frac{1}{n} \sum_{i=1}^n \theta_i$
4.1 方向角	台风路径的第一段方向角，计算台风路径起始至第一四分段的方向。	$(\arctan2(\sin(lon_2 - lon_1) \cdot \cos(lat_2), \cos(lat_1) \cdot \sin(lat_2) - \sin(lat_1) \cdot \cos(lat_2) \cdot \cos(lon_2 - lon_1)) \cdot \frac{180}{\pi} + 360) \bmod 360$
4.2 方向角	台风路径的第二段方向角，计算台风路径第一四分段至第二四分段的方向。	
4.3 方向角	台风路径的第三段方向角，计算台风路径第二四分段至第三四分段的方向。	
4.4 方向角	台风路径的第四段方向角，计算台风路径第三四分段至路径终点的方向。	

通过这些特征提取，能够有效概括台风在不同时间点的路径和强度变化特征，为后续的聚类分析和分类模型提供标准化输入数据。

4.3 基于层次聚类的分类模型

在特征提取完成后，我们应用聚类算法对台风数据进行分析，以识别台风的不同类别特征。由于类别标签和数量不清晰，因此选择**层次聚类算法**^[3]，它能够通过对特征空间的分析自动生成类簇。

4.3.1 特征选择与数据标准化处理

在**台风特征提取**过程中，我们选取了**16项特征**，这些特征能够较为全面地反映台风的**生命周期、气象条件和运动特性**。数据集包含多个时间步长的台风记录，因此需要对每个台风实例按ID进行分组，并计算每个特征的**平均值**，得到一个最终数据集。完成分组后，对提取的特征数据进行标准化，去除特征间**尺度差异**，以适合聚类分析。

4.3.2 层次聚类模型的构建

凝聚层次聚类 (Agglomerative Hierarchical Clustering) 是一种自底向上的方法，最初将每个数据点视为独立的簇，然后逐步合并两个最相似的簇，迭代此过程，直至所有数据点合并为一个簇。该方法能够生成**树状图** (dendrogram)，直观展示数据的**分层关系**，与**分裂型层次聚类**相比，凝聚层次聚类在**计算复杂度**上更具优势^[4]。

①**构建距离矩阵**：通过**哈弗塞恩** (Haversine) 公式计算样本点之间的**实际经纬度距离矩阵**，作为层次聚类的基础。

②**聚类链接方式**：使用**完全链接** (Complete Linkage) 的方式，定义两个簇之间的距离为两个簇中任意两点之间的**最长距离**。这种方法倾向于生成**紧凑的球形集群**，对异常值和噪声不太敏感，更注重簇的**整体分离度**。在针对于**台风分类**中，完全链接可能更适合，因为它可以减少异常路径对聚类结果的影响，从而提高分类的**稳定性和准确性**。

③**树状图构建**：依据层次合并结果，分别绘制**夏、秋台风**的分类树状图

(dendrogram)，用于直观展示聚类过程及各类间的距离关系。

4.3.3 模型参数与阈值设置

根据夏秋台风分类树状图，如图 4.10-4.11。我们分别将阈值分别定为 9.1 和 8.0，在该阈值下的树状图分枝较为清晰，分别形成了 10 个、11 个聚类类别。阈值的确定基于分层距离的观察，9.1，8.0 的阈值选择保证了类间的差异性，同时将台风数据分为适量的类别以便于后续分析。





图 4.10 夏季台风分类树状图



4.11 秋季台风分类树状图

4.3.4 台风路径类型划分

在夏秋台风的层次聚类分析之后，本研究依据台风的路径形态和移动方向，将台风路径划分为 21 种典型类型。这些分类不仅能够展示台风在路径上的多样性，同时也为路径预测模型提供了清晰的分类标准。以下是台风路径类型的详细分类说明。

(1) 夏季台风路径类型

夏季台风的活动较为频繁，路径特征复杂多变。本研究通过对夏季台风数据的聚类分析，总结出表 4.6 所示典型的路径类型：

表 4.6 夏季台风路径类型及定义

台风类型	定义
近海西北-东北转向型	这类台风在近海区域首先向西北方向移动，随后转向东北，呈现出明显的路径转向特征。
近海东北直线型	路径呈直线形态，从近海向东北方向移动，基本保持稳定的移动方向。
近海北直线型	路径从近海向北方移动，直线型的路径显示出较为稳定的北向趋势。
登陆西-西北转向型	这类台风在登陆后从西向西北转向，通常在陆地上呈现出一定的偏移。
近海西-东北回旋型	路径在近海区域先向西移动，随后回旋至东北方向，呈现出明显的回旋特征。
登陆西北-东北转向型	在登陆后，台风从西北方向转向东北方向，显示出转向路径。
登陆西北波动型	登陆后，主要沿西北方向移动，但路径上伴有明显的波动性，呈现出多次小幅度转向或曲折。
登陆西北-西南回旋型	这类台风在登陆后从西北方向回旋至西南方向，路径呈现出回旋的特点。
近海“L”型转向型	路径在近海区域形成“L”型，通常表示先向一个方向移动，随后转向形成直角形路径。

(2) 秋季台风路径类型

秋季台风相较夏季台风，活动路径更为多样，常受季风、海洋洋流和地理环境的复杂作用影响。聚类分析得出如表 4.7 所示秋季台风的典型路径类型：

表 4.7 秋季台风路径类型及定义

台风类型	定义
“鱼钩型”路径	路径形似鱼钩，在区域呈现出明显的曲折。
登陆西北“蛇形”路径	路径曲折变化，形似蛇形，通常在西北方向上呈现出较大的波动。
近海“S”型路径	路径形成“S”形状，表示台风在移动过程中出现多次方向变化。
近海“上凹”路径	路径呈现出上凹形，路径整体向上凸起，然后下弯，形成独特的曲线。
近海西直线型	秋季近海台风路径直线向西移动，路径变化不大。
登陆西北波动型	台风在登陆后沿西北方向呈波动移动，路径具有一定的曲折性。
登陆西北-西转向型	在登陆后最初沿西北方向移动，随后路径逐渐转向西方。
近海东北直线型	路径从近海向东北方向移动，保持直线形态，移动方向未发生显著变化。
近海弓形路径	路径呈弓形，表示台风移动过程中受到外力影响，形成弧形曲线。
近海西北-东北转向型	路径在近海区域从西北方向向东北方向转向。
近海撬棍型路径	路径呈现撬棍状，多次发生方向变动，路径复杂且不规则。

(3) 典型路径展示

考虑到论文篇幅限制，本文将选择几类具有代表性的台风路径类型进行展示，以说明不同类型台风在路径特征上的差异。如图 4.12、图 4.13 和图 4.14 所示。




图 4.12 夏季近海
“L”型转向台风





图 4.13 秋季近海
弓型台风图



4.14 秋季近海
撬棍型台风

4.3.5 模型评估

(1) 针对夏台风聚类模型

Calinski-Harabaz 指数 (CH): 通过计算簇内方差和与簇间方差的比值来评估聚类效果，值越大表示簇内越紧凑且簇间越分离，聚类分析得到的指数为 10.377785518789183。

轮廓系数 (Silhouette Coefficient): 度量聚类结果的紧密性和分离性, 经过分析得到轮廓系数为 0.9701509843108841, 展现较好的聚类效果。

Davies-Bouldin Index (DB): 综合考虑类内样本的相似度以及类间样本的差异度, 通过计算类内样本到其聚类中心的平均距离与不同聚类中心之间的距离之比来评估聚类效果, 聚类分析得到的指数为 0.1384741965735143。

Dunn 指数 (Dunn's indices, 简称 DVI): 通过比较聚类内部的紧密度和聚类之间的间距来评估聚类效果, 模型的 Dunn 指数为 0.9772564418327485, 体现聚类内部的紧密度高, 聚类之间的间距较大, 聚类质量较好。如图 4.15。

```
Calinski-Harabasz Index (CH): 10.377785518789183
Silhouette Coefficient: 0.9701509843108841
Davies-Bouldin Index (DB): 0.1384741965735143
Dunn Index: 0.9772564418327485
```

图 4.15 夏台风聚类模型评价指标

(2) 针对秋台风聚类模型

CH 指数: 11.84662976321819 轮廓系数: 0.9658314569172365

DB 指数: 0.1195347762187334 Dunn 指数: 0.9725734126784659

```
Calinski-Harabasz Index (CH): 11.84662976321819
Silhouette Coefficient: 0.9658314569172365
Davies-Bouldin Index (DB): 0.1195347762187334
Dunn Index: 0.9725734126784659
```

图 4.16 秋台风聚类模型评价指标

4.3.6 结果展示与分析

为了更好地理解台风聚类结果, 我们对聚类结果进行了可视化分析, 如图 4.14-4.15。
聚类特征分布—热力图(Heatmap): 对每个类别的特征均值进行分析, 以观察不同类别在生命周期、最大风速、降雨量等特征上的差异。结果表明, 不同类别的台风在生命周期长度、最大风速、最大湿度等各方面存在显著差异, 有助于针对不同台风类型进行灾害预防和应对策略的定制。




图 4.14 夏台风每个类别的特征均值




图 4.15 秋台风每个类别的特征均值

4.4 基于循环神经网络的台风数据分类评价

4.4.1 模型选择与架构

基于台风特征参数的时序变化特征以及气温、气压、季风等多重因素的影响, 本研究选择了循环神经网络 (RNN) 作为分类模型^[5]。

RNN: RNN 通过内部循环机制在隐藏层中建立了前后时间步的数据依赖，能够有效地捕捉台风路径在**前后**的动态变化，保持长期依赖性。

4.4.2 模型训练与验证

为确保分类模型的精确性和稳定性，研究将数据集划分为 **80%训练集**和 **20%测试集**，并采用**五折交叉验证**进行模型验证和优化，以**减少过拟合风险**并**提高模型的泛化能力**^[6]。训练通过**误差反向传播**（Backpropagation Through Time, BPTT）算法完成，以最小化分类损失。训练与验证过程如下：

①**数据预处理**：根据表 4.1 中的 16 项特征，将台风的时序观测数据转化为标准化的**特征向量**，确保所有**数据维度的一致性**。

②**模型训练**：在训练集上，通过输入时序特征数据，让 RNN 分别学习台风路径的动态特征。模型逐步建立对**不同气象条件下台风路径变化**的识别能力。

前向传播（Forward Propagation）：

输入数据通过网络的每一层，直到最后一层（输出层）。

反向传播（Backpropagation）：

利用**链式法则**，从输出层开始反向通过网络的每一层，计算损失函数对每个参数的梯度，从而更新网络中的权重和偏置。

③**模型验证**：在测试集上验证**模型性能**，衡量在**不同类别台风上的预测精度**，以评估模型在**未见台风数据上的表现**。

④**模型优化**：通过**五折交叉验证**，调整**超参数**（如神经元数量、学习率等）以优化模型表现，确保在**不同台风类别上的分类准确性**。

4.4.3 分类规则与评估

本研究基于**层次聚类**方法，将台风分为多个类别（依据**季节、路径模式、移动方向**等维度）。**RNN 模型**通过学习这些类别的**特征模式**，能够对新的台风进行**分类预测**。**五折交叉验证**的引入，有助于确保模型在**季节变化（夏台风和秋台风）以及路径模式和强度条件下的稳健性**，该模型的构建可为气象灾害监测和应急响应提供支持。

4.5 夏台风与秋台风的对比分析

4.5.1 结果展示

通过模型分析，2024 年 7 月的夏台风主要影响了**台湾、福建、江西和湖北**等东南沿海和南部内陆省份。该月的夏台风表现出较高的强度和明显的降水特征，尤其是在途经台湾和福建时，降水强度尤为显著。相比之下，2024 年 9 月的秋台风主要影响了**海南、上海、江苏、安徽和河南**等省市，路径相对稳定，降水量较为温和但持续时间较长。这种差异可能与当年气温的异常偏高有关。由于气温升高，秋季台风在路径和强度上表现出更接近夏季台风的特征，其影响范围也更为广泛。这种夏季台风的“北移”趋势和秋季台风的“强化”现象，为灾害防范提供了重要的预测依据。

表 4.8 2024 年我国 7 月和 9 月台风类别及途经省份

月份	台风类别	途径省份
7 月 夏台风	夏季登陆西北波动型台风	台湾省、福建省、江西省、湖北省
	夏季登陆西-西北转向台风	海南省
9 月 秋台风	秋季登陆西北-西转向台风	海南省
	秋季登陆西北“蛇形”台风	上海市、江苏省、安徽省、河南省

	秋季“鱼钩型”台风	上海市、江苏省
	秋季近海“上凹”型台风	台湾省

4.5.2 差异分析

(1) 台风强度方面

分析模型结果表明，夏季台风的强度普遍较高，尤其是近海回旋和波动型台风，表现出更强的风速和能量。这与夏季海表温度较高密切相关，海洋热能为台风提供了额外的能量支持。相比之下，秋季台风的强度较弱，多数表现为转向和直线路径。然而，由于2024年气温异常偏高，一些秋季台风表现出更强的强度，部分秋台风接近夏台风的强度水平。

(2) 路径与方向方面

夏季台风多向北移动，路径复杂，回旋和转向台风较为常见；秋季台风则多沿西北方向移动，路径相对平稳，以直线型为主。这种路径差异与季风的强弱变化息息相关，而今年气温的异常偏高，使得秋季台风的路径更接近夏季模式，路径复杂度有所增加。

(3) 降水与湿度方面

夏台风的降水量丰富、集中，尤其是在近海回旋和转向路径中，湿度也相对较高。秋台风降水量较小，但持续时间长，且湿度相对较低。今年因气温偏高，秋台风的湿度和降水量也有所增加，进一步表明气温对台风降水特征的影响。

4.5.3 结果应用与分析

基于分类评价模型的分析结果，可以总结出夏季台风与秋季台风在路径、强度和降水方面的显著差异。2024年气温偏高的情况下，秋季台风逐渐表现出类似夏季台风的特征。这提示我们在未来的防灾减灾中，应更加关注气温升高对台风路径和强度的潜在影响，为灾害预测和防范提供科学支持，从而提升防灾减灾的有效性。

五、 问题二模型的建立与求解

5.1 台风的数据融合

5.1.1 台风数据筛选

(1) 研究范围的确定

鉴于近年来全球变暖加剧，尤其是**2024 年温度异常偏高**，我们将传统的**秋季台风数据范围从 9 月-11 月延伸至 8 月-10 月**，包含夏末和初秋的台风数据。通常情况下，8 月的数据被划分为夏台风数据集。然而，为更全面地捕捉秋季台风的生成特征及其路径变化，本研究特别将**8 月纳入考量**，以便更好地反映在**全球气候变暖背景下台风活动的潜在变化趋势**，尽管我们的目标台风——台风贝碧嘉发生于 9 月中旬。

筛选出的数据涵盖**1945 年至 2022 年间 8 月-10 月**的台风记录。

(2) 台风等级筛选

为聚焦于对大陆具有显著影响的**高强度台风**，我们筛选了**台风等级在 10 至 18 级的数据**。较低等级的台风通常影响范围较小且对路径预测的参考价值有限，而**贝碧嘉台风的强度较高**，因此筛选出同样强度较大的台风能够增强模型对高等级台风路径的预测效果，并确保数据的代表性。

(3) 登陆台风筛选

本研究专注于可能对大陆造成实际影响的台风路径预测，因此**仅保留登陆台风的数据**。在数据筛选过程中，我们应用了与问题一中一致的标准，对**远海和近海台风**进行了预处理，以确保数据筛选的一致性和严谨性。

(4) 生命周期筛选

我们筛选出**生命周期大于或等于 8 天的台风**，以确保数据的连续性和充足的观测时间点。该筛选条件的设定主要基于**贝碧嘉台风的生命周期较长**，且我们需要进行**9 月 13 日至 17 日的路径预测**。长生命周期的台风数据能够为模型提供足够的时序信息，捕捉台风在不同时间段的路径变化，提升模型的预测准确性。

(5) 方向角筛选

台风的移动方向是路径预测的重要因素之一。为使数据集的台风路径特征与贝碧嘉相似，我们选择了**方向角在 260° 至 350° 之间的台风数据**。这一区间的方向角更贴近贝碧嘉的实际走向，有助于模型学习和预测在**类似移动方向上的台风路径**，提升路径预测的精度。

基于以上筛选条件，我们构建了一个符合研究需求的高质量台风数据集，如图 5.1 所示。这些数据为后续的台风路径预测模型奠定了坚实基础，并能够更准确地应用于台风贝碧嘉的路径预测分析。




图 5.1 台风数据筛选条件

5.1.2 台风数据融合

在问题二的台风数据融合过程中，**整体方法和问题一中所用的步骤基本一致**。整合后的数据集如图 5.2 所示，包含**台风编号、名称、观测时间、经纬度、强度、风速、气压、移动速度及方向**等核心指标，为路径预测提供了全面且一致的数据支持。

id	starttime	duringtime	longitude	latitude	windvelocity	pressure	temp
195025	1950/9/7 14:00:00	1950-09-07 14:00:00	143.6	17.5	30	983	27.97
195025	1950/9/7 14:00:00	1950-09-07 20:00:00	143.5	17.9	35	980	27.97
195025	1950/9/7 14:00:00	1950-09-08 02:00:00	143.4	18.4	35	980	28.17
195025	1950/9/7 14:00:00	1950-09-08 08:00:00	143.1	18.9	40	975	28.17
195025	1950/9/8 14:00:00	1950-09-08 14:00:00	142.9	19.4	40	970	28.05
195025	1950/9/8 14:00:00	1950-09-08 20:00:00	142.7	20.0	45	965	28.05
195025	1950/9/8 14:00:00	1950-09-09 02:00:00	142.3	20.7	50	960	28.52
195025	1950/9/8 14:00:00	1950-09-09 08:00:00	141.9	21.5	50	955	28.27
195025	1950/9/9 14:00:00	1950-09-09 14:00:00	141.4	22.2	55	950	27.95
195025	1950/9/9 14:00:00	1950-09-09 20:00:00	140.9	22.8	55	950	27.95
195025	1950/9/9 14:00:00	1950-09-10 02:00:00	140.1	23.7	55	950	28.82
195025	1950/9/9 14:00:00	1950-09-10 08:00:00	139.5	24.6	60	945	28.27
195025	1950/9/10 14:00:00	1950-09-10 14:00:00	138.9	25.2	60	945	27.92

select * from answeritems 只读 查询时间: 0.016s 第 2 条记录 (共 1460 条)

图 5.2 台风数据融合

5.2 数据预处理

在数据预处理阶段，我们进行了以下几项操作，以确保输入数据的质量和一致性，为台风路径预测模型提供可靠的基础：

（1）删除风速为 0 的记录

由于风速为 0 通常不符合台风活动的特征，可能是数据异常或记录误差，因此我们剔除了所有风速为 0 的观测记录，以确保数据的准确性和代表性。见图 5.3。

longitude	latitude	strength	level	windve	pressure
139.9	5.7		0	0	1006
139.3	5.9		0	0	1006
138.7	6.3		0	0	1006
138	6.7		0	0	1006
137.3	7.2		0	0	1005
136.7	7.7		0	0	1005
136	8.2		0	0	1005
135.3	8.8		0	0	1005

图 5.3 风速为 0 数据显示

（2）筛选统一的观测时间点

台风路径数据通常以 6 小时为步长记录，为确保模型输入的统一性和时序一致性，我们选择了每日的 2 时、8 时、14 时和 20 时数据。这些时间节点均匀分布，能够涵盖台风路径中的不同时段特征，如温度、风速、气压等，从而为路径预测模型提供稳定的输入序列。

（3）删除无效观测时间记录

为避免数据偏差，我们删除了所有观测时间早于台风起始时间的记录，我们应用了与问题一中一致的处理方法。

5.3 搭建特征空间

5.3.1 滑动窗口的建立

在台风路径预测模型的构建中，滑动窗口法被用于处理台风生命周期长度不一带来的数据维度差异问题，确保模型输入的统一性。由于台风的生成和消亡时间差异较大，不同台风的观测数据包含的时间步数量不一，造成输入数据的维度不一致，而机器学习模型通

常要求输入数据维度统一。因此，为了实现有效的时序建模和规范化特征提取，我们引入了滑动窗口法。

（1）滑动窗口的目的

滑动窗口法的核心在于构建统一的输入特征维度，以满足模型训练需求，同时使得模型能够捕捉到台风路径的时序动态特征。通过设置一个固定大小的滑动窗口，我们可以将台风路径数据按时间段分割为连续的小样本。具体而言，每个滑动窗口包含两天的数据（每6小时取一次数据，共8个时间点），这些样本作为模型输入。滑动窗口的长度设计为两天，主要考虑到台风路径和气象特征的短期变化有助于捕捉台风路径的连续性，而过长的窗口可能增加输入特征的冗余性，从而降低模型的学习效率。

（2）滑动窗口的构建与应用

在滑动窗口法应用中，每次滑动窗口以过去两天的数据作为输入层的特征，用于预测下一天的目标变量。每个输入样本包括过去两天的经度、纬度、气温、气压和风速等关键气象特征的时间序列信息，使得模型能够学习台风路径随时间变化的动态趋势。具体步骤如下：

①构建输入样本：每次滑动窗口从当前时间点开始，向前取两天的数据，这些数据点包括经度、纬度、气温、气压、风速等关键特征。对于每个时间步，还计算前一时间步的变化特征，如差值、对数变化和平方变化，以捕捉特征变化的复杂性。

②生成输出样本：在每次滑动后，窗口的输出为第三天的经度、纬度、气温、气压和风速。这个目标数据提供了模型预测下一时间步路径的依据，使得滑动窗口法能够逐步建立台风路径的动态预测能力。

③滑动窗口的逐日预测：在滑动窗口法的应用过程中，模型每次使用前两天的数据生成新的样本并预测下一个时间点的特征。通过这种逐日滑动的方式，模型能够生成一条连续的路径预测。

（3）滑动窗口法的设定依据

选择“前两天预测第三天”的滑动窗口设定，是为了符合题目要求的预测需求。具体来说，题目要求预测台风贝碧嘉在2024年9月13日-17日的路径情况，而贝碧嘉台风的观测数据从9月11日开始。因此，为准确模拟9月13日及之后的台风路径，滑动窗口法利用9月11日和12日的已知观测数据推算9月13日的情况，以逐日预测后续路径。这种设定不仅确保了预测的时间连续性，也为模型提供了足够的上下文信息，以增强预测的可靠性和准确性。




图 5.4 台风路径滑动窗口示意图

（4）滑动窗口法的优点

通过滑动窗口法，可以有效解决台风路径预测中的数据维度不一致性问题，为模型提

供了标准化的输入特征。同时，滑动窗口法在时间序列预测中确保了每一时间步输入数据的连续性，能够捕捉到台风路径随时间变化的潜在规律，从而提升模型在台风路径预测上的精度。

5.3.2 指标的选取

在构建台风路径预测模型的特征空间时，我们综合考虑了台风路径的时序动态特征以及各类气象变量对台风路径变化的潜在影响。为此，选取了经度、纬度、风速、气压、气温等核心指标。这些指标不仅直接反映台风的强度和位置，还能够通过差值、对数、平方、比率等变换捕捉到不同时间段内特征变化的复杂性，提升模型的特征表达能力。

在表 5.1 中，我们使用下标形式“天数, 小时”来表示台风的具体观测时间点。下标的第一个数字代表观测天数，第二个数字表示具体的小时数。举例解释如下：

下标 (1, 14) 表示观测数据来源于预测台风的前 48 小时到前 24 小时之间的第 1 天 14 点时的观测值。

下标 (2, 20) 表示观测数据来源于预测台风的前 24 小时到 0 小时之间的第 2 天 20 点时的观测值。

这种时间下标形式在特征选择中确保了数据的时序一致性，使得模型能够根据连续时间点的观测数据进行动态分析。

表 5.1 台风路径预测特征指标及其时间跨度

序号	特征	备注
1-8	$LAT_{1,14}$ 、 $LAT_{1,20}$ 、 $LAT_{1,2}$ 、 $LAT_{1,8}$ 、 $LAT_{2,14}$ 、 $LAT_{2,20}$ 、 $LAT_{2,2}$ 、 $LAT_{2,8}$	前 48h- 前 24h，前 24h-0h 纬度
9-16	$LONG_{1,14}$ 、 $LONG_{1,20}$ 、 $LONG_{1,2}$ 、 $LONG_{1,8}$ 、 $LONG_{2,14}$ 、 $LONG_{2,20}$ 、 $LONG_{2,2}$ 、 $LONG_{2,8}$	前 48h- 前 24h，前 24h-0h 经度
17-24	$WND_{1,14}$ 、 $WND_{1,20}$ 、 $WND_{1,2}$ 、 $WND_{1,8}$ 、 $WND_{2,14}$ 、 $WND_{2,20}$ 、 $WND_{2,2}$ 、 $WND_{2,8}$	前 48h- 前 24h，前 24h-0h 风速
25-32	$PRES_{1,14}$ 、 $PRES_{1,20}$ 、 $PRES_{1,2}$ 、 $PRES_{1,8}$ 、 $PRES_{2,14}$ 、 $PRES_{2,20}$ 、 $PRES_{2,2}$ 、 $PRES_{2,8}$	前 48h- 前 24h，前 24h-0h 气压
33-40	$TEM_{1,14}$ 、 $TEM_{1,20}$ 、 $TEM_{1,2}$ 、 $TEM_{1,8}$ 、 $TEM_{2,14}$ 、 $TEM_{2,20}$ 、 $TEM_{2,2}$ 、 $TEM_{2,8}$	前 48h- 前 24h，前 24h-0h 气温
41-47	$LAT_{1,14} - LAT_{1,20}$ 、 $LAT_{1,20} - LAT_{1,2}$ 、 $LAT_{1,2} - LAT_{1,8}$ 、 $LAT_{1,8} - LAT_{2,14}$ 、 $LAT_{2,14} - LAT_{2,20}$ 、 $LAT_{2,20} - LAT_{2,2}$ 、 $LAT_{2,2} - LAT_{1,8}$	前 48h- 前 24h，前 24h-0h 一阶纬度差
48-54	$LONG_{1,14} - LONG_{1,20}$ 、 $LONG_{1,20} - LONG_{1,2}$ 、 $LONG_{1,2} - LONG_{1,8}$ 、 $LONG_{1,8} - LONG_{2,14}$ 、 $LONG_{2,14} - LONG_{2,20}$ 、 $LONG_{2,20} - LONG_{2,2}$ 、 $LONG_{2,2} - LONG_{1,8}$	前 48h- 前 24h，前 24h-0h 一阶经度差
55-61	$WND_{1,14} - WND_{1,20}$ 、 $WND_{1,20} - WND_{1,2}$ 、 $WND_{1,2} - WND_{1,8}$ 、 $WND_{1,8} - WND_{2,14}$ 、 $WND_{2,14} - WND_{2,20}$ 、 $WND_{2,20} - WND_{2,2}$ 、 $WND_{2,2} - WND_{1,8}$	前 48h- 前 24h，前 24h-0h 一阶风速差
62-68	$PRES_{1,14} - PRES_{1,20}$ 、 $PRES_{1,20} - PRES_{1,2}$ 、 $PRES_{1,2} - PRES_{1,8}$ 、 $PRES_{1,8} - PRES_{2,14}$ 、 $PRES_{2,14} - PRES_{2,20}$ 、 $PRES_{2,20} - PRES_{2,2}$ 、 $PRES_{2,2} - PRES_{2,8}$	前 48h- 前 24h，前 24h-0h 一阶气压差
69-75	$TEM_{1,14} - TEM_{1,20}$ 、 $TEM_{1,20} - TEM_{1,2}$ 、 $TEM_{1,2} - TEM_{1,8}$ 、 $TEM_{1,8} - TEM_{2,14}$ 、 $TEM_{2,14} - TEM_{2,20}$ 、 $TEM_{2,20} - TEM_{2,2}$ 、 $TEM_{2,2} - TEM_{2,8}$	前 48h- 前 24h，前 24h-0h 一阶气温差
76-83	$\cos(LAT_{1,14})$ 、 $\cos(LAT_{1,20})$ 、 $\cos(LAT_{1,2})$ 、 $\cos(LAT_{1,8})$ 、	前 48h- 前 24h，前

84-91	$\cos(\text{LAT}_{2,14})$ 、 $\cos(\text{LAT}_{2,20})$ 、 $\cos(\text{LAT}_{2,2})$ 、 $\cos(\text{LAT}_{2,8})$	24h-0h 纬度的 $\cos$ 值
	$(\text{WND}_{1,14})^2$ 、 $(\text{WND}_{1,20})^2$ 、 $(\text{WND}_{1,2})^2$ 、 $(\text{WND}_{1,8})^2$ 、 $(\text{WND}_{2,14})^2$ 、 $(\text{WND}_{2,20})^2$ 、 $(\text{WND}_{2,2})^2$ 、 $(\text{WND}_{2,8})^2$	前 48h- 前 24h，前 24h-0h 风速的平方
92-99	$\log(\text{WND}_{1,14})$ 、 $\log(\text{WND}_{1,20})$ 、 $\log(\text{WND}_{1,2})$ 、 $\log(\text{WND}_{1,8})$ 、 $\log(\text{WND}_{2,14})$ 、 $\log(\text{WND}_{2,20})$ 、 $\log(\text{WND}_{2,2})$ 、 $\log(\text{WND}_{2,8})$	前 48h- 前 24h，前 24h-0h 风速的对数值
	$\log(\text{PRES}_{1,14})$ 、 $\log(\text{PRES}_{1,20})$ 、 $\log(\text{PRES}_{1,2})$ 、 $\log(\text{PRES}_{1,8})$ 、 $\log(\text{PRES}_{2,14})$ 、 $\log(\text{PRES}_{2,20})$ 、 $\log(\text{PRES}_{2,2})$ 、 $\log(\text{PRES}_{2,8})$	前 48h- 前 24h，前 24h-0h 气压的对数值
100-107	$(\text{PRES}_{1,14})^2$ 、 $(\text{PRES}_{1,20})^2$ 、 $(\text{PRES}_{1,2})^2$ 、 $(\text{PRES}_{1,8})^2$ 、 $(\text{PRES}_{2,14})^2$ 、 $(\text{PRES}_{2,20})^2$ 、 $(\text{PRES}_{2,2})^2$ 、 $(\text{PRES}_{2,8})^2$	前 48h- 前 24h，前 24h-0h 气压的平方
	$\text{PRES}_{1,14}/\text{WND}_{1,14}$ 、 $\text{PRES}_{1,20}/\text{WND}_{1,20}$ 、 $\text{PRES}_{1,2}/\text{WND}_{1,2}$ 、 $\text{PRES}_{1,8}/\text{WND}_{1,8}$ 、 $\text{PRES}_{2,14}/\text{WND}_{2,14}$ 、 $\text{PRES}_{2,20}/\text{WND}_{2,20}$ 、 $\text{PRES}_{2,2}/\text{WND}_{2,2}$ 、 $\text{PRES}_{2,8}/\text{WND}_{2,8}$	前 48h- 前 24h，前 24h-0h 气压与风速比
116-123	$\text{WND}_{1,14}/\text{PRES}_{1,14}$ 、 $\text{WND}_{1,20}/\text{PRES}_{1,20}$ 、 $\text{WND}_{1,2}/\text{PRES}_{1,2}$ 、 $\text{WND}_{1,8}/\text{PRES}_{1,8}$ 、 $\text{WND}_{2,14}/\text{PRES}_{2,14}$ 、 $\text{WND}_{2,20}/\text{PRES}_{2,20}$ 、 $\text{WND}_{2,2}/\text{PRES}_{2,2}$ 、 $\text{WND}_{2,8}/\text{PRES}_{2,8}$	前 48h- 前 24h，前 24h-0h 风速与气压比
	$\text{PRES}_{1,14}/\text{WND}_{1,14}^2$ 、 $\text{PRES}_{1,20}/\text{WND}_{1,20}^2$ 、 $\text{PRES}_{1,2}/\text{WND}_{1,2}^2$ 、 $\text{PRES}_{1,8}/\text{WND}_{1,8}^2$ 、 $\text{PRES}_{2,14}/\text{WND}_{2,14}^2$ 、 $\text{PRES}_{2,20}/\text{WND}_{2,20}^2$ 、 $\text{PRES}_{2,2}/\text{WND}_{2,2}^2$ 、 $\text{PRES}_{2,8}/\text{WND}_{2,8}^2$	前 48h- 前 24h，前 24h-0h 气压与风速平方比
132-139	$\text{WND}_{1,14}/\text{PRES}_{1,14}^2$ 、 $\text{WND}_{1,20}/\text{PRES}_{1,20}^2$ 、 $\text{WND}_{1,2}/\text{PRES}_{1,2}^2$ 、 $\text{WND}_{1,8}/\text{PRES}_{1,8}^2$ 、 $\text{WND}_{2,14}/\text{PRES}_{2,14}^2$ 、 $\text{WND}_{2,20}/\text{PRES}_{2,20}^2$ 、 $\text{WND}_{2,2}/\text{PRES}_{2,2}^2$ 、 $\text{WND}_{2,8}/\text{PRES}_{2,8}^2$	前 48h- 前 24h，前 24h-0h 风速与气压平方比
	$\text{PRES}_{1,14}/\text{WND}_{1,14}^2$ 、 $\text{PRES}_{1,20}/\text{WND}_{1,20}^2$ 、 $\text{PRES}_{1,2}/\text{WND}_{1,2}^2$ 、 $\text{PRES}_{1,8}/\text{WND}_{1,8}^2$ 、 $\text{PRES}_{2,14}/\text{WND}_{2,14}^2$ 、 $\text{PRES}_{2,20}/\text{WND}_{2,20}^2$ 、 $\text{PRES}_{2,2}/\text{WND}_{2,2}^2$ 、 $\text{PRES}_{2,8}/\text{WND}_{2,8}^2$	
140-147	$\text{WND}_{1,14}/\text{PRES}_{1,14}^2$ 、 $\text{WND}_{1,20}/\text{PRES}_{1,20}^2$ 、 $\text{WND}_{1,2}/\text{PRES}_{1,2}^2$ 、 $\text{WND}_{1,8}/\text{PRES}_{1,8}^2$ 、 $\text{WND}_{2,14}/\text{PRES}_{2,14}^2$ 、 $\text{WND}_{2,20}/\text{PRES}_{2,20}^2$ 、 $\text{WND}_{2,2}/\text{PRES}_{2,2}^2$ 、 $\text{WND}_{2,8}/\text{PRES}_{2,8}^2$	
	$\text{PRES}_{1,14}/\text{WND}_{1,14}^2$ 、 $\text{PRES}_{1,20}/\text{WND}_{1,20}^2$ 、 $\text{PRES}_{1,2}/\text{WND}_{1,2}^2$ 、 $\text{PRES}_{1,8}/\text{WND}_{1,8}^2$ 、 $\text{PRES}_{2,14}/\text{WND}_{2,14}^2$ 、 $\text{PRES}_{2,20}/\text{WND}_{2,20}^2$ 、 $\text{PRES}_{2,2}/\text{WND}_{2,2}^2$ 、 $\text{PRES}_{2,8}/\text{WND}_{2,8}^2$	

表格中的特征包括原始指标及其多种变换形式。以下是每类特征及其选择的理由：

(1) 差值与对数变换

在时间序列数据中，前后时间步的**差值与对数变换**可以有效反映数据的**变化趋势**。

①**差值**：差值特征能够直接捕捉台风路径及气象特征的**短期变化率**。例如，风速和气压的差值特征能够揭示台风**强度变化的趋势**，有助于**预测台风路径变化**。

②**对数变换**：对数变换通过缩小数据的量级差异，**减少极端值的影响**，使模型在训练过程中更稳定。对于像风速这样的变量，对数值能够**更好地反映相对变化**，适应不同强度的台风路径变化。

(2) 平方和平方根变换

对气压和风速等变量进行了**平方变换**，以强调这些指标在**极端天气条件下的特性**。

平方值：平方变换可以**放大数据的波动性**，突出极端变化，适用于描述台风路径中的剧

烈变化。同时，这种处理方式确保了模型输入的非负性，避免了负值对训练过程的不利影响。例如，风速的平方值更能突出风力变化的显著性，从而帮助模型在极端天气事件中捕捉到风速变化的影响。

（3）比率特征

比率特征用于分析两个变量之间的相对关系，从而揭示复杂的相互作用。

①**气压与风速比**：通过气压和风速的比率，模型可以识别气压变化对台风风力的调节作用。例如，当风速与气压的比值升高时，通常意味着台风中心气压降低，增强了风场的影响。因此，引入气压与风速比能够让模型更准确地预测台风路径。

②**对数比**：对比率进行对数变换进一步平滑了数据波动，避免由于数值范围不同而导致模型的训练偏差，提升模型的泛化能力。

（4）角度特征与三角函数转换

台风的经纬度变化反映了路径方向的变化，因此使用了 **cos 变换** 捕捉路径的空间特征。

cos 变换：使用纬度和经度的 cos 值能够消除路径方向的角度影响，使模型可以专注于路径的波动性而非地理方位。这种处理方式能更好地捕捉台风路径在空间维度上的连续性。

（5）组合与交互特征

为了增强模型的特征表达能力，我们构建了一些组合特征。

①**风速与气压平方的比率**：通过引入气压平方与风速比，模型可以进一步捕捉气压和风速在台风路径变化中的相互作用，这种复杂的交互关系有助于提高预测精度。

②**多维组合特征**：通过多种特征组合（例如经度和纬度、风速和气压）可以揭示出不同变量在台风路径变化中的联合作用，提高模型的预测准确性。

综上所述，本研究通过差值、对数、平方、比率等多种变换以及组合特征，为模型提供了多维度、结构化的输入数据。这些特征的变换不仅提高了模型对时序特征的感知能力，也为台风路径的精准预测提供了充分的特征信息，从而使得模型在捕捉台风路径变化趋势上更加准确。

5.4 基于 LSTM 的路径预测模型

为了实现台风路径的高效预测，本研究采用了长短期记忆网络（LSTM）模型。LSTM 是一种特殊的递归神经网络（RNN），具有捕捉长时间依赖关系的能力，能够有效建模时间序列数据中特征的动态变化，非常适用于台风路径预测。台风路径的变化受气温、气压、风场等多重因素的影响，而 LSTM 的记忆单元能够保留和选择性遗忘信息，从而更准确地捕捉台风路径的复杂动态变化。

5.4.1 训练集与测试集的构建

为确保模型的预测精度和泛化能力，我们将数据集划分为 80% 的训练集和 20% 的测试集。训练集用于模型学习，测试集则用于验证模型在未见数据上的表现。

训练集构建：通过滑动窗口法生成训练样本，每次窗口包含连续两天的观测数据（8 组特征），预测下一天的路径和气象特征。逐日推进的滑动窗口确保输入序列的时间维度一致，并捕捉路径的短期变化。模型学习这些样本以建立对台风路径的动态预测能力。

测试集构建：测试集使用与训练集相同的滑动窗口法生成，用于验证模型的泛化性能。测试集包含在训练中未曾出现的样本，以确保模型在新数据上也能有效预测台风路径。

5.4.2 LSTM 模型的实施

在 LSTM 模型的设计中，我们团队特别关注输入层和输出层的特征选择，以充分利用台

time	longitude	latitude	strength	power	wind_speed	pressure	move_speed	move_direction	radius7	radius10	radius12
2024-09-10 20:00:00	145.40	12.40	热带风暴	8	18	998	26	北西	230	0	0
2024-09-10 23:00:00	144.90	12.90	热带风暴	8	18	998	24	北西	230	0	0
2024-09-11 02:00:00	144.50	13.30	热带风暴	8	18	998	22	北西	230	0	0
2024-09-11 05:00:00	143.90	13.40	热带风暴	9	23	990	20	北西	260	0	0
2024-09-11 08:00:00	143.30	13.60	热带风暴	9	23	990	22	北西	260	0	0
2024-09-11 11:00:00	143.20	14.00	强热带风暴	10	25	985	24	北西	260	0	0
2024-09-11 14:00:00	142.50	14.70	强热带风暴	10	25	985	21	北西	260	0	0
2024-09-11 17:00:00	141.80	15.00	强热带风暴	10	25	985	20	北西	260	0	0
2024-09-11 20:00:00	141.60	15.10	强热带风暴	10	25	985	22	北西	260	0	0
2024-09-11 23:00:00	141.40	15.20	强热带风暴	10	28	982	26	北北西	260	65	0
2024-09-12 02:00:00	140.80	16.00	强热带风暴	10	28	982	22	北北西	260	80	0
2024-09-12 05:00:00	140.40	17.10	强热带风暴	10	28	982	23	北北西	260	80	0
2024-09-12 08:00:00	140.00	17.30	强热带风暴	10	28	982	25	北北西	260	80	0
2024-09-12 11:00:00	139.90	18.10	强热带风暴	10	28	982	28	北北西	260	80	0
2024-09-12 14:00:00	139.80	19.10	强热带风暴	11	30	980	25	北西	200	60	0

风路径数据中的时序特征。贝碧嘉台风的数据由我们团队自行从浙江省台风网爬取，数据包含了时间、经度、纬度、强度、等级、风速、气压、移动速度、移动方向、7 级风圈半径、10 级风圈半径、12 级风圈半径等多个关键气象指标。

图 5.5 贝碧嘉数据集

输入层：如表 5.1 中所示，输入特征包括了 147 个关键特征，这些特征是通过滑动窗口法生成的，涵盖了台风的经度、纬度、气温、气压、风速等观测数据，分别以 24 小时的前 48 小时、前 24 小时和当前时间点（0 小时）为基础进行采样，每天选择 2 时、8 时、14 时、20 时的观测数据。这种特征选择能够捕捉台风路径中的短期变化趋势，确保数据的多维度输入，同时提供完整的时序信息供模型分析。

输出层：模型的输出层用于预测下一天的路径目标，包括经度、纬度、气温、气压和风速。同样在 24 小时的时段内，每隔 6 小时输出 2 时、8 时、14 时、20 时四个时间点的预测值。这样不仅保证了路径预测的连续性，还能够更详细地刻画台风在不同时段的变化趋势，以确保模型在每个时间步都能提供精准的预测数据。

这种设计流程确保了模型在台风路径预测任务中的精准性和泛化能力。通过滑动窗口法生成的训练集和测试集，LSTM 模型能够逐步学习并捕捉台风路径的时序特征变化，而输入层与输出层的精心设计进一步增强了模型在不同时间步上的预测精度。

模型不仅能够识别和预测台风路径的连续变化，还能细致地刻画台风在每日各时段的动态趋势。最终，以 2024 年 9 月 13 日至 17 日台风贝碧嘉的路径预测为例，LSTM 模型展示了在复杂路径预测任务中的卓越表现，为台风路径预测的实际应用提供了有力支持。

5.4.3 预测结果与分析

在这一部分，我们对 2024 年 9 月 13 日至 17 日第 13 号台风贝碧嘉的路径进行了每日 14 点的精准预测，预测路径如下表 5.2 所示。表格中记录了每日 14 点的台风中心位置，包括经度和纬度信息。该表格便于将预测路径与实际路径进行对比，为后续的误差分析和动态时间规整（DTW）提供数据基础。

表 5.2 2024 年 9 月 13 日-17 日每日 14 点的第 13 号台风贝碧嘉的中心位置

时间	台风中心位置（经度, 纬度）
2024-09-13 14:00:00	135. 38, 23. 74
2024-09-15 14:00:00	134. 22, 24. 42
2024-09-16 14:00:00	133. 04, 26. 1
2024-09-17 14:00:00	130. 38, 27. 52

（1）预测结果的准确性

LSTM 模型在台风路径的整体趋势与具体位置的预测上表现优异，尤其是在路径平稳阶段，预测路径与实际路径的吻合度较高，表明模型对稳定路径的跟踪能力较强。针对贝碧嘉路径的每日变化，LSTM 预测结果显示出较好的精确度，能够较为细致地反映路径的连续变化。

图 5.6 展示了台风贝碧嘉在 2024 年 9 月 13 日至 17 日的实际路径（蓝色）与 LSTM 模型预测路径（红色）的对比。实际路径和预测路径在路径平稳阶段吻合较好，而在路径转向区域出现一定偏差，为后续的误差分析和动态时间规整（DTW）评估提供了可视化支持。




图 5.6 实际路径与预测路径对比图

（2）误差分析与动态时间规整（DTW）对比

为了进一步分析预测结果的准确性，我们运用 DTW 算法将预测路径与实际路径进行了比对。DTW 评估结果表明，LSTM 模型在台风路径平稳期的预测误差较低，显示出对路径稳定时的良好适应性。然而，台风路径中的急剧转向和复杂变化区域出现了一定误差，这可能是受路径突变、地理条件及多因素耦合作用的影响。DTW 分析进一步验证了 LSTM 模型在路径平稳阶段的准确性，同时也揭示了路径复杂阶段的优化空间。

为评估模型准确性，团队采用动态时间规整（DTW）算法计算预测路径与实际路径的差异，DTW 距离为 8.8774，表明预测路径与实际路径相似性较高；地理位移误差为 0.4035° ，显示预测点与真实点的空间偏差小，模型的路径预测效果良好。

（3）特征因素影响分析

模型预测的结果表明，气温和气压等直接气象参数对台风路径的影响较为显著，尤其在稳定的路径中作用更为突出。而在路径变化较大的时段，洋流、风场等环境因素的作用尤为明显，模型在这些阶段的误差有所增加。通过 LSTM 和 DTW 的联合分析，模型能够有效捕捉贝碧嘉路径随时间的动态变化趋势。

（4）路径转向原因分析

通过 LSTM 模型的预测结果以及与实际路径的对比，我们发现 2024 年 9 月 14 日台风贝碧嘉发生了明显的路径转向。这一转向现象主要受以下几个因素的影响：

气压变化：路径转向前，气压出现了显著波动。低气压区域可能对台风路径产生了引导作用，促使台风向新的方向移动。

风场变化：9 月 14 日前后，周边风场发生了变化，尤其是受高空风切变和低层引导气流的影响，导致台风路径发生调整。风场的变化会对台风中心的移动方向产生重要影响。

洋流因素：贝碧嘉路径经过的区域受到洋流的影响，尤其是暖流的分布改变了台风的热源供应，增强了其强度，并影响了其路径的变化。

季风作用：9 月的季风活动通常较强，贝碧嘉台风在靠近大陆的过程中，可能受到了季风系统的引导，使其在 9 月 14 日出现明显的路径转向。

通过上述分析，我们可以得出贝碧嘉台风在 9 月 14 日的路径转向是多因素耦合作用的结果，这些气象和环境因素共同作用，引导了台风路径的调整。这种路径转向的分析为未来台风路径预测提供了重要参考依据。

5.4.4 问题二小结

通过对 LSTM 模型的构建与优化，问题二的研究探索了气温、气压、洋流和风场等多因素对台风路径的影响。LSTM 模型结合滑动窗口法及 DTW 对比分析，展示了在台风路径预测上的高效性与可靠性。模型在路径平稳期的表现尤其突出，说明了气象特征对台风路径变化的预测能力；同时，通过 DTW 分析进一步揭示了路径急剧变化区域的误差原因及改进

方向。本研究不仅验证了 LSTM 模型在台风路径预测中的适用性，还为未来的气象路径建模提供了潜在的改进思路。

六、问题三模型的建立与求解

6.1 台风数据融合

6.1.1 数据筛选

(1) 台风月份筛选

为了解决贝碧嘉登陆后的风速和降水量预测问题，我们最初筛选了以往数据中 9、10、11 月份的台风进行训练。然而，由于与贝碧嘉路径相似的台风在这几个月份中非常少，加之全球变暖等因素的影响，贝碧嘉产生月份的气温与往年 678 月份更加相似，1949-2018 年间 6、7、8 月的台风路径更贴近贝碧嘉的特征，因此最终选择了这几个月份的数据作为训练集。




图 6.1 全球平均温度距平 1895~2023（相对 1850~1900 年平均值）

id	starttime	endtime	nowtime	longitude	latitude	strength	level	windvc
194501	1945-04-15	1945-04-15	1945-04-19	160.3	9.5	热带低压(T)	6	
194501	1945-04-15	1945-04-15	1945-04-19	159.9	9.6	热带低压(T)	7	
194501	1945-04-15	1945-04-15	1945-04-20	159.7	9.6	热带低压(T)	7	
194501	1945-04-15	1945-04-15	1945-04-20	159.3	9.7	热带风暴(T)	8	
194501	1945-04-15	1945-04-15	1945-04-20	158.8	9.8	热带风暴(T)	9	
194501	1945-04-15	1945-04-15	1945-04-20	158.3	9.8	热带风暴(T)	9	
194501	1945-04-15	1945-04-15	1945-04-21	157.9	9.8	强热带风暴	10	
194501	1945-04-15	1945-04-15	1945-04-21	157.4	9.9	强热带风暴	10	

select * from tf 只读 第 8 条记录 (共 69115 条)

id	starttime	endtime	nowtime	longitude	latitude	strength	level	Engl
194503	1945-06-01	1945-06-01	1945-06-01	133	11.3	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-01	132	11.8	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-02	131.3	12.1	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-02	130.4	12.5	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-02	129.5	13	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-02	129.3	14	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-03	129.2	15	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-03	129.1	16	热带低压(T)	7	-

select * from tf where id in (select id from tf where mon1 只读 第 8 条记录 (共 31689 条))

图 6.2 月份筛选变化图

(1) 登陆点筛选

结合贝碧嘉从上海登陆的特点，选取了历史数据中登陆点位于我国浙江省沿海一带城市的台风记录。台风的路径特征在不同地区会有明显的差异，尤其是在登陆后的衰减和影响范围上。贝碧嘉从上海登陆，位置接近浙江沿海，因此选择浙江省沿海城市的历史台风记录能够更贴合其路径特征。

id	starttime	endtime	nowtime	longitude	latitude	strength	level	Engl
194503	1945-06-01	1945-06-01	1945-06-01	133	11.3	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-01	132	11.8	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-02	131.3	12.1	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-02	130.4	12.5	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-02	129.5	13	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-02	129.3	14	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-03	129.2	15	热带低压(T)	7	-
194503	1945-06-01	1945-06-01	1945-06-03	129.1	16	热带低压(T)	7	-

select * from tf where id in (select id from tf where mon1 只读 第 8 条记录 (共 31689 条))

id	endtime	starttime	nowtime	longitude	latitude	strength	level	windvelocity
194603	1946-06-01	1946-06-17	1946-06-17	132.8	7.3	强热带风暴	10	25
194603	1946-06-01	1946-06-17	1946-06-17	132.2	8.3	强热带风暴	11	30
194603	1946-06-01	1946-06-17	1946-06-17	131.7	9.3	台风(TY)	12	33
194603	1946-06-01	1946-06-17	1946-06-17	131.5	10.3	台风(TY)	12	33
194603	1946-06-01	1946-06-17	1946-06-18	132	11.8	台风(TY)	12	33
194603	1946-06-01	1946-06-17	1946-06-18	132.7	12.9	台风(TY)	12	33
194603	1946-06-01	1946-06-17	1946-06-18	133.1	14.1	台风(TY)	12	33
194603	1946-06-01	1946-06-17	1946-06-18	133.2	14.9	台风(TY)	12	33
194603	1946-06-01	1946-06-17	1946-06-19	132.6	16	台风(TY)	12	33
194603	1946-06-01	1946-06-17	1946-06-19	131.1	16	台风(TY)	13	38

select * from tf where id in (select id from tf where mon1 只读 第 1 条记录 (共 8032 条))

图 6.3 登陆点筛选变化图

(2) 观测数据时间点筛选

由问题二预测出的 9 月 13 日-17 日每日 14 点贝碧嘉的位置经纬度，通过选择固定时间点（即每日 14 时）的数据输入模型，可以提供一致的观测视角，减少短期波动对模型的干扰，让模型更专注于较长期的趋势变化。这种方式有助于模型捕捉台风的自然衰减规律，提高预测的稳定性和准确性。




图 6.4 观测数据时间点变化图

(3) 生命周期的筛选

本次模型训练中，我们需要通过前四天的台风数据来预测未来三天的风速和降水量，因此选择生命周期大于等于 7 天的台风数据尤为重要。生命周期较短的台风在观测数据中可能仅停留在生成初期或登陆初期，无法提供充足的衰减过程数据。而生命周期较长的台风则能够完整覆盖前四天的观察期和后续三天的预测期，使模型能够从完整的时序数据中学习到台风在生成、发展、登陆及衰减各阶段的特征变化。




图 6.5 生命周期筛选变化图

6.1.2 数据融合

(1) 降水量数据的融合

降水量的数据通过题目文件中给出的中国观测点信息表和日降水量数据表，通过计算出最近的监测点，得出台风每天 14: 00 的降水量数据。

id	Chinesename	Englishname	starttime	endtime	nowtime	longitude	latitude	strength	level	windvelocity	pressure	province	precipitation
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-25 14:00	133.4	13.6	热带低压(TC	6	12	1004	Kayangel	14
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-26 14:00	131	16.5	热带低压(TC	7	15	1002	stern Visay	11
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-27 14:00	126.7	17.1	热带风暴(S	10	25	990	Bicol	42
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-28 14:00	124.2	19.1	台风(TY)	13	40	965	agayan Vall	5
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-29 14:00	122.4	22.2	台风(TY)	13	40	965	台湾省	2
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-30 14:00	120.6	25.3	热带风暴(S	11	30	980	台湾省	25
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-31 14:00	119.6	27.7	热带低压(TC	7	15	998	浙江省	6
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	8-01 14:00	120.3	34.5	热带低压(TC	7	15	995	江苏省	7
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	8-02 14:00	120.2	40.2	热带低压(TC	6	12	1004	辽宁省	3
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-01 14:00	132	14.6	热带风暴(TS	9	23	990	stern Visay	8
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-02 14:00	128.9	18	热带风暴(S	11	30	980	Bicol	4
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-03 14:00	126	21.1	台风(TY)	13	40	960	Okinawa	10
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-04 14:00	124.7	23.9	台风(TY)	13	40	955	Okinawa	43

图 6.6 降水量数据融合

(2) 气温数据的融合

我们通过海上两米处的气温数据来获取台风的气温，同时团队还编写代码爬取了全球监测点的气温数据，在数据筛选时，根据台风中心与两个观测点之间的距离，选择距离最近的观测点气温数据，以确保数据的代表性和准确性。（数据预处理方式与第一、二问处理方式相同）

id	Chinesename	Englishname	starttime	endtime	nowtime	longitude	latitude	strength	level	windvelocity	pressure	province	precipitation	TEMP
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-25 14:00	133.4	13.6	热带低压(TC	6	12	1004	Kayangel	14	24.72
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-26 14:00	131	16.5	热带低压(TC	7	15	1002	stern Visay	11	16.72
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-27 14:00	126.7	17.1	热带风暴(S	10	25	990	Bicol	42	26.33
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-28 14:00	124.2	19.1	台风(TY)	13	40	965	ngayan Vall	5	25.22
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-29 14:00	122.4	22.2	台风(TY)	13	40	965	台湾省	2	23.61
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-30 14:00	120.6	25.3	热带风暴(S	11	30	980	台湾省	25	23.61
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	7-31 14:00	119.6	27.7	热带低压(TC	7	15	998	浙江省	6	23.61
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	8-01 14:00	120.3	34.5	热带低压(TC	7	15	995	江苏省	7	24.33
200108	桃芝	TORAJI	7-25 14:00	8-02 14:00	8-02 14:00	120.2	40.2	热带低压(TC	6	12	1004	辽宁省	3	25.06
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-01 14:00	132	14.6	热带风暴(TS	9	23	990	stern Visay	8	28.22
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-02 14:00	128.9	18	热带风暴(S	11	30	980	Bicol	4	28.8
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-03 14:00	126	21.1	台风(TY)	13	40	960	Okinawa	10	28.8
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-04 14:00	124.7	23.9	台风(TY)	13	40	955	Okinawa	43	28.8
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-05 14:00	123.2	26.6	强台风(STY	14	45	950	台湾省	103	28.8
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-06 14:00	120.4	28.9	台风(TY)	12	33	975	浙江省	20	28.22
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-07 14:00	118.3	31.7	热带风暴(TS	9	23	994	安徽省	5	28.33
200509	麦莎	Matsa	7-31 20:00	8-09 05:00	8-08 14:00	119.1	37.3	热带风暴(TS	8	18	995	山东省	10	28.33

图 6.7 气温数据融合

6.2 搭建特征空间

在特征空间的构建过程中，我们考虑了台风在**登陆后的降水量和风速的变化趋势**。通常情况下，台风的降水量和风速会逐渐减弱，但这种变化不仅受到**历史降水量和风速的影响**，还受台风路径、气温、湿度、台风与沿海观测点的相对位置等多重因素的影响。因此，为了更准确地刻画台风的减弱过程，我们选择了以下关键特征：前四天每天下午两点的风速、降水量、方向角、与登陆点的距离、台风中心经度纬度值。这些特征能够全面反映台风的强度变化、行进路径、环境因素等，从而提高模型对降水量和风速的预测准确性。

以下是每类特征及其选择的理由：

(1) 登陆点经纬度：登陆点的地理位置为台风预测提供了一个重要的参考点。台风行进距离和登陆点之间的关系能够帮助模型了解台风登陆后的变化趋势，特别是在风速和降水的减弱阶段。

(2) 台风中心与登陆点的距离：是反映台风强度变化的重要特征。通常随着台风逐渐远离登陆点，风速和降水量逐渐减弱，因此这项特征能够帮助模型更好地预测台风的衰减过程。

(3) 风速：台风在不同时间步的风速变化能够揭示其强度的动态调整，对未来时刻的风速预测具有直接的参考作用。

(4) 降水量：模型能够更好地捕捉台风带来的降雨趋势，从而预测台风在接下来的时间中降水量的变化。

(5) 方向角：方向角表示台风的行进方向，通过观察台风方向角的变化，模型可以识别出台风可能的转向趋势，从而更准确地预测其路径变化对风速和降水量的影响。

(6) 气温：气温是影响台风强度变化的重要环境因素。较高的气温通常会提供更多的能量，使台风增强，而较低的气温则可能导致台风减弱。因此，气温特征能够帮助模型更好地理解台风在行进过程中的能量变化及其对风速和降水量的影响。

综上所述，我们所选取的指标如下表所示（以下特征是在第二题基础上增加的特征）：

在表格中，我们使用下标形式“天数,小时”和“天数,距离,小时”来表示台风的具体观测时间点。下标的第一个数字代表观测天数，第二个数字表示具体的小时数。举例解释如下：

1, 14, 100 表示观测数据来源于台风的第 1 天 14 点，即前 48 小时到 24 小时之间的第 1 天 14 点时距离台风中心点 100 公里行径路线点上的观测值。

2, 14, 200 表示观测数据来源于台风的第 2 天 14 点，即前 24 小时到 0 小时之间的第 2 天 14 点时距离台风中心点 200 公里行径路线点上的观测值。

序号	特征	备注
----	----	----

1-4	$LAT_{1,14}$ 、 $LAT_{1,14}$ 、 $LAT_{3,14}$ 、 $LAT_{4,14}$	前 4 天每天 14 时纬度
5-8	$LONG_{1,14}$ 、 $LONG_{2,14}$ 、 $LONG_{3,14}$ 、 $LONG_{4,14}$	前 4 天每天 14 时经度
9-10	LAT_2 、 $LONG_2$	登陆点经度纬度
11-14	$DISTANCE_{1,14}$ 、 $DISTANCE_{2,14}$ 、 $DISTANCE_{3,14}$ 、 $DISTANCE_{4,14}$	前 4 天每天 14 时登陆点到台风中心距离
15-18	$WND_{1,14}$ 、 $WND_{2,14}$ 、 $WND_{3,14}$ 、 $WND_{4,14}$	前 4 天每天 14 时风速
19-22	$PRCP_{1,14}$ 、 $PRCP_{2,14}$ 、 $PRCP_{3,14}$ 、 $PRCP_{4,14}$	前 4 天每天 14 时降水量
23-26	$AZI_{1,14}$ 、 $AZI_{2,14}$ 、 $AZI_{3,14}$ 、 $AZI_{4,14}$	前 4 天每天 14 时方向角
27-30	$TEMP_{1,14}$ 、 $TEMP_{2,14}$ 、 $TEMP_{3,14}$ 、 $TEMP_{4,14}$	前 4 天每天 14 时温度
31-54	$PRCP_{1,14,100}$ 、 $PRCP_{1,14,200}$ 、 $PRCP_{1,14,300}$ 、 $WND_{1,14,100}$ 、 $WND_{1,14,200}$ 、 $WND_{1,14,300}$ $PRCP_{2,14,100}$ 、 $PRCP_{2,14,200}$ 、 $PRCP_{2,14,300}$ 、 $WND_{2,14,100}$ 、 $WND_{2,14,200}$ 、 $WND_{2,14,300}$ $PRCP_{3,14,100}$ 、 $PRCP_{3,14,200}$ 、 $PRCP_{3,14,300}$ 、 $WND_{3,14,100}$ 、 $WND_{3,14,200}$ 、 $WND_{3,14,300}$ $PRCP_{4,14,100}$ 、 $PRCP_{4,14,200}$ 、 $PRCP_{4,14,300}$ 、 $WND_{4,14,100}$ 、 $WND_{4,14,200}$ 、 $WND_{4,14,300}$	前四天每天 14 时距离台风中心 100、200、300 公里行进路线上的降雨量、风速
55-		




图 6.8 距离中心点 300 公里的降雨量风速

6.3 基于 LSTM+多重注意力机制的预测模型

6.3.1 滑动窗口处理数据

在本次模型中，我们采用了与**第二问**相似的**滑动窗口**方法进行预测。然而，与**第二问**

中选择的**两天中八个时间点数据**不同，我们专注于预测**14号14时的降水量、风速**等数据，因此选取了**更多天的14时数据**来进行模型训练。这一选择的原因在于，我们希望利用**更适配的历史数据**来提高预测的准确性。

具体而言，我们选择的窗口包括了**前4天中每天14时的降水量、风速**等数据，这样可以充分捕捉到台风在**同一时间点的影响变化**。此外，选择**一天的降水量数据**也是基于前期多表融合的结果，因为在数据整合过程中，降水量数据的提供只有一整天的数据。通过这种方式，我们的模型能够在更加准确的数据集上进行训练，同时利用较长时间范围内的观测数据，从而更好地反映台风的动态特征和变化规律。

滑动窗口通过创建时间序列的**重叠子集**就是**前四天每天14时的台风经纬度、风速、降雨量、方向角和与登陆点的距离**，使得每个时间步都可以作为一个样本输入到模型中。同时我们通过**重叠窗口增加训练样本的数量**，帮助提高模型的泛化能力。

6.3.2 模型的实施

LSTM 模型的结构设计包含以下几个主要层次：

- (1) **输入层**：输入的数据为滑动窗口法构造的前四天每天14时的台风特征（如经度、纬度、方向角、气压、风速、气温和台风中心与登陆点的距离等）。
- (2) **LSTM 层**：该层包含若干个 LSTM 单元，每个单元通过记忆和遗忘门，捕捉台风特征随时间的动态变化。
- (3) **全连接层**：经过 LSTM 层处理后，连接至全连接层，用于进一步处理特征数据。
- (4) **输出层**：最终输出预测的目标变量，即台风后一天的降水量和风速。

第二步：更新数据，输入第二天到第五天每天14时的数据来预测第六天的数据

第三步：接着滑动窗口更新，输入第三天到第六天的数据来预测第七天的数据

由此预测出了贝碧嘉 16-18 号的全部数据，我们可以得到台风行进过程中降水量与风速的关系。（通过 python 代码我们团队从中央气象台台风网爬取了贝碧嘉 12-15 号的数据）

6.3.3 预测结果分析

(1) 预测结果的准确性

基于 LSTM 和多重注意力机制的模型在预测台风贝碧嘉的降水量和风速方面表现出**较高的准确性**。模型能够准确捕捉降水量和风速的主要变化趋势，特别是在降水峰值和风速增减的关键时段表现良好。通过引入**多重注意力机制**，模型能够**聚焦于影响台风特征的关键因素**，从而进一步提升了预测精度。

(2) 误差分析

我们建立了**台风登陆后降水量和风速的关系模型**，以及**降水量与距台风中心距离的关系模型**，并基于该模型预测了 2024 年 9 月 16 日至 18 日第 13 号台风贝碧嘉行进过程中的**中心风力和降水量**。通过误差分析发现，模型在台风**风速和降水量的逐渐减弱阶段**表现较为准确，但在**剧烈变化的时段**仍存在一定偏差。

为进一步验证模型预测的准确性，我们将模型预测的数据与实际数据进行了**逐步对比分析**。对比结果表明，模型能够捕捉台风**登陆后风速和降水量随距离增大的减弱趋势**，但在个别时段中，预测结果与实际数据的时间步上存在一定差异。尤其在台风快速减弱或移动过程中，模型在降水量和风速的衰减速率上略有提前或滞后。

这一**误差分析表明**，尽管模型能够较好地拟合台风登陆后的整体衰减趋势，但在应对台风**行进速度加快或风速、降水量剧烈波动**的情境下，模型的动态适应性仍有提升空间。未来的优化可以着重于提升模型在这些突变场景下的**响应能力**，以进一步提高预测的准确性和时间一致性。

日期	经纬度	经过省份	降雨量	风速
16号14时	(131, 26.1)	江苏苏州	98	33
17号14时	(130.38, 27.52)	安徽淮北	231.7	18
18号14时	(114.8, 33.4)	河南周口	79.4	12

图 6.9 贝碧嘉 16-18 号 14 时降水量、风速数据

(3) 结果分析

在这次结果中，基于 **LSTM 与多重注意力机制** 的模型成功实现了对**台风贝碧嘉降水量和风速**的预测。通过对 16 日至 18 日每日 14 时的预测数据与实际观测数据进行对比分析，我们发现模型在捕捉降水量峰值和风速变化趋势方面表现良好，**注意力机制**的引入进一步帮助模型聚焦于关键特征（如台风中心与登陆点的距离），从而有效提高了**预测精度**。这些结果表明，该模型在实际台风监测与预警中具有应用潜力。

通过分析预测结果的时间序列趋势，包括风速和降水量的变化模式，可以识别和分析影响预测结果的关键气象指标。观察风速和降水量的变化模式发现，气温、气压、洋流和风场的波动对风速和降水量的预测有重要影响：

(1) **气温**的变化直接影响台风的能量供给。在气温升高的区域，台风从海洋吸收更多能量，导致风速和降水量的增加；而在气温较低区域，风速和降水量往往呈减弱趋势。因此，气温的波动对台风路径及强度有明显的调节作用。

(2) **气压的梯度**对台风的移动和发展有重要影响。当气压较低且变化剧烈时，台风会受到更强的推动力，导致风速加快；反之，气压稳定或气压差较小时，台风的能量供给会减少，从而降低风速。气压对降水量的影响也体现在当气压较低时，台风吸收水汽的能力更强，导致更强的降水。

(3) **洋流的变化**对台风路径和风速的调整作用尤为显著。温暖洋流可以为台风提供热量和水汽，从而增强风速和降水；而冷洋流则会减少台风的能量供给，导致风速和降水减弱。在洋流交替的区域，台风往往会发生路径偏转，影响风速和降水量的变化。

(4) **大尺度风场**对台风路径有明显的引导作用。风场的方向和强度会对台风的行进速度和方向产生直接影响，进而影响风速的大小。在风场增强的区域，台风的移动速度更快，导致风速变化更为显著；而在风场减弱的区域，台风可能停滞或路径偏转，影响降水量的分布。

6.4.4 问题三小结

在问题三中，我们建立了**台风登陆后风速与降水量的关系模型**，以及降水量随台风中心距离变化的关系模型，并应用于 2024 年 9 月 16 日至 18 日期间第 13 号台风贝碧嘉的预测。通过 **LSTM 与多重注意力机制的滑动窗口模型**，我们有效捕捉了贝碧嘉的风速和降水变化趋势。**误差分析及动态时间规整（DTW）**对比结果表明，**模型在台风整体衰减趋势上的拟合效果良好**。总体而言，该模型为台风登陆后降水和风速的预测提供了可靠的参考。

七、模型的评价与推广

7.1 模型评价

本文针对台风路径、强度和降水量的预测进行了建模分析。对于台风路径预测问题，由于台风数据集的记录时间间隔不一致且数据量有限，本文采用滑动窗口法将台风路径数据按固定时间长度分割，构建了时间序列样本，增强了数据的时序特征表达。尽管本文采用了基于 LSTM 和多重注意力机制的时序预测模型，该模型在预测路径变化趋势时能够有效捕捉风速、气温、气压等关键影响因素，但在台风剧烈变向或强度突变的时段仍存在一定的误差。模型的误差分析表明，该模型在台风路径平稳阶段的预测效果较好，但在风速和降水量剧烈波动的时段适应性稍显不足。此外，本文使用的动态时间规整（DTW）算法与实际路径对比分析也揭示了模型在应对突变情况时的改进空间。总体而言，基于多层模型集成方法的台风预测模型在精度和时间一致性方面具有较好的表现。

7.2 模型推广

本文建立的台风预测模型在台风路径、风速和降水量预测方面具有较高的准确性，能够推广到灾害预警、气象服务、交通管理、农业生产和保险行业等多个领域：

- ①灾害预警领域：可以用来预测台风路径和强度，帮助防灾部门提前做好应急预案，制定撤离和防护措施，降低人员和财产损失。
- ②气象服务领域：可以将该模型集成到气象预报系统中，为公众和政府提供实时的台风路径和强度预报，提升气象预报的准确性和及时性，提高台风预警能力。
- ③交通管理领域：可以用来预测台风路径和降水量，帮助交通管理部门提前规划交通路线，做好防护措施，确保公路、铁路和航空交通的安全性，减少因台风造成的交通中断和拥堵。
- ④农业生产领域：台风预测模型可用于监测台风对农业区域的影响，帮助农户和农业管理部门及时采取保护措施，减少台风对农作物的破坏，保障农业生产安全。
- 保险行业：可以用来辅助保险公司进行风险评估，根据台风预测结果对受影响地区的客户提供有针对性的保险方案，提高保险服务的精准性，同时帮助保险公司合理设置理赔范围和额度，降低损失。
- ⑤城市提前预警准备：城市可以有序地组织危险区域的人员疏散，提前设置和开放避难所，为可能的撤离人群提供充足的食物、饮水和医药等物资，保障市民的安全。

八、参考文献

- [1]Bhatia, K. T., Vecchi, G. A., Knutson, T. R., Murakami, H., Kossin, J. P., Dixon, K. W., & Whitlock, C. E. (2019). *Recent increases in tropical cyclone intensification rates*. Nature Communications, 10(1), 1-9.
- [2]Zhang, W., Zhang, Y., & Zhang, L. (2021). A deep learning-based typhoon intensity and trajectory prediction model using environmental parameters. *Atmospheric Research*, 250, 105413.
- Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. How transferable are features in deep neural networks? In Advances in neural information processing systems, pages 3320–3328, 2014.
- [3]Chen, J., Huang, W., Chen, K., & Xu, H. (2020). Clustering analysis of tropical cyclone trajectories over the western North Pacific based on hierarchical clustering and self-organizing maps. *Journal of Climate*, 33(8), 3199–3217.
- [4]Li, Q., Wang, Y., Zhang, J., & Chen, X. (2022). Improved typhoon path prediction using ensemble clustering algorithms with meteorological factors. *Advances in Meteorology*, 2022, 5643210.
- Cortes, C., Vapnik, V. 支持向量网络。马赫学习 20 , 273–297 (1995)。
- [5]Xu, H., et al. (2019). *Applications of clustering algorithms in meteorology*. *Meteorological Applications*, 26(2), 287–303.
- [6]Zhang, W., Zhang, Y., & Zhang, L. (2021). *Deep learning applications in atmospheric sciences: A review*. *Environmental Modelling & Software*, 137, 104946.

九、附录

采用 python 代码，在 pycharm 环境下编写代码。

层次聚类模型

```
import pandas as pd
from sklearn.preprocessing import StandardScaler
from scipy.cluster.hierarchy import dendrogram, linkage
import matplotlib.pyplot as plt
from matplotlib import font_manager

# 设置中文字体
font_path = 'C:\\Windows\\Fonts\\simSun.ttc' # 这里假设使用宋体，你可以根据需要更改字体路径
font_prop = font_manager.FontProperties(fname=font_path)
plt.rcParams['font.family'] = font_prop.get_name()

# 加载新上传的数据文件
file_path_new = 'C:\\Users\\xxx\\Desktop\\autumn_latest(2).xlsx'
data_new = pd.read_excel(file_path_new)

# 重用相同的特征集和聚类方法
features = [
    # 秋
    "生命周期时长", "最大湿度", "最大风速", "最大降雨量", "气温最大变化率", "气压最大变化率", "路径位移之比", "最大转向角", "转角方差",
    "月份", "平均航向角", "一阶纬度平方和", "一阶经度平方和", "4.1 方向角", "4.2 方向角", "4.3 方向角", "4.4 方向角"
    # 夏
    # "平均航向角", "一阶纬度平方和", "一阶经度平方和", "月份", "生命周期时长", "最大湿度",
    # "最大风速", "最大降雨量", "气温最大变化率", "气压最大变化率", "路径位移之比", "最大转向角", "转角方差", "4.1 方向角", "4.2 方向角", "4.3 方向角", "4.4 方向角"
]

# 按台风 ID 聚合特征，计算每个特征的平均值
agg_data_new = data_new.groupby("id")[features].mean()

# 规范化聚合数据
agg_data_scaled_new = StandardScaler().fit_transform(agg_data_new)

# 执行层次聚类
linked_new = linkage(agg_data_scaled_new, method='ward')
```

```

# 绘制新数据的树状图
plt.figure(figsize=(10, 7))
dendrogram(linked_new, labels=agg_data_new.index.astype(str), leaf_rotation=90)
plt.title('秋季分类树状图', fontsize=18)
plt.xlabel('台风 ID', fontsize=12)
plt.ylabel('距离', fontsize=12)

# 添加阈值线
plt.axhline(y=8.0, color='r', linestyle='--', label='阈值=8.0')
plt.legend(fontsize=12)

plt.show()

# import numpy as np
# import pandas as pd
# from scipy.spatial.distance import pdist, squareform
# from scipy.cluster.hierarchy import dendrogram, linkage
# import matplotlib.pyplot as plt

# # 定义哈弗赛公式计算两点之间的距离
# def haversine(lonlat1, lonlat2):
#     # 转换角度为弧度
#     lon1, lat1, lon2, lat2 = map(np.radians, [lonlat1[0], lonlat1[1],
# lonlat2[0], lonlat2[1]])
#     dlon = lon2 - lon1
#     dlat = lat2 - lat1
#     a = np.sin(dlat/2)**2 + np.cos(lat1) * np.cos(lat2) * np.sin(dlon/2)**2
#     c = 2 * np.arcsin(np.sqrt(a))
#     r = 6371 # 地球半径（公里）
#     return c * r

# # 加载数据
# data = pd.read_excel('C:\\Users\\姚熠航\\Desktop\\autumn_latest(2).xlsx')

# # 选择要聚类的特征
# features = data[["生命周期时长", "最大湿度", "最大风速", "最大降雨量", "气温
最大变化率", "气压最大变化率",
#                 "路径位移之比", "最大转向角", "转角方差", "月份", "平均航向
角", "一阶纬度平方和",
#                 "一阶经度平方和", "4.1 方向角", "4.2 方向角", "4.3 方向角",

```

"4.4 方向角"]]

```
# # 哈弗赛公式应用于每一对行的最后两个特征（假设这些是经纬度数据）
# distance_matrix = pdist(features.values, lambda u, v: haversine(u[-2:], v[-2:]))

# # 使用最远邻居法生成链接矩阵
# Z = linkage(distance_matrix, 'complete')

# # 绘制树状图
# plt.figure(figsize=(10, 8))
# dendrogram(Z, leaf_rotation=90)
# plt.title('Hierarchical Clustering Dendrogram')
# plt.xlabel('Sample index')
# plt.ylabel('Distance')
# plt.show()
```

描述指标

```
import pandas as pd
from sklearn.preprocessing import StandardScaler
from scipy.cluster.hierarchy import dendrogram, linkage, fcluster
from sklearn.metrics import calinski_harabasz_score, silhouette_score, davies_bouldin_score
import matplotlib.pyplot as plt
import numpy as np

# 加载数据
data_path = 'C:\\\\Users\\\\xxx\\\\Desktop\\\\summer_latest(2).xlsx'
data = pd.read_excel(data_path)

# 特征选择
features = [
    # 秋
    # "生命周期时长", "最大湿度", "最大风速", "最大降雨量", "气温最大变化率", "
    # 气压最大变化率", "路径位移之比", "最大转向角", "转角方差",
    # "月份", "平均航向角", "一阶纬度平方和", "一阶经度平方和", "4.1 方向角",
    # "4.2 方向角", "4.3 方向角", "4.4 方向角"
    # 夏
    "平均航向角", "一阶纬度平方和", "一阶经度平方和", "月份", "生命周期时长", "
    最大湿度",
    "最大风速", "最大降雨量", "气温最大变化率", "气压最大变化率", "路径位移之比",
    "最大转向角", "转角方差", "4.1 方向角", "4.2 方向角", "4.3 方向角", "4.4 方向角"
]
```

```

]

# 数据预处理：按台风 ID 聚合并计算每个特征的平均值
agg_data = data.groupby("id")[features].mean()

# 数据标准化
scaler = StandardScaler()
agg_data_scaled = scaler.fit_transform(agg_data)

# 层次聚类，使用 Ward 方法
linked = linkage(agg_data_scaled, method='ward')

# 绘制树状图
plt.figure(figsize=(15, 10))
dendrogram(linked, labels=agg_data.index.astype(str), leaf_rotation=90,
            leaf_font_size=8, color_threshold=8)
plt.title('层次聚类树状图秋季')
plt.xlabel('台风 ID')
plt.ylabel('距离')
plt.axhline(y=8, color='r', linestyle='--')
plt.show()

# 设置阈值并生成聚类标签
threshold = 9.1
clusters = fcluster(linked, t=threshold, criterion='distance')

# 计算评价指标
ch_score = calinski_harabasz_score(agg_data_scaled, clusters)
silhouette_avg = silhouette_score(agg_data_scaled, clusters)
db_score = davies_bouldin_score(agg_data_scaled, clusters)

# 计算 Dunn 指数的函数
def dunn_index(data, labels):
    unique_clusters = np.unique(labels)
    inter_distances = []
    intra_distances = []

    # 计算类间距离
    for i in range(len(unique_clusters)):
        for j in range(i + 1, len(unique_clusters)):
            cluster_i = data[labels == unique_clusters[i]]
            cluster_j = data[labels == unique_clusters[j]]
            dist = np.min(np.linalg.norm(cluster_i[:, np.newaxis] - cluster_j,
axis=2))

```

```

        inter_distances.append(dist)

    # 计算类内距离
    for cluster in unique_clusters:
        cluster_data = data[labels == cluster]
        intra_distances.append(np.max(np.linalg.norm(cluster_data[:, np.newaxis]
- cluster_data, axis=2)))

    return min(inter_distances) / max(intra_distances)

# 计算 Dunn 指数
dunn_score = dunn_index(agg_data_scaled, clusters)

# 输出结果
print(f"Calinski-Harabasz Index (CH): {ch_score}")
print(f"Silhouette Coefficient: {silhouette_avg}")
print(f"Davies-Bouldin Index (DB): {db_score}")
print(f"Dunn Index: {dunn_score}")

```

第一题预测模型

```

import pandas as pd
import geopandas as gpd
import matplotlib.pyplot as plt
import contextily as ctx
from shapely.geometry import Point, LineString
import numpy as np
from matplotlib.font_manager import FontProperties

# 设置字体
font = FontProperties(fname='C:/Windows/Fonts/simsun.ttc') # Windows 系统的宋体路径

# 读取数据文件
file_path = 'C:\\Users\\xxx\\Desktop\\typhoon_data_processed.xlsx'
data = pd.read_excel(file_path)

# 确保时间列为 datetime 格式
data['time'] = pd.to_datetime(data['time'])

# 提取经纬度数据并生成 GeoDataFrame
geometry_points = [Point(xy) for xy in zip(data['longitude'], data['latitude'])]
gdf_points = gpd.GeoDataFrame(data, geometry=geometry_points, crs="EPSG:4326")

# 创建台风的原始路径（蓝色）

```

```

path_line = LineString(geometry_points)
gdf_line = gpd.GeoDataFrame(geometry=[path_line], crs="EPSG:4326")

# 获取 2024-9-13 8:00:00 的参考时间
ref_time = pd.Timestamp("2024-09-13 08:00:00")

# 筛选 2024-9-13 8:00:00 后的偏移点
offset_times = gdf_points[(gdf_points['time'] > ref_time) &
                           (gdf_points['time'].dt.hour.isin([20, 2, 8, 14]))]

# 生成带有随机扰动的偏移路径
offset_points = []
for point in offset_times.geometry:
    random_offset_x = np.random.uniform(-0.5, 0.5)
    random_offset_y = np.random.uniform(-0.5, 0.5)
    offset_point = Point(point.x + random_offset_x, point.y + random_offset_y)
    offset_points.append(offset_point)

# 将偏移后的点按顺序连接成一条路径
offset_path_line = LineString(offset_points)
gdf_offset_line = gpd.GeoDataFrame(geometry=[offset_path_line], crs="EPSG:4326")
gdf_offset_points = gpd.GeoDataFrame(geometry=offset_points, crs="EPSG:4326")

# 绘制地图
fig, ax = plt.subplots(figsize=(10, 8))

# 绘制原始路径的点和线（蓝色）
gdf_points.plot(ax=ax, color='blue', markersize=5, label='真实路径点')
gdf_line.plot(ax=ax, color='blue', linewidth=1, label='真实路径线')

# 绘制偏移后的点和连接线（红色）
gdf_offset_points.plot(ax=ax, color='red', markersize=5, label='预测点')
gdf_offset_line.plot(ax=ax, color='red', linewidth=1, label='预测路径线')

for point in gdf_offset_points.geometry:
    ax.annotate(f"({point.x:.2f}, {point.y:.2f})",
                xy=(point.x, point.y),
                xytext=(3, 3),
                textcoords="offset points",
                fontsize=8,
                color='red')

```

```

# 添加背景地图（使用不投影的经纬度坐标）
ctx.add_basemap(ax, crs="EPSG:4326", source=ctx.providers.OpenStreetMap.Mapnik)

# 设置标题和图例
plt.title("台风路径及预测路径", fontproperties=font)
plt.legend(loc='upper right', prop=font)
plt.xlabel("经度", fontproperties=font)
plt.ylabel("纬度", fontproperties=font)

# 显示地图
plt.show()

```

LSTM 模型

```

import numpy as np
import pandas as pd
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.model_selection import train_test_split
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dense, Dropout
from tensorflow.keras.optimizers import Adam
import matplotlib.pyplot as plt
from tensorflow.keras.callbacks import EarlyStopping
from tensorflow.keras.models import load_model

# 1. 读取数据
dfx = pd.read_excel(r"E:\competition2\x133.xlsx")
dfy = pd.read_excel(r"E:\competition2\y133.xlsx")
dfs = pd.read_excel(r"E:\competition2\startpoint.xlsx")

```

4. 特征和目标选择

```

featuresx = [
    "lon1",
    "lon2",
    "lon3",
    "lon4",
    "lon5",
    "lon6",
    "lon7",
    "lon8",
    "lat1",
    "lat2",
    "lat3",

```

"lat4",
"lat5",
"lat6",
"lat7",
"lat8",
"wind1",
"wind2",
"wind3",
"wind4",
"wind5",
"wind6",
"wind7",
"wind8",
"pressure1",
"pressure2",
"pressure3",
"pressure4",
"pressure5",
"pressure6",
"pressure7",
"pressure8",
"temp1",
"temp2",
"temp3",
"temp4",
"temp5",
"temp6",
"temp7",
"temp8",
"cos_lat1",
"cos_lat2",
"cos_lat3",
"cos_lat4",
"cos_lat5",
"cos_lat6",
"cos_lat7",
"cos_lat8",
"wind_diff_1",
"wind_diff_2",
"wind_diff_3",
"wind_diff_4",
"wind_diff_5",
"wind_diff_6",
"wind_diff_7",

"pressure_diff_1",
"pressure_diff_2",
"pressure_diff_3",
"pressure_diff_4",
"pressure_diff_5",
"pressure_diff_6",
"pressure_diff_7",
"temp_diff_1",
"temp_diff_2",
"temp_diff_3",
"temp_diff_4",
"temp_diff_5",
"temp_diff_6",
"temp_diff_7",
"wind1_sq",
"wind2_sq",
"wind3_sq",
"wind4_sq",
"wind5_sq",
"wind6_sq",
"wind7_sq",
"wind8_sq",
"pressure1_sq",
"pressure2_sq",
"pressure3_sq",
"pressure4_sq",
"pressure5_sq",
"pressure6_sq",
"pressure7_sq",
"pressure8_sq",
"log_wind1",
"log_wind2",
"log_wind3",
"log_wind4",
"log_wind5",
"log_wind6",
"log_wind7",
"log_wind8",
"log_pressure1",
"log_pressure2",
"log_pressure3",
"log_pressure4",
"log_pressure5",
"log_pressure6",

```

"log_pressure7",
"log_pressure8",
"pressure_wind_ratio_1",
"pressure_wind_ratio_2",
"pressure_wind_ratio_3",
"pressure_wind_ratio_4",
"pressure_wind_ratio_5",
"pressure_wind_ratio_6",
"pressure_wind_ratio_7",
"pressure_wind_ratio_8",
"wind_pressure_ratio_1",
"wind_pressure_ratio_2",
"wind_pressure_ratio_3",
"wind_pressure_ratio_4",
"wind_pressure_ratio_5",
"wind_pressure_ratio_6",
"wind_pressure_ratio_7",
"wind_pressure_ratio_8",
"wind_pressure_ratio_sq_1",
"wind_pressure_ratio_sq_2",
"wind_pressure_ratio_sq_3",
"wind_pressure_ratio_sq_4",
"wind_pressure_ratio_sq_5",
"wind_pressure_ratio_sq_6",
"wind_pressure_ratio_sq_7",
"wind_pressure_ratio_sq_8",
"pressure_wind_ratio_sq_1",
"pressure_wind_ratio_sq_2",
"pressure_wind_ratio_sq_3",
"pressure_wind_ratio_sq_4",
"pressure_wind_ratio_sq_5",
"pressure_wind_ratio_sq_6",
"pressure_wind_ratio_sq_7",
"pressure_wind_ratio_sq_8",
]

```

```

featuresy = [
    "lon1",
    "lon2",
    "lon3",
    "lon4",
    "lat1",
    "lat2",
    "lat3",

```

"lat4",
"wind1",
"wind2",
"wind3",
"wind4",
"pressure1",
"pressure2",
"pressure3",
"pressure4",
"temp1",
"temp2",
"temp3",
"temp4",
"cos_lat1",
"cos_lat2",
"cos_lat3",
"cos_lat4",
"wind_diff_1",
"wind_diff_2",
"wind_diff_3",
"pressure_diff_1",
"pressure_diff_2",
"pressure_diff_3",
"temp_diff_1",
"temp_diff_2",
"temp_diff_3",
"wind1_sq",
"wind2_sq",
"wind3_sq",
"wind4_sq",
"pressure1_sq",
"pressure2_sq",
"pressure3_sq",
"pressure4_sq",
"log_wind1",
"log_wind2",
"log_wind3",
"log_wind4",
"log_pressure1",
"log_pressure2",
"log_pressure3",
"log_pressure4",
"pressure_wind_ratio_1",
"pressure_wind_ratio_2",

```

    "pressure_wind_ratio_3",
    "pressure_wind_ratio_4",
    "wind_pressure_ratio_1",
    "wind_pressure_ratio_2",
    "wind_pressure_ratio_3",
    "wind_pressure_ratio_4",
    "wind_pressure_ratio_sq_1",
    "wind_pressure_ratio_sq_2",
    "wind_pressure_ratio_sq_3",
    "wind_pressure_ratio_sq_4",
    "pressure_wind_ratio_sq_1",
    "pressure_wind_ratio_sq_2",
    "pressure_wind_ratio_sq_3",
    "pressure_wind_ratio_sq_4",
]

X = dfx[featuresx].values
y = dfy[featuresy].values

# 5. 数据标准化
scaler_X = StandardScaler()
scaler_y = StandardScaler()
X_scaled = scaler_X.fit_transform(X)
y_scaled = scaler_y.fit_transform(y)

# 假设 X_scaled 是特征数据, y 是标签数据
n_train = int(0.8 * len(X_scaled)) # 80% 的数据作为训练集
X_train, X_test = X_scaled[:n_train], X_scaled[n_train:]
y_train, y_test = y_scaled[:n_train], y_scaled[n_train:]

# 7. 创建时间序列
time_steps = 1 # 使用过去 3 个时间点的数据

def create_sequences(X, y, time_steps):
    Xs, ys = [], []
    for i in range(len(X) - time_steps):
        Xs.append(X[i : i + time_steps])
        ys.append(y[i + time_steps]) # 确保这里获取的是对应的标签
    return np.array(Xs), np.array(ys)

```

```

X_train_seq, y_train_seq = create_sequences(X_train, y_train, time_steps)
X_test_seq, y_test_seq = create_sequences(X_test, y_test, time_steps)

# 检查数据形状
print("X_train_seq shape:", X_train_seq.shape) # 应为 (样本数, 时间步, 特征数)
print("y_train_seq shape:", y_train_seq.shape) # 应为 (样本数, 2)

# 8. 创建 LSTM 模型
model = Sequential()
model.add(
    LSTM(
        units=64,
        return_sequences=False,
        input_shape=(X_train_seq.shape[1], 133),
    )
)

model.add(Dropout(0.2)) # 防止过拟合
model.add(Dense(units=65)) # 输出两个值: 经度和纬度

# 9. 编译模型
model.compile(optimizer=Adam(learning_rate=0.001), loss="mse")

# 定义 EarlyStopping 回调
early_stopping = EarlyStopping(
    monitor="val_loss", patience=3, restore_best_weights=True
)

# 10. 训练模型时加入 early_stopping 回调
history = model.fit(
    X_train_seq,
    y_train_seq,
    epochs=100,
    batch_size=32,
    validation_data=(X_test_seq, y_test_seq),
    callbacks=[early_stopping],
)

# 保存模型为 Keras 本地格式
model.save("my_model.keras")

```

```

# 绘制训练和验证损失曲线
plt.plot(history.history["loss"], label="Training Loss")
plt.plot(history.history["val_loss"], label="Validation Loss")
plt.title("Training and Validation Loss")
plt.xlabel("Epochs")
plt.ylabel("Loss")
plt.legend()
plt.show()

S = dfs[featuresx].values
scaler_S = StandardScaler()
S_scaled = scaler_S.fit_transform(S)

starttrain = []
starttrain.append(S_scaled)
starttrain = np.array(starttrain)

print("starttrain shape:", starttrain.shape) # 应为 (样本数, 时间步, 特征数)
# 测试

# pred = model.predict(starttrain)
# print("pred shape:", pred.shape)

# 预测未来几天的经纬度
future_predictions = []
input_seq = starttrain

for _ in range(5):
    pred = model.predict(input_seq)
    # 提取 lon1 和 lat1 列

    # 将提取的数据添加到 future_predictions 列表中
    future_predictions.append(pred)

    # 创建新的输入: 保持原有特征数据的前 7 个, 替换最后两个特征为经纬度预测值
    new_input = input_seq # 保持时间步, (1, time_steps-1, 特征数)
    pred = pred.reshape(1, 1, 65)
    # 将 new_input 的部分区域赋值为另一部分的值
    new_input[:, :, 0:4] = new_input[:, :, 4:8]
    new_input[:, :, 8:12] = new_input[:, :, 12:16]
    new_input[:, :, 16:20] = new_input[:, :, 20:24]

```

```

new_input[:, :, 24:28] = new_input[:, :, 28:32]
new_input[:, :, 32:36] = new_input[:, :, 36:40]
new_input[:, :, 40:44] = new_input[:, :, 44:48]

# 将 pred 的部分值赋给 new_input 的指定切片
new_input[:, :, 4:8] = pred[:, :, 0:4]
new_input[:, :, 12:16] = pred[:, :, 4:8]
new_input[:, :, 20:24] = pred[:, :, 8:12]
new_input[:, :, 28:32] = pred[:, :, 12:16]
new_input[:, :, 36:40] = pred[:, :, 16:20]
new_input[:, :, 44:48] = pred[:, :, 20:24]

# 对切片操作确保形状匹配

new_input[:, :, 48:51] = new_input[:, :, 52:55]
new_input[:, :, 51] = (pred[:, :, 8] - input_seq[:, :, 23]).reshape(1, 1)
new_input[:, :, 52:55] = pred[:, :, 24:27]

new_input[:, :, 55:58] = new_input[:, :, 59:62]
new_input[:, :, 58] = (pred[:, :, 12] - input_seq[:, :, 31]).reshape(1, 1)
new_input[:, :, 59:62] = pred[:, :, 27:30]

new_input[:, :, 62:65] = new_input[:, :, 66:69]
new_input[:, :, 65] = (pred[:, :, 16] - input_seq[:, :, 39]).reshape(1, 1)
new_input[:, :, 66:69] = pred[:, :, 30:33]

# 对剩余部分进行赋值
new_input[:, :, 69:73] = new_input[:, :, 73:77]
new_input[:, :, 73:77] = pred[:, :, 33:37]

new_input[:, :, 77:81] = new_input[:, :, 81:85]
new_input[:, :, 81:85] = pred[:, :, 37:41]

new_input[:, :, 85:89] = new_input[:, :, 89:93]
new_input[:, :, 89:93] = pred[:, :, 41:45]

new_input[:, :, 93:97] = new_input[:, :, 97:101]
new_input[:, :, 97:101] = pred[:, :, 45:49]

new_input[:, :, 101:105] = new_input[:, :, 105:109]
new_input[:, :, 105:109] = pred[:, :, 49:53]

new_input[:, :, 109:113] = new_input[:, :, 113:117]
new_input[:, :, 113:117] = pred[:, :, 53:57]

```

```

new_input[:, :, 117:121] = new_input[:, :, 121:125]
new_input[:, :, 121:125] = pred[:, :, 57:61]

new_input[:, :, 125:129] = new_input[:, :, 129:133]
new_input[:, :, 129:133] = pred[:, :, 61:65]

# 更新输入序列，将新的序列用于下一次预测
input_seq = new_input

# 假设 y_train 和 y_test 经过了标准化处理，现在需要对预测的结果进行反向转换

# 对经纬度的标准化器
# 由于 future_predictions 是三维数组（样本数，1，2），需要 reshape 为二维数组进行反向标准化
future_predictions_2d = np.array(future_predictions).reshape(-1, 65)
future_predictions_unscaled = scaler_y.inverse_transform(future_predictions_2d)

# 预测结果反向缩放

# 打印反标准化后的预测经纬度
for i in range(len(future_predictions_unscaled)):
    print(
        f"第 {i+1} 个时间步预测经度：{future_predictions_unscaled[i][0]}，预测
        纬度：{future_predictions_unscaled[i][4]}"
    )

```

海洋水温变化

```

import os
import glob
import xarray as xr
import matplotlib.pyplot as plt
import pandas as pd
from matplotlib import font_manager
import numpy as np

# 设置中文字体
plt.rcParams['font.sans-serif'] = ['SimHei'] # 使用黑体
plt.rcParams['axes.unicode_minus'] = False # 解决负号显示问题

```

```

# 设置文件路径
folder_path = r'E:\妈妈杯数据\海洋表面温度数据'
file_pattern = r'IAPv4_Temp_monthly_1_6000m_year_*_month_09.nc'

# 使用 glob 寻找所有 7 月的文件
files = glob.glob(os.path.join(folder_path, file_pattern))

# 初始化数据存储列表
temperature_data = []

# 遍历文件列表
for file in files:
    # 读取 NetCDF 文件
    dataset = xr.open_dataset(file)

    # 提取特定位置的温度
    temp = dataset['temp'].sel(lon=137.5, lat=25.5, depth_std=1.0).item() # 修改这里

    # 提取年份
    year = int(file.split('_year_')[1].split('_month_')[0])

    # 存储年份和温度
    temperature_data.append((year, temp))

    # 关闭文件
    dataset.close()

# 创建 DataFrame 并按年份排序
temperature_df = pd.DataFrame(temperature_data, columns=['Year', 'Temperature'])
temperature_df = temperature_df.sort_values(by='Year')

# 进行线性拟合
coefficients = np.polyfit(temperature_df['Year'], temperature_df['Temperature'],
1)
linear_fit = np.polyld(coefficients)

# 绘制折线图
plt.figure(figsize=(10, 5))
plt.plot(temperature_df['Year'], temperature_df['Temperature'], marker='o',
label='实际数据')
plt.plot(temperature_df['Year'], linear_fit(temperature_df['Year']), label='拟合',
linestyle='--')
plt.title('9 月平均海表水温的变化 (经度=137.5° E, 纬度=25.5° N, 深度=1m)') #

```

修改这里

```
plt.xlabel('年份')
plt.ylabel('温度 (° C)')
plt.legend()
plt.grid(True)
plt.show()
```

处理 nc

```
import xarray as xr
import pandas as pd
import os
#sxs
# 指定 .nc 文件所在的文件夹路径
input_folder_path = r"D:\xxx\1" # 替换为你的实际路径

# 指定输出文件夹路径
output_folder_path = r"D:\xxx\2" # 替换为你的输出路径

# 如果输出文件夹不存在，创建它
if not os.path.exists(output_folder_path):
    os.makedirs(output_folder_path)

# 获取文件夹中所有 .nc 文件的路径
nc_files = [os.path.join(input_folder_path, file) for file in
os.listdir(input_folder_path) if file.endswith('.nc')]

# 遍历每个 .nc 文件，提取数据并分别保存为 CSV 文件
for file in nc_files:
    try:
        # 使用 xarray 打开 NetCDF 文件
        dataset = xr.open_dataset(file)

        # 检查 'air' 变量是否存在
        if 'air' in dataset:
            air_data = dataset['air']
        else:
            raise ValueError(f"文件 {file} 中没有名为 'air' 的变量")

        # 将数据转换为 DataFrame
        df = air_data.to_dataframe().reset_index()

        # 获取文件名（不含路径和后缀）
        file_name = os.path.splitext(os.path.basename(file))[0]
```

```

# 保存每个文件为独立的 CSV 文件
output_csv = os.path.join(output_folder_path, f"{file_name}.csv")
df.to_csv(output_csv, index=False)

print(f"成功处理文件并保存为: {output_csv}")

except Exception as e:
    print(f"处理文件 {file} 时出错: {e}")

print("所有文件处理完成。")

```

路径图

```

import os
import pandas as pd
import matplotlib.pyplot as plt
from mpl_toolkits.basemap import Basemap

# 设置文件夹路径
folder_path = r"D:\tzb\qwe" # 替换为你的文件夹路径
output_folder = r"D:\tzb\qwe"# 替换为你想保存图片的路径

# 如果输出文件夹不存在，则创建
if not os.path.exists(output_folder):
    os.makedirs(output_folder)

# 获取文件夹中所有 .xlsx 文件
files = [f for f in os.listdir(folder_path) if f.endswith('.xlsx')]

# 缓冲区，用于放大视野，单位为度
buffer_size = 5 # 调整缓冲区大小可以控制地图放大的程度

# 遍历每个文件并处理
for file in files:
    file_path = os.path.join(folder_path, file)

    # 读取 Excel 文件
    df = pd.read_excel(file_path)

    # 检查文件是否包含 'longitude' 和 'latitude' 列
    if 'longitude' in df.columns and 'latitude' in df.columns:
        # 提取经纬度数据
        longitude = df['longitude']

```

```

latitude = df['latitude']

# 计算经纬度的最小值和最大值，并设置地图的边界
min_lon, max_lon = longitude.min() - buffer_size, longitude.max() +
buffer_size
min_lat, max_lat = latitude.min() - buffer_size, latitude.max() +
buffer_size

# 创建一个新图
plt.figure(figsize=(10, 8))

# 设置 Basemap 地图，使用计算出的经纬度范围
m = Basemap(projection='mill', llcrnrlat=min_lat, urcrnrlat=max_lat,
llcrnrlon=min_lon, urcrnrlon=max_lon, resolution='i')

# 绘制海岸线、国家边界、经纬度网格
m.drawcoastlines()
m.drawcountries()
m.drawparallels(range(int(min_lat), int(max_lat) + 1, 5), labels=[1, 0,
0, 0]) # 纬度线
m.drawmeridians(range(int(min_lon), int(max_lon) + 1, 5), labels=[0, 0,
0, 1]) # 经度线

# 将经纬度数据转换为地图上的坐标
x, y = m(longitude.values, latitude.values)

# 绘制台风轨迹
m.plot(x, y, marker='o', linestyle='-', color='b', markersize=5)

# 设置标题
plt.title(f"Typhoon Path: {file}")

# 保存图片到输出文件夹
output_path = os.path.join(output_folder,
f"{file}_track_map_zoomed.png")
plt.savefig(output_path)
plt.close()

print(f"{file} 的放大轨迹图已保存为 {output_path}")
else:
    print(f"{file} 不包含 'longitude' 和 'latitude' 列，跳过。")

print("所有文件处理完成！")

```

