

队伍编号	MCB2401349
赛道	(A)

基于 K-means 聚类与 LSTM 时间序列的台风路径问题研究

摘 要

自古以来，台风便深刻影响着人类的日常生活，是最严重的自然灾害之一，常引发狂风、暴雨等自然灾害，突发性强、破坏力大。本文基于 K-means 聚类对台风类别进行了划分，借助 LSTM 时间序列与指数衰减模型预测了台风的路径及中心风力等特征。

针对问题一，本文建立了 K-means 聚类模型对不同特征的台风类别进行了划分。首先对数据进行预处理，包含风向等非数值数据类型进行转换，处理缺失值、异常值等；接着观察数据集发现，本题数据基本为非线性数据，因此采用斯皮尔曼相关系数分析台风特征参数与环境特征参数之间的相关性。随后，采用 K-means 聚类方法对台风的路径特征与强度特征两方面进行聚类分析，通过手肘法与轮廓系数综合考虑确定最佳聚类数分别为 4 类与 3 类。最后，计算 7 月与 9 月台风数据点与各个聚类中心点的欧氏距离，依据最小欧氏距离划分类别。

针对问题二，本文建立了台风路径的 LSTM 时间序列预测模型。首先，统一数据集记录的时间间隔为 6 小时，以减少模型预测偏差。接着，引入了循环神经网络及其改进形式 LSTM 来处理时序数据，将数据集被分为训练集和测试集，分别用于模型训练和性能评估，采用平均绝对误差和均方根误差作为预测评价指标，得出经度的 MAE 和 RMSE 值分别为 2.627、5.765，纬度的 MAE 和 RMSE 值分别为 1.807、3.461，确保最终训练模型表现良好，然后输入参数即可求得预测结果。最后通过动态时间规整算法对预测路径与真实路径进行对比分析，计算求得 DTW 距离为 10.32，可以认为模型的预测效果较好，拟合程度较高。

针对问题三，本文建立了台风行进途中降水量的指数衰减模型。首先，筛选并整合台风数据集中的关键特征，如风速、降水量、中心位置等，并采用哈佛辛公式计算基站与台风中心之间的距离，为后续分析打下基础。接着，构建了指数衰减模型来拟合风速与降水量的关系以及距台风中心距离与降水量的关系，通过最小二乘法估计模型参数，得出风速与降水量的相关性不明显，而距台风中心距离与降水量拟合效果较好，决定系数约为 0.54。此外，台风中心风力的变化呈现出时间序列特性，因此可利用 LSTM 模型预测台风中心风力。最后，结合风速-降水量模型和 LSTM 预测结果，对降水量进行了预测，由于数据的波动性，模型曲线未能很好地与实际数据点相吻合。总的来说，风速对降水量的影响并不是唯一的决定性因素，可能还有其他未被考量的环境因素对降水量产生显著影响。

关键词：K-means 聚类 斯皮尔曼相关系数 循环神经网络 LSTM 指数衰减

目录

一、 问题重述	1
二、 问题分析	1
2.1 问题一的分析	1
2.2 问题二的分析	1
2.3 问题三的分析	1
三、 模型假设	2
四、 符号说明	2
五、 模型的建立与求解	3
5.1 问题一模型的建立与求解	3
5.1.1 数据预处理	3
(一) 数据优化	3
(二) 相关性分析	5
5.1.2 聚类分析	6
(一) 可视化分析	6
(二) 特征工程	8
(三) 手肘法与轮廓系数	9
(四) 路径特征聚类	10
(五) 强度特征聚类	12
5.1.3 台风类别划分	13
5.2 问题二模型的建立与求解	14
5.2.1 数据预处理	14
5.2.2 时间序列预测模型	14
(一) 模型引入	14
(二) LSTM 预测模型	16
(三) 预测评价指标	17
(四) 预测结果分析	17
5.2.3 对比分析	18
(一) DTW 算法	18
(二) 对比分析	19
5.3 问题三模型的建立与求解	19
5.3.1 数据准备	19
5.3.2 拟合关系	20
(一) 指数衰减模型	20
(二) 拟合风速与降水量关系	20
(三) 拟合降水量与距台风中心距离关系	20
5.3.3 预测及分析	21
(一) LSTM 预测风力	21
(二) 预测降水量	22
六、 模型的评价、改进	23
6.1 模型的优点	23
6.2 模型的缺点	23
6.3 模型的改进	23
七、 参考文献	23

一、问题重述

问题 1: 探索台风的气象特性，如强度和风速，与气温、气压、季风等环境因素的关联，并开发一个评价模型用于台风的分类。使用 2024 年夏季和秋季的台风数据，应用该模型区分不同季节的台风类别，并探讨夏季台风与秋季台风之间的主要区别。

问题 2: 综合考虑影响台风路径的多种因素，如气温、气压、洋流和风场，构建一个预测模型。以 2024 年 9 月的第 13 号台风“贝碧嘉”为研究对象，预测其移动轨迹，并利用 DTW 算法对模型预测的路径与实际路径进行对比分析。

问题 3: 分析台风登陆后风速和降水量随时间和距离台风中心的变化规律，并建立相应的数学模型。以 2024 年 9 月 16 日至 18 日的第 13 号台风“贝碧嘉”为例，根据模型预测台风移动过程中的中心风力和降水量，并进行相应的数据分析。

二、问题分析

2.1 问题一的分析


首先，针对问题一，我们目的在于揭示台风的气象特征，例如风速和强度，与环境参数如气温、气压和季风之间的潜在联系，并建立一个评估模型用于对台风进行分类。利用 2024 年夏秋季节的台风数据，我们执行了数据的预处理、相关性分析和聚类分析等步骤，开发出一个能够识别不同季节台风特征的模型，并分析了夏季与秋季台风之间的显著差异。在此过程中，我们对数据进行了细致的处理，包括特殊指标的量纲转换、缺失值的填补以及异常值的识别与修正，随后运用斯皮尔曼等级相关系数评估了变量间的关联性，并采用 K-means 聚类算法对台风数据进行分类。

2.2 问题二的分析

对于问题二，我们的目标是构建一个模型，该模型能够综合多种因素，如气温、气压、洋流和风场，以预测台风的移动路径。以 2024 年 9 月的第 13 号台风“贝碧嘉”为例，我们通过时间序列分析和长短期记忆网络（LSTM）模型预测了台风的轨迹，并运用动态时间弯曲（DTW）算法比较了模型预测路径与实际路径的一致性。在数据预处理阶段，我们统一了台风数据的时间记录间隔，并采用了 LSTM 模型，这是一种特别适合处理序列数据的神经网络架构，能够有效预测台风在未来多个时间点的中心位置。

2.3 问题三的分析

问题三，我们的目的地是分析台风登陆后风速和降水量随时间和距离台风中心点的变化规律，并建立相应的数学模型。以 2024 年 9 月 16 日至 18 日的第 13 号台风“贝碧嘉”为案例，我们预测了台风移动过程中中心风力和降水量的变化，并进行了数据分析。在数据准备阶段，我们筛选并汇总了风速、降水量、中心位置和中心风力等关键特征，并通过哈弗辛公式计算了基站与台风中心点之间的直线距离。接着，我们应用指数衰减模型来描述台风登陆后风速和降水量的变化，并利用最小二乘法来确定模型参数的最佳估计值^[1]。



三、模型假设

- **数据完整：**现实中的数据集难免会有缺失或异常，我们相信通过恰当的处理手段，比如数据填补和修正，能够确保我们所使用数据集的完整性和可靠性。
- **环境恒定：**在模型预测的短期内，我们认为影响台风路径和特性的环境因素变化不大，可以视为相对稳定。
- **路径预测的简化处理：**为了简化计算，我们暂且将台风的路径视为短期内近似直线。
- **指数衰减规律的适用性：**我们假设台风登陆后风速和降水量的减弱遵循指数衰减的模式，有助于我们构建模型来模拟这些随时间变化的现象。

四、符号说明

符号	说明
w_i	第 i 次定位时台风路径强度的权重因子
X	台风的经度集群中心
Y	台风的纬度集群中心

k	K-means 聚类中的聚类数
C_i	聚类后的第 i 个簇
p	C_i 中的样本点
m_i	C_i 的质心
$s(i)$	$s(i)$ 是样本点 i 的轮廓系数
$a(i)$	样本点 i 的簇内凝聚度
$b(i)$	样本点 i 的簇间分离度
t_i	台风数据的第 i 个时间序列
n	预测的样本数量
lat_1	点 1 的纬度值
lat_2	点 2 的纬度值
Δlat	两点之间的纬度差值
$\Delta long$	两点之间的经度差值

五、模型的建立与求解

5.1 问题一模型的建立与求解

5.1.1 数据预处理

(一) 数据优化

通过查阅各类论文文献，我们首先从数据集里台风的众多参数中筛选出需要的环境特征参数，即气温、气压、季风，用于分析与台风特征参数的关系。对数据集进行初步分析后，发现数据集中存在大量的无效数据，为便于后续建模需要，按下列方法对数据集进行优化处理：

(1) 特殊指标量纲化：对于部分非数据格式的特殊指标，我们需要将其进行量纲化。例如，移动方向的原数据均采用文字表示，我们需要将其转换为对应角度值以便于后续计算，与此同时，我们发现移动方向的数据集中存在数十种不同的方向，为简化模型，我们将部分相邻的方向进行合并，例如将西西北、西北偏西、西北西三个方向均视作西西北方向，其余方位的方向同样处理。




图 1 风向对照图

如图 1 所示，通过对移动方向的简化处理，我们最终获得十六个方向的简化风向图，并为每个方向赋予其对应的角度值。

同时我们对台风强度的指标进行数字编码，如下表所示同时我们对台风强度的指标进行数字编码，如下表所示：

表 1 台风强度编码表

台风强度	数字编码
空值	0
热带低压	1
热带风暴	2
强热带风暴	3
台风	4
强台风	5
超强台风	6

(2)缺失值处理: 通过计算数据缺失值占比发现，台风强度的缺失值占比为 8.1%，在同一台风的数据范围内采用最临近插补法填补缺失值，即在数据范围内寻找距离缺失值最近的值进行填补；而对于其他参数，缺失值占比最高的指标仅有 3.01%，对整体数据集影响可忽略，因此可直接删除记录。

(3)异常值处理: 通过观测数据集可发现部分参数存在大量的异常值，首先我们对风速、气压、海洋温度的数据进行 $K-S$ 正态性检验（假设 H_0 : 整体具有正态分布）。

如表 2 所示，检验结果表明，数据不服从正态分布，因此我们通过绘制风速的箱线图来检测异常值。

表 2 K-S 检验结果表

单样本柯尔莫戈洛夫-斯米诺夫检验				
		风速	气压	海洋温度
个案数		67040	67040	67040
正态参数 ^{a,b}	平均值	27.81	980.29	17.826891010755890
	标准偏差	15.022	22.921	9.033563615225223
最极端差值	绝对	.129	.155	.132
	正	.129	.114	.126
	负	-.077	-.155	-.132
检验统计		.129	.155	.132
渐近显著性（双尾）		.000 ^c	.000 ^c	.000 ^c
a. 检验分布为正态分布。				
b. 根据数据计算。				
c. 里利氏显著性修正。				




图 2 风速箱线图

如图 2 所示,以风速为例,大部分风速的值处于 $[0, 61]$,而少数风速高达 110km/s ,显然不符合一般规律。随后采用最邻近插补法替换异常值,即在同一台风的数据范围内寻找距离最近的非异常值进行替换,对于其它参数的异常值也采用同样方法处理。

(二) 相关性分析

首先为了分析台风特征参数(强度、等级、风速)与环境特征参数(气温、气压、季风)的相关性,我们采用斯皮尔曼相关系数来进行相关性分析。

斯皮尔曼相关系数是一种非参数统计量,用于衡量两个变量之间的相关性。它通

过比较变量的秩次而不是原始数值来计算相关性，并且不要求数据为线性关系，因此特别适用于本题的非线性关系的数据。其计算公式为：

$$\rho=1-\frac{6\sum d_i^2}{n(n^2-1)} \tag{1}$$

其中， ρ 是斯皮尔曼相关系数， d_i 是每一对观测值在两个变量中的秩次差， n 是样本数量。




图 3 相关性分析热力图

- 如图 3 所示，我们可以得知：
- 台风强度、台风等级与风速、气压之间呈现强相关关系，因为台风是一种低气压系统，台风强度越大、等级越高、风速越快，通常中心气压越低，符合气象学原理，低气压和高风速是台风的重要特征。
 - 气温、季风与台风强度等指标之间的相关性较弱，这说明气温、季风与台风的强度、等级、风速和气压之间没有明显的直接关系，对台风特征参数的直接影响较小。

5. 1. 2 聚类分析

(一) 可视化分析

根据数据集中提供的台风经纬度数据，我们对台风的运动路径进行可视化，以此初步分析台风的活动特征。









图 4 不同强度下的台风路径图

台风路径可视化图




图 5 所有台风的路径图

以上为 1943 至 2023 年间不同台风强度的台风路径图以及所有台风的路径图，根据上列可视化图我们可以得知：

- 不同强度的台风，如普通台风和超强台风，在路径上可能存在一定的差异。一般来说，超强台风可能由于其强大的能量，路径可能相对更加稳定且覆盖范围可能更广。
- 不同强度台风的路径走向可能受到多种因素影响，如大气环流、海洋温度等。例如，较高强度的台风可能在特定的大气环流条件下更容易沿着特定的方向移动。
- 在某些经度区域可能更容易形成特定强度的台风，或者这些区域的海洋条件和大气环境更有利于台风的发展和移动。

根据以上分析，我们可以了解到台风的路径受到多种环境参数的影响，不同的台风之间呈现出不同的路径特征，因此可将路径特征作为台风分类的标准之一。通过查阅相关的文献发现，过去专家对台风的分类标准中，依据强度特征分类是最典型的分类标准，因此我们选择将路径特征与强度特征作为台风分类评价模型的两类特征，通过这两类特征的综合特征对台风类别进行最终判定。由于数据集中提供的数据没有标签，因此在本题中我们采用 K-means 聚类方法对台风进行分类。

K-means 模型是一种无监督学习模型，适用于数据集中没有提供数据标签的情况。在 K-means 算法中，事先并不需要给定样本的类别标签信息。它的目标是将给定的数据集划分为 K 个聚类，使得每个数据点都属于离它最近的聚类中心所在的簇。算法通过不断迭代更新聚类中心和数据点的所属簇，以达到优化目标函数（通常是最小化数据点到其所属聚类中心的距离之和）的目的^[2]。

（二）特征工程

为了更好地反映台风的路径特征，我们首先选择经纬度作为台风路径的基本特征，除此之外，为实现更好地聚类效果，我们利用经纬度数据构建出经度集群中心、纬度集群中心、经度方差、纬度方差和协方差五项新特征作为用于 K-means 聚类的路径特征。

首先，台风的经度集群中心与纬度集群中心可由如下公式得到：

$$X = \frac{1}{\sum_{i=1}^n w(i)} \sum_{i=1}^n w(i)x_i \quad (2)$$

$$Y = \frac{1}{\sum_{i=1}^n w(i)} \sum_{i=1}^n w(i)y_i \quad (3)$$

在式(2)、式(3)中，变量 x_i 和 y_i 代表的是台风在特定时刻所处的经度和纬度， n 则统计了台风路径上的定位次数。在此， w_i 是用于衡量第 i 次定位时台风路径强度的一个权重因子，我们选取了风速的平方根作为权重 w_i 的计算方式。这么做的意图是为了均衡路径上各个位置的重要性，防止个别极端风速值对整体路径分析的影响，确保路径上各点的权重不会出现过大的偏差，进而更贴切地描绘出台风的整体移动路径。

随后，经度方差、纬度方差和协方差可由如下公式得到：

$$\text{Var}(x) = \frac{1}{\sum_{i=1}^n w(i)} \sum_{i=1}^n w(i)(x_i - X)^2 \quad (4)$$

$$Var(y) = \frac{1}{\sum_{i=1}^n w(i)} \sum_{i=1}^n w(i)(y_i - Y)^2 \quad (5)$$

$$Var(xy) = \frac{1}{\sum_{i=1}^n w(i)} \sum_{i=1}^n w(i)(x_i - X)(y_i - Y) \quad (6)$$

在式(4)、式(5)、式(6)中，变量 X 、 Y 为由式(2)与式(3)计算得到的经度集群中心与纬度集群中心，而变量 x_i 、 y_i 、 $w(i)$ 的定义与式(2)、式(3)相同。

(三) 手肘法与轮廓系数

在进行 K-means 聚类之前，我们首先需要确定最优 k 值，即聚类数量，可以采用手肘法与轮廓系数法来寻找最优 k 值，从而使得聚类的结果更加准确。

手肘法是一种能够确定 k 值的较为直观的方式。它是通过绘制误差平方和 (SSE) 与 k 值的关系图来找到最优 k 值。一般情况下，随着 k 值不断增大，SSE 会逐渐下降，而当到达某个特定的点之后，SSE 的下降速度会明显变缓，从而形成一个类似“肘部”的形状，这个点往往被视作是最优的 k 值。SSE 的计算公式如下：

$$SSE = \sum_{i=1}^k \sum_{p \in C_i} |p - m_i|^2 \quad (7)$$

其中， C_i 是第 i 个簇， p 是 C_i 中的样本点， m_i 是 C_i 的质心 (C_i 中所有样本的均值)，SSE 是所有样本的聚类误差，代表了聚类效果的好坏。

轮廓系数属于评估样本聚类质量的一种指标，其将聚类的凝聚度与分离度进行了结合，用以评估聚类效果。该指标综合考量了样本与其簇内其他样本的距离以及与最近簇样本的距离，在求出所有样本的轮廓系数后取平均值便得到平均轮廓系数。平均轮廓系数处于 $[-1, 1]$ 这个取值范围内，当簇内样本距离更近，簇间样本距离更远时，平均轮廓系数会增大，且平均轮廓系数越大，聚类效果就越好，其中平均轮廓系数最大时对应的 k 值就是最佳聚类数。轮廓系数 $s(i)$ 的计算公式如下：

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (8)$$

其中， $s(i)$ 是样本点 i 的轮廓系数， $a(i)$ 是簇内凝聚度， $b(i)$ 是簇间分离度。




图 6 手肘法分析结果图




图 7 轮廓系数分析结果图

如图 6 与图 7 所示，通过手肘法和轮廓系数来确定最优 k 值，即最佳聚类数，可以得出如下结论：

- **手肘法：**在 $k = 4$ 时， SSE 的下降速度会明显变缓，此点可作为最优 k 值。
- **轮廓系数：**在 $k = 4$ 和 $k = 6$ 时，平均轮廓系数为极大值点，此时聚类效果较好。

(四) 路径特征聚类

通过对手肘法与轮廓系数的综合考量，我们选定 $k = 4$ 作为最佳聚类数，依据 $k = 4$ 的聚类数结合经度集群中心、纬度集群中心、经度方差、纬度方差和协方差五项路径特征进行 K-means 聚类。




图 8 路径特征聚类结果图

如图 8 所示，可以看出台风依据路径特征被分为了 4 种类别，每种颜色各代表一

种类别的台风，分别以经纬度为横、纵坐标绘制二维可视化图来呈现不同的聚类组。每个组的台风在经纬度特征上有一定的差异，反映了不同的活动范围和路径走向。不同聚类的台风在经纬度质心上有明显区别，表明它们在不同的经纬度区域活动。例如，聚类 1 可能主要在某一特定范围活动，而聚类 4 则在相对较远的另一个区域活动。

接下来对聚类得到的各个类别的台风路径展开可视化分析。通过对台风路径进行可视化分析，我们可以更加明晰地观测到台风从形成至消亡的运动路径，进而有利于分析出台风路径的变化规律。




图 9 各种类别的台风路径图

如图 9 所示，通过观察台风从生成到消散的运动路径，我们可以对台风的各种类别进行详细地分析和划分。

- **第一类台风命名为西行类：**这一类别的台风通常生成于较低的纬度，并向西方向移动，路径相对直线。它们通常在菲律宾海西部形成，随后可能影响中国南部沿海地区，如海南和广东。这些台风在移动过程中强度可能逐渐增强，并在接近中国沿海时达到最大强度。主要活动范围大约在北纬 10 度到 20 度，东经 110 度到 125 度之间。
- **第二类台风命名为西北转向类：**这类台风在生成后，最初向西北方向移动，随后在接近中国东海或琉球群岛附近时发生转向，可能向东北方向偏转。它们通常在较高的纬度形成，可能影响华东沿海地区，包括浙江、上海、江苏等地。这些台风的路径形状呈明显的弯曲状，主要活动范围在北纬 20 度到 30 度，东经 120 度到 135 度之间。

- **第三类台风命名为北上类：**北上类的台风在生成后，大多时间向偏北方向移动，路径接近直线。它们可能在南海中部形成，随后向北移动，影响华南沿海地区，如广东、福建，甚至可能到达江西和湖南等内陆地区。这些台风在移动过程中，强度变化不大，主要活动范围在北纬 15 度到 25 度，东经 105 度到 125 度之间。

- **第四类台风命名为东北转向类：**这类台风在生成后，通常向西北方向移动，并在接近日本南部或韩国附近时，突然转向东北方向。它们可能在较低的纬度形成，主要影响日本、韩国等地区，有时也可能影响中国东北部沿海。路径形状同样呈现为弯曲状，主要活动范围在北纬 25 度到 35 度，东经 125 度到 145 度之间。

（五） 强度特征聚类

与上述路径特征聚类采用类似的方法，首先我们选择台风强度、台风等级、风速、气压作为强度特征聚类的四个特征，随后同样采用手肘法与轮廓系数来确定最优 k 值，即最佳聚类数。




图 10 手肘法分析结果图




图 11 轮廓系数分析结果图

如图 10 与图 11 所示，我们可选定 $k = 3$ 作为最佳聚类数，依据 $k = 3$ 的聚类数再次采用 K-means 聚类方法来对强度特征进行聚类。




图 12 强度特征聚类结果图

如图 12 所示，根据聚类的结果，我们可以将台风的强度特征类别分为如下几种类别：

- **第一类台风为弱台风：**该类台风一般表现为较弱的风力，风速大致在 0 到 40m/s 之间，伴随着较高的气压，大约在 980hpa 到 1020hpa 之间，这些台风通常对沿海地区的影响较小，属于弱台风级别。
- **第二类台风为中等台风：**该类台风一般表现为中等强度的风力，风速介于之前描述的范围之间，气压也相对较低，大约在 960hpa 到 1010hpa 之间，这些台风通常对沿海地区有一定程度的影响，属于中等强度台风级别。
- **第三类台风为强台风：**该类台风一般表现为更强的风力，风速超过之前描述的范围，气压也较低，大约在 930hpa 到 1000hpa 之间，这些台风通常对沿海地区造成很大的影响，属于较强台风级别。

5.1.3 台风类别划分

首先我们需要在网上搜寻到 2024 年我国 7 月和 9 月的台风数据，并获取上述分类评价模型所需要的各项指标，随后将对应的参数值代入到模型中，将得到的路径特征类别与强度特征类别综合考量后可得出以下结果：

表 3：2024 年我国 7 月和 9 月台风类别及途经省份

月份	台风类别	途经省份
7 月 夏台风	西行类弱台风	海南、福建、江西、湖北
	西行类中等台风	海南、福建
	西行类强台风	台湾
9 月 秋台风	西行类强台风	海南、广东
	东北转向类弱台风	浙江、上海、江苏
	北上类中等台风	上海、江苏
	北上类弱台风	江苏、安徽、河南

接下来，我们将上述不同分类的台风路径进行可视化展示，直观地展现出每个台风的整体运动路径，通过观察每个类别的台风从形成到消亡的过程，从而进一步分析夏台风与秋台风之间的差异。




图 13 2024 年 7、9 月台风路径图

从表 3 和图 13 可以看出，7 月份的夏台风主要呈现西行类路径，且涵盖了弱、中等以及强三个不同的强度级别台风，多在西太平洋上向西移动，形成了以海南、福建等省份为主要影响区域的西行类台风；而 9 月份的秋台风，除了依然存在西行类的强台风外，还出现了东北转向类的弱台风以及北上类的中等和弱台风，西行类台风主要影响海南、广东、广西等沿海省份，东北转向类台风通常在转向后可能影响东海沿海地区，包括浙江、上海、江苏等省份，北上类台风主要会影响福建、浙江等省份，并可能继续向北影响江苏、上海甚至更北的省份。这种在路径和强度上的变化，反映了夏季风和秋季风的气候特点对台风的影响。

5.2 问题二模型的建立与求解

5.2.1 数据预处理

在数据集中，不同台风的记录时间的间隔存在差异，原数据集中包含了 1 小时、3 小时和 6 小时三种时间间隔，为了简化计算过程，并减少由于时间间隔不一致引起的模型预测偏差，我们选择删除每小时和每 3 小时记录的台风数据，仅保留每 6 小时一次的记录，以此来统一时间间隔。假设台风数据的时间序列集为 $\{t_1, t_2, \dots, t_n\}$ ， t_i 表示台风数据的第 i 个时间序列，设定如下筛选公式：

$$t_{i+1} - t_i = b \quad (9)$$

通过上式对台风数据的时间序列集进行筛选，从而使得台风的数据记录保持一致的时间间隔。

5.2.2 时间序列预测模型

(一) 模型引入

本问题专注于预测台风的移动路径，这属于一个标准的时序回归问题，其核心目的在于预测未来众多时间点台风的中心坐标。此任务的关键在于将台风的历史移动路径以及相关环境要素作为输入参数，通过时序模型的处理，最终预测出未来众多时刻的台风中心位置，即台风的移动路径。对于该问题，我们选择使用循环神经网络作为本题处理时序问题的预测模型。

循环神经网络，简称为 RNN，是一种能够处理序列数据的神经网络模型，同时也是深度学习领域中的一种神经网络架构。与传统的单向传播的前馈神经网络相比，RNN 在处理每一个输入元素时都会维持一个持续的隐藏状态，这个状态会在时间序列中的每一个步骤中被更新并传递至下一步，使得模型具备了存储先前数据信息的能力。这种结构使得 RNN 能够理解输入序列中的上下文关系，进而更有效地处理序列数据的特有属性。RNN 的细胞结构图如下：




图 14 RNN 细胞结构图

由图 14 可得，RNN 运行原理的计算公式如下：

$$\begin{cases} a^{(t)} = \tanh(W_{aa} * a^{(t-1)} + W_{ax} * X^{(t)} + b_1) \\ y^{(t)} = \text{soft max}(W_{ya} * a^{(t)} + b_2) \end{cases} \quad (10)$$

其中： $a^{(t)}$ 、 $X^{(t)}$ 和 $y^{(t)}$ 分别代表隐藏状态、输入和输出； W_{aa} 是从上一个时间步到当前时间步的权重矩阵，它决定了如何将前一个时间步的隐藏状态 $a^{(t-1)}$ 映射到当前的隐藏状态 $a^{(t)}$ ； W_{ax} 是输入门权重矩阵，它决定如何将当前时间步的输入 $X^{(t)}$ 映射到当前的隐藏状态 $a^{(t)}$ ； b_1 是用于调整线性变换结果的偏置项； $\tanh(\)$ 是一个激活函数，用于将上述加权和通过非线性转换得到最终的隐藏状态 $a^{(t)}$ ； W_{ya} 是输出层权重矩阵，它决定如何将当前时间步的隐藏状态 $a^{(t)}$ 映射到输出 $y^{(t)}$ ； b_2 是输出层的偏置项； $\text{soft max}(\)$ 是一个归一化指数函数。

然而，在实际应用中，RNN 容易受到短期记忆的限制。当处理一条极其长的序列时，RNN 往往难以将早期时间步的信息有效传递到后续时间步，这可能导致从序列开始时就丢失关键信息，并遭遇梯度消失的问题。为了克服这一缺陷，我们转而采用 RNN 的一种改进形式——LSTM 模型，它能够在一定程度上缓解信息丢失和梯度消失的问题。

(二) LSTM 预测模型

LSTM（长短时记忆网络）是一种常用于处理序列数据的深度学习模型，与传统的 RNN（循环神经网络）相比，LSTM 引入了三个门，分别是输入门、遗忘门、和输出门和一个细胞状态，这些机制使得 LSTM 能够更好地处理序列中的长期依赖关系^[3]。LSTM 的细胞结构图如下：




图 15 LSTM 细胞结构图

由图 15 可得，LSTM 运行原理的计算公式如下：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (11)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (12)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (13)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (14)$$

$$h_t = o_t * \tanh(C_t) \quad (15)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (16)$$

下面对上述公式进行简要说明：

- 在式(10)中， f_t 是遗忘门的输出，用于决定上一个状态 h_{t-1} 中的哪些信息应该被丢弃； σ 是sigmoid函数，它将输入值映射到0到1之间； W_f 是权重矩阵， b_f 是偏置项。
- 式(11)用于计算输入门的输出，式(12)用于计算候选细胞状态的激活值，同样地， σ 是sigmoid函数，而tanh是双曲正切函数，两者均用于调整数值范围。
- 式(13)用于计算输出门的输出，式(14)根据当前的细胞状态 C_t 和输出门 o_t 来确定下一个隐藏状态 h_t 。
- 式(15)是细胞状态的计算公式，当前细胞状态 C_t 由上一时刻的细胞状态 C_{t-1} 通过遗忘门 f_t 进行过滤，以及新的候选细胞状态 $\tilde{C}_t$ 通过输入门 i_t 来更新得到。

从上述公式可以观察到，LSTM 的反向传播算法的数学推导相当复杂，这是由于涉及了大量变量。尽管如此，LSTM 确实能够在某种程度上解决信息丢失和梯度消失的问题，进而高效地学习长序列中的依赖性，适合处理长时间序列数据的预测问题，因此在本题中，我们最终采用 LSTM 预测模型来实现台风移动路径的预测。

(三) 预测评价指标

在本题中，我们采用了 LSTM 模型对台风路径进行预测。为了量化模型预测的准确性，我们引入了两个常用的性能评价指标：平均绝对误差(MAE)和均方根误差(RMSE)。

平均绝对误差(MAE)是衡量预测值与实际值之间差异的一种简单且直观的方法。它计算了预测值与实际值之间差的绝对值的平均数，能够提供预测误差的一个总体概览。其计算公式如下：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (17)$$

其中， n 为样本数量， y_i 是样本的实际值， $\hat{y}_i$ 是样本的预测值。 MAE 的值越低，表明模型的预测越接近实际值，模型的准确性越高。

均方根误差(RMSE)则是另一种评价预测准确性的指标，它考虑了预测值与实际值之间差异的平方，然后计算这些平方差的平均数的平方根。RMSE 对较大的误差赋予更高的权重，因此它能够突出预测中的较大偏差。其计算公式如下：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (18)$$

其中， n 为样本数量， y_i 是样本的实际值， $\hat{y}_i$ 是样本的预测值。与 MAE 相似， $RMSE$ 的值越低，模型的预测性能越好。

通过这两个指标，代入训练模型得到的经纬度预测值与实际值，我们可以客观地评估 LSTM 模型在台风路径预测任务中的表现，确保最终模型表现良好。

(四) 预测结果分析




图 16 预测结果图

上图展示了 LSTM 模型在 6 小时间隔下的预测效果。整体来看，预测路径与实际路径在经度和纬度上的变化趋势大致相同，表明 LSTM 模型能够捕捉到台风路径的基本运动特征。

表 4 预测结果的 RMSE 与 MAE 结果图

	RMSE	MAE
经度	5.765	2.627
纬度	3.461	1.807

上表给出了最终模型的 RMSE 与 MAE 结果，这两项指标用于评估 LSTM 模型在台风路径预测任务中的表现，从而在训练过程中筛选出最优模型进行预测。

6 小时的预测间隔是一个相对较短的时间范围，然而，随着时间的推移，预测误差可能会累积，导致预测路径与实际路径之间的差异增大。尽管在某些时间段存在一定偏差，但 LSTM 模型的预测结果仍然具有实际应用价值，如台风预警和灾害管理等，并且预测结果可以与实际观测数据结合使用，以提高台风路径预测的准确性和可靠性。

同时，给出 2024 年 9 月 13 日-17 日每日 14 点的第 13 号台风贝碧嘉的中心位置的预测值，如表 5 所示。

表 5：2024 年 9 月 13 日-17 日每日 14 点的第 13 号台风贝碧嘉的中心位置

时间	台风中心位置（经度/纬度）
13 日 14:00	135.7/23.1
14 日 14:00	129.8/27.2
15 日 14:00	126.2/30.5
16 日 14:00	121.7/31.7
17 日 14:00	116.6/31.9

5.2.3 对比分析

（一）DTW 算法

动态时间规整算法（DTW）是一种基于动态规划的计算两个时间序列之间相似度的算法。它通过在时间轴上非线性地“扭曲”时间序列，使两个序列在比较时能够对齐，即使它们在时间轴上的进展速度不同。

它的基本思想是在保持原始时间序列特征的前提下，通过拉伸或压缩其中一个时间序列，使其与另一个时间序列对齐，然后计算两个对齐后的时间序列之间的距离。具体来说，DTW 算法主要包括以下几个步骤：

（1）**初始对齐：**首先，我们需要找到一个初始的对齐点，作为后续计算的起点。常见的做法是将两个时间序列的第一个点作为初始对齐点。

（2）**距离计算：**接下来，我们计算两个时间序列中所有可能的配对点的距离。对于每个配对点，我们可以采用不同的距离度量方法，比如欧氏距离、曼哈顿距离等。

（3）**最短路径搜索：**由于直接计算所有配对点的距离可能会非常耗时，所以我

们需要一种更高效的方法来找到最短路径。这里可以使用动态规划的思想，逐步构建一个代价矩阵，记录每一步的计算结果，最终得到两个时间序列之间的总距离。

(4) **结果输出：**最后，我们将得到的总距离作为两个时间序列之间的相似度得分。一般来说，相似度越高，两个时间序列越接近；相似度越低，两个时间序列的差异越大。

总的来说，DTW 算法的核心在于如何有效地计算两个时间序列之间的距离，以及如何在保证准确性的同时提高计算效率。

(二) 对比分析

在本题中，我们采用 LSTM 模型预测未来众多时间点台风的中心坐标。为了检验模型的预测效果，我们使用动态时间规整算法（DTW）来对台风中心位置的真实值与预测值进行对比分析。

表 6：台风贝碧嘉部分中心位置的真实值与预测值

时间	真实位置（经度/纬度）	预测位置（经度/纬度）
13 日 14:00	135.6/23.6	135.7/23.1
14 日 14:00	130.3/27.3	129.8/27.2
15 日 14:00	126.2/30.1	126.2/30.5
16 日 14:00	120.5/31.5	121.7/31.7
17 日 14:00	116.3/33.0	116.6/31.9

上表展示了台风贝碧嘉 5 个时间点的中心位置的真实值与预测值。通过计算 DTW 距离来衡量预测路径与真实路径的拟合程度，最终得出 DTW 距离约为 10.32，意味着两个时间序列之间的差异较小，它们的形状、趋势和模式相似度较高，可以认为模型的预测效果较好，拟合程度较高。对比结果显示，LSTM 预测模型在本题有着较高的准确性，非常适用于作为长时间序列的台风路径的预测。

5.3 问题三模型的建立与求解

5.3.1 数据准备

首先，我们需要从台风数据集中筛选出需要的特征，包括风速、降水量、中心位置、中心风力等重要特征，并依据表之间共用的数据将重要特征汇总到一张表中，以便后续时间序列模型需要。

根据题目要求，我们还需计算出基站与台风中心之间的距离，由于该两点的经纬度坐标均已知，因此我们采用哈佛辛公式来计算两点距离。

哈佛辛公式是用于估算地球表面上任意两点，基于它们的经纬度坐标所对应的直线距离的方法。它能够计算出两点之间的大圆距离，而不是简单的欧几里得距离，其计算公式如下：

$$a = \sin^2(\frac{\Delta lat}{2}) + \cos(lat_1) \cdot \cos(lat_2) \cdot \sin^2(\frac{\Delta long}{2}) \tag{19}$$

$$c = 2 \cdot a \tan 2(\sqrt{a}, \sqrt{1-a}) \tag{20}$$

$$d = R \cdot c \tag{21}$$

其中， Δlat 是两点纬度的差值， $\Delta long$ 是两点经度的差值， lat_1 和 lat_2 分别是两点的纬度值， R 是地球半径，一般取值为 6371 千米， d 为最终计算出的两点之间的距离。需要注意的是，哈佛辛公式中角的计算是以弧度为单位的，因此在开始计算距离之前我们首先需要把经纬度从角度值转换为弧度值。

5.3.2 拟合关系

(一) 指数衰减模型

通过对历史台风数据的分析，我们发现台风在登陆后，其强度、风速、降水量通常会随着时间的推移而减弱，这一物理过程与指数衰减的特性相似，降水量和风速的减少也呈现出类似于指数衰减的模式。而指数衰减模型在描述随时间快速减少的量时能够表现出良好的拟合效果，适合用于描述本题台风行进途中的衰减现象。

指数衰减模型可以用以下数学表达式来描述：

$$N(t) = Ne^{-\lambda t} \quad (22)$$

其中， $N(t)$ 为时刻 t 时的值， N_0 为初始值， λ 是衰减常数， t 为时间。

(二) 拟合风速与降水量关系

在本题中，我们可以将指数衰减模型应用于描述台风登陆后风速和降水量以及距台风中心距离的变化，假设降水量 P 随风速 v 的增加而指数衰减，将指数衰减模型中的自变量与因变量替换为风速与降水量，由此可得到如下公式：

$$P(v) = P_0 e^{-\alpha v} \quad (23)$$

其中， P_0 为降水量的初始值， α 为衰减常数。

在使用该模型前，我们首先需要对衰减常数 α 进行估计，通过不断拟合数据来实现，再使用最小二乘法来确定最佳估计值。




图 17 降水量与风速拟合关系图

由上图可得，风速与降水量之间存在一定的相关性，实际数据点在风速区间内的分布显示出这种关系的复杂性，有的风速区间数据点集中，有的则分散。红色拟合曲线尝试描绘这种关系的大致趋势，但受数据波动性影响，曲线在某些区域与数据点贴合不佳。总体而言，风速对降水量的影响并非唯一决定因素，其他变量和数据的自然变异性可能导致拟合曲线并不完美。

(三) 拟合降水量与距台风中心距离关系

与上述同理，对于降水量 P 与距台风中心距离 d 的关系也采用指数衰减模型进行拟合，由此可得如下公式：

$$P(\alpha) = P_0 e^{-\beta d} \quad (24)$$

其中， P_0 为降水量的初始值， β 为衰减常数，通过拟合数据和最小二乘法确定参数 β 的最佳估计值。




图 18 降水量与距台风中心距离拟合关系图

由上图可得，我们可以看到实际观测值和模拟值在大部分区域都有较好的吻合度。然而，在某些距离范围内，特别是当距离大于 600 时，实际观测值明显高于模拟值，这表明当距离增加到一定程度时，模型的预测能力会有所下降。此外，决定系数 R^2 约为 0.54，这意味着模型解释了大约 54% 的数据变异，虽然不是非常高，但在某些情况下可能仍然被认为是可接受的。总的来说，这个拟合模型在一定程度上能够反映降水量随距离的变化趋势。

5.3.3 预测及分析

(一) LSTM 预测风力

通过对数据集的深入分析，我们观察到台风移动过程中中心风力的变化呈现出显著的时间序列特性，同问题 2 类似，我们可以采用 LSTM（长短时记忆网络）预测模型进行预测。LSTM 能够高效地学习长序列中的依赖性，非常适合处理本题长时间序列中心风力的预测问题。

在完成数据准备后，我们将处理后的数据集按照 8:2 的比例分为训练集和测试集，输入训练集不断对模型进行训练，并通过计算平均绝对误差 (MAE) 和均方根误差 (RMSE) 来衡量模型的预测性能，以确保最终训练出的模型具有较好的表现。




图 19 中心风力预测结果图

如图 19 所示，从整体上看，预测风力曲线与实际风力曲线保持了较好的一致性，实际风力与预测风力都呈现下降的趋势，特别是在主要的风力变化趋势上，两者基本吻合，这表明 LSTM 模型能够有效地捕捉到台风中心风力变化的规律。然而，在某些特定的时间段，预测风力和实际风力之间存在一定的差异，这可能意味着在这个时间段内，某些因素没有被充分考虑进预测模型，导致预测值与实际情况有所偏差，例如天气系统的突然变化、地形的影响或者是其他未知的气象条件等^[4]。

(二) 预测降水量

在通过 LSTM 模型得到台风中心风力的预测值后，我们将其代入风速-降水量的指数衰减模型中，得到降水量的预测结果如下：




图 20 降水量预测结果图

如上图所示，降水量整体上呈现出轻微下降的趋势，然而变化幅度相当有限，预测结果并不尽如人意。这种情况可能是由于之前所构建的风速-降水量的指数衰减模

型的拟合效果不佳所引起的，由于数据的波动性，模型曲线未能很好地与实际数据点相吻合。总的来说，风速对降水量的影响并不是唯一的决定性因素，可能还有其他未被考量的环境因素对降水量产生显著影响。

六、模型的评价、改进

6.1 模型的优点

综合优点：我们的模型综合了多个环境参数，如气温、气压和季风，提供了一个全面的框架来分析台风特性和路径。这种综合方法使我们能够捕捉到台风行为的复杂性，并提供了更准确的预测。

适应情况广：特别是在问题二中，我们采用的 LSTM 模型展现了强大的时间序列预测能力，能够适应台风路径的非线性特征，这对于提前预警和准备至关重要。

分类能力：问题一中的分类模型能够有效地区分不同季节的台风，这对于理解季节变化对台风特性的影响具有重要意义。

6.2 模型的缺点

数据依赖性：我们的模型在很大程度上依赖于数据的质量和完整性。任何数据集中的偏差或误差都可能影响模型的预测结果。

过拟合风险：特别是在机器学习模型中，存在过拟合的风险，即模型可能过于适应训练数据，而忽略了泛化能力。

6.3 模型的改进

数据集成：通过集成更多的历史数据和实时监测数据，可以提高模型的泛化能力和预测精度。

模型融合：考虑使用集成学习方法，结合多个模型的预测结果，以提高预测的稳定性和准确性。

七、参考文献

- [1]陈鸿生,林小刚,林晓珍.长短期记忆神经网络(LSTM)对风暴潮数值模拟的优化应用[J].海洋预报,2024,41(04):1-10.
- [2]张锋,张怡,裴愉涛,等.基于气象监测数据的台风风场降尺度预测方法及应用研究[J].能源工程,2023,43(06):51-59.
- [3]孙敖.融合深度学习方法的台风路径预测研究[D].上海海洋大学,2023.
- [4]高鹏.基于深度学习对西北太平洋台风路径的预测研究[D].中国民用航空飞行学院,2023

附录

附录 1

介绍：数据处理,Matlab

```
1. function data_processing()
2.     % 数据处理，处理 1945-2023.csv 文件
3.     cd('D:\Desktop\数模\MathorCup\1729850593344182\2024 年 MathorCup 大数据挑战赛-赛道 A 初赛\A 题代码');
4.     filename = "1945-2023.xlsx";
5.
6.     opts = detectImportOptions(filename);
7.     opts.VariableNamingRule = 'preserve';
8.     opts = setvartype(opts, 12, 'double');
9.     opts = setvartype(opts, 13, 'string'); % 设置"移动方向"列的类型为 string
10.    opts = setvartype(opts, 14, "double");
11.
12.    tb1 = readtable(filename,opts);
13.    %%
14.    % 后面
15.    filename = "未加入 2024 年数据.xlsx";
16.
17.    opts = detectImportOptions(filename);
18.    opts.VariableNamingRule = 'preserve';
19.    t1 = readtable(filename,opts);
20.
21.    %%
22.    % 提出几列
23.    % t1 = tb1(:,[1 4 6 7 8 9 10 11 14]);
24.    t1 = tb1(:,[1 4 6 7 8 9 10 11 12 13 14]);
25.    t1 = sortrows(t1, {'台风编号', '当前台风时间'});
26.
27.
28.    %%
29.    % 将 1945-2023 数据中台风的时间转化为可用的形式
30.    % 再根据起始时间转化为季风的类型
31.    dateStrArray = string(t1(:, "台风起始时间").Variables);
32.    t1("台风起始时间") = datetime(dateStrArray, 'InputFormat', 'yyyy-MM-dd''T''HH:mm:ss', 'Format', 'default');
33.
34.    dateStrArray = string(t1(:, "当前台风时间").Variables);
35.    t1("当前台风时间") = datetime(dateStrArray, 'InputFormat', 'yyyy-MM-dd''T''HH:mm:ss', 'Format', 'default');
36.
```

```

37. % t1.([2 3]) = datestr(dt,'yyyy-mm-dd HH:MM:SS')
38. %%
39. % 再根据起始时间转化为季风的类型
40. %1 为春, 2 为夏, 3 为秋, 4 为冬
41. m = month(t1.("台风起始时间"));
42. temp = ones(size(m));
43. for i = 1:height(m)
44.     switch m(i)
45.         case {3 4 5}
46.             temp(i) = 1;
47.         case {6,7,8}
48.             temp(i) = 2;
49.         case {9,10,11}
50.             temp(i) = 3;
51.         case {12,1,2}
52.             temp(i) = 4;
53.     end
54. end
55. t1.("季节") = temp;
56.
57. %%
58. % sum(ismissing(t1))
59. t1.("台风强度") = fillmissing(t1.("台风强度"),"previous");
60.
61. %%
62. % 在这之前应该做缺失值处理
63. % 把台风强度转化为 0 1 2 3 4 5 6
64. StrArray = string(t1.("台风强度"));
65. temp = ones(size(StrArray));
66. for i = 1:height(temp)
67.     switch StrArray(i)
68.         case ""
69.             temp(i) = 0;
70.         case "热带低压(TD)"
71.             temp(i) = 1;
72.         case "热带风暴(TS)"
73.             temp(i) = 2;
74.         case "强热带风暴(STS)"
75.             temp(i) = 3;
76.         case "台风(TY)"
77.             temp(i) = 4;
78.         case "强台风(STY)"

```

```

79.         temp(i) = 5;
80.     case "超强台风(Super TY)"
81.         temp(i) = 6;
82.     end
83. end
84. t1.(6) = temp;
85.
86.
87. %%
88. % t1 个属性的数据类型
89. summary(t1);
90. %%
91. length(t1.(1));
92. %%
93. sum(isnan(t1.("移动速度")));
94. %%
95. sum(ismissing(t1.("移动方向")));
96. %%
97. t1.(10) = string(t1.(10));
98. %%
99. %
100. % cd('D:\Desktop\数模\MathorCup\1729850593344182\2024 年 MathorCup 大数据挑战赛-赛道 A 初赛\海洋温度数据
    (air.2m.gauss)\海洋温度数据(air.2m.gauss.1948)');
101. % temp = ncread("air.2m.gauss.1948.nc", 'air');
102. % size(temp)
103. % temp(:, :, 1)
104. % %%
105. % temp = squeeze(temp);
106. % size(temp);
107. % temp(:, :, 1)
108. % temp = ncread("air.2m.gauss.1952.nc", 'air' );
109. % temp(90,44,363)
110. %%
111. data(66,39,272,21);
112. data(90,44,363)
113. %%
114. % B = t1.("海洋温度")==0;
115. % count = sum(B)
116.
117.
118. %%
119. % 处理海洋温度数据

```

```

120.     lon = 192;
121.     lat = 94;
122.
123.     day = 366;
124.     year = 77;
125.     data = zeros(lon,lat,day,year);
126.     %%
127.     % 处理 air.2m.gauss.1948 中的 .nc 数据
128.     cd('D:\Desktop\数模\MathorCup\1729850593344182\2024 年 MathorCup 大数据挑战赛-赛道 A 初赛\海洋温度数据
        (air.2m.gauss)\海洋温度数据(air.2m.gauss.1948)');
129.     for i = 1948:2023
130.         filename = "air.2m.gauss."+i+".nc";
131.         temp = ncread(filename,'air' );
132.         % temp = squeeze(temp);
133.         if mod(i,4)~=0
134.             zeroRow = zeros(192,94,1);
135.             % 将全零行添加到原始数组的末尾
136.             temp = cat(3, temp, zeroRow);
137.         end
138.         data(:,:,i-1947) = temp;
139.     end
140.     %%
141.     % 对于经纬度，每个数据的经纬度分部是一样的，所以选一个就行
142.     lat_d = ncread("air.2m.gauss.1948.nc",'lat' );
143.     lon_d = ncread("air.2m.gauss.1948.nc",'lon' );
144.     %%
145.     temp = lat_d(:,:,1)
146.     % lat_d;
147.     % lon_d;
148.     %%
149.     clc;
150.     data(:,:,end-1,end-1)
151.     %%
152.     % 从 low_id 开始有海洋温度
153.     low_id = 1;
154.     temp1 = t1("当前台风时间").Year;
155.     while true
156.         if temp1(low_id)>=1948
157.             break;
158.         end
159.         low_id = low_id+1;
160.     end

```

```

161. % low_id = 1515;
162. %%
163. % 将经纬度和对应的海洋温度数据填入 t1 中
164. temperature = zeros(height(t1),1);
165. for i = low_id:height(t1)
166.     year = t1("当前台风时间")(i).Year;
167.     day = t1("当前台风时间")(i).Day;
168.     lon = t1("经度")(i);
169.     lat = t1("纬度")(i);
170.     % 经度和维度在 lat_d 和 lon_d 中的位置
171.     lon_i = floor(lon./1.875);
172.     lat_i = floor((90-lat)./(180/94));
173.     temperature(i) = data(lon_i,lat_i,day,year-1947);
174. end
175. t1("海洋温度") = temperature;
176.
177. %%
178. % 可能需要，对海洋温度进行处理，比如转化为摄氏温度
179. t1("海洋温度") = t1("海洋温度")-273.15;
180.
181. %%
182. % 接下来处理季风的数据
183. % 可能就是之前季节的处理
184.
185.
186.
187.
188.
189. %%
190. % 接下来到数据的归一（标准）化处理和缺失值处理还有异常值处理
191.
192. %%
193. %先缺失值处理
194. %%
195. sum(ismissing(t1))
196. %%
197. size(t1,1)
198. sum(isnan(t1("气压"))))
199. % 缺失 2083，总 69130，占 3.01%，我想丢掉
200. % 这个会处理比较久
201. t1 = rmmissing(t1,'DataVariables','气压');
202. %%

```

```

203.
204. % 缺失数据矩阵，台风等级和风速都有部分缺失，可以差值处理
205. % t1 = fillmissing(t1(:,['台风等级','风速']),'DataVariables','气压',)
206. % t1 = fillmissing(t1,"linear",'DataVariables','台风等级');
207. % t1 = fillmissing(t1,"linear",'DataVariables','风速');
208. % 但是不太好，因为这样台风等级和风速就有非整数了，建议删除，反正只有 7 个
209. t1 = rmmissing(t1,'DataVariables','台风等级');
210. t1 = rmmissing(t1,'DataVariables','气压');
211.
212.
213. %%
214. %先判断气压和风速是否符合正态分布
215. % 可以画 QQ 图，可以画直方图，
216. % 这里用 KS 检验（但是需要先标准化）
217.
218. % my_kstest(t1("风速"))
219. my_kstest(t1("气压"))
220. % my_kstest(t1("海洋温度"))
221. % 最终这两个都不符合正态分布
222.
223. %%
224. % 异常值查找个数
225. TF = isoutlier(t1(:,[6,7,8,9,13]),"quartiles");
226. disp(sum(TF))
227. % 0 3184 1599 2224 1635
228. % 强度 等级 风速 气压 温度
229. %%
230. % 台风等级的异常值全是 0
231. disp(sum(t1(8)==0))
232.
233. %%
234. % 异常值处理(如果符合标准正态分布的话)
235. % TF1 = isoutlier(t1("气压"),"mean");
236. % 690 异常值
237. % TF2 = isoutlier(t1("风速"),"mean");
238. % 412 异常值
239. TF1 = isoutlier(t1("气压"),"quartiles");
240. % 2224 异常值
241. TF2 = isoutlier(t1("风速"),"quartiles");
242. % 1599 异常值
243. TF3 = isoutlier(t1("海洋温度"),"quartiles");
244. disp("气压有"+sum(TF1)+"个异常值")

```

```

245.     disp("风速有"+sum(TF2)+"个异常值")
246.     disp("海洋温度有"+sum(TF3)+"个异常值")
247.
248.     %%
249.     yichangzhi = nonzeros(TF1.*t1("气压"));
250.     disp("气压异常最小"+min(yichangzhi))
251.     yichangzhi = nonzeros(TF2.*t1("风速"));
252.     disp("风速异常最大"+min(yichangzhi))
253.     yichangzhi = nonzeros(TF3.*t1("海洋温度"));
254.     disp("海洋温度异常最小"+min(yichangzhi))
255.
256.     %%
257.     % 异常值处理
258.     % 台风等级异常值不处理
259.     % 台风风速和气压异常值都用最近上一个非离群值填充
260.     t1 = filloutliers(t1,"previous",'quartiles','DataVariables','风速');
261.     t1 = filloutliers(t1,"previous",'quartiles','DataVariables','气压');
262.     t1 = filloutliers(t1,"previous",'quartiles','DataVariables','海洋温度');
263.
264.     %%
265.     % 标准化处理
266.     t1("海洋温度") = normalize(t1('海洋温度'),1,'zscore');
267.     t1("气压") = normalize(t1('气压'),1,'zscore');
268.     t1("台风强度") = normalize(t1('台风强度'),1,'zscore');
269.     t1("台风等级") = normalize(t1('台风等级'),1,'zscore');
270.     t1("风速") = normalize(t1('风速'),1,'zscore');
271.
272.     %%
273.     % 附加处理，移动方向和移动速度
274.
275.
276.     % 先算移动速度
277.     distance = zeros(height(t1),1);
278.     speed = zeros(height(t1),1);
279.     lon = t1("经度");
280.     lat = t1("纬度");
281.     time = t1("当前台风时间");
282.     dtime = diff(time);
283.     dtime(end+1) = "00:00:00";
284.     dtime = seconds(dtime)./3600;
285.     %%
286.     group = groupsummary(t1, '台风编号');

```

```

287.
288.     group_id = group.GroupCount;
289.     group_id = cumsum(group_id);
290.     %%
291.     group_id = [0;group_id];
292.     group_id(end) = [];
293.     group_id = group_id+1;
294.     %%
295.     group_count = group.GroupCount;
296.
297.     %%
298.     for i = 1:height(t1)-1
299.         distance(i) = haversine(lat(i),lon(i),lat(i+1),lon(i+1));
300.     end
301.     %%
302. index = 0;
303.     for i = 1:size(group_id)
304.         % i 是第几组
305.         for cnt = 1:group_count(i)
306.             % j 是第 i 组的第 j 个数据
307.             % index = group_id(i)+cnt-1;
308.             index = index+1;
309.             if cnt==1
310.                 speed(index) = distance(index)./dtime(index);
311.             elseif cnt == group_count(i)
312.                 speed(index) = distance(index-1)./dtime(index-1);
313.             else
314.                 speed(index) = (distance(index-1)+distance(index))./(dtime(index-1)+dtime(index));
315.             end
316.             if speed(index)<0
317.                 disp(distance(index-1));
318.                 disp(distance(index))
319.                 dtime(index-1)
320.                 dtime(index)
321.
322.                 a=1;
323.             end
324.         end
325.     end
326. % 化为 km/h
327. speed = floor(speed./1000);
328. %%

```

```

329. writematrix(speed,"myspeed.xlsx")

330. %%

331. % 将 speed 填入 t1 的移动速度中缺失部分

332. leak_speed = isnan(t1("移动速度"));

333. leak_speed = leak_speed.*speed;

334. t1 = fillmissing(t1,'constant',0,'DataVariables','移动速度');

335. t1("移动速度") = t1("移动速度")+leak_speed;

336. %%

337.     % 再算移动方向

338.

339.     degree = zeros(height(t1),1);

340.     lon = t1("经度");

341.     lat = t1("纬度");

342.     speed = t1("移动速度");

343.     %%

344.     group = groupsummary(t1, '台风编号');

345.     group_id = group.GroupCount;

346.     group_id = cumsum(group_id);

347.     group_id = [0;group_id];

348.     group_id(end) = [];

349.     group_id = group_id+1;

350.     %%

351.     group_count = group.GroupCount;

352.     %%

353.     for i = 1:height(t1)-1

354.         degree(i) = cal_degree(lat(i),lon(i),lat(i+1),lon(i+1));

355.     end

356.     %%

357.     index = 0;

358.     for i = 1:size(group_id,1)

359.         % i 是第几组

360.         for cnt = 1:group_count(i)

361.             % j 是第 i 组的第 j 个数据

362.             % index = group_id(i)+cnt-1;

363.             index = index+1;

364.             if cnt==1

365.                 degree(index);

366.             elseif cnt == group_count(i)

367.                 degree(index) = cal_degree(lat(index-1),lon(index-1),lat(index),lon(index));

368.             else

369.                 % speeds = speed(index-1)+speed(index);

```

```

370.             % degree(index) = (degree(index-1)*speed(index-
           1)/speeds) + (degree(index)*speed(index)/speeds);
371.             degree(index) = deg_merge(degree(index-1),degree(index),speed(index-1),speed(index));
372.         end
373.     end
374. end
375. %%
376. % 在这之前要对 t1 的表中风向中的英文转为中文
377. % 对表中的中文方位改成度数
378.
379.     filename = "temp";
380.
381.     opts = detectImportOptions(filename);
382.     opts.VariableNamingRule = 'preserve';
383.     opts = setvartype(opts, 10, 'string'); % 设置"移动方向"列的类型为 string
384.
385.     temp = readtable(filename,opts);
386.     %%
387.
388.     directions = temp11("移动方向");
389.
390.     %%
391.     unmiss_directions = ~ismissing(directions);
392.     % directions(directions=="0") = [];
393.     % temp11(directions=="0",:) = [];
394.     %%
395.     cd('D:\Desktop\数模\MathorCup\1729850593344182\2024 年 MathorCup 大数据挑战赛-赛道 A 初赛\A 题代码');
396.
397.     for i = 1:size(directions,1)
398.         if(unmiss_directions(i))
399.             directions(i) = countDirections(directions(i));
400.         end
401.     end
402.
403.     % a = directions(unmiss_directions);
404.
405.     %%
406.     for i = 1:size(directions,1)
407.         if(unmiss_directions(i))
408.             directions(i) = direction_turn_degree(directions(i));
409.         end
410.     end

```

```

411.
412.    %%
413.    % 将给的方向和算的方向放一起
414.    directions = str2double(directions);
415.    directions = fillmissing(directions,'constant',0);
416.    leak_directions = ismissing(directions);
417.    leak_directions = leak_directions.*degree;
418.    directions = directions + leak_directions;
419.    %%
420.    t1("移动方向") = str2double(t1("移动方向"));
421.    t1("移动方向") = directions;
422.    %%
423.    writematrix([directions,degree],"给的方向和算的方向.xlsx")
424.    % writematrix(degree,"算的方向.xlsx")
425. %%
426. % 现在还要对移动方向和速度进行异常值处理
427.    % 无缺失值
428.    directions = t1("移动方向");
429.    speed = t1("移动速度");
430.    %%
431.    my_kstest(directions)
432.    my_kstest(speed)
433.    %都不服从正太分布
434.    %%
435.    TF1 = isoutlier(directions,"quartiles");
436.    TF2 = isoutlier(speed,"quartiles");
437.    %
438.    sum(TF1)
439.    sum(TF2)
440.    %%
441.    yichangzhi = nonzeros(TF2.*speed);
442.    disp("速度异常最小"+min(yichangzhi))
443.    disp("速度异常最大"+max(yichangzhi))
444.    t1 = filloutliers(t1,"previous",'quartiles','DataVariables','移动速度');
445.
446. %%
447. sum(ismissing(speed))
448.
449.
450. %%
451. temp = t1("台风编号");
452.

```

```

453.    %%
454.    % 季节的数据暂时还没处理
455.    writetable(t1,"temp.xlsx")
456.    %%
457.    writematrix(degree,"degree.xlsx")
458. end

```

附录 2

介绍：画图,Matlab

```

1.  function draw(t1)
2.      %%
3.      cd('D:\Desktop\数模\MathorCup\1729850593344182\2024 年 MathorCup 大数据挑战赛-赛道 A 初赛\A 题代码');
4.      filename = "temp.xlsx";
5.
6.      opts = detectImportOptions(filename);
7.      opts.VariableNamingRule = 'preserve';
8.      opts = setvartype(opts, 10, 'string'); % 设置"移动方向"列的类型为 string
9.
10.     t1 = readtable(filename,opts);
11.     %%
12.     %先画出台风轨迹图
13.     % 总共有 1815 个台风
14.     loc = t1(:,["台风编号","经度","纬度"]);
15.     x_t = zeros(250,1);
16.     y_t = zeros(250,1);
17.     last_id = loc("台风编号")(1);
18.     % 总共有 1815 个台风
19.     colors = rand(2000,3);
20.     % 每个台风的颜色
21.     j = 1;
22.     % 每个台风经过的点个数
23.     cnt = 0;
24.     figure;
25.     hold on
26.     for i = 1:size(t1,1)
27.         % 如果编号不同,便开始画图
28.         cnt = cnt +1;
29.         if(last_id~=loc("台风编号")(i))
30.             plot(x_t(1:cnt-1) ,y_t(1:cnt-1) , 'Color',colors(j,:));
31.             last_id = loc("台风编号")(i);
32.             cnt = 1;

```

```

33.         j = j+1;
34.     end
35.     x_t(cnt) = loc("经度")(i);
36.     y_t(cnt) = loc("纬度")(i);
37. end
38. title("台风路径可视化图")
39. xlabel("经度");
40. ylabel("纬度");
41. hold off
42.
43. %%
44. % 强度分布图
45. % summaryStats = groupsummary(t1, '台风强度');
46.
47. gscatter(t1("经度"), t1("纬度"), t1("台风强度"));
48. title("台风路径可视化图")
49. xlabel("经度");
50. ylabel("纬度");
51.
52. %%
53. % 按强度分类的台风路径图
54. % 但是好像没用到
55.
56. % 假设 T 是你的数据表, 'X' 和 'Y' 是数值列, 'Category' 是分类列
57. qiangdu = unique(t1("台风强度")); % 找出所有唯一的类别
58.
59. % 预设颜色或标记, 以区分不同的类别
60. colors = lines(numel(qiangdu)); % 自动生成颜色
61.
62. % 绘制散点图
63. figure; % 创建一个新的图形窗口
64. hold on; % 保持图形, 以便在同一图上绘制所有类别
65. for i = 1:numel(qiangdu)
66.     % 找出当前类别的所有数据点
67.     idx = t1("台风强度") == qiangdu(i);
68.     subplot(3, 2, i); % 创建子图位置
69.     % 绘制当前类别的数据点
70.     scatter(t1("经度")(idx), t1("纬度
    ")(idx), 2, colors(i,:), 'filled', 'DisplayName', num2str(qiangdu(i)));
71.
72.     legend show; % 显示图例
73.     xlabel('经度'); % X 轴标签

```

```

74.         ylabel('纬度'); % Y 轴标签
75.         title('台风强度等级' );
76.     end
77.
78.     hold off;
79.
80.
81.
82.     %%
83.     % 再画中国大陆
84.     % 暂时还没有实现!!!!!!
85.
86. % 加载中国省界地图数据（使用 gadm41_CHN_1.shp 文件）
87. china_provinces = shaperead('gadm41_CHN_1.shp'); % 替换为实际文件路径
88.
89. % 创建图形
90. figure;
91. hold on;
92. % 绘制省界
93. for k = 1:length(china_provinces)
94.     % 绘制省的多边形边界
95.     geoshow(china_provinces(k), 'DisplayType', 'polygon', 'FaceColor', [0.9 0.9 0.9], 'EdgeColor', 'k');
96.
97.     % 计算省的中心位置用于标注
98.     province_center_lon = mean(china_provinces(k).X(~isnan(china_provinces(k).X)));
99.     province_center_lat = mean(china_provinces(k).Y(~isnan(china_provinces(k).Y)));
100.
101.     %% 添加省份名称
102.     text(province_center_lon, province_center_lat, china_provinces(k).NAME_1, ...
103.         'HorizontalAlignment', 'center', 'FontSize', 8, 'Color', 'b');
104. end
105. title('中国省界图及省份名称');
106. xlabel('经度');
107. ylabel('纬度');
108. % 不用 hold off 才能画其他图
109.
110.
111.
112. group = groupsummary(t1, '台风编号');
113. group_count = group.GroupCount;
114. group_id = group.GroupCount;
115. group_id = cumsum(group_id);

```

```

116. group_end = group_id;
117. group_id = [0;group_id];
118.
119. group_id(end) = [];
120.
121. group_id = group_id+1;
122. red = [1, 0, 0]; % 红色 (RGB) 1
123. green = [0, 1, 0]; % 绿色 (RGB) 2
124. blue = [0, 0, 1]; % 蓝色 (RGB) 3
125.
126. % 创建一个包含三种颜色的矩阵
127. colors = [red; green; blue];
128. ind = 0;
129. for i = 1:size(group_id,1)
130.     for j = 2:group_count(i)
131.         ind = group_id(i)+j-1;
132.         % len = group_id(i):group_end(i);
133.         % plot(t1(len,"经度").Variables,t1(len,"纬度").Variables,'Color' ,colors(t1(len,"分类
            2").Variables,:));
134.
135.         colorIdx = t1("分类 2")(ind); % 取分类 2 的值作为索引
136.         plot([t1("经度")(ind-1), t1("经度")(ind)], ...
137.             [t1("纬度")(ind-1), t1("纬度")(ind)], ...
138.             'Color', colors(colorIdx, :), 'LineWidth', 1);
139.
140.     end
141. end
142.
143. %%
144. % 异常值处理，用箱线图看
145.
146. % 风速 气压 海洋温度
147. title_xiangxian = "风速";
148. data = t1.(title_xiangxian);
149. stats= boxplot(data, 'Orientation', 'horizontal');
150. title(title_xiangxian+'的箱线图');
151. xlabel(title_xiangxian);
152. % disp(stats);
153.
154.
155. %%
156. % 这里的频布直方图是为了判断是否符合正态分布

```

```

157. % 画气压的直方图
158. my_histogram(t1.("气压"), "气压")
159. %%
160. % 画风速的直方图
161. my_histogram(t1.("风速"), "风速")
162.
163.
164. %%
165. % 这里的 QQ 图也是为了判断是否符合正态分布
166. % QQ 图
167. my_qq(t1.("气压"), "气压");
168. % my_qq(t1.("风速"), "风速")
169.
170. %%
171. % ks 检验
172. my_kstest(t1.("海洋温度"))
173.
174. %%
175. % 这里的热力图是为了直观判断相关系数矩阵的相关关系
176. % 热力图
177. % 要现在 data_processing.m 中处理出 R
178. h = heatmap(R);
179. % titles1 = {'附件一速度', '根据经纬度算出的速度'};
180. % titles2 = {'根据经纬度算出的速度', '附件一速度'};
181. name = {'台风强度', '台风等级', '风速', '气压', '气温', '季风'};
182. % h.Colormap = jet;
183. h.Title = '相关性热力图';
184. h.Colormap = hot; % 使用 'hot' 颜色映射
185.
186. h.XDisplayLabels = name;
187. h.YDisplayLabels = name';
188. % h.ColorbarVisible = "on";
189. % h.XDisplayLabels = titles1;
190. % h.YDisplayLabels = titles2;
191.
192.
193.
194. %%
195. temp = t1(:, {'风速', '海洋温度'})
196. temp = sortrows(temp, [2, 1])
197. %%
198. scatter(temp.("海洋温度"), temp.("风速"), 5);

```

```

199.
200.
201. %%
202. % 绘制散点图
203. scatter3(t1.("气压"),t1.("台风强度"),t1.("海洋温度"),5);
204. xlabel('气压');
205. ylabel('季节');
206. zlabel('海洋温度');
207.
208. %%
209. % 对台风编号聚类，取第一个
210.
211. firstData = groupsummary(t1, '台风编号')
212. temp = firstData.GroupCount;
213. temp = cumsum(temp)
214. %%
215. temp = [1;temp];
216. temp(end) = [];
217.
218. %%
219. temp = [t1(temp,"纬度"),t1(temp,"经度")]
220. temp = table2array(temp)
221. scatter(temp(:,2),temp(:,1))
222. %%
223. scatter(t1.("经度"),t1.("纬度"),1)
224.
225.
226. %%
227.
228.
229.     filename = "2024 年的数据.xlsx";
230.
231.     opts = detectImportOptions(filename);
232.     opts.VariableNamingRule = 'preserve';
233.     t1 = readtable(filename,opts);
234.
235. %%
236.
237. %2024 年台风路径图
238. group = groupsummary(t1, '台风编号');
239. group_count = group.GroupCount;
240. group_id = group.GroupCount;

```

```

241. group_id = cumsum(group_id);
242. group_end = group_id;
243. group_id = [0;group_id];
244.
245. group_id(end) = [];
246.
247. group_id = group_id+1;
248. red = [1, 0, 0]; % 红色 (RGB) 1
249. green = [0, 1, 0]; % 绿色 (RGB) 2
250. blue = [0, 0, 1]; % 蓝色 (RGB) 3
251.
252. % 创建一个包含三种颜色的矩阵
253. colors = [red; green; blue];
254. ind = 0;
255. for i = 1:size(group_id,1)
256.     for j = 2:group_count(i)
257.         ind = group_id(i)+j-1;
258.         % len = group_id(i):group_end(i);
259.         % plot(t1(len,"经度").Variables,t1(len,"纬度").Variables,'Color',colors(t1(len,"分类
260.         2").Variables,:)) );
261.         colorIdx = t1("分类 2")(ind); % 取分类 2 的值作为索引
262.         plot([t1("经度")(ind-1), t1("经度")(ind)], ...
263.             [t1("纬度")(ind-1), t1("纬度")(ind)], ...
264.             'Color', colors(colorIdx, :), 'LineWidth', 1);
265.
266.     end
267. end
268.
269. end

```

附录 3

介绍台风分类（K-means 模型）

```

1. function q1()
2.     %%
3.     % 读取数据
4.     cd('D:\Desktop\数模\MathorCup\1729850593344182\2024 年 MathorCup 大数据挑战赛-赛道 A 初赛\A 题代码');
5.     filename = "数据暂时处理完.xlsx";
6.     opts = detectImportOptions(filename);
7.     opts.VariableNamingRule = 'preserve';
8.     t1 = readtable(filename,opts);
9.     %%

```

```

10. % 相关性分析
11. temp = t1(:,{'台风强度','台风等级','风速','气压','海洋温度','季节'});
12. % temp = t1(:,{'台风强度','台风等级','风速','气压','海洋温度','移动速度'});
13. % temp.("海洋温度") = exp(temp.("海洋温度"));
14. temp =table2array(temp);
15. %%
16. % 因为变量之间的关系是非线性的，但是要画散点图进行判断
17.
18.
19.
20. %%
21. % R = corr(t1);
22. % R = corr(temp,'Type','Pearson');
23.
24. % 1.0000    0.9039    0.9507   -0.9218    0.0403
25. % 0.9039    1.0000    0.9785   -0.8612    0.0704
26. % 0.9507    0.9785    1.0000   -0.9202    0.0741
27. % -0.9218   -0.8612   -0.9202    1.0000    0.0140
28. % 0.0403    0.0704    0.0741    0.0140    1.0000
29.
30. R = corr(temp,'Type','Spearman');
31.
32. % 1.0000    0.9690    0.9660   -0.9238   -0.0539
33. % 0.9690    1.0000    0.9969   -0.9315   -0.0359
34. % 0.9660    0.9969    1.0000   -0.9326   -0.0352
35. % -0.9238   -0.9315   -0.9326    1.0000    0.1565
36. % -0.0539   -0.0359   -0.0352    0.1565    1.0000
37. %
38. % 列 1 至 5
39. %
40. % 1.0000    0.9690    0.9661   -0.9244   -0.0534    0.0088
41. % 0.9690    1.0000    0.9970   -0.9323   -0.0355   -0.0093
42. % 0.9661    0.9970    1.0000   -0.9333   -0.0343   -0.0071
43. % -0.9244   -0.9323   -0.9333    1.0000    0.1550   -0.0078
44. % -0.0534   -0.0355   -0.0343    0.1550    1.0000   -0.1606
45. % 0.0088   -0.0093   -0.0071   -0.0078   -0.1606    1.0000
46. %
47.
48.
49. disp(R)
50. %%
51. % K=4,进行 k-means 聚类

```

```

52. % rng('default'); % 使用默认种子
53.
54. % k = 4;
55. k=3;
56. % 读取数据
57. % data = t1(:,{'经度质心','纬度质心','经度方差','纬度方差','协方差'});
58. data = t1(:,{'台风强度','台风等级','风速','气压'});
59.
60. data = table2array(data);
61. normalized_data = normalize(data, 'range', [0 1]);
62.
63. % [idx, C] = kmeans(data, k);
64. [idx, C] = kmeans(normalized_data, k);
65.
66. % labels = {'Class 1', 'Class 2', 'Class 3','Class 4'};
67.
68. % t1("分类1") = idx;
69. t1("分类2") = idx;
70. % save('centroids2.mat', 'C');
71.
72. %%
73. % 分类后的台风路径图
74. route = t1(:,{'台风编号','经度','纬度','分类1'});
75. colors = {[1, 0, 0], [0, 1, 0], [0, 0, 1], [1, 1, 0]};
76. c1 = route(route("分类1")==1,:);
77. c2 = route(route("分类1")==2,:);
78. c3 = route(route("分类1")==3,:);
79. c4 = route(route("分类1")==4,:);
80. %%
81. c= c3;
82. loc = c(:,["台风编号","经度","纬度"]);
83.
84.
85. x_t = zeros(250,1);
86. y_t = zeros(250,1);
87. last_id = loc("台风编号")(1);
88. % 总共有 1815 个台风
89. colors = rand(2000,3);
90. % 每个台风的颜色
91. j = 1;
92. % 每个台风经过的点个数
93. cnt = 0;

```

```

94.     figure;
95.     hold on
96.
97.     for i = 1:size(c,1)
98.
99.
100.        % 如果编号不同,便开始画图
101.        cnt = cnt +1;
102.        if(last_id~=loc("台风编号")(i))
103.            plot(x_t(1:cnt-1) ,y_t(1:cnt-1) , 'Color',colors(j,:));
104.            last_id = loc("台风编号")(i);
105.            cnt = 1;
106.            j = j+1;
107.        end
108.        x_t(cnt) = loc("经度")(i);
109.        y_t(cnt) = loc("纬度")(i);
110.    end
111.    title("台风路径可视化图"+c.("分类 1")(1))
112.    xlabel("经度");
113.    ylabel("纬度");
114.    hold off
115.
116. %%
117. % 气压、最大风速散点图
118. % gscatter(t1.("经度质心"), t1.("纬度质心"), t1.("分类 1"),[],[],15);
119. gscatter(t1.("风速"),t1.("气压"), t1.("分类 2"));
120. title("台风强度特征聚类图")
121. xlabel("风速");
122. ylabel("气压");
123.
124. %%
125. % 对 2024 年的数据进行分类
126. % 读取数据
127. % data = t1(:,{'经度质心','纬度质心','经度方差','纬度方差','协方差'});
128.
129. data = t1(:,{'台风强度','台风等级','风速','气压'});
130. data = table2array(data);
131. distances = pdist2(data,C);
132. [~, clusters] = min(distances, [], 2);
133. t1.("分类 2") = clusters;
134.
135. %%

```

```
136.     writetable(t1,"2024 年的数据.xlsx")
137.
138.
139. end
```

附录 4

介绍： LSTM 训练代码,Python

```
1.  import numpy as np
2.  import pandas as pd
3.  from keras.src.layers import Dropout
4.  from keras.src.optimizers import Adam
5.  from tensorflow.keras.models import Sequential
6.  from tensorflow.keras.layers import LSTM, Dense
7.  from tensorflow.keras.models import load_model
8.  from sklearn.preprocessing import MinMaxScaler
9.  from sklearn.metrics import mean_squared_error, mean_absolute_error
10. import matplotlib.pyplot as plt
11.
12. # 加载数据
13. # 这里假设 t1 是一个 pandas DataFrame，包含所有台风数据
14. # 示例数据加载
15.
16. plt.rcParams['font.sans-serif'] = ['SimHei']
17. plt.rcParams['font.size'] = 15
18.
19.
20. t1 = pd.read_csv('用于 LSTM.csv') # 示例加载数据
21. print(t1.columns)
22.
23. # 提取特征和目标
24. features = t1[['经度', '纬度', '台风等级', '风速', '气压', '海洋温度']]
25. # features = t1[['台风等级', '风速', '气压', '海洋温度']]
26. # targets = t1[['经度', '纬度']] # 目标为经度和纬度
27. targets = t1[['风速']]
28.
29. # 按台风编号分组并处理序列数据
30. # 不然会导致在每个台风的最后一个点时预测不准确
31. group = t1.groupby('台风编号').size().values
32. group_id = np.cumsum(group)
33. group_end = group_id - 1
34. group_start = np.insert(group_id[:-1], 0, 0)
```

```

35.
36. features = np.delete(features, group_end, axis=0)
37. targets = np.delete(targets, group_start, axis=0)
38.
39. # 数据归一化
40. # scaler = MinMaxScaler(feature_range=(0, 1))
41. # features = scaler.fit_transform(features)
42. # targets = scaler.fit_transform(targets)
43.
44. # 设置时间步和构建时间序列数据
45. time_steps = 4
46. X, Y = [], []
47. for i in range(time_steps, len(features)):
48. X.append(features[i-time_steps:i, :])
49. Y.append(targets[i, :])
50.
51. X, Y = np.array(X), np.array(Y)
52.
53. # 划分训练集和测试集
54. train_ratio = 0.8
55. num_train = int(train_ratio * X.shape[0])
56. X_train, X_test = X[:num_train], X[num_train:]
57. Y_train, Y_test = Y[:num_train], Y[num_train:]
58.
59. # 下面是对模型进行进一步训练时的代码
60. # model = load_model('trained_lstm_model1.keras')
61. #
62. # new_learning_rate = 0.01 # 设置新的学习率
63. # optimizer = Adam(learning_rate=new_learning_rate)
64. #
65. # model.fit(X_train, Y_train, epochs=50, batch_size=16)
66. #
67. #
68. # model.compile(optimizer=optimizer, loss='mean_squared_error')
69.
70.
71. # 构建 LSTM 网络
72. model = Sequential()
73. model.add(LSTM(64, input_shape=(X_train.shape[1], X_train.shape[2]), return_sequences=True))
74. model.add(LSTM(64, return_sequences=False))
75. model.add(Dense(Y_train.shape[1]))
76. model.compile(optimizer='adam', loss='mse')

```

```

77. # #
78. # # # 训练网络
79. history = model.fit(X_train, Y_train, epochs=150, batch_size=16, validation_split=0.1, verbose=1)
80.
81. # 预测
82. Y_pred = model.predict(X_test)
83.
84. # 反归一化
85. # Y_test = scaler.inverse_transform(Y_test)
86. # Y_pred = scaler.inverse_transform(Y_pred)
87.
88. # 可视化结果
89. plt.figure(figsize=(12, 6))
90. plt.subplot(2, 1, 1)
91. plt.plot(Y_test[:, 0], 'b', label='真实经度')
92. plt.plot(Y_pred[:, 0], 'r--', label='预测经度')
93. plt.title('经度预测')
94. plt.xlabel('时间步')
95. plt.ylabel('经度')
96. plt.legend()
97.
98. plt.subplot(2, 1, 2)
99. plt.plot(Y_test[:, 1], 'b', label='真实纬度')
100. plt.plot(Y_pred[:, 1], 'r--', label='预测纬度')
101. plt.title('纬度预测')
102. plt.xlabel('时间步')
103. plt.ylabel('纬度')
104. plt.legend()
105. plt.tight_layout()
106. plt.savefig('预测模型 1.png', dpi=300, bbox_inches='tight') # 保存为 PNG 格式
107. plt.show()
108.
109.
110. # 计算 RMSE
111. rmse_longitude = np.sqrt(mean_squared_error(Y_test[:, 0], Y_pred[:, 0]))
112. # rmse_latitude = np.sqrt(mean_squared_error(Y_test[:, 1], Y_pred[:, 1]))
113. print(f"经度的 RMSE: {rmse_longitude}")
114. mae_longitude = mean_absolute_error(Y_test[:, 0], Y_pred[:, 0])
115. # 计算纬度的 MAE
116. # mae_latitude = mean_absolute_error(Y_test[:, 1], Y_pred[:, 1])
117.
118. print(f"经度的 MAE: {mae_longitude}")

```

```
119. # 保存模型
120. model.save("trained_lstm_model2.keras")
```

附录 5

介绍：指数衰减模型,Python

```
1. import numpy as np
2. import pandas as pd
3. from scipy.optimize import curve_fit
4. import matplotlib.pyplot as plt
5.
6. plt.rcParams['font.sans-serif'] = ['SimHei']
7. plt.rcParams['font.size'] = 15
8.
9. # file_path = r"D:\Desktop\数模\MathorCup\1729850593344182\2024 年 MathorCup 大数据挑战赛-赛道 A 初赛\降水量统
   计数据\降水与距离（降维 1 筛检 3）.xlsx"
10. # df = pd.read_excel(file_path)
11. # df = pd.read_csv(file_path, encoding='gbk')
12.
13. # file_path = r"D:\Desktop\数模\MathorCup\1729850593344182\2024 年 MathorCup 大数据挑战赛-赛道 A 初赛\降水量统
   计数据\风速与降水 2.xlsx"
14. # df = pd.read_excel(file_path)
15.
16. file_path = r"D:\Desktop\数模\MathorCup\1729850593344182\2024 年 MathorCup 大数据挑战赛-赛道 A 初赛\降水量统计数
   据\降水与距离（降维 1 筛检 2）.xlsx"
17. df = pd.read_excel(file_path)
18.
19. # 假设 x_data 和 y_data 是你的两组数据，分别代表自变量和因变量
20. x_data = df['距离'].values
21. # x_data = df['平均风速'].values
22. # y_data = df['日降水量'].values
23.
24. # x_data = df['风速'].values
25. y_data = df['每日降水'].values
26.
27. # 指数衰减模型函数
28. def exp_decay(x, a, b, c):
29.     return a * np.exp(-b * x) + c
30.
31. # 使用 curve_fit 进行非线性最小二乘拟合
32. params, covariance = curve_fit(exp_decay, x_data, y_data, p0=[1, 0.1, 0])
33.
```

```

34. # 提取拟合参数
35. a, b, c = params
36.
37. # 使用拟合参数生成模型预测
38. y_fit = exp_decay(x_data, y_data, b, c)
39.
40. # 绘制原始数据和拟合曲线
41. plt.scatter(x_data, y_data, label='实际', color='blue')
42. plt.scatter(x_data, y_fit, label='拟合', color='red')
43. plt.title('距离降水量拟合')
44. plt.xlabel('距离')
45. # plt.xlabel('风速')
46. plt.ylabel('降水')
47. plt.legend()
48. plt.show()
49.
50. # 打印拟合参数
51. print(f"Fitted parameters: a = {a}, b = {b}, c = {c}")
52.
53. # 计算 R^2 值
54. residuals = y_data - y_fit
55. ss_res = np.sum(residuals**2)
56. ss_tot = np.sum((y_data - np.mean(y_data))**2)
57. r_squared = 1 - (ss_res / ss_tot)
58. print(f"R^2 value: {r_squared}")
59. # 样本数量
60. n = len(y_data)
61. # 计算均方误差 (MSE)
62. mse = ss_res / n
63. print(f"均方误差 (MSE): {mse:.4f}")
64.
65. # 下面是预测
66. # 预测新数据
67. # 假设新的风速数据 x_new
68. x_new = pd.read_excel(r'D:\Desktop\数模\MathorCup\1729850593344182\2024 年 MathorCup 大数据挑战赛-赛道 A 初赛\A
    题代码\预测风速.xlsx')
69. y_new_pred = exp_decay(x_new, a, b, c)
70. print(f"Predictions for new data: {y_new_pred}")
71.

```

--