

队伍编号	MCB2401113
赛道	A

基于多重气象特征的台风分类与路径预测：贝碧嘉案例分析

摘要

作为极端气象事件，台风对沿海地区的安全和经济活动构成了重大威胁。随着全球气候变化日趋明显，台风的频率与强度也可能发生变化，因而对其路径、强度及环境影响的精确预测变得尤为重要。台风的形成与发展受气温、气压、洋流和风场等多重气象因素的影响，这些因素的复杂相互作用使台风的研究具有高度挑战性。近年来，大数据和机器学习技术的进步为台风路径预测及其影响因素分析带来了显著提升，但数据维度不一致、特征提取不足及模型鲁棒性较弱等问题依然存在，制约了实际应用效果。因此，系统性地研究台风的分类、路径预测及登陆后衰减特征，有助于深入理解台风的行为模式，为灾害预警和应对策略的制定提供有力的数据支持和理论基础。

首先，本次赛题围绕台风分类、路径预测和登陆后风速与降水量衰减的需求展开。研究团队首先针对台风分类评价，利用多个权威数据集及中国气象局获取的气象数据，提取台风的时序观测数据，并转化为一致性的 17 个特征向量，以确保后续建模时特征维度统一。团队通过 CHk-means 来进行聚类，得出了初步的台风分类结果，共分类 10 类，并对每个类别进行了命名。同时，团队再使用神经网络进行台风分类，利用各种特征将台风归类。最后再利用评价模型和降维分析与神经网络的结合对影响因素小的特征删除完成降维处理，得到最终的分类见表 4.2。通过对比夏季和秋季台风的特征差异，发现夏季台风通常受到低气压和西南季风的影响，路径较为复杂，且更容易深入内陆。而在秋季，气压较高，气压梯度增大，台风受东北季风的控制，路径多沿海偏东北方向转向，表现出相对稳定的特点，影响范围也较小。此外，研究还表明，随着全球气候的变暖，秋季台风的路径逐渐表现出与夏季台风相似的趋势。这一发现为更全面地理解台风的行为模式及其在气候变化下的演变提供了重要依据。

其次，在台风路径预测方面，研究团队重点分析了气温、气压、洋流和风场等多种因素对路径的影响，旨在预测 2024 年 9 月 13 日至 17 日第 13 号台风贝碧嘉的中心位置。为提高预测精度，团队选择了发生时期、强度及中心位置相近的历史台风数据作为训练样本。鉴于台风生命周期长短不一且数据记录频率不一致，团队采用了步长为 2 天的滑动窗口方法，将每条台风数据划分为多个训练样本，以便更全面地刻画台风在不同发展阶段的特征变化。最终提取了 147 个时序特征，包括经度、纬度、风速、气压和气温等关键气象变量，并基于长短期记忆网络（LSTM）算法进行逐步预测，具体预测结果如表 5.2。为评估模型的准确性，团队采用动态时间规整（DTW）算法来计算预测路径与实际路径之间的差异。DTW 距离为 3.29，表明两条路径在地理位置上的累积差异较小，这一评估方法能够有效揭示路径预测的误差，为理解台风路径的动态变化特征提供了有力依据。

最后，针对台风登陆后风速和降水量的衰减预测，研究团队分析台风中心风速和降水量与登陆距离的关系，在问题二的特征基础上，采用步长为 4 天的滑动窗口法，以每日 14 时的台风数据进行特征扩充，共计 103 个时序特征。并结合 LSTM 与多重注意力机制，逐步预测风速和降水量的动态变化。研究还分析影响预测结果的关键气象指标，为有效应对台风灾害提供数据支持。

关键词：Haversine；CHk-means；神经网络；LSTM；DTW；多重注意力机制

目 录

一、问题重述	1
1.1 问题背景	1
1.2 目标任务	1
二、模型假设及符号	2
2.1 模型假设	2
2.2 主要的符号说明	2
三、问题分析	3
3.1 针对问题一	3
3.2 针对问题二	4
3.3 针对问题三	5
四、问题一模型的建立和求解	6
4.1 台风数据融合	6
4.1.1 台风数据筛选	6
4.1.2 多表数据融合	6
4.2 数据预处理	7
4.3 搭建特征空间	8
4.3.1 气温角度	8
4.3.2 气压角度	8
4.3.3 季风角度	8
4.3.4 其他路径和角度特征	9
4.4 基于改进的 K-MEANS 的台风聚类算法	9
4.4.1 k-means 算法的改进	10
4.4.2 台风的聚类	10
4.4.3 CHk-means 算法的复杂度分析	11
4.4.4 聚类结果评价	11
4.5 基于神经网络的台风数据分类评价	13
4.5.1 神经网络分类模型	13
4.5.2 模型的训练、验证及预测	13
4.5.3 夏、秋台风区别分析	14
五、问题二模型的建立与求解	16
5.1 台风数据融合	16
5.1.1 台风数据筛选	16
5.1.2 多表数据融合	17
5.2 数据预处理	17
5.3 搭建特征空间	18
5.3.1 滑动窗口的建立	18
5.3.2 指标的选取	18
5.4 基于 LSTM 的路径预测模型	20
5.4.1 LSTM 模型	20
5.4.2 模型的构建与训练	21

5.4.3 预测结果及 DTW 分析	22
六、问题三模型的建立与求解	24
6.1 台风数据融合	24
6.2 搭建特征空间	24
6.2.1 滑动窗口的建立	24
6.2.2 指标的获取	25
6.3 基于 LSTM+多重注意力机制的预测模型	26
6.3.1 LSTM 模型+多重注意力机制	26
6.3.2 模型的动态实施	26
6.4 问题三小结	26
七、模型的评价与推广	27
7.1 问题一模型评价和推广	27
7.1.1 问题一模型评价	27
7.1.2 问题一模型推广	27
7.2 问题二模型评价和推广	27
7.2.1 问题二模型评价	27
7.2.2 问题二模型推广	27
7.3 问题三模型评价和推广	28
7.3.1 问题三模型评价	28
7.3.2 问题三模型推广	28
八、参考文献	29
九、附录	30

一、问题重述

1.1 问题背景

台风作为一种极具破坏性的自然现象，由强烈的热带气旋在太平洋地区生成，对环境和人类生活产生了深远的影响。台风形成后，伴随着大量水汽在海面上移动，并随着强度的增强而引发风暴潮、强降雨和洪水等灾害。其突发性强、破坏力大特点使台风成为全球最严重的自然灾害之一^[1]。

台风对沿海地区不仅带来了自然的考验，更是对人类防灾减灾能力的严峻挑战。面对台风的侵袭，许多国家和地区采取了多种应对措施。虽然无法完全阻止台风的来袭，但有效的预防和应急响应机制能够显著减少其带来的损失。同时，台风也让我们深刻认识到自然的强大力量。人类在享受自然馈赠的同时，应谨慎对待可能带来的威胁，从而增强风险意识和应对能力。

近年来，随着台风预测和监测技术的进步，我们对台风的理解和应对能力不断提升。现代气象技术的进步，使我们能够更加准确地确定台风的位置、强度、移动路径和速度。通过提前发布台风预警，实时更新台风的动向，有效降低了台风可能造成的生命财产损失^[2]。

同时，基于数据分析和机器学习方法的台风分类与预测模型的建立，为减轻台风的危害提供了新的解决方案。这些模型通过分类和预测不同类型的台风行为，不仅提升了台风预测的精准性，还为制定防灾策略提供了科学依据^[3]。

1.2 目标任务

通过建立预测模型，使得新台风形成后，可以尽快预测出其强度、移动路径、降雨量等情况，具体任务如下：

问题一：分析台风特征参数（强度、等级、风速等）与气温、气压、季风的关系，依据气温、气压、季风等因素的影响，建立台风的分类评价模型，明确类别划分的标准或评价算法，进行不同特征的台风类别划分。夏台风生成于 6-8 月，秋台风 9-11 月，根据所建立的分类评价模型，以 2024 年我国 7 月和 9 月为例，给出台风类别及途径省份的列表，并分析夏台风与秋台风的区别。

问题二：除温度、气压、季风外，台风的路径还受地球自转偏向力等多重因素影响。根据气温、气压、洋流、风场等多种因素，建立台风路径预测的模型。并且以 2024 年 9 月 13 日-17 日每日 14 点的第 13 号台风贝碧嘉为例，预测行进路线，运用 Dynamic Time Warping (DTW) 动态时间规整算法与台风实际行进路线进行对比。

问题三：请建立台风在登陆后的行进过程中降水量及风速的关系及降水量与距台风中心距离的关系。并且以 2024 年 9 月 16 日-18 日的第 13 号台风贝碧嘉为例，根据所建立的模型，预测贝碧嘉行进途中的中心风力及降水量，进行分析。

二、模型假设及符号

2.1 模型假设

为了便于考虑问题，团队在不影响模型准确率的前提下，做出以下假设：

1. 假设台风只影响季风区
2. 假设台风与观测点的距离和时间在某阈值之内
3. 假设海上 2 米的温度来作为台风在登陆前的气温
4. 假设观测的两个观测点之间的路径以两点间的直线近似代替
5. 假设陆地观测点与台风中心点最近的气温作为台风登陆后的气温
6. 假设台风速度空缺值为 0

2.2 主要的符号说明

符号	意义
d	两点间的直线距离
r	地球半径
$\varphi_1 \varphi_2$	两点的纬度
$\lambda_1 \lambda_2$	两点的经度
θ	最大转向角
RH	相对湿度
e	水汽分压
e^x	当前温度下水汽饱和分压
$\arccos$	反余弦函数
A	路径的方向向量
S^2	路径转向角波动的方差
ΔT	气温变化量
ΔP	气压变化量
Δt	时间变化量
Σ	求和符号
$\text{Max}(R_i)$	最大值
T_{start}	台风开始时间
AvgAngle	平均角度
Bearing qli	第一段的台风偏角
LAT_{1-14}	第一天 14 点的纬度
LONG_{1-14}	第一天 14 点的经度
WND_{1-14}	第一天 14 点的风速
PRES_{1-14}	第一天 14 点的气压
TEM_{1-14}	第一天 14 点的气温
LAT_{24}	前 24 小时纬度
LONG_{24}	前 24 小时经度
WND_{24}	前 24 小时风速
PRES_{24}	前 24 小时气压
TEM_{24}	前 24 小时气温
Distance24	前 24 小时台风中心与登陆城市中心距离

三、问题分析

3.1 针对问题一

本研究聚焦于台风的分类评价，深入探讨台风类别与气温、气压、季风等关键气象因素的关联性。基于赛题组提供的多源数据集，为全面揭示各数据集的内在关系，本文对台风数据、观测点数据及气象数据进行整合与特征提取，构建了系统化的分析框架。**季风因子由于难以直接量化，通过降水量、湿度等维度来表征。**同时，**团队将台风的时序观测数据转化为一致的特征向量**，以增强模型的精度并提升分类评价的效率。

在构建台风分类评价模型的过程中，研究团队从季节、路径等多个角度出发，建立了全面的气象指标体系。为解决台风与观测点空间单位不一致的问题，使用 Haversine 公式计算台风每个时刻与最近观测点的距离，以确保数据的一致性。**在聚类分析阶段，为克服传统 K-means 对噪点的敏感性，本文采用改进的 CHk-means 算法。**CHk-means 引入了局部异常因子 (LOF) 以有效处理离群点，结合精确选取初始簇中心及时方法确定合理簇数 k ，从而显著提升了聚类结果的稳定性与准确性。基于聚类模型的分类结果，研究团队进一步开展了多维分析，以提炼和解读不同台风类别的特征模式。

为进一步提升分类的精细度，**本文考虑神经网络在处理非线性特征方面表现优异，对台风进行更为深入的分类解析。**同时，为优化计算效率，结合主成分分析 (PCA) 对特征空间进行降维，筛选出影响较小的变量，最终构建了高效、精确的台风分类模型。通过构建的特征向量及训练模型，对 2024 年 7 月和 9 月的台风实现精准分类。并分析夏台风和秋台风的特征区别，为后续分析和台风预警提供科学支持，流程图如图 3.1 所示。




图 3.1 问题一技术流程图

3.2 针对问题二

在台风路径预测中，路径的动态变化受多种气象因素的共同影响，包括气温、气压、洋流、风场以及地球自转偏向力（如科里奥利力）。这些因素复杂交织，使得台风路径预测成为一个高度非线性和时变的挑战。传统模型在应对台风路径的复杂特性和不一致的数据记录频率时往往受到限制，因此，探索更加灵活、鲁棒的路径预测方法显得尤为重要。

为了应对这一挑战，本研究将多种时间序列建模方法引入台风路径预测中，包括**滑动窗口方法**、**长短期记忆网络（LSTM）**和**动态时间规整（DTW）**算法等。滑动窗口法将台风的路径数据分割成两天，以六小时为为时间间隔，整合训练样本。团队选择经纬度、气温气压等指标，结合作差，取对数，平方等手段深度挖掘细化台风路径在不同发展阶段的特征，有效解决台风生命周期和记录频率不一致的问题。同时，LSTM 模型凭借其其对长时依赖关系的处理能力，能够在时间维度上捕捉路径中的动态变化，使其适用于捕捉台风路径的非线性趋势。借此预测贝碧嘉 9 月 13 日至 9 月 17 日台风中心的前进路径。

此外，为了评估模型的预测效果，研究团队引入了 DTW 算法，以便在时间和空间维度上对比预测路径与实际路径的差异。DTW 能够有效揭示路径预测中的误差分布，并识别影响路径变化的关键因素，提供对模型精度的深入分析。为进一步提升模型的鲁棒性，本研究还考虑多模型融合和轨迹聚类等方法，利用不同模型的长处来增强路径预测的准确性与稳定性。

综上所述，本研究在多因素、多模型的框架下，系统构建了台风路径预测模型，旨在捕捉复杂气象因素的动态交互关系，从而实现对台风路径的精确预测，为防灾减灾工作提供科学支持，流程图见图 3.2。




图 3.2 问题二技术流程图

3.3 针对问题三

为了更准确地预测台风登陆后风速和降水量的逐步衰减过程，研究团队聚焦于分析台风中心风速和降水量随登陆点距离增大而逐渐减弱的规律。以 2024 年 9 月 16 日至 18 日期间的第 13 号台风贝碧嘉为研究案例，团队构建了专门的风速和降水量衰减模型，并通过实际观测数据对模型进行验证。为更好地捕捉台风强度变化，团队从历史台风数据中挑选了在时间、生命周期和登陆地点上相似的台风作为训练样本，确保模型能够适应不同阶段的台风演变特征。

在预测过程中，团队延续了问题二中的滑动窗口特征提取方法，逐步预测未来几天的降水量和风速。考虑到降水量数据以日为单位记录，此次预测主要将台风登陆后四天每天 14 时的观测数据作为模型的输入特征，用于揭示风速和降水随距离增加而减弱的趋势。在此基础上，团队还在原有特征集的基础上，增添了一些关键变量，例如台风中心到登陆点的距离、中心风速、气温，以及台风中心半径 100 公里、200 公里、300 公里范围内的降水量。这些因素有效捕捉了台风衰减过程中风速和降水量的空间和强度特征。

为了避免 LSTM 在长时间序列处理中的信息丢失，团队引入了多重注意力机制，使得模型能够更高效地学习台风衰减的时序特征，同时聚焦于对风速和降水量变化产生显著影响的关键变量。逐步预测过程中，模型动态生成后续时间段的风速和降水量数据，从而模拟了台风路径上的衰减模式。通过进一步分析这些时间序列变化的趋势，团队得以识别影响预测效果的主要气象因素（例如气温、气压、洋流和风场的变化），从而深入了解风速和降水随距离增加而变化的规律。这种方法不仅优化了模型的预测能力，还为风速和降水量变化机制提供了更为全面的视角,流程图如图 3.3 所示。




图 3.3 问题三技术流程图

四、问题一模型的建立和求解

4.1 台风数据融合

4.1.1 台风数据筛选

问题一的核心在于探讨台风特征参数（如强度、等级、风速）与气温、气压以及季风等环境因素的关联性，并基于这些影响因素构建台风的分类评价模型。赛题提供了从 1945 年开始的台风数据，台风特征受到海温、气压、洋流等长期气候因素的影响，可能在数十年间出现阶段性的变化。从图 4.1 可知 1945-2023 年 7 月海洋表面 2 米的温度变化趋势。




图 4.1 历史水温趋势图

通过图 4.1，团队发现年代久远的气象数据与最近年份的气象数据存在波动，若使用全局数据，将会影响台风分类评价模型的效果。因此，团队使用 2013 年-2022 年的台风数据，用于分析近年来台风特征的变化规律和分类模式。

4.1.2 多表数据融合

由于在赛题所给总表里缺少一些环境因素数据，但在对台风进行分类评价时所需要的评价因素必不可缺，例如：气温、降水量、湿度等，所以需要从赛题提供的其他可参考数据中找出含有这些评价因素的数据集，并且将这些数据与总表相连。

气温方面，团队选取海洋温度数据集中的海洋表面 2m 的数据来刻画台风中心气温，随着台风的行进，由海洋登陆，团队发现登陆后继续使用海表 2m 温度刻画已不再完全合适，故使用 Python 从中国气象局中爬取中国逐日气象数据，其中的气温数据列作为登陆后台风中心气温的刻画。而对于气温的选取，团队发现表中存在台风经纬度和各观测站经纬度，故通过 **Haversine 公式** 使用两地经纬度来计算每个台风各个时间点时位置距离最近的观测点位，公式如下：

$$d = 2r \cdot \arcsin \left(\sqrt{\sin^2\left(\frac{\Delta\phi}{2}\right) + \cos(\phi_1) \cdot \cos(\phi_2) \cdot \sin^2\left(\frac{\Delta\lambda}{2}\right)} \right)$$

通过 Haversine 公式比较两个观测点距台风中心的距离，团队决定选取距离较近的作为气温数据。

降水量方面，由于最大降水量可以更好地用于区分不同台风的强度和影响范围。夏台风和秋台风的降水特征可能存在显著差异，而最大降水量能够更好地捕捉这些差异。因此团队决定选取降水量数据集中最大小时降雨量表中的数据，如图 4.2 所示。

- 分类数据下载：
- 观测站信息: [China_Sta.csv](#)
 - 日降水量数据: [1949-2018_DailyPrecipitation.csv](#)
 - 总降水量数据: [1949-2018_TotalPrecipitation.csv](#)
 - 最大小时降雨量数据: [1951-2018_MaxHourlyPrecipitation.csv](#)
 - 大风数据: [1949-2018_Wind.csv](#)
 - 阵风数据: [1949-2018_Gust.csv](#)
 - 八级风起止时间数据: [1949-2018_W8Date.csv](#)

图 4.2 降雨量数据集选取图

湿度方面，在实际观测中，露点温度通常比直接观测湿度更为稳定和准确。湿度测量容易受到

温度、压力等因素的波动影响，而露点温度则相对不受这些短期波动的干扰。特别是在台风等极端天气条件下，露点温度比湿度数据更容易获得稳定、可靠的数值，从而有助于提高模型分析的准确性。因此团队决定使用露点温度代替湿度。

4.2 数据预处理

(1) 在多源台风数据的融合处理中，海洋表面温度和观测站气温分别来源于不同数据集，二者单位不同，必须进行统一处理以确保数据的可比性和一致性。为了有效地进行特征提取和台风特征分析，需要将所有气温数据转换为相同的单位制。

在多表数据融合时气温的选取分别为海洋表面 2m 温度的数据、观测站气温的数据。同时，团队发现，海洋表面温度 2m 的数据单位为开尔文，所以需要将其转换为摄氏度，保证单位一致化；观测站气温中的数据单位为华氏度，同理也要处理成摄氏度。

(2) 由于 99.99 本身在实际气象观测中的降水量意义非常不现实，在气象和环境数据的标准化管理存储中，99.99 或类似的数值（如 999.9）常被使用来标记“无降水”或“数据缺失”的情境。在大多数情况下并不存在如此高的降水量。

因此本团队将降水量 99.99 视为异常值，并在做处理时使用线性插入处理异常值，如图 4.3 所示。

	LATITUDE_C	LONGITUDE_C	DISTANCE_C	TEMP	PRCP	humidity	LA1LONGITUD	DISTANCE_B
25	16.1902	140.625	16.6988	23.11	0.08	10.52	22.1121.55	2095.9
25	16.1902	140.625	113.775	23.11	0.08	10.52	22.1121.55	1992.46
92	16.1902	138.75	107.818	23.11	0.08	10.52	22.1121.55	1917.33
08	18.095	138.75	81.5298	23.11	0.096	10.47	22.1121.55	1822.51
55	18.095	136.875	93.2328	23.11	0.112	10.47	22.1121.55	1751.64
55	18.095	136.875	56.2541	23.11	0.128	10.47	22.1121.55	1691.38
55	18.095	136.875	78.7906	23.11	0.144	10.47	22.1121.55	1628.51
2	19.9997	136.875	82.9616	22.44	0.16	10.12	22.1121.55	1594.26
2	19.9997	136.875	78.0673	22.44	0.16	10.12	22.1121.55	1543.45
12	19.9997	135	99.7077	22.44	0.16	10.12	22.1121.55	1499.84
93	21.9044	135	123.94	22.44	0.16	10.12	22.1121.55	1467.73
02	21.9044	135	39.6524	21.89	0.03	9.49	22.1121.55	1409.46
02	21.9044	135	75.8681	22.33	0	8.21	25.1122.066667	1306.17

图 4.3 线性插入处理异常值

(3) 相对湿度（RH）可以通过露点温度和气温的物理关系计算。相对湿度定义为空气中水汽分压 e 和在当前温度下水汽饱和分压 e^s 的比值，通常表示为百分比：

$$e = 6.11 * 10^{(\frac{7.5 * T_{dew}}{237.3 + T_{dew}})}$$

根据气温 T，可以计算出该温度下的饱和水汽分压 e^s ：

$$e_s = 3.11 * 10^{(\frac{7.5 * T}{237.3 + T})}$$

此时可以计算 RH：

$$RH = \frac{e}{e_s} * 100\%$$

湿度值并没有数据集直接给出，故团队通过露点温度（dewp 列）和观测站的气温（temp 列）计算出得到。

(4) 台风降水量的测量数据通常是根据特定时刻所选取的观测站的降水量进行估计，但如果观测站距离台风的中心位置过远，这些数据可能无法准确反映台风所导致的降水量。

故本团队设置了一个距离阈值：400 公里，剔除那些与台风实际中心点距离超过阈值的观测站降雨量数据，任何超过该距离的观测站降雨量将被视为噪声数据，并从数据集中移除。

(5) 在数据检验过程中，发现部分观测时间比台风实际产生的时间要早，或者比台风实际结束时间要晚。这些数据可能是由于记录错误或数据汇集过程中出现偏差而导致的。如果观测数据当

前时间在台风形成之前或结束之后，该数据实际上则视为无效。数据见图 4.4 所示。

id	Chinesename	Englishname	starttime	endtime	nowtime	longitude	latitude	strength	level	windvel
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 05:00:00	123.3	9.4	热带低压(TD)	7	
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 08:00:00	122.3	9.5	热带低压(TD)	7	
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 11:00:00	121.4	9.5	热带低压(TD)	7	
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 14:00:00	120.7	9.4	热带低压(TD)	7	
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 17:00:00	119.9	9.3	热带低压(TD)	7	
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 20:00:00	119	9.3	热带低压(TD)	7	
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 23:00:00	118.3	9.5	热带低压(TD)	7	
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-03 02:00:00	117.2	9.8	热带低压(TD)	7	

图 4.4 台风正式生成前及结束后数据图

因此，本文通过严格对比观测时间和台风的实际生成和结束时间，筛选出那些在台风生成之前和台风结束之后的观测数据，视为无关值并予以删除。

(6) 在台风数据总表中，台风速度存在空缺值，如图 4.5。

nowtime	longitude	latitude	strength	level	windvelocity	pressure	direction	mov
1949-01-13 08:00:00	139.9	5.7		0	0	1006		
1949-01-13 14:00:00	139.3	5.9		0	0	1006		
1949-01-13 20:00:00	138.7	6.3		0	0	1006		
1949-01-14 02:00:00	138	6.7		0	0	1006		
1949-01-14 08:00:00	137.3	7.2		0	0	1005		
1949-01-14 14:00:00	136.7	7.7		0	0	1005		
1949-01-14 20:00:00	136	8.2		0	0	1005		
1949-01-15 02:00:00	135.3	8.8		0	0	1005		
1949-01-20 20:00:00	126.6	11.3		0	0	1006		
1949-01-21 02:00:00	125.7	11.2		0	0	1006		
1949-01-21 08:00:00	124.9	11.3		0	0	1008		

图 4.5 台风速度空缺值

经分析，这些空缺值通常出现在台风刚形成或即将结束的阶段。由于台风在生成初期和消散末期的运动速度变化较为剧烈，且观测站的设备可能难以在此阶段准确捕捉台风的运动情况，因此出现速度数据的缺失。为解决这一问题，本团队选择将这些空缺值设置为 0。

4.3 搭建特征空间

4.3.1 气温角度

- **气温最大变化率：**反映台风路径中陆地或海洋近地面气温的最大变化情况，衡量台风路径中温度变化的显著程度。
- **最大湿度：**湿度的最大值，可以从侧面反映出水汽含量以及温度对湿度的影响。
- **最大降雨量：**降雨量通常受到温度影响，温度升高往往导致水汽凝结量增加，从而影响降雨量。
- **最大风速：**气温变化可能影响台风的强度，因此风速也可以从气温角度考量。

4.3.2 气压角度

- **气压最大变化率：**台风生命周期内气压的最大变化速率，用于衡量台风在气压方面的强度变化。
- **最大风速：**气压与风速有紧密的联系，通常在气压降低时，台风风速会显著增加。
- **路径转角波动：**由于气压变化可能导致路径转角波动，气压对路径的方向性会有影响。
- **生命周期时长：**气压的波动性和变化速率也影响台风的生命周期。

4.3.3 季风角度

- **最大湿度：**季风带来大量水汽，因此湿度的变化往往和季风强弱相关。
- **最大降雨量：**季风带来的水汽会直接影响降雨量，因此可以从季风角度考量最大降雨量。
- **路径长度与直线距离的比率：**季风会导致路径出现偏移或绕行，从而影响路径的曲折程度。
- **月份：**季风影响因月份而异，特别在 6-11 月的季风旺季，台风的路径和强度可能会因季风影响而有显著差异。

4.3.4 其他路径和角度特征

这些特征主要反映台风的路径形态和方向性，并不直接与气温、气压或季风相关，但在特征分类和模型构建时可以作为路径类的独立特征，辅助分析台风的行进特性。

- **最大转向角**：用于衡量台风路径的突然转折情况。
- **路径转角波动**：即转向角的方差，反映路径的曲折程度。
- **路径长度与直线距离的比率**：衡量台风路径相对于起点到终点的曲折度。
- **一阶纬度平方和**：反映台风在纬度上的变化幅度。
- **一阶经度平方和**：反映台风在经度上的变化幅度。
- **平均角度**：台风路径的平均转角，衡量路径的整体弯曲程度。
- **第一至第四分段的方位角**：台风路径分段后的偏角，描述台风路径的方向性变化。

为有效预测台风路径及强度并制定应对措施，准确分析台风特征参数（强度、风速、气压、气温等）并建立分类模型具有重要意义。故需要通过特征方程的构建。

本题所选取的特征与相关信息如表 4.1 所示。

表 4.1 问题一特征表

特征	定义	公式
最大转向角	台风每段路径相对起始角度的最大偏转角度，衡量台风路径的突然转折情况。	$\theta = \arccos(\frac{\overrightarrow{AA'} \cdot \overrightarrow{BB'}}{ \overrightarrow{AA'} \cdot \overrightarrow{BB'} })$
路径转角波动	台风路径方向变化的波动性，即转向角的方差，反映台风路径的曲折程度。	$S^2 = \frac{\sum_{i=1}^n (\theta_i - \theta)^2}{n}$
气温最大变化率	（陆地的近地面气温，海洋的近海面气温）最大变化率	$\text{Max}(\frac{\Delta T}{\Delta t})$
气压最大变化率	台风生命周期内气压的最大变化速率，反映台风强度变化。	$\text{Max}(\frac{\Delta P}{\Delta t})$
路径长度与直线距离的比率	台风实际路径长度与起点到终点的直线距离之比，反映台风路径的曲折程度。	$\frac{S}{\overline{S}}$
最大降雨量	台风过程中每个时间段的降雨量的最大值，雨水会影响台风结构进而影响台风轨迹。	$\text{Max}(R_i)$
最大湿度	台风生命周期内的最大湿度，衡量水汽含量对台风强度的影响。	$\text{Max}(RH_i)$
最大风速	台风过程中观测到的最大风速，反映台风强度	$\text{Max}(v_i)$
生命周期时长	台风从生成到消失的总持续时间，衡量台风的生命周期长度。	$T_{\text{末}} - T_{\text{初}}$
一阶纬度平方和	台风在每个观测时间点的纬度变化量的平方和，反映纬度的变化幅度对台风路径的影响。	$\sum_{i=1}^n (\Delta LAT_i)^2$
一阶经度平方和	台风在每个观测时间点的经度变化量的平方和，反映经度的变化幅度对台风路径的影响。	$\sum_{i=1}^n (\Delta LON_i)^2$
月份	台风产生的月份	$month_i$
平均角度	台风在每个观测时间点与每个相邻时间点的夹角的平均值，反映台风路径的弯曲程度	$AvgAngle_i$
第一分段的方位角	台风路径均分为 4 段，第一段的台风偏角	$Bearing_q1_i$
第二分段的方位角	台风路径均分为 4 段，第二段的台风偏角	$Bearing_q2_i$
第三分段的方位角	台风路径均分为 4 段，第三段的台风偏角	$Bearing_q3_i$
第四分段的方位角	台风路径均分为 4 段，第四段的台风偏角	$Bearing_q4_i$

4.4 基于改进的 k-means 的台风聚类算法

4.4.1 k-means 算法的改进

为了解决 k-means 的这些问题，本文采用了改进版的^[4]CHk-means 算法。CHk-means 引入了三项主要改进：

仔细播种方法 (Careful Seeding)：通过更加科学的方式选择初始簇中心，避免了随机选择带来的不稳定性。

局部异常因子 (LOF) 算法处理离群点：在聚类前期，通过 LOF 算法检测数据集中的离群点并将其剔除，以避免这些异常点对聚类结果的影响。

肘方法确定 k 值：使用肘方法合理地选择 k 值，确保所选的簇数能够反映数据的内部结构。具体的 CHk-means 算法流程如下：

(1) **肘方法确定 k 值：**首先通过肘方法计算最合适的 k 值。肘方法通过分析不同 k 值下误差平方和 (SSE) 的变化，找到拐点处的 k 值，作为最终的簇数。

(2) **LOF 检测离群点：**在聚类之前，使用局部异常因子 (LOF) 算法对数据集中的每个点进行异常因子计算，标记出离群点并在聚类过程中剔除这些离群点，防止它们干扰聚类结果。

(3) **仔细播种方法选择初始簇中心：**首先随机选择一个点作为第一个簇中心，之后每次选择距离已选中心最远的点作为下一个簇中心，直到选择出 k 个簇中心。这种方法有效避免了初始簇中心选择不当带来的不稳定性。

(4) **重新计算簇中心：**使用已选簇中心，计算每个簇中点的均值作为新的簇中心，分配数据点到最近的簇中心，重复此步骤，直到聚类结果收敛。

(5) **最终输出聚类结果：**当聚类结果不再发生变化时，输出最终的聚类结果。

CHk-means 算法相较于传统的 k-means 算法，CHk-means 的改进主要体现有**更好的初始中心选择**。通过仔细播种方法选取初始簇中心，减少了随机性带来的不稳定聚类结果。**离群点处理**，通过 LOF 算法提前剔除离群点，使聚类过程更加准确，避免离群点对聚类中心的干扰。**合理的 k 值选择**，肘方法能够为数据集选择最合适的簇数，避免了人为设置 k 值的盲目性。

4.4.2 台风的聚类

首先通过肘方法确定夏季台风合适的 k 值，如图 4.6。




图 4.6 肘方法得夏季台风 k 值

从图 4.7 中可以看出，曲线在 k=10 附近出现了明显的“肘部”——即从 k=10 开始，曲线的下降趋势减缓，之后随着 k 的增加，inertia 的减少变得相对缓慢。这个现象表明，当 k=10 时，每个簇的紧密性和总误差平方和都达到了一个较为理想的平衡状态，继续增加 k 值虽然可以略微减小误差，但带来的边际收益（误差减少量）已显著减小。

因此，选择 k=10 可以在保证聚类效果的同时避免过多的簇数导致的模型复杂性，从而得到较为合理且稳定的聚类结果。

秋季台风合适的 k 值如下图 4.7 所示。




图 4.7 秋季台风 k 值

接着通过 LOF 算法剔除离群的台风数据点，避免异常值干扰分类结果。然后，使用仔细播种方法科学选择初始簇中心，进行聚类分析。

通过 CHk-means 算法对 2024 年 7 月和 9 月的台风数据进行聚类分析后，本文发现该算法有效提升了聚类效果。聚类后的台风类别划分更加清晰，并且减少了由于随机初始簇中心和离群点引起的分类误差，最终为台风分类模型的后续分析提供了更可靠的结果。

4.4.3 CHk-means 算法的复杂度分析

CHk-means 算法的时间复杂度较传统 K-means 稍高。CHk-means 在选择初始簇中心时引入了仔细播种方法，并使用 LOF 算法检测离群点，其时间复杂度约为 $O(k^2 \times n)$ ，其中 n 为数据集对象总数， k 为簇数。尽管时间复杂度有所提升，但在实际应用中，CHk-means 算法能够提供更高的聚类准确性和稳定性。

4.4.4 聚类结果评价

CHk-means 算法对夏季台风的聚类结果显示如图 4.8。




图 4.8 夏季台风聚类结果图

对秋季台风的聚类结果显示如图 4.9。




图 4.9 秋季台风聚类结果图

不同台风类别具有明显的特征差异。特别是在台风路径的转向角、降雨量、气压变化等特征上，聚类分析结果能够较好地反映出台风在这些因素上的显著差异。这表明，CHk-means 算法能够有效应用于台风分类问题中，为台风行为的进一步分析提供了坚实基础。

4.4.5 台风分类

以 2024 年我国 7 月和 9 月为例

本次分类通过对夏季和秋季台风的路径、登陆情况、运动方式和强度特性等维度的划分，构建了全面的台风分类体系。该体系不仅突出了不同季节台风在路径和特性上的差异，还展现了季节变化对台风运动轨迹和强度的影响。这种分类方法能够帮助深入理解台风的行为模式，特别是不同季节的台风在路径和强度上所表现的特点。

夏：

夏季台风主要呈现西北向移动，登陆频率较高，且路径多样。根据其行进方式和强度，夏季台风进一步划分为以下十类：

- (1) **北-登陆-转向**：路径向北移动并登陆，出现转向。
- (2) **西北-登陆-转向-弱**：向西北方向移动并登陆，但强度较弱且伴随转向。
- (3) **西北-登陆-转向-强**：向西北移动，登陆后转向，强度较高。
- (4) **西北-登陆-直线**：向西北方向移动并登陆，路径相对直线，强度较高。
- (5) **西北-近海-回旋**：接近西北近海区域，并在近海产生回旋。
- (6) **北-近海-转向**：移动路径向北，近海转向，未直接登陆。
- (7) **西-登陆-转向**：向西移动并登陆，随后出现转向。
- (8) **东北-近海-转向**：路径向东北移动，主要在近海区域活动，随后出现转向。
- (9) **西北-登陆-回旋-弱**：西北方向登陆后，产生回旋现象。
- (10) **西北-登陆-回旋-强**：西北方向移动并登陆，强度较高，并伴随回旋。

秋：

秋季台风的路径呈现出与夏季台风不同的特性。相较夏季，秋季台风更多地发生在西至西北方向，登陆较少，近海活动较多。具体分为以下十类：

- (1) **西-登陆-直线-弱**：向西移动，登陆后保持直线路径，强度较弱。
- (2) **西北-近海-回旋**：路径向西北移动，在近海区域发生回旋。
- (3) **西北-登陆-直线**：向西北方向移动并登陆，路径相对直线。
- (4) **西北-近海-转向-强**：西北方向移动，在近海区域出现转向，强度较强。
- (8) **西北-近海-转向-弱**：西北方向移动，在近海区域产生转向，强度较弱。
- (5) **北-登陆-转向**：路径向北移动并登陆，随后产生转向。
- (6) **北-近海-回旋**：路径向北移动，在近海区域产生回旋。
- (7) **东北-近海-转向**：路径向东北方向，近海区域转向。

- (9) 西-登陆-直线-强: 向西方向移动并登陆, 保持相对直线的路径。
- (10) 西-近海-回旋: 向西方向移动, 并在近海区域产生回旋。

4.5 基于神经网络的台风数据分类评价

在台风聚类后, 本文进一步利用分类模型对台风进行精细分类。由于分类任务需要监督学习方法, 我们采用神经网络等模型, 并通过训练集和验证集进行评估。

4.5.1 神经网络分类模型

神经网络是一个强大的非线性分类模型, 特别适合处理高维数据。其基本构建过程如下:

- 输入层:** 接收特征方程中提取的所有特征, 作为输入数据。
- 隐藏层:** 通过多个隐藏层, 每一层包含若干神经元, 并使用激活函数 (如 ReLU) 引入非线性。
- 输出层:** 输出分类结果, 根据模型的任务设置多个类别。
- 损失函数:** 使用交叉熵损失函数计算预测结果与真实标签之间的误差。
- 优化算法:** 采用 Adam 优化算法, 逐步更新权重参数, 最小化损失函数。

4.5.2 模型的训练、验证及预测

训练: 在神经网络的训练过程中, 我们对模型进行多次迭代, 并通过验证集评估模型性能。主要指标包括:

- 准确率:** 正确分类的样本占总样本的比例。
- 损失值:** 衡量模型在训练和验证集上的损失。
- F1 值:** 结合精确率和召回率的综合评估指标, 能够更全面反映模型性能。

数据集划分:

为了训练和验证分类模型, 首先需要将数据集划分为训练集和验证集。我们采用 28 分配, 其中 80% 的数据用于训练, 20% 的数据用于验证。

- 训练集:** 用于模型训练, 包含完整的特征和标签。
 - 验证集:** 用于评估模型的性能, 避免过拟合问题。
- 当模型通过验证集测试, 如图 4.10 所示。

	precision	recall	f1-score	support
0	1.00	1.00	1.00	5
1	0.00	0.00	0.00	1
2	1.00	1.00	1.00	2
3	0.33	1.00	0.50	1
4	1.00	1.00	1.00	1
5	0.00	0.00	0.00	1
6	1.00	0.50	0.67	2
7	1.00	1.00	1.00	2
8	0.67	1.00	0.80	2
9	1.00	1.00	1.00	1
accuracy			0.83	18
macro avg	0.70	0.75	0.70	18
weighted avg	0.81	0.83	0.80	18

图 4.10 验证集测试结果

且表现出稳定的分类性能后, 我们将其应用于新台风数据的预测任务。通过提取新台风的特征方程, 输入训练好的神经网络模型, 得出其所属的台风类别。

预测: 2024 年 7 月 9 月台风类别和途径省份结果见表 4.2。

表 4.2 台风类别及途径省份表

月份	台风类别	途径省份
7 月夏台风	西北-登陆-回转	福建省、台湾省、江西省、湖北省
	西-登陆-直线-弱	海南省
9 月秋台风	西-登陆-直线-弱	海南省
	西北-登陆-回旋	台湾省
	西北-登陆-回转	上海市、江苏省、安徽省、河南省

4.5.3 夏、秋台风区别分析

(1) 路径方向与转向角

夏季台风：总体上，夏季台风路径多朝西北方向移动并登陆，具有显著的转向特征。类别如“北 登 转”与“西北 登 转”型台风，路径转向角较大，且在进入大陆前后经常发生急剧的路径转折。

秋季台风：秋季台风路径更多为西或西北方向移动，登陆频率较低，但具有明显的近海活动特征，如“西北 近海 回旋”和“东北 近海 转向”。秋季台风的转向角整体较小，路径偏稳定。这说明秋季台风受引导气流较稳定，且影响范围更集中于近海区域。

(2) 路径曲折程度与路径转角波动

夏季台风中的“回旋”类台风：如“西北 近海 回旋”和“西北 登 回旋 强”类别的路径转角波动较大，路径显得更加曲折。路径长度与直线距离的比率较高，显示出这些类别的台风更容易在近海区域回旋徘徊。

秋季台风的“转向”类：例如“西北 近海 转向”和“东北 近海 转”类别中路径相对较直，但在近海区域出现明显的转向现象，转角波动相对较小。路径与直线距离比率稍低，但显示出秋季台风路径相对稳定且转向集中在近海范围内。

(3) 气压变化率与强度

夏季台风中的强度差异：在“西北 登 直 强”和“西北 登 回旋 强”等类别中，气压最大变化率和最大风速显著高，表明此类台风强度较高且在路径上具有明显的破坏力。尤其是路径较直的“西北 登 直 强”类别，气压梯度较大，反映出强气压支持了台风强度的提升。

秋季台风中的强度差异：秋季台风总体强度较弱，气压变化率在“西 登 直 弱”和“西北 近海 回旋”类别中相对较小。这种现象显示出秋季台风强度多受近海洋面温度和气压梯度较弱的环境控制，因此其整体风速和破坏力较夏季台风稍弱。

(4) 湿度与降水特征

夏季台风的湿度和降水特点：夏季台风通常受季风影响显著，湿度较高，尤其是在“西北 近海 回旋”和“北 登 转”等类别中，降水量最大，湿度值达到峰值。这些类别的台风在路径曲折且靠近陆地时更容易吸收大量水汽，导致降水增多。

秋季台风的湿度和降水特点：秋季台风降水量和湿度值相对较低，尤其是在“西 登 直 弱”和“北 近海 回旋”类别中。这表明秋季台风受季风影响较弱，降水量显著低于夏季台风，降水主要集中在台风行进至近海时。

(5) 生命周期与路径曲折比率

夏季台风的生命周期差异：例如，“西北 登 转 强”类台风生命周期较长，路径直线度较高。这些台风通常具有强度较高且生命周期较长的特点。而在“北 近海 转向”和“西北 登陆 回旋”等类别中，生命周期相对较短，反映出这些类别的台风更可能受到北方气流的影响，在进入大陆后较快消散。

秋季台风的生命周期差异：秋季台风多在近海回旋，生命周期通常较短。例如，“西北 近海 回旋”类和“东北 近海 转”类台风路径曲折比率较高且生命周期短，显示秋季台风更多受局部气流影响，移动缓慢且在近海区域消散。

(6) 气温变化率的影响

夏季台风中的气温变化率：夏季台风如“西北 登 直 强”类，气温最大变化率较高，显示出台风在沿途吸收大量热量，强度增强。同时，这类台风的移动速度较快，更可能在登陆前加剧。

秋季台风中的气温变化率：秋季台风整体气温变化率较低，尤其是在“北 登 转向”和“东北 近海 转”类别中，气温变化率趋于稳定。这与秋季台风受到的热量供应有限、季风减弱有关，表明此类台风在低海温区域活动较多，路径上的温度变化幅度不大。

（7）季节性差异的总结

夏季台风的特征总结：夏季台风整体表现出路径曲折、多次转向以及高湿度和高降水量的特点，路径中受到季风和北方气流的显著影响。强度较高的类别表现为路径相对直线，如“西北 登 直 强”；而路径较为曲折、转向多的台风则表现出回旋特征，例如“西北 近海 回旋”。

秋季台风的特征总结：秋季台风则偏向西北或西方向的近海活动，降水量和湿度偏低。秋季台风多在近海转向或回旋，路径较直，受引导气流稳定控制，如“西北 近海 转向”。秋季台风生命周期短，气温变化率和气压变化率较低，强度不及夏季台风。

通过以上特征指标的对比分析，能够进一步明确各类台风在路径方向、强度、湿度和气压变化等方面的差异性。这些差异性为后续台风路径预测和强度分析提供了依据，同时也反映出季节和环境因素在不同类别台风形成过程中的影响，为制定相应的防灾措施提供了科学支持。

五、问题二模型的建立与求解

台风路径预测是气象科学中的一个重要问题，预测精度的提高能够为防灾减灾提供更好的决策支持。台风路径受气象、海洋、风场、地球自转等多种因素的影响，因此一个精确的预测模型必须结合多维度的特征信息。本题旨在寻找一个合适的路径预测模型，并通过历史数据的过滤条件及特征空间扩展进行建模，最终通过动态时间规整法（DTW）来评估预测路径与实际路径的吻合程度。

5.1 台风数据融合

5.1.1 台风数据筛选

由于历史台风数据数量大，种类复杂，为了向模型提供更好的输入数据。团队需要对历史台风数据进行合理的筛选，以此来增加模型的准确性。故依据以下五点进行筛选。

（1）月份相似。台风的形成和发展受季节影响显著，不同月份的台风可能由于海洋温度、气压等因素有很大的差异。月份相近的台风可能会在相似的气候条件下发展出相似的路径。因此筛选出与 9 月贝碧嘉台风临近的 8, 9, 10 三个月份的台风。

（2）强度相近。作为刻画台风的重要指标之一，一般来说，台风的强度越大，其破坏力就越强，甚至可以改变周围的高压系统，从而影响台风路径。因此筛选出最大值达到 10 级及以上强度的台风。

（3）寿命相似。台风的寿命反映了其持续时间的长短，寿命长的台风会受到更大的周围环境的影响，可能有更复杂的路径。通过选择寿命相似的台风，可以更好的控制潜在因素。因此选择寿命大于等于八天的台风。

（4）登陆情况。台风在海洋上与在陆地上所处的环境不同。登陆台风通常在过境陆地时因地形摩擦和热量供给减少而迅速减弱，可能导致路径突然改变。因此筛选出与贝碧嘉一致的登陆台风。

（5）行进角度。行进角度描述了台风的移动方向变化程度。不同的行进角度可能受到不同的大气环流影响，从而影响台风的路径。因此筛选出西，西北，北三个方向的台风。

通过对原始数据的筛选得到初步数据，如图 5.1。




图 5.1 台风数据筛选流程图

最后，从 1813 条台风里筛选出了 109 条符合要求的台风，例如编号 195025、195030、195121 这三条台风，如图 5.2。

1	id	starttime	lon1	lon2	lon3	lon4	lon5	lon6	lon7	lon8	lat1
2	195025	1950/9/10	138.2	138.9	135.1	137.1	136.0	134.4	133.7	133.0	26.0
3	195025	1950/9/7	1143.5	143.4	143.1	142.9	142.7	142.3	141.9	143.6	17.9
4	195025	1950/9/8	1142.9	142.7	142.3	141.9	140.9	140.1	139.5	141.4	19.4
5	195025	1950/9/9	1139.5	138.9	137.1	136.0	138.2	141.4	140.9	140.1	24.6
6	195030	1950/10/1	120.6	118.3	119.0	119.7	121.6	122.5	123.4	124.7	17.0
7	195030	1950/10/2	117.1	117.3	117.5	117.8	118.3	119.0	119.7	120.6	19.9
8	195030	1950/10/3	117.8	117.5	117.3	117.1	116.8	116.4	115.7	114.5	18.8
9	195030	1950/10/4	114.5	116.8	116.4	115.7	113.5	112.5	111.6	110.6	21.4
10	195030	1950/9/27	144.6	137.0	138.3	139.4	140.6	141.7	142.7	143.6	11.2
11	195030	1950/9/28	139.4	138.3	137.0	135.6	134.1	132.6	131.3	140.6	12.7
12	195121	1951/9/12	146.1	145.4	144.4	143.5	142.5	141.7	140.6	139.4	8.9
13	195121	1951/9/13	142.5	141.7	140.6	139.4	138.2	137.0	135.8	134.5	11.2
14	195121	1951/9/14	138.2	137.0	135.8	134.5	133.5	132.5	131.8	131.0	13.0
15	195121	1951/9/15	133.5	132.5	131.8	131.0	130.1	129.3	128.5	127.7	13.1
16	195121	1951/9/16	130.1	129.3	128.5	127.7	126.8	126.0	125.4	124.7	14.1

图 5.2 筛选后的台风样本

5.1.2 多表数据融合

根据题目要求，需要依据气温、气压、洋流、风场等因素建立模型。风场因素可以由风速进行刻画。因此总表里只缺少气温数据，需要从其他表补充数据。当台风距离内陆观测点距离过大时，逐日降水数据集里的站点气温无法作为台风气温，此时需要用海洋表面 2m 数据集里的气温作为台风气温。因此，需要使用逐日降水数据集和海洋表面 2m 数据集两个表与主表进行连接，取台风当前经纬度和两个表内同一时间经纬度的实际距离最近的温度作为气温值，如图 5.3。

id	starttime	duringtime	longitude	latitude	windvelocity	pressure	temp
195025	1950/9/7 14:	1950/9/7 14:	143.6	17.5	30	983	27.97
195025	1950/9/7 14:	1950/9/7 20:	143.5	17.9	35	980	27.97
195025	1950/9/7 14:	1950/9/8 2:0	143.4	18.4	35	980	28.17
195025	1950/9/7 14:	1950/9/8 8:0	143.1	18.9	40	975	28.17
195025	1950/9/7 14:	1950/9/8 14:	142.9	19.4	40	970	28.05
195025	1950/9/7 14:	1950/9/8 20:	142.7	20.0	45	965	28.05
195025	1950/9/7 14:	1950/9/9 2:0	142.3	20.7	50	960	28.52
195025	1950/9/7 14:	1950/9/9 8:0	141.9	21.5	50	955	28.27
195025	1950/9/8 14:	1950/9/8 14:	142.9	19.4	40	970	28.05
195025	1950/9/8 14:	1950/9/8 20:	142.7	20.0	45	965	28.05
195025	1950/9/8 14:	1950/9/9 2:0	142.3	20.7	50	960	28.52
195025	1950/9/8 14:	1950/9/9 8:0	141.9	21.5	50	955	28.27
195025	1950/9/8 14:	1950/9/9 14:	141.4	22.2	55	950	27.95

图 5.3 添加气温列

5.2 数据预处理

为了提升数据质量和一致性，确保预测的可靠性和准确性，增强模型的稳定性和泛化能力。团队对数据做以下处理。

(1) 由于数据中存在当前时间早于起始时间和当前时间晚于结束时间的行数据。为了确保数据的合理性和准确性。团队删除了这些行数据，如图 5.4。

id	Chinesename	Englishname	starttime	endtime	nowtime	longitude	latitude	strength	level
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 05:00:00	123.3	9.4	热带低压(TD)	7
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 08:00:00	122.3	9.5	热带低压(TD)	7
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 11:00:00	121.4	9.5	热带低压(TD)	7
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 14:00:00	120.7	9.4	热带低压(TD)	7
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 17:00:00	119.9	9.3	热带低压(TD)	7
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 20:00:00	119	9.3	热带低压(TD)	7
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-02 23:00:00	118.3	9.5	热带低压(TD)	7
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-03 02:00:00	117.2	9.8	热带低压(TD)	7
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-03 05:00:00	116	10.3	热带低压(TD)	7
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-03 08:00:00	116.1	10.7	热带风暴(TS)	8
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-03 11:00:00	115.4	10.6	热带风暴(TS)	8
201801	布拉万	Bolaven	2018-01-03 08:00:00	2018-01-04 11:00:00	2018-01-03 14:00:00	114.8	10.9	热带风暴(TS)	8

图 5.4 数据异常图 1

(2) 由于数据表中存在风速值为 0 的空缺值数据。为了不影响后续特征工程的搭建，团队删除了存在风速值为 0 的行数据，如图 5.5。

starttime	endtime	nowtime	longitude	latitude	strength	level	windvelocity	pressure	direction
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-13 08:00:00	139.9	5.7		0	0	1006	
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-13 14:00:00	139.3	5.9		0	0	1006	
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-13 20:00:00	138.7	6.3		0	0	1006	
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-14 02:00:00	138	6.7		0	0	1006	
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-14 08:00:00	137.3	7.2		0	0	1005	
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-14 14:00:00	136.7	7.7		0	0	1005	
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-14 20:00:00	136	8.2		0	0	1005	
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-15 02:00:00	135.3	8.8		0	0	1005	
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-20 20:00:00	126.6	11.3		0	0	1006	
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-21 02:00:00	125.7	11.2		0	0	1006	
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-21 08:00:00	124.9	11.3		0	0	1008	
1949-01-13 08:00:00	1949-01-25 08:00:00	1949-01-21 14:00:00	124.3	11.4		0	0	1008	

图 5.5 数据异常图 2

(3) 由于题目需要预测贝碧嘉台风从 13 号开始到 17 号每天的 14 点的经度和纬度。团队保留了以 14 点为起始点，时间间隔为 6 小时的行数据，包括 14, 20, 2, 8 四个时间点的数据。

5.3 搭建特征空间

搭建合理的特征空间对 LSTM 模型的训练至关重要。它能提升模型的预测准确性，捕捉关键信息，减少冗余提高计算效率，同时帮助模型理解数据的非线性关系，增强其泛化能力。通过融合多源数据，特征空间的构建为 LSTM 模型的训练和预测奠定了坚实的基础。

5.3.1 滑动窗口的建立

滑动窗口是一种有效的时间序列处理方法，通过将长时间序列数据分割为固定长度的片段，捕捉时间依赖性并构建输入特征。这种方法有助于减少噪声影响，提高模型的泛化能力和预测准确性，同时允许动态更新输入数据，以适应环境变化。

由于贝碧嘉台风开始时间为 9 月 10 号 20 点，需要预测的开始时间为 9 月 13 号 14 点，因此无法建立三天的滑动窗口，对于本题团队退而求其次，选择两天的滑动窗口去预测第三天台风的经度和纬度，如下图 5.6。




图 5.6 滑动窗口图

5.3.2 指标的选取

在分析台风数据时，团队发现每条台风记录的寿命存在差异，这导致了数据维度的不一致性。由于机器学习模型（尤其是深度学习模型如 LSTM）在训练和预测时要求输入的数据维度保持一致，因此团队必须采取措施来解决这一问题。为此，团队需要从已有的数据中提取具有代表性的特征值作为指标，以便将不同寿命的台风记录转换为统一的格式。这一过程不仅能够有效地处理不同维度的数据，还能确保模型在训练时能够充分利用所有可用信息，提高预测的准确性和可靠性，如表 5.1。

表 5.1 特征表

序号	特征	备注：前 48h，每日 14, 20,2,8 四点，共 8 个点数据
1-8	LAT_{1-14} 、 LAT_{1-20} 、 LAT_{2-2} 、 LAT_{2-8} 、 LAT_{2-14} 、 LAT_{2-20} 、 LAT_{3-2} 、 LAT_{3-8}	前 48h 纬度
9-16	$LONG_{1-14}$ 、 $LONG_{1-20}$ 、 $LONG_{2-2}$ 、 $LONG_{2-8}$ 、 $LONG_{2-14}$ 、 $LONG_{2-20}$ 、 $LONG_{3-2}$ 、 $LONG_{3-8}$	前 48h 经度
17-24	WND_{1-14} 、 WND_{1-20} 、 WND_{2-2} 、 WND_{2-8} 、 WND_{2-14} 、 WND_{2-20} 、 WND_{3-2} 、 WND_{3-8}	前 48h 风速
25-32	$PRES_{1-14}$ 、 $PRES_{1-20}$ 、 $PRES_{2-2}$ 、 $PRES_{2-8}$ 、 $PRES_{2-14}$ 、 $PRES_{2-20}$ 、 $PRES_{3-2}$ 、 $PRES_{3-8}$	前 48h 气压
33-40	TEM_{1-14} 、 TEM_{1-20} 、 TEM_{2-2} 、 TEM_{2-8} 、 TEM_{2-14} 、 TEM_{2-20} 、 TEM_{3-2} 、 TEM_{3-8}	前 48h 气温
41-47	$LAT_{1-20} - LAT_{1-14}$ 、 $LAT_{2-2} - LAT_{1-20}$ 、 $LAT_{2-8} - LAT_{2-2}$ 、 $LAT_{2-14} - LAT_{2-8}$ 、 $LAT_{2-20} - LAT_{2-14}$ 、 $LAT_{3-2} - LAT_{2-20}$ 、 $LAT_{3-8} - LAT_{3-2}$	前 6h-48h 一阶纬度差
48-54	$LONG_{1-20} - LONG_{1-14}$ 、 $LONG_{2-2} - LONG_{1-20}$ 、 $LONG_{2-8} - LONG_{2-2}$	前 6h-48h 一阶经度差

55-61	LONG ₂₋₁₄ - LONG ₂₋₈ 、LONG ₂₋₂₀ - LONG ₂₋₁₄ 、LONG ₃₋₂ - LONG ₂₋₂₀ 、 LONG ₃₋₈ - LONG ₃₋₂	前 6h-48h 一阶风速差
	WND ₁₋₂₀ - WND ₁₋₁₄ 、WND ₂₋₂ - WND ₁₋₂₀ 、WND ₂₋₈ - WND ₂₋₂ 、 WND ₂₋₁₄ - WND ₂₋₈ 、WND ₂₋₂₀ - WND ₂₋₁₄ 、WND ₃₋₂ - WND ₂₋₂₀ 、 WND ₃₋₈ - WND ₃₋₂	
62-68	PRES ₁₋₂₀ - PRES ₁₋₁₄ 、PRES ₂₋₂ - PRES ₁₋₂₀ 、PRES ₂₋₈ - PRES ₂₋₂ 、 PRES ₂₋₁₄ - PRES ₂₋₈ 、PRES ₂₋₂₀ - PRES ₂₋₁₄ 、PRES ₃₋₂ - PRES ₂₋₂₀ 、 PRES ₃₋₈ - PRES ₃₋₂	前 6h-48h 一阶气压差
	TEM ₁₋₂₀ - TEM ₁₋₁₄ 、TEM ₂₋₂ - TEM ₁₋₂₀ 、TEM ₂₋₈ - TEM ₂₋₂ 、 TEM ₂₋₁₄ - TEM ₂₋₈ 、TEM ₂₋₂₀ - TEM ₂₋₁₄ 、TEM ₃₋₂ - TEM ₂₋₂₀ 、 TEM ₃₋₈ - TEM ₃₋₂	
69-75	cos(LAT ₁₋₁₄)、cos(LAT ₁₋₂₀)、cos(LAT ₂₋₂)、cos(LAT ₂₋₈)、 cos(LAT ₂₋₁₄)、cos(LAT ₂₋₂₀)、cos(LAT ₃₋₂)、cos(LAT ₃₋₈)	前 6h-48h 一阶气温差
76-83		前 48h 纬度的 cos 值
84-91	(WND ₁₋₁₄) ² 、(WND ₁₋₂₀) ² 、(WND ₂₋₂) ² 、(WND ₂₋₈) ² 、(WND ₂₋₁₄) ² 、 (WND ₂₋₂₀) ² 、(WND ₃₋₂) ²	前 48h 风速的平方
92-99	log(WND ₁₋₁₄)、log(WND ₁₋₂₀)、log(WND ₂₋₂)、log(WND ₂₋₈)、 log(WND ₂₋₁₄)、log(WND ₂₋₂₀)、log(WND ₃₋₂)、log(WND ₃₋₈)	前 48h 风速的对数值
100-107	log(PRES ₁₋₁₄)、log(PRES ₁₋₂₀)、log(PRES ₂₋₂)、log(PRES ₂₋₈)、 log(PRES ₂₋₁₄)、log(PRES ₂₋₂₀)、log(PRES ₃₋₂)、log(PRES ₃₋₈)	前 48h 气压的对数值
108-115	(PRES ₁₋₁₄) ² 、(PRES ₁₋₂₀) ² 、(PRES ₂₋₂) ² 、(PRES ₂₋₈) ² 、(PRES ₂₋₁₄) ² 、 (PRES ₂₋₂₀) ² 、(PRES ₃₋₂) ² 、(PRES ₃₋₈) ²	前 48h 气压的平方
116-123	PRES ₁₋₁₄ /WND ₁₋₁₄ 、PRES ₁₋₂₀ /WND ₁₋₂₀ 、PRES ₂₋₂ /WND ₂₋₂ 、 PRES ₂₋₈ /WND ₂₋₈ 、PRES ₂₋₁₄ /WND ₂₋₁₄ 、PRES ₂₋₂₀ /WND ₂₋₂₀ 、 PRES ₃₋₂ /WND ₃₋₂ 、PRES ₃₋₈ /WND ₃₋₈	前 48h 气压与风速比
124-131	WND ₁₋₁₄ /PRES ₁₋₁₄ 、WND ₁₋₂₀ /PRES ₁₋₂₀ 、WND ₂₋₂ /PRES ₂₋₂ 、 WND ₂₋₈ /PRES ₂₋₈ 、WND ₂₋₁₄ /PRES ₂₋₁₄ 、WND ₂₋₂₀ /PRES ₂₋₂₀ 、 WND ₃₋₂ /PRES ₃₋₂ 、WND ₃₋₈ /PRES ₃₋₈	前 48h 风速与气压比
132-139	PRES ₁₋₁₄ /WND ₁₋₁₄ ² 、PRES ₁₋₂₀ /WND ₁₋₂₀ ² 、PRES ₂₋₂ /WND ₂₋₂ ² 、 PRES ₂₋₈ /WND ₂₋₈ ² 、PRES ₂₋₁₄ /WND ₂₋₁₄ ² 、PRES ₂₋₂₀ /WND ₂₋₂₀ ² 、 PRES ₃₋₂ /WND ₃₋₂ ² 、PRES ₃₋₈ /WND ₃₋₈ ²	前 48h 气压与风速比的平方
140-147	WND ₁₋₁₄ /PRES ₁₋₁₄ ² 、WND ₁₋₂₀ /PRES ₁₋₂₀ ² 、WND ₂₋₂ /PRES ₂₋₂ ² 、 WND ₂₋₈ /PRES ₂₋₈ ² 、WND ₂₋₁₄ /PRES ₂₋₁₄ ² 、WND ₂₋₂₀ /PRES ₂₋₂₀ ² 、 WND ₃₋₂ /PRES ₃₋₂ ² 、WND ₃₋₈ /PRES ₃₋₈ ²	前 48h 风速与气压比的平方

前面已经分析过了选择前两天数据以及纬度、经度、风速等基础数据的原因。在此基础上团队继续扩建特征值，并分析这些特征值的作用。

前 6h-48h 一阶风速差：风速的变化可以指示台风的强度变化及其发展潜力，对于预测路径变化和强度演变具有重要意义。

前 6h-48h 一阶气压差：气压是台风强度的关键指标，气压差异可以揭示台风的减弱或增强趋势。气压的变化直接影响台风的动力学特性，从而影响其移动路径。

前 6h-48h 一阶气温差：温度的变化通常影响气体的密度和台风的热力学特性。此特征量可以提供有关台风能量来源的重要信息。

前 48h 纬度的 $\cos$ 值：纬度的 $\cos$ 值可用于计算地球表面不同纬度对风场和气压场的影响。此特征可以帮助模型理解台风在不同纬度的行为特征。

前 48h 风速的平方：虽然已有风速指标，但风速对台风路径影响巨大，其平方可以增强风速对路径的影响。提高模型对极端情况的敏感性。

前 48h 风速的对数值：风速的对数值有助于减小异常值对模型的影响。它可以增强模型对风速变化的敏感性，从而更有效地捕捉与台风路径相关的风速特征。

前 48h 气压的对数值：气压的对数变换可以用于处理其非线性特性和异常值。这一特征可以使模型更好地理解气压对台风移动和强度变化的影响。

前 48h 气压的平方：类似地，此特征的平方增强气压对台风路径的影响。

前 48h 气压与风速比：这一比值特征有助于分析气压和风速之间的相互关系，反映出台风的动力学特性，进而影响其路径和强度变化。

前 48h 风速与气压比：这一比值特征反映了台风的动力学特性和强度变化。较高的风速与低气压比通常表明台风强度增强，可能导致路径的偏转

前 48h 气压与风速比的平方：该特征通过平方操作强调了气压与风速比的影响力，特别是在台风强度变化剧烈时。

前 48h 风速与气压比的平方：类似地，此特征的平方处理使得模型在评估风速与气压比的影响时更加灵敏，有助于捕捉到强烈变化情况下的动态行为。

5.4 基于 LSTM 的路径预测模型

5.4.1 LSTM 模型

LSTM (Long Short-Term Memory) 模型是一种特殊的递归神经网络 (RNN)，它最初由 Hochreiter 和 Schmidhuber 提出^[5]，后经 Grave 改进^[6]。它被设计用于处理和预测时间序列数据。LSTM 在结构上引入了“记忆细胞”和“门控机制”，使其具备控制保持和遗忘数据方面的能力，这使得它在长时间序列数据中表现更佳。除此之外，LSTM 能够解决传统 RNN 模型在长序列中出现的梯度消失和梯度爆炸问题，使其适用于更复杂、长时间依赖的序列预测任务，如天气预报、股票预测、自然语言处理等。台风路径受历史移动轨迹、气象条件（如温度、湿度、气压）等长时间累积的影响。LSTM 通过其记忆单元和门控机制，能够捕获和保留这些长期依赖关系，从而更准确地预测台风路径，因此本题才用 LSTM 模型进行台风路径预测。

下图为循环神经网络结构图，分为输入层、隐藏层、输出层以及隐藏层间的信息流动，如图 5.7。




图 5.7 循环神经网络结构图

输入层：橙色节点，接收来自时间序列的数据输入。

隐藏层：蓝色节点。在每一个时间步，隐藏层会处理输入信息并保留一些重要的信息传递到下一个时间步。

输出层：绿色节点。每个时间步的输出可以被用于下一时间步的计算，也可以是模型的最终输出。

黑色和黄色的连接：代表信息在不同节点之间的传递。黄色连接通常表示隐藏状态的传递，也即跨时间步的信息流动，使得每个时间步可以依赖于之前的时间步的记忆。

下图是记忆细胞内的详细结构，分为遗忘门，输入门，输出门，如图 5.8。




图 5.8 记忆细胞内部结构

遗忘门：决定在单元状态中需要保留多少过去的信息，也就是控制上一个时间步的记忆在当前时刻的保留程度。

输入门：控制当前输入对单元状态的影响，决定当前时刻的新信息在多大程度上被添加到记忆细胞（Cell State）中。

输出门：决定当前时间步的单元状态中哪些部分会被输出成隐藏状态 h_{t_tht} ，并传递到下一个时间步或作为最终输出。

5.4.2 模型的构建与训练

(1) 模型构建

输入层：5.3.2 所建立的前 48 小时在 2, 8, 14, 20 八个点的 147 个指标。

输出层：24 小时在 2, 8, 14, 20 四个点的 65 个指标。共 365 行数据。

优化器：采用 Adam 优化器，并且设定学习率为 0.001。

损失函数：采用均方误差（MSE）作为损失函数，衡量模型预测的路径与实际路径之间的差异。

防过拟合机制：模型加入了 EarlyStopping 原理，设定 patience 值为 3，当训练损失值连续三次下降，则自动停止 epoch 迭代。用于防止模型过拟合并节省训练时间。

(2) 模型训练

执行 python 代码，调用相关库，得到损失图评价图。如图 5.9。




图 5.9 MSE 损失评价图

观察此图，在接近第 13-15 轮次时，训练损失继续下降，而验证损失出现了轻微的上升趋势。这可能表明模型开始在训练集上过拟合，模型在训练集上表现更好，但在验证集上的表现没有进一步提升，因此停止 Epochs 迭代。

5.4.3 预测结果及 DTW 分析

根据训练好的模型，放入贝碧嘉台风 9 月 11 日 14 点开始的 48 小时数据（数据来源于由浙江省水利厅、浙江省水利信息管理中心主办的台风信息发布系统——“台风路径”）见图 5.10。

time	longitude	latitude	strength	power	wind_speed	pressure	move_speed	move_direction	radius7	radius10	radius12
2024-09-10 20:00:00	145.40	12.40	热带风暴	8	18	998	20	北西	230	0	0
2024-09-10 23:00:00	144.90	12.90	热带风暴	8	18	998	24	北西	230	0	0
2024-09-11 02:00:00	144.50	13.30	热带风暴	8	18	998	22	北西	230	0	0
2024-09-11 05:00:00	143.90	13.40	热带风暴	9	23	990	20	北西	260	0	0
2024-09-11 08:00:00	143.30	13.60	热带风暴	9	23	990	22	北西	260	0	0
2024-09-11 11:00:00	143.20	14.00	强热带风暴	10	25	985	24	北西	260	0	0
2024-09-11 14:00:00	142.50	14.70	强热带风暴	10	25	985	21	北西	260	0	0
2024-09-11 17:00:00	141.80	15.00	强热带风暴	10	25	985	20	北西	260	0	0
2024-09-11 20:00:00	141.60	15.10	强热带风暴	10	25	985	22	北西	260	0	0
2024-09-11 23:00:00	141.40	15.20	强热带风暴	10	28	982	26	北北西	260	65	0
2024-09-12 02:00:00	140.80	16.00	强热带风暴	10	28	982	22	北北西	260	80	0
2024-09-12 05:00:00	140.40	17.10	强热带风暴	10	28	982	23	北北西	260	80	0
2024-09-12 08:00:00	140.00	17.30	强热带风暴	10	28	982	25	北北西	260	80	0
2024-09-12 11:00:00	139.90	18.10	强热带风暴	10	28	982	28	北北西	260	80	0
2024-09-12 14:00:00	139.80	19.10	强热带风暴	11	30	980	25	北西	200	60	0
2024-09-12 17:00:00	139.50	20.10	强热带风暴	11	30	980	25	北西	200	60	0
2024-09-12 20:00:00	138.90	20.40	强热带风暴	11	30	980	24	北西	200	60	0
2024-09-12 23:00:00	138.40	20.70	强热带风暴	11	30	980	25	北西	200	60	0
2024-09-13 02:00:00	137.60	21.00	强热带风暴	11	30	980	28	北西	200	60	0
2024-09-13 05:00:00	137.30	21.10	强热带风暴	11	30	980	27	北西	200	60	0
2024-09-13 08:00:00	137.10	21.70	强热带风暴	10	28	982	32	北西	175	60	0
2024-09-13 11:00:00	136.30	22.50	强热带风暴	10	28	982	32	北西	175	60	0
2024-09-13 14:00:00	135.60	23.60	强热带风暴	10	28	982	32	北西	175	60	0
2024-09-13 17:00:00	135.00	24.30	强热带风暴	10	28	982	31	北西	175	60	0
2024-09-13 20:00:00	133.80	24.90	强热带风暴	10	28	982	29	北西	175	60	0
2024-09-13 23:00:00	133.20	25.20	强热带风暴	10	28	982	28	北西	175	60	0
2024-09-14 02:00:00	132.70	25.30	强热带风暴	10	28	982	33	北西	175	60	0
2024-09-14 05:00:00	132.20	25.70	强热带风暴	10	28	982	33	北西	175	60	0

图 5.10 贝碧嘉台风数据图

预测 9 月 13 日 14 点开始的 24 小时数据，并将预测得到的数据与 9 月 12 日的数据合并，预测 9 月 14 日的 24 小时数据。通过循环预测，从而得到最终的 13 日到 17 日 14 点的预测经度和纬度。预测结果如表 5.2。

表 5.2 2024 年 9 月 13 日-17 日每日 14 点的第 13 号台风贝碧嘉的中心位置

时间	台风中心位置(经度/纬度)
13 日 14:00	135.02/23.28
14 日 14:00	130.70/28.02
15 日 14:00	126.81/30.10
16 日 14:00	120.52/31.76
17 日 14:00	117.08/32.50

使用真实贝碧嘉数据与预测数据画出真实的台风路径与预测台风路径进行对比。如图 5.11。




图 5.11 台风路径对比图

首先，通过 DTW 指标分析：

（1）图中显示的 DTW 距离为 3.29，表明两条路径在地理位置上的累积差异较小，说明它们在位置上相对接近。DTW 距离越小，表示两个路径的相似性越高。

（2）匹配点数为 5，表示在 DTW 路径匹配过程中，两个路径的关键点之间找到了五对对应的匹配点。这意味着在路径整体上有足够的匹配点来表示相似性。

（3）图中计算出的真实线段距离为 338.36KM，一般来说，真实线段距离越小，说明两条路径的地理位置越接近。338.36 公里的距离表明真实路径和预测路径之间的误差相对适中，不完全重合但也偏差不大。

其次，从图中真实数据和预测数据的经纬度变化趋势来看，两条曲线整体变化方向一致，具有较高的趋势相关性。尽管在部分区间存在轻微偏差，但总体相似性较高，表明两者在经纬度上的变化是相符的，说明模型的预测结果与真实路径具有较好的重合度。

六、问题三模型的建立与求解

6.1 台风数据融合

为明确降水量与风速、降水量与距台风中心距离的关系，并有效预测台风贝碧嘉的中心风力和降水量，团队在原有台风数据表的基础上中加入了降雨量和气温数据。气温在台风形成和强度中的作用尤为重要，特别是在 7 月至 9 月期间，气温波动对台风特征的影响更加明显。2024 年夏季气温显著偏高，进一步突显了贝碧嘉的典型夏季台风特征。因此，团队认为夏台风战线拉长，秋台风有夏台风的趋势化，重点关注 7 月至 9 月的气温数据，以确保数据的代表性和准确性。

为与贝碧嘉路径相似，团队筛选了登陆浙江、江苏、上海、山东，且登陆时方向角为西北的台风样本，如图 6-1。

endtime	nowtime	longitude	latitude	strength	level	windvelocity	pressure	direction	movevelocity	province
2019-08-13 11:00:00.00	2019-08-09 14:00:00.000	122.6	27	超强台风(Sup 17	58	920	西北	15	浙江省	
2021-07-30 17:00:00.00	2021-07-25 14:00:00.000	122.2	30	台风(TY) 13	38	965	西北	12	浙江省	
2021-07-30 17:00:00.00	2021-07-26 14:00:00.000	120.9	30.8	强热带风暴(S 10	25	980	西北	7	浙江省	
2021-07-30 17:00:00.00	2021-07-27 14:00:00.000	119	31.3	热带风暴(TS) 8	18	985	西北	13	江苏省	

图 6.1 相近登陆点与方位角台风展示

这些数据有助于深入理解贝碧嘉在典型夏季气温影响下的特征，为风速和降水量的预测提供可靠支持。

依据题目要求，需要依据气温、降水量、距台风中心距离等因素建立模型。总表中缺少气温与降水量数据，因此需要从其他表补充数据。因现有的降水量数据绝大部分为日均降水，现取一天为时间步长，依据台风与观测点远近，取爬取的中国逐日降水数据集里的站点气温或海洋表面 2m 数据集里的气温作为气温，取爬取的中国逐日降水数据集里的站点降水量或 1949-2018 日平均降水数据集作为降水量数据，并与主表进行连接，取台风当前经纬度和同一时间经纬度的实际距离最近的温度和降水量作为气温值和降水量值。

数据预处理延用了前期清洗方法，包括缺失值与异常值的处理。在降水量和气温数据的处理过程中，团队将降水量与风速、降水量与距台风中心的距离作为核心指标，分阶段进行筛选。为保证数据的时效性，团队仅选取持续时间超过 7 天、且包含登陆前 4 天和登陆后 3 天数据的台风样本。在清洗后的数据上，通过统计学习方法对贝碧嘉行进途中的中心风力和降水量进行了回归分析，并通过多元回归与时序模型模拟和预测其风速和降水趋势。

6.2 搭建特征空间

6.2.1 滑动窗口的建立

为有效捕捉台风路径及特征的时序变化，团队在模型中引入滑动窗口方法，将连续的时序特征分段处理。滑动窗口通过对台风历史数据的分块，帮助模型捕捉短期内的特征动态变化，以提高对未来路径和强度的预测精度。

在本研究中，滑动窗口长度设定为四天，每个窗口包含台风在前四天的特征数据。每个窗口记录了每日 14 时的关键指标，包括风速、降水量、经纬度、方向角等。对于经纬度，本题选取了第二题预测的经纬度数据为基准，将这些特征输入 LSTM 模型，能够帮助模型提取和学习不同时间点的台风特征变化，滑动窗口特征数据如图 6.2。

#	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	id	starttime	lon1	lon2	lon3	lon4	lat1	lat2	lat3	lat4	wind1	wind2	wind3	wind4	pressure
2	195025	1950/9/10	138.9	138.2	137.1	136.0	25.2	26.0	26.6	27.3	60	60	60	60	945
3	195025	1950/9/7	1143.6	143.5	143.4	143.1	17.5	17.9	18.4	18.9	30	35	35	40	983
4	195025	1950/9/8	1142.9	142.7	142.3	141.9	19.4	20.0	20.7	21.5	40	45	50	50	970
5	195025	1950/9/9	1141.4	140.9	140.1	139.5	22.2	22.8	23.7	24.6	55	55	55	60	950
6	195030	1950/10/1	121.6	122.5	123.4	124.7	16.8	16.5	16.0	15.5	30	30	30	30	988
7	195030	1950/10/2	119.7	120.6	119.0	118.3	17.2	17.0	17.7	18.3	30	30	35	35	985
8	195030	1950/10/3	117.8	117.5	117.3	117.1	18.8	19.2	19.5	19.9	35	35	35	35	980
9	195030	1950/10/4	115.7	116.8	116.4	114.5	21.3	20.3	20.7	21.4	30	35	35	25	986
10	195030	1950/9/27	141.7	142.7	144.6	143.6	12.1	11.9	11.2	11.6	20	20	12	15	995
11	195030	1950/9/28	140.6	138.3	137.0	139.4	12.4	12.9	13.1	12.7	20	20	20	20	995
12	195121	1951/9/12	146.1	145.4	144.4	143.5	8.9	9.4	10.0	10.6	12	15	15	15	1004
13	195121	1951/9/13	142.5	141.7	140.6	139.4	11.2	11.7	12.2	12.7	15	15	15	15	1004
14	195131	1951/9/14	139.7	137.0	136.0	134.5	13.0	13.0	13.0	13.0	15	15	15	15	1003

图 6.2 滑动窗口特征数据

滑动窗口逐步滑动，更新输入特征，使模型在每个时间步中都能够获取到最近几天的动态信息，从而增强了模型对未来一天台风特征的预测能力。滑动窗口的建立不仅确保了输入特征的时间一致性，也为模型捕捉台风移动和强度变化提供了更细致的时序结构。

6.2.2 指标的获取

为深入分析台风在登陆后的降水量和风速变化规律，团队基于贝碧嘉台风的特征数据，构建了台风登陆后行进过程中的降水量和风速特征空间。观测表明，台风登陆后，其影响力逐渐减弱，表现为风速和降水量的减少，且随着台风中心与受影响区域距离的增加，这种衰减更为显著。为此，团队从降水量、风速、方向角等多维度选取关键指标，搭建了具有代表性的特征空间。

风速反映台风强度的核心特性，团队选取前四天的风速数据捕捉其时序变化趋势，帮助预测台风在不同区域的衰减规律。降水量作为水汽输送和降水强度的直接体现，团队同样选取前四天数据来判断各阶段降水强度和受影响区域的降水分布。

同时，台风中心距离是衡量台风陆地影响深度的重要变量。团队计算了台风中心与登陆点的逐日距离，并结合风速和降水量变化，分析了台风在不同位置的衰减趋势，为路径预测提供支持。因台风寿命差异导致数据维度不一致，团队提取统一特征，确保模型输入一致，提升了预测的准确性和可靠性。

在台风预测模型中，前 65 个指标基于第二题，用于预测台风的中心经纬度。这些指标包含路径、强度和环境因素等关键信息，以便捕捉台风位置的变化趋势。在此基础上，进一步加入降水量、风速和台风中心距离，以支持对贝碧嘉台风行进途中的中心风力及降水量的预测。通过这三项补充指标，模型能够更全面地了解台风在移动过程中的强度变化，为路径和风速的精准预测提供多维度支持。特征如下表 6.1 所示

表 6.1 特征值

序号	特征	备注
1-4	LAT_{24} 、 LAT_{48} 、 LAT_{72} 、 LAT_{96}	前 96h 纬度
5-8	$LONG_{24}$ 、 $LONG_{48}$ 、 $LONG_{72}$ 、 $LONG_{96}$	前 96h 经度
9-12	WND_{24} 、 WND_{48} 、 WND_{72} 、 WND_{96}	前 96h 风速
13-16	$PRES_{24}$ 、 $PRES_{48}$ 、 $PRES_{72}$ 、 $PRES_{96}$	前 96h 气压
17-20	TEM_{24} 、 TEM_{48} 、 TEM_{72} 、 TEM_{96}	前 96h 气温
21-23	$WND_{48} - WND_{24}$ 、 $WND_{72} - WND_{48}$ 、 $WND_{96} - WND_{72}$	前 24h-96h 一阶风速差
24-26	$PRES_{48} - PRES_{24}$ 、 $PRES_{72} - PRES_{48}$ 、 $PRES_{96} - PRES_{72}$	前 24h-96h 一阶气压差
27-29	$TEM_{48} - TEM_{24}$ 、 $TEM_{72} - TEM_{48}$ 、 $TEM_{96} - TEM_{72}$	前 24h-96h 一阶气温差
30-33	$\cos(LAT_{24})$ 、 $\cos(LAT_{48})$ 、 $\cos(LAT_{72})$ 、 $\cos(LAT_{96})$	前 96h 纬度的 cos 值
34-37	$(WND_{24})^2$ 、 $(WND_{48})^2$ 、 $(WND_{72})^2$ 、 $(WND_{96})^2$	前 96h 风速的平方
38-41	$\log(WND_{24})$ 、 $\log(WND_{48})$ 、 $\log(WND_{72})$ 、 $\log(WND_{96})$	前 96h 风速的对数值
42-45	$\log(PRES_{24})$ 、 $\log(PRES_{48})$ 、 $\log(PRES_{72})$ 、 $\log(PRES_{96})$	前 96h 气压的对数值
46-49	$(PRES_{24})^2$ 、 $(PRES_{48})^2$ 、 $(PRES_{72})^2$ 、 $(PRES_{96})^2$	前 96h 气压的平方
50-53	$PRES_{24}/WND_{24}$ 、 $PRES_{48}/WND_{48}$ 、 $PRES_{72}/WND_{72}$ 、 $PRES_{96}/WND_{96}$	前 96h 气压与风速比
54-57	$WND_{24}/PRES_{24}$ 、 $WND_{48}/PRES_{48}$ 、 $WND_{72}/PRES_{72}$ 、 $WND_{96}/PRES_{96}$	前 96h 风速与气压比
58-61	$(PRES_{24}/WND_{24})^2$ 、 $(PRES_{48}/WND_{48})^2$ 、 $(PRES_{72}/WND_{72})^2$ 、 $(PRES_{96}/WND_{96})^2$	前 96h 气压与风速比的平方
62-65	$(WND_{24}/PRES_{24})^2$ 、 $(WND_{48}/PRES_{48})^2$ 、 $(WND_{72}/PRES_{72})^2$ 、 $(WND_{96}/PRES_{96})^2$	前 96h 风速与气压比的平方
66-67	LAT/LON	台风登陆点（纬度/经度）
68-71	$Distance_{24}$ 、 $Distance_{48}$ 、 $Distance_{72}$ 、 $Distance_{96}$	前 96h 台风中心与登陆

		城市中心距离
72-75	R_{24} 、 R_{48} 、 R_{72} 、 R_{96}	前 96h 降水
76-79	θ_{24} 、 θ_{48} 、 θ_{72} 、 θ_{96}	前 96h 方向角

6.3 基于 LSTM+多重注意力机制的预测模型

为深入分析台风在登陆后的降水量和风速变化规律，建立了基于 LSTM + 多重注意力机制的预测模型。本模型在捕捉时序动态特征的同时，通过注意力机制聚焦于重要的时空特征，从而提高对贝碧嘉台风路径和强度的预测精度。

6.3.1 LSTM 模型+多重注意力机制

在台风预测模型中，通过数据预处理，将历史数据（经纬度、风速、降水量、方向角等）进行归一化处理，形成多维时序输入，并采用滑动窗口方法生成四天的每日 14 时特征数据作为模型的输入，以预测次日 14 时的降水量和风速。LSTM 层用于捕捉台风路径和强度的动态变化，结合记忆单元，有效地提取时序特征。

此外，模型引入了多重注意力机制^[7]，包括时间注意力机制和空间注意力机制，进一步提升预测的准确性。时间注意力机制通过为不同时间步加权，使模型自动聚焦于历史数据中对未来预测更为关键的时间点，从而更有效地捕捉台风特征变化的关键时刻。空间注意力机制则通过识别台风路径中的重要地理位置，为不同位置赋予权重，使模型能聚焦于对路径和强度变化具有重要影响的空间区域，例如靠近陆地或进入特定海域的关键节点。

通过将多重注意力机制的加权输出与 LSTM 的隐层状态进行融合，模型输出预测的未来一天台风特征（如风速和降水量）。在模型训练过程中，采用均方误差（MSE）作为损失函数，通过反向传播最小化误差，从而优化模型的预测性能。

6.3.2 模型的动态实施

在模型的输入层中，团队采用前四天的每日 14 时的降水量、风速、经纬度和方向角数据加上第二题中总特征作为输入特征。模型通过 LSTM 和注意力机制的协同作用，提取时序特征并识别关键时空点。输出层预测未来一天（次日 14 时）的台风降水量和风速，以提供更准确的台风行进和强度预测。

结合问题二预测的经纬度结果，保留最新三天数据，并将问题二的预测数据加入，形成新的四天数据集，再次用于路径预测。随着每次预测生成的新数据，模型会将最早的数据替换掉，从而实现四天数据的滚动更新和连续预测。这种改进使得模型在空间和时间维度上更为精确，能够动态地整合路径信息，更好地捕捉台风中心的移动趋势与受影响区域的关系，为防灾决策提供更加科学的支持。

6.3.3 预测结果及分析

模型针对 2024 年 9 月 16 日至 18 日的第 13 号台风贝碧嘉进行了实际预测实验。在输入台风的历史降水量、风速和路径数据后，模型成功预测了未来一天的降水量和中心风速。结果表明，贝碧嘉的降水和风速随其向西北方向推进逐渐减弱，同时受台风影响的地区的降水量和风速随台风中心距离增加逐步减小。通过时空注意力机制的引入，模型更精准地捕捉到了台风行进过程中的关键特征变化，体现了该模型的预测优势。结果如下表 6.2。

表 6.2 2024 年 9 月 16 日-18 日每日 14 点的第 13 号台风贝碧嘉的中心风力及降水量

时间	经纬度	经过省份	降雨量	风速
9 月 16 日 14:00	(126, 25.3)	江苏省	92	31
9 月 17 日 14:00	(126.8, 26.96)	安徽省	226.4	17
9 月 18 日 14:00	(112.5, 32.5)	河南省	77.6	13

6.4 问题三小结

基于 LSTM + 多重注意力机制的台风预测模型能够充分利用历史时序特征和关键时空信息，有效预测了贝碧嘉行进过程中的降水量和风速变化。通过关注时间和空间上的关键特征点，模型提高了预测精度，为台风路径和强度的预警分析提供了更具参考价值的数据支持。

七、模型的评价与推广

7.1 问题一模型评价和推广

7.1.1 问题一模型评价

在台风分类评价模型中，我们使用了台风特征参数（如强度、等级、风速等）以及气温、气压和季风等环境因素，结合 CHk-means 改进算法和神经网络分类模型。模型在聚类方面通过 CHk-means 算法实现了更为细致的类别划分。聚类结果表现出不同类别台风在路径形态、风速、降水等方面的显著差异，显示了算法对数据特征的敏感性和分类准确性。在分类方面，神经网络模型通过高维数据输入，准确分类了夏台风和秋台风，并在验证集上表现出较高的准确率和 F1 值，证明了模型在分类上的有效性。

7.1.2 问题一模型推广

（1）灾害预警与风险管理系统

台风分类评价模型能够通过台风特征参数（如风速、强度、降水量等）和环境因素（气温、气压、季风）的组合实现对台风类别的细致划分。这一模型可以推广到气象部门的台风预警和风险管理系统中，用于增强台风风险的分级评估。基于模型的预测，气象部门可以将台风划分为不同风险等级并标示可能的影响范围，协助政府和居民更精准地判断灾害风险，提前做好应对措施。

（2）农业与基础设施防灾准备

对于农业部门和关键基础设施管理部门，台风分类模型能够提供区域台风预警。例如，当模型预测出即将影响该区域的台风类别为强降雨型时，农业部门可以提前部署水利设施，保护农作物免受洪涝灾害；基础设施管理部门则可提前检查和加固易受风雨侵害的基础设施，如电网、通信塔等，以减少灾害损失。

（3）应急响应与资源分配

该模型也可以与应急管理部的灾害响应系统对接，便于在不同的灾害风险级别下合理配置救援资源。模型可用于指导应急响应的具体安排，例如在高风险区域部署更多的救援人员和物资储备。这种分级管理有助于优化救援资源的利用，避免资源分配不均，并提高救灾效率。

（4）科研和教育领域

在气象科学研究中，台风分类评价模型可以作为研究工具，用于分析台风特征在不同类别台风中的表现差异。同时，它还可以用于气象学教学，通过真实数据的分析和模型模拟，让学生更直观地了解台风的形成和发展机制，推动气象教育的发展。

7.2 问题二模型评价和推广

7.2.1 问题二模型评价

台风路径预测模型结合了 LSTM 时间序列模型和 Dynamic Time Warping (DTW) 动态时间规整方法。LSTM 模型在捕捉台风路径的时间依赖性上表现优异，DTW 则在路径对比中提供了细致的路径形态对齐能力。通过误差度量，LSTM 模型在路径预测中展示了较高的精确度，并且在不同时间点上，预测路径与实际路径的偏差较小。DTW 对比则进一步证实了预测路径与实际路径的形态相似性，说明模型能够有效模拟台风行进的复杂路径变化。

7.2.2 问题二模型推广

（1）实时路径预测与决策支持系统

台风路径预测模型结合了 LSTM 和 DTW 算法，能够捕捉台风行进路径的时间依赖性和空间变化。这一模型可以推广应用到实时台风路径预测系统中，帮助气象部门及时发布预警，并协助决策层制定更科学的疏散和避险策略。例如，当模型预测台风即将登陆某地，决策者可以根据路径预测结果提前疏散居民，减少人员伤亡。

（2）保险行业的风险预测与定价

保险公司可以利用台风路径预测模型进行灾害风险的提前评估，制定保险产品的风险定价机制。通过模型的预测数据，保险公司可以评估特定地区受到台风影响的可能性，合理设计保险产品，为高风险地区的客户提供专属的保险方案，并优化理赔流程，提高应对自然灾害的金融保障能力。

（3）跨部门的数据共享和信息集成

台风路径预测涉及气温、气压、海洋洋流、风场等多种气象因素，因此可以推广应用到综合的跨部门数据共享平台中。这一平台可以将路径预测与相关气象数据实时集成，提供给交通运输、农业、电力等部门使用。通过统一的路径预测信息，各部门可以根据路径预测结果调整生产和调度计划，例如调整船运和航班路线、提前保护农作物、优化电网调度等。

（4）扩展到其他动态轨迹预测领域

除了台风路径预测外，LSTM-DTW 模型组合还可以应用于其他动态轨迹的预测，例如洪水扩散、地震后滑坡的移动路径等。通过适当的数据调整，模型可以推广至其他自然灾害的轨迹预测中，进一步支持多灾种风险预警系统的建设，形成跨越灾种的预测平台。

7.3 问题三模型评价和推广

7.3.1 问题三模型评价

登陆后风速与降水量关系模型利用 LSTM 对降水量和风速变化进行建模，展示了登陆后随时间演化的台风特性，成功捕捉了风速与降水量之间的非线性关系。模型通过特征提取，在台风距离、风速与降水之间找到了重要的关联性，预测了台风贝碧嘉在特定时间点的风力和降水情况，为台风影响的局部分析提供了可靠依据。

7.3.2 问题三模型推广

（1）灾后恢复规划与资源分配

登陆后风速与降水量关系模型能够对台风登陆后的降水和风速变化进行分析，这为灾后恢复和资源分配提供了重要依据。通过预测登陆后不同时段的风速和降水强度，应急管理部门可以合理安排救援物资和人员的部署。例如，在预测降水量大的区域，可以提前调配救援设备，确保迅速开展排水和清理工作，以减少灾害对居民生活和经济的长期影响。

（2）城市排水与防洪系统优化

该模型可以应用于城市规划中，特别是用于优化城市排水和防洪系统的设计。在模型的指导下，城市管理者可以更科学地布局排水管道、提高排水系统的设计标准，并确定关键区域的排水容量，避免台风导致的大规模内涝。此外，该模型还可以用于实时监测降水与风速变化，为突发的强降雨做出及时的响应和调度。

（3）水库和河流的水位控制

水利部门可以利用该模型预测台风带来的降水量，及时调整水库和河道的水位控制策略。例如，提前释放水库水位，为可能的台风降水腾出储水空间，降低洪水风险。此外，模型可以帮助水利工程师更精确地判断河道水位的变化，为沿岸地区的防洪提供预警，保护居民的生命财产安全。

（4）农业生产规划和灾害防范

对农业生产而言，该模型可用于预测台风对种植业的影响。通过了解降水量和风速的变化趋势，农民可以提前采取防护措施，例如搭建防风屏障、加固大棚、调整种植计划等，以减少台风对农作物的破坏。同时，模型还可以为农田排水系统的建设提供指导，确保台风过境后农田排水顺畅，减轻积水对作物的危害。

（5）环境和生态系统保护

风速和降水量的变化可能会对生态系统造成影响。通过预测台风登陆后的风速和降水分布，生态保护部门可以更好地评估台风对森林、湿地等生态环境的影响，并制定适当的保护措施。例如，在强降雨和大风的影响下，森林管理者可以加强对林区的巡查，防范树木倒伏和泥石流等次生灾害；湿地保护区可以采取相应的措施保护水生生物和湿地生态系统的稳定。

八、参考文献

- [1] Gray, W. M. (1985). "Tropical cyclone global climatology." *Atmosphere-Ocean*, 23(3), 227-279.
- [2] Emanuel, K. A. (2005). "Increasing destructiveness of tropical cyclones over the past 30 years." *Nature*, 436(7051), 686-688.
- [3] Elsner, J. B., & Jagger, T. H. (2006). "Prediction models for annual US hurricane counts." *Climate Dynamics*, 27(7-8), 635-644.
- [4] 栗庆杰. 启发式 k-means 聚类算法的改进与应用研究[D]. 大连交通大学, 2023.
- [5] Hochreiter S, Schmidhuber J. Long short-term memory[J]. *Neural computation*, 1997, 9(8): 1735-1780.
- [6] Graves A, Supervised sequence labelling with Recurrent Neural Networks[J]. *Studies in Computational Intelligence*, 2012.
- [7] D. Bahdanau, K. Cho, Y. Bengio. Neural Machine Translation by Jointly Learning to Align and Translate[C]// International Conference on Learning Representations (ICLR), San Diego, United States, 2015.

九、附录

采用 python 代码，在 vscode 环境下编写代码。

CHK-means 聚类:

```
import os
import pandas as pd
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA

# 1. 读取台风数据 (Excel 文件)
data = pd.read_excel(r"E:\competiton\autumn_latest0_processed.xlsx")

# 2. 提取特征列，移除台风 id 列
features = data.iloc[:, 1:].values # 从第 2 列开始提取特征

# 3. 数据标准化
scaler = StandardScaler()
features_scaled = scaler.fit_transform(features)

# 4. 使用肘部法则寻找最佳 k 值
inertias = []
ks = range(1, 40) # 测试 1 到 14 个聚类中心
for k in ks:
    kmeans = KMeans(n_clusters=k, random_state=42)
    kmeans.fit(features_scaled)
    inertias.append(kmeans.inertia_)

# 可视化肘部图
plt.figure(figsize=(8, 4))
plt.plot(ks, inertias, "-o")
plt.title("Elbow Method For Optimal k")
plt.xlabel("Number of clusters k")
plt.ylabel("Inertia")
plt.xticks(ks)
plt.grid(True)
plt.show()

# 选择一个合适的 k 值后继续执行
optimal_k = int(
    input("Enter the optimal number of clusters as observed from the plot: ")
)
kmeans = KMeans(n_clusters=optimal_k, random_state=42)
```

```

clusters = kmeans.fit_predict(features_scaled)
data["cluster"] = clusters

# 保存结果到Excel 文件
output_file_path = r"E:\competiton\autumn_kmeansAuto_clustered.xlsx"
if not os.path.exists(output_file_path):
    data.to_excel(output_file_path, index=False)
    print(f"Clustered data saved to: {output_file_path}")
else:
    print(f"File already exists: {output_file_path}. Not saved.")

# 使用 PCA 进行可视化 (降维到 2 维)
pca = PCA(n_components=2)
reduced_data = pca.fit_transform(features_scaled)
plt.figure()
plt.scatter(reduced_data[:, 0], reduced_data[:, 1], c=clusters, cmap="viridis")
plt.title("K-Means Clustering of Typhoons with Optimal k")
plt.xlabel("PCA Component 1")
plt.ylabel("PCA Component 2")
plt.show()

```

神经网络:

```

import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.utils import to_categorical
from sklearn.metrics import classification_report, accuracy_score

# 加载数据
data = pd.read_excel(
    r"E:\competiton\summer_kmeans_clustered.xlsx"
) # 更换为你的文件路径

# 准备数据
# 假设数据集第一列是 ID, 后面 13 列是特征, 最后一列是标签
X = data.iloc[:, 1:-1].values # 从第二列到倒数第二列是特征
y = data.iloc[:, -1].values # 最后一列是标签

# 数据标准化
scaler = StandardScaler()

```

```

X_scaled = scaler.fit_transform(X)

# 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.2, random_state=42
)

# 转换标签为独热编码
# 注意：标签需要从 0 开始递增编码，如果你的标签不是这样，请先转换它们
num_classes = len(np.unique(y))
y_train_encoded = to_categorical(y_train, num_classes=num_classes)
y_test_encoded = to_categorical(y_test, num_classes=num_classes)

# 创建模型
model = Sequential(
    [
        Dense(128, activation="relu", input_shape=(X_train.shape[1],)),
        Dense(64, activation="relu"),
        Dense(
            num_classes, activation="softmax"
        ), # 输出层节点数为类别数，激活函数使用 softmax
    ]
)

# 编译模型
model.compile(
    optimizer=Adam(learning_rate=0.001),
    loss="categorical_crossentropy",
    metrics=["accuracy"],
)

# 训练模型
history = model.fit(
    X_train, y_train_encoded, epochs=50, batch_size=32, validation_split=0.1
)

# 预测
y_pred = model.predict(X_test)
y_pred_labels = np.argmax(y_pred, axis=1)

# 评估模型
print("Accuracy:", accuracy_score(y_test, y_pred_labels))
print(classification_report(y_test, y_pred_labels))

```

LSTM 模型:

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.model_selection import train_test_split
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dense, Dropout
from tensorflow.keras.optimizers import Adam
import matplotlib.pyplot as plt
from tensorflow.keras.callbacks import EarlyStopping
from tensorflow.keras.models import load_model

# 1. 读取数据
dfx = pd.read_excel(r"E:\competition2\xl47.xlsx")
dfy = pd.read_excel(r"E:\competition2\y147.xlsx")
dfs = pd.read_excel(r"E:\competition2\startpoint.xlsx")

# 4. 特征和目标选择
featuresx = [
    "lon1",
    "lon2",
    "lon3",
    "lon4",
    "lon5",
    "lon6",
    "lon7",
    "lon8",
    "lat1",
    "lat2",
    "lat3",
    "lat4",
    "lat5",
    "lat6",
    "lat7",
    "lat8",
    "wind1",
    "wind2",
    "wind3",
    "wind4",
    "wind5",
    "wind6",
    "wind7",
    "wind8",
    "pressure1",
    "pressure2",
```

"pressure3",
"pressure4",
"pressure5",
"pressure6",
"pressure7",
"pressure8",
"temp1",
"temp2",
"temp3",
"temp4",
"temp5",
"temp6",
"temp7",
"temp8",
"cos_lat1",
"cos_lat2",
"cos_lat3",
"cos_lat4",
"cos_lat5",
"cos_lat6",
"cos_lat7",
"cos_lat8",
"wind_diff_1",
"wind_diff_2",
"wind_diff_3",
"wind_diff_4",
"wind_diff_5",
"wind_diff_6",
"wind_diff_7",
"pressure_diff_1",
"pressure_diff_2",
"pressure_diff_3",
"pressure_diff_4",
"pressure_diff_5",
"pressure_diff_6",
"pressure_diff_7",
"temp_diff_1",
"temp_diff_2",
"temp_diff_3",
"temp_diff_4",
"temp_diff_5",
"temp_diff_6",
"temp_diff_7",
"wind1_sq",
"wind2_sq",
"wind3_sq",

"wind4_sq",
"wind5_sq",
"wind6_sq",
"wind7_sq",
"wind8_sq",
"pressure1_sq",
"pressure2_sq",
"pressure3_sq",
"pressure4_sq",
"pressure5_sq",
"pressure6_sq",
"pressure7_sq",
"pressure8_sq",
"log_wind1",
"log_wind2",
"log_wind3",
"log_wind4",
"log_wind5",
"log_wind6",
"log_wind7",
"log_wind8",
"log_pressure1",
"log_pressure2",
"log_pressure3",
"log_pressure4",
"log_pressure5",
"log_pressure6",
"log_pressure7",
"log_pressure8",
"pressure_wind_ratio_1",
"pressure_wind_ratio_2",
"pressure_wind_ratio_3",
"pressure_wind_ratio_4",
"pressure_wind_ratio_5",
"pressure_wind_ratio_6",
"pressure_wind_ratio_7",
"pressure_wind_ratio_8",
"wind_pressure_ratio_1",
"wind_pressure_ratio_2",
"wind_pressure_ratio_3",
"wind_pressure_ratio_4",
"wind_pressure_ratio_5",
"wind_pressure_ratio_6",
"wind_pressure_ratio_7",
"wind_pressure_ratio_8",
"wind_pressure_ratio_sq_1",

```

        "wind_pressure_ratio_sq_2",
        "wind_pressure_ratio_sq_3",
        "wind_pressure_ratio_sq_4",
        "wind_pressure_ratio_sq_5",
        "wind_pressure_ratio_sq_6",
        "wind_pressure_ratio_sq_7",
        "wind_pressure_ratio_sq_8",
        "pressure_wind_ratio_sq_1",
        "pressure_wind_ratio_sq_2",
        "pressure_wind_ratio_sq_3",
        "pressure_wind_ratio_sq_4",
        "pressure_wind_ratio_sq_5",
        "pressure_wind_ratio_sq_6",
        "pressure_wind_ratio_sq_7",
        "pressure_wind_ratio_sq_8",
    ]

```

```

featuresy = [
    "lon1",
    "lon2",
    "lon3",
    "lon4",
    "lat1",
    "lat2",
    "lat3",
    "lat4",
    "wind1",
    "wind2",
    "wind3",
    "wind4",
    "pressure1",
    "pressure2",
    "pressure3",
    "pressure4",
    "temp1",
    "temp2",
    "temp3",
    "temp4",
    "cos_lat1",
    "cos_lat2",
    "cos_lat3",
    "cos_lat4",
    "wind_diff_1",
    "wind_diff_2",
    "wind_diff_3",
    "pressure_diff_1",

```

```

    "pressure_diff_2",
    "pressure_diff_3",
    "temp_diff_1",
    "temp_diff_2",
    "temp_diff_3",
    "wind1_sq",
    "wind2_sq",
    "wind3_sq",
    "wind4_sq",
    "pressure1_sq",
    "pressure2_sq",
    "pressure3_sq",
    "pressure4_sq",
    "log_wind1",
    "log_wind2",
    "log_wind3",
    "log_wind4",
    "log_pressure1",
    "log_pressure2",
    "log_pressure3",
    "log_pressure4",
    "pressure_wind_ratio_1",
    "pressure_wind_ratio_2",
    "pressure_wind_ratio_3",
    "pressure_wind_ratio_4",
    "wind_pressure_ratio_1",
    "wind_pressure_ratio_2",
    "wind_pressure_ratio_3",
    "wind_pressure_ratio_4",
    "wind_pressure_ratio_sq_1",
    "wind_pressure_ratio_sq_2",
    "wind_pressure_ratio_sq_3",
    "wind_pressure_ratio_sq_4",
    "pressure_wind_ratio_sq_1",
    "pressure_wind_ratio_sq_2",
    "pressure_wind_ratio_sq_3",
    "pressure_wind_ratio_sq_4",
]

```

```

X = dfx[featuresx].values
y = dfy[featuresy].values

```

5. 数据标准化

```

scaler_X = StandardScaler()
scaler_y = StandardScaler()
X_scaled = scaler_X.fit_transform(X)

```

```

y_scaled = scaler_y.fit_transform(y)

# 假设 X_scaled 是特征数据, y 是标签数据
n_train = int(0.8 * len(X_scaled)) # 80% 的数据作为训练集
X_train, X_test = X_scaled[:n_train], X_scaled[n_train:]
y_train, y_test = y_scaled[:n_train], y_scaled[n_train:]

# 7. 创建时间序列
time_steps = 1 # 使用过去 3 个时间点的数据

def create_sequences(X, y, time_steps):
    Xs, ys = [], []
    for i in range(len(X) - time_steps):
        Xs.append(X[i : i + time_steps])
        ys.append(y[i + time_steps]) # 确保这里获取的是对应的标签
    return np.array(Xs), np.array(ys)

X_train_seq, y_train_seq = create_sequences(X_train, y_train, time_steps)
X_test_seq, y_test_seq = create_sequences(X_test, y_test, time_steps)

# 检查数据形状
print("X_train_seq shape:", X_train_seq.shape) # 应为 (样本数, 时间步, 特征数)
print("y_train_seq shape:", y_train_seq.shape) # 应为 (样本数, 2)

# 8. 创建 LSTM 模型
model = Sequential()
model.add(
    LSTM(
        units=64,
        return_sequences=False,
        input_shape=(X_train_seq.shape[1], 147),
    )
)

model.add(Dropout(0.2)) # 防止过拟合
model.add(Dense(units=65)) # 输出两个值: 经度和纬度

# 9. 编译模型
model.compile(optimizer=Adam(learning_rate=0.001), loss="mse")

```

```

# 定义 EarlyStopping 回调
early_stopping = EarlyStopping(
    monitor="val_loss", patience=3, restore_best_weights=True
)

# 10. 训练模型时加入 early_stopping 回调
history = model.fit(
    X_train_seq,
    y_train_seq,
    epochs=50,
    batch_size=32,
    validation_data=(X_test_seq, y_test_seq),
    callbacks=[early_stopping],
)

# 保存模型为 Keras 本地格式
model.save("my_model.keras")

# 绘制训练和验证损失曲线
plt.plot(history.history["loss"], label="Training Loss")
plt.plot(history.history["val_loss"], label="Validation Loss")
plt.title("Training and Validation Loss")
plt.xlabel("Epochs")
plt.ylabel("Loss")
plt.legend()
plt.show()

S = dfs[featuresx].values
scaler_S = StandardScaler()
S_scaled = scaler_S.fit_transform(S)

starttrain = []
starttrain.append(S_scaled)
starttrain = np.array(starttrain)

print("starttrain shape:", starttrain.shape) # 应为 (样本数, 时间步, 特征数)
# 测试

# pred = model.predict(starttrain)
# print("pred shape:", pred.shape)

# 预测未来几天的经纬度
future_predictions = []

```

```
input_seq = starttrain
```

```
for _ in range(5):
```

```
    pred = model.predict(input_seq)
```

```
    # 提取 lon1 和 lat1 列
```

```
    # 将提取的数据添加到 future_predictions 列表中
```

```
    future_predictions.append(pred)
```

```
    # 创建新的输入：保持原有特征数据的前 7 个，替换最后两个特征为经纬度预测值
```

```
    new_input = input_seq # 保持时间步, (1, time_steps-1, 特征数)
```

```
    pred = pred.reshape(1, 1, 65)
```

```
    # 将 new_input 的部分区域赋值为另一部分的值
```

```
    new_input[:, :, 0:4] = new_input[:, :, 4:8]
```

```
    new_input[:, :, 8:12] = new_input[:, :, 12:16]
```

```
    new_input[:, :, 16:20] = new_input[:, :, 20:24]
```

```
    new_input[:, :, 24:28] = new_input[:, :, 28:32]
```

```
    new_input[:, :, 32:36] = new_input[:, :, 36:40]
```

```
    new_input[:, :, 40:44] = new_input[:, :, 44:48]
```

```
    # 将 pred 的部分值赋给 new_input 的指定切片
```

```
    new_input[:, :, 4:8] = pred[:, :, 0:4]
```

```
    new_input[:, :, 12:16] = pred[:, :, 4:8]
```

```
    new_input[:, :, 20:24] = pred[:, :, 8:12]
```

```
    new_input[:, :, 28:32] = pred[:, :, 12:16]
```

```
    new_input[:, :, 36:40] = pred[:, :, 16:20]
```

```
    new_input[:, :, 44:48] = pred[:, :, 20:24]
```

```
    # 对切片操作确保形状匹配
```

```
    new_input[:, :, 48:51] = new_input[:, :, 52:55]
```

```
    new_input[:, :, 51] = (pred[:, :, 8] - input_seq[:, :, 23]).reshape(1, 1)
```

```
    new_input[:, :, 52:55] = pred[:, :, 24:27]
```

```
    new_input[:, :, 55:58] = new_input[:, :, 59:62]
```

```
    new_input[:, :, 58] = (pred[:, :, 12] - input_seq[:, :, 31]).reshape(1, 1)
```

```
    new_input[:, :, 59:62] = pred[:, :, 27:30]
```

```
    new_input[:, :, 62:65] = new_input[:, :, 66:69]
```

```
    new_input[:, :, 65] = (pred[:, :, 16] - input_seq[:, :, 39]).reshape(1, 1)
```

```
    new_input[:, :, 66:69] = pred[:, :, 30:33]
```

```
    # 对剩余部分进行赋值
```

```
    new_input[:, :, 69:73] = new_input[:, :, 73:77]
```

```
    new_input[:, :, 73:77] = pred[:, :, 33:37]
```

```

new_input[:, :, 77:81] = new_input[:, :, 81:85]
new_input[:, :, 81:85] = pred[:, :, 37:41]

new_input[:, :, 85:89] = new_input[:, :, 89:93]
new_input[:, :, 89:93] = pred[:, :, 41:45]

new_input[:, :, 93:97] = new_input[:, :, 97:101]
new_input[:, :, 97:101] = pred[:, :, 45:49]

new_input[:, :, 101:105] = new_input[:, :, 105:109]
new_input[:, :, 105:109] = pred[:, :, 49:53]

new_input[:, :, 109:113] = new_input[:, :, 113:117]
new_input[:, :, 113:117] = pred[:, :, 53:57]

new_input[:, :, 117:121] = new_input[:, :, 121:125]
new_input[:, :, 121:125] = pred[:, :, 57:61]

new_input[:, :, 125:129] = new_input[:, :, 129:133]
new_input[:, :, 129:133] = pred[:, :, 61:65]

# 更新输入序列，将新的序列用于下一次预测
input_seq = new_input

# 假设 y_train 和 y_test 经过了标准化处理，现在需要对预测的结果进行反向转换

# 对经纬度的标准化器
# 由于 future_predictions 是三维数组（样本数，1，2），需要 reshape 为二维数组进行反向标准化
future_predictions_2d = np.array(future_predictions).reshape(-1, 65)
future_predictions_unscaled = scaler_y.inverse_transform(future_predictions_2d)

# 预测结果反向缩放

# 打印反标准化后的预测经纬度
for i in range(len(future_predictions_unscaled)):
    print(
        f"第 {i+1} 个时间步预测经度：{future_predictions_unscaled[i][0]}，预测纬度：{future_predictions_unscaled[i][4]}"
    )

```

DTW 分析：

```

import matplotlib.pyplot as plt
import cartopy.crs as ccrs
import cartopy.feature as cfeature
from fastdtw import fastdtw
import numpy as np
from scipy.spatial.distance import euclidean

# 真实经纬度数据
real_lon = [135.60, 130.30, 126.20, 120.50, 116.30]
real_lat = [23.60, 27.30, 30.10, 31.50, 33.00]

# 预测经纬度数据
predicted_lon = [
    134.01751708984375,
    133.80987548828125,
    133.6492919921875,
    133.552001953125,
    133.48092651367188,
]
predicted_lat = [
    14.138378143310547,
    14.145237922668457,
    14.103515625,
    14.062126159667969,
    14.006451606750488,
]

# 绘制真实地图上的路径
fig, ax = plt.subplots(
    1, 2, figsize=(15, 7.5), subplot_kw={"projection": ccrs.PlateCarree()}
)
ax[0].set_extent([110, 140, 10, 40], crs=ccrs.PlateCarree())
ax[0].add_feature(cfeature.LAND)
ax[0].add_feature(cfeature.OCEAN)
ax[0].add_feature(cfeature.COASTLINE)
ax[0].add_feature(cfeature.BORDERS, linestyle=":")

# 绘制真实经纬度路径
ax[0].plot(
    real_lon,
    real_lat,
    marker="o",
    color="blue",
    label="Real Path",
    transform=ccrs.PlateCarree(),

```

```

)
for lon, lat in zip(real_lon, real_lat):
    ax[0].text(
        lon,
        lat,
        f"({lon}, {lat})",
        fontsize=8,
        color="blue",
        transform=ccrs.PlateCarree(),
    )

# 绘制预测经纬度路径
ax[0].plot(
    predicted_lon,
    predicted_lat,
    marker="x",
    color="red",
    linestyle="--",
    label="Predicted Path",
    transform=ccrs.PlateCarree(),
)

for lon, lat in zip(predicted_lon, predicted_lat):
    ax[0].text(
        lon,
        lat,
        f"({lon:.2f}, {lat:.2f})",
        fontsize=8,
        color="red",
        transform=ccrs.PlateCarree(),
    )

ax[0].set_title("Real vs Predicted Typhoon Path on Map")
ax[0].legend()

# 执行 DTW 分析并绘制 DTW 匹配路径
real_coords = np.column_stack((real_lon, real_lat))
predicted_coords = np.column_stack((predicted_lon, predicted_lat))
distance, path = fastdtw(real_coords, predicted_coords, dist=euclidean)

# 提取匹配的坐标
real_path_points = [real_coords[i] for i, _ in path]
predicted_path_points = [predicted_coords[j] for _, j in path]

# 绘制 DTW 匹配路径图
ax[1].plot(
    [p[0] for p in real_path_points],

```

```

        [p[1] for p in real_path_points],
        "o-",
        color="blue",
        label="Real Path Points",
    )
ax[1].plot(
    [p[0] for p in predicted_path_points],
    [p[1] for p in predicted_path_points],
    "x--",
    color="red",
    label="Predicted Path Points",
)

# 添加每对匹配的点之间的连线
for real_point, pred_point in zip(real_path_points, predicted_path_points):
    ax[1].plot(
        [real_point[0], pred_point[0]],
        [real_point[1], pred_point[1]],
        "gray",
        linestyle="dotted",
    )

ax[1].set_title(f"DTW Path Matching\nDTW Distance: {distance:.2f}")
ax[1].set_xlabel("Longitude")
ax[1].set_ylabel("Latitude")
ax[1].legend()

plt.show()

```

