

队伍编号	MCB2500884
题号	A

针对复杂场景下集装箱外表面损伤的智能检测与分析系统

摘要

港口自动化与智慧物流的快速发展对集装箱外观损伤的检测精度和处理效率提出了更高要求。传统人工巡检方式效率低、误检率高，难以满足高密度、多批次的实时检测需求。为此，本文基于深度学习与计算机视觉技术，提出了一种从图像级残损判定、目标检测到结构健康评估的集装箱智能检测体系，实现了从视觉识别到安全量化的端到端建模与评估。

针对**问题一**，构建了基于残差神经网络的图像级二分类模型 **CABNet**，实现对“完好/破损”图像的快速判定。针对标签层级不一致问题，本文通过目标实例聚合策略构造图像级标签，并采用轻量卷积架构与迁移学习提升泛化性能。模型在 *test* 数据集上取得**准确率 98.0%**，能够有效完成残损样本的预筛选。

针对**问题二**，提出了改进型 **YOLOv11** 集装箱缺陷检测模型，用于识别凹陷（dent）、孔洞（hole）、锈蚀（rusty）及新增的表面划痕（scratch）四类破损。模型在主干网络中融合多尺度特征融合结构（FPN+PAN）与通道-空间注意力模块（CBAM），并采用 **COCO 预训练权重** 进行迁移学习，最终模型在 *test* 数据集上取得 **Precision = 0.817、Recall = 0.750、mAP@0.5 = 0.809、mAP@0.5:0.95 = 0.628**。通过独立 IoU 匹配脚本验证预测框与真实框重叠率，平均 **IoU = 0.863**，检测成功率 **79.6%**，**F1-score = 0.728**，表明模型在复杂光照与背景干扰下仍具高鲁棒性。

针对**问题三**，基于检测结果构建了集装箱健康评估系统（Container Health Metrics System），实现结构级状态分析与安全等级判定。系统综合考虑缺陷类型、面积比例、位置分布及复合破损关系，建立损伤得分函数 $S_d = \sum_i \omega_{t_i} \cdot s_{a_i} \cdot \omega_{l_i} \cdot p_i$ ，并定义健康指数 $HI = 1 - S_d$ 。在此基础上，引入基于问题一当中的**四分类检测模型**，实现对集装箱健康状态（Excellent、Good、Poor、Critical）的自动识别。批量评估结果显示，系统平均**健康指数为 0.749**，其中 **Excellent 与 Good 样本占比 51.0%**，高风险样本（Poor + Critical）占比 **28.3%**。四分类模型在 *test* 数据集上达到**总体准确率 80.0%**，进一步验证了健康指数在表征结构状态方面的有效性与可学习性。

关键词：深度学习；计算机视觉；CABNet；YOLOv11；集装箱健康评估系统

目录

一、引言	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
二、问题一求解	6
2.1 问题一分析	6
2.2 模型建立	7
2.2.1 特征提取骨干网络	8
2.2.2 注意力块	8
2.2.3 分类器模块	9
2.3 模型求解	10
2.4 结果分析	11
三、问题二求解	14
3.1 问题二分析	14
3.2 模型建立	15
3.3 模型求解	16
3.4 结果分析	17
四、问题三求解	19
4.1 多分类集装箱缺陷检测模型	19
4.1.1 数据处理	19
4.1.2 模型求解	20
4.1.3 结果分析	21
4.2 集装箱健康状态分析系统	22
4.2.1 系统设计	23
4.2.2 结果分析	23
五、总结与展望	26
5.1 研究总结	26
5.2 研究展望	26
参考文献	28
附录 1: 问题一的 python 代码	31
附录 2: 问题二的 python 代码	48
附录 3: 问题三的 python 代码	127
3.1 多分类集装箱缺陷检测模型	127
3.2 集装箱健康状态分析系统	147

一、引言

1.1 研究背景与意义

在全球贸易持续扩张与现代物流体系日益复杂的背景下，集装箱作为国际货运的核心载体，其结构完整性与外观状态对保障运输安全与货物完好具有关键作用。在长期的装卸、堆叠及远途运输过程中，集装箱容易受到机械碰撞、环境侵蚀与结构疲劳等因素影响，导致表面出现裂纹、凹陷、锈蚀乃至穿孔等损伤。这些损伤若未能及时发现并处理，不仅会显著缩短集装箱的使用寿命，还可能引发货物受潮、污染等安全事故，给物流企业带来严重经济损失与运营风险。

目前，集装箱的外观检查仍主要依赖人工目视，该方法不仅效率低下，且受人员经验、疲劳程度及现场环境等多种因素影响，检测结果主观性强，难以满足现代化港口对高效率、自动化作业的需求。随着人工智能技术，尤其是计算机视觉领域的快速发展，基于图像的自动化缺陷检测逐渐成为替代人工检查的有效手段。通过在港口关键位置部署边缘算力设备，并结合先进算法，可实现集装箱外观状态的实时、高效与精准评估，显著提升检测的自动化水平与可靠性。

因此，研究具备高鲁棒性与泛化能力的智能检测技术，推动集装箱破损检测从“人眼判别”向“机器视觉”的转变，不仅有助于提升港口作业效率、降低运营成本，也对促进物流行业智能化升级、保障全球供应链安全具有重要的现实意义。

1.2 国内外研究现状

集装箱作为全球供应链的关键载体，承载了世界贸易的大部分货物流动^[1]；近年在地缘冲突、航线绕行与成本波动背景下，其周转效率与安全合规的重要性进一步上升，亟需依托标准化、可量化的状态评估体系支撑运营连续性与风险控制。现场人工巡检受强反光、阴影、污渍与多尺度损伤（如凹陷、裂纹、锈蚀）干扰，存在主观性强、效率低与覆盖不足的问题^[2]。基于计算机视觉的集装箱破损智能检测，能够在复杂背景下实现快速有无损筛查与关键区域精细定位，为港口与运营方提供可追溯证据链与可复制流程，因而具有突出的现实必要性 with 推广价值。

最早期的研究多以手工特征与规则或传统学习器为主线，围绕“增强—分割—表征—判别”的工程化流程展开。早期在海事金属结构领域，Bonnín-Pascual 与 Ortiz^[3]提出基于连通性与渗流思想的裂纹生长检测与基于颜色直方图与 GLCM 的锈蚀识别，在近实时条件下实现了裂纹连通形态的鲁棒提取与锈蚀区域的候选筛选，奠定了后续海事表面缺陷视觉化检测的算法雏形。其后，Ortiz 等人^[4]将图像采集平台与轻量前馈神经网络结合到船体巡检中，利用微型无人机拓展视角覆盖，以颜色与纹理等显式特征作为输入完成涂层破损与腐蚀的自动判别，显著缓解传统人工近距巡检的效率瓶颈。在“几何与多视”方向，Aijazi 等人^[5]基于多视位彩色三维 LiDAR 点云配准开展船体表面锈蚀斑点的自动检测与分析，通过跨视角重建减轻单幅图像光照与反光扰动的影响，提升了候选区域的一致性与可量化性。与此同时，工业表面检测的经典管线在多材料场景不断被验证。例如 Li 等人^[6]以 Gabor 滤波与 PCNN 进行织物缺陷增强与分割，体现了频域纹

理与脉冲耦合神经网络在弱对比缺陷上的互补性；针对金属与焊缝等结构化工业纹理，早期研究通常采用以梯度方向直方图等显式特征与支持向量机等分类器构成的“特征—分类器”范式来建立基线；在一般工业表面检测中，Ding 等人^[7]验证了 HOG 与支持向量机结合并配合 AdaBoost 特征选择的有效性，能够在低样本与近实时条件下保持鲁棒；而在焊缝射线图像场景，Valavanis 与 Kosmopoulos^[8]将几何与纹理描述子与多类支持向量机等学习器结合，实现对气孔、未融合与裂纹等多类型缺陷的自动识别，随后 Kasban 等人^[9]基于倒谱与高阶谱特征提出了自动检测流程，并在噪声与模糊条件下系统评估其鲁棒性。总体而言，这一时期的方法在可解释性与实现简便上具优势，但对复杂背景、强反光与阴影、多尺度与类别长尾仍敏感，跨场景泛化与极小缺陷（如细裂缝）召回率受限，从而为后续基于深度学习的端到端方法留出了改进空间。

在深度学习技术快速发展的背景下，卷积神经网络凭借其端到端学习与层次化特征表征能力，逐渐成为集装箱破损检测的主流方法，并催生了从图像分类到目标检测、再到精细分割的完整技术体系。早期研究者将深度卷积神经网络引入集装箱破损识别任务，İmamoğlu 等人^[10]对比了多种卷积神经网络架构在集装箱损伤二分类任务中的性能，通过实验验证了深度学习相比传统方法在准确率与鲁棒性上的显著优势，为后续研究奠定了基础。为实现破损区域的精确定位，目标检测技术被引入集装箱检测任务。Ren 等人^[11]提出的 Faster R-CNN 通过区域提议网络生成候选破损区域再经精细分类与边界框回归，实现了多类型破损的精确定位，其特征金字塔结构对多尺度破损具有良好适应性。Redmon 等人^[12]提出的 YOLO 系列通过单次前向传播同时完成分类与定位，显著提升了检测速度使实时监测成为可能；其后发布的 YOLOv3^[13]采用 Darknet-53 骨干网络并引入多尺度预测策略，在保持速度优势的前提下提升了小目标检测性能。针对集装箱检测的特殊挑战，研究者们采用 Focal Loss 等损失函数缓解类别不平衡问题，设计多尺度特征融合策略增强对不同尺寸破损的检测能力。尽管目标检测方法解决了破损定位问题，但矩形边界框难以精确描述锈蚀与裂纹等不规则形状。为获得像素级精细定位结果，Ronneberger 等人^[14]提出的 U-Net 采用编码器-解码器结构与跳跃连接，通过融合浅层细节与深层语义信息实现了对破损边界的精细勾勒；He 等人^[15]提出的 Mask R-CNN 在 Faster R-CNN 基础上增加分割分支，同时完成检测、分类与像素级分割，有效处理多个破损区域重叠的复杂情况。研究者们进一步引入注意力机制突出破损特征并抑制背景干扰，为破损的定量评估提供了精确信息基础。尽管卷积神经网络在破损检测中取得显著进展，但现有方法在多尺度特征融合和跨层级信息交互方面仍存在局限，导致对不同尺寸破损目标的泛化能力不足，特别是在复杂港口环境中容易出现误检与漏检并存的现象，为提高模型多尺度特征的判别能力提供研究方向。

随着深度学习技术在工业视觉检测中的广泛应用，基于 YOLO 系列和 ResNet 架构的改进模型逐渐成为集装箱破损检测的研究热点。这些方法在保持高推理速度的同时，通过优化网络结构、增强特征融合机制和引入注意力模块，显著提升了多尺度破损特征的提取能力与定位精度。在 YOLO 架构的改进方面，研究者针对集装箱表面破损的多尺度特性与复杂背景干扰进行了系列优化。Redmon 等人^[13]提出的 YOLOv3 首次引入 Darknet-53 骨干网络，通过残差连接缓解深层网络梯度消失问题，为后续改进奠定基础。Bochkovskiy 等人^[16]提出的 YOLOv4 整合了 Mish 激活函数、SPP 模块和尤其能增强多

尺度特征融合的 PANet 结构,显著提升了对小尺度目标的检测性能,从而为后续将其应用于锈蚀斑点等微小缺陷的检测奠定了坚实基础。

针对集装箱表面细微裂纹与锈蚀等小尺度破损难检测的问题,可借鉴自动驾驶领域的小物体检测思路。Benjumea 等人^[17]提出的 YOLO-Z 模型,通过替换骨干网络、增加检测层与优化锚框,有效增强了 YOLOv5 的微小目标检测能力,为该问题提供了直接的技术方案。Li 等人^[18]针对金属板材表面气孔、夹杂等微小点状缺陷在复杂纹理背景下难以识别的问题,将高效的 EMA 注意力机制嵌入 YOLOv7 的骨干网络末端,有效增强了模型对细微瑕疵的特征提取能力。为解决集装箱图像中破损区域尺度差异大的问题,Liu 等人^[19]提出的 YOLOv8 模型,其本身通过重新设计的特征金字塔的高效的 C2f 模块,实现了强大的多尺度特征融合能力,为检测不同尺寸的破损提供了先进的基准模型。在 YOLOv8 已为多尺度破损检测提供强大基准的基础上,后续版本在精度与效率的平衡以及特定缺陷的感知能力上持续深化。针对集装箱图像中破损形态的极端多样性与背景的复杂性,Wang 等人^[20]提出的 YOLOv9 模型引入了可编程梯度信息 (PGI) 和广义高效层聚合网络 (GELAN),从根本上解决了深度网络中信息丢失所带来的瓶颈。该设计确保了从浅层细节特征到深层语义特征的高效传输与利用,使其在面对集装箱表面大面积油漆剥落与细微裂纹并存等复杂场景时,仍能保持卓越的特征表征能力,显著提升了复杂破损模式的综合检出率。为满足港口实时检测系统对极高推理速度的需求,YOLOv10 模型由 Ao 等人^[21]进行了开创性的端到端优化。该模型通过提出“一致性双重分配”训练策略,成功摒弃了对非极大值抑制 (NMS) 后处理的依赖,从而大幅降低了推理延迟。同时,其引入的新型部分自注意力模块 (PSA) 有效捕获了破损区域的长程空间依赖关系,在不牺牲速度的前提下,尤其强化了对集装箱表面长条状刮痕、拼接缝开裂等线性延伸缺陷的连续定位精度,实现了精度与速度的兼得。

在 ResNet 骨干网络的优化方面,研究者通过增强特征表征能力与感受野扩展来提升破损分类的准确性。针对集装箱表面的细微缺陷,Zhang 等人^[22]提出的 ResNeSt 网络通过其特征图分组与跨组注意力机制,能自适应地聚焦于裂纹、锈蚀等关键特征,显著增强了模型在复杂背景下的特征判别能力,为精准检测提供了强大支持。Chen 等人^[23]提出的 DeepLab 模型通过其核心组件——空洞空间金字塔池化 (ASPP),利用并行多空洞率卷积捕获多尺度上下文信息。这一机制为提升模型对集装箱表面尺度各异破损的检测能力与边界定位精度,提供了关键技术方案。针对集装箱破损的多尺度特性,Chen 等人^[24]通过在其 ASPP 模块中集成图像级特征,有效增强了模型捕获全局上下文的能力。该设计能精准建模从细微裂纹到大面积锈蚀的完整信息,显著提升检测鲁棒性。在轻量化方向,为满足实时检测与边缘部署的需求,研究者采用了专为移动端设计的高效架构。例如,Sandler 等人^[25]提出的 MobileNetV2,通过其核心的倒残差结构与线性瓶颈,在保证特征表达能力的同时,极大地降低了模型的参数量与计算复杂度。该网络可作为替代 ResNet 等大型骨干网络的轻量级基础,为在算力受限的港口现场部署集装箱破损检测系统提供了关键技术支持。

尽管基于改进 YOLO 和 ResNet 的方法在集装箱破损检测中取得显著进展,但在实际应用中仍面临诸多挑战。由于真实场景中破损样本分布极不均衡,模型训练易被大量简单负样本 (正常箱体表面) 主导,导致对稀少的细微裂纹等缺陷学习不足。为应对此

挑战，Lin 等人^[26]提出的 Focal Loss 通过重塑损失函数，降低易分类样本的权重，使模型聚焦于难例与少数类样本，从而有效缓解了类别不平衡问题。其次，港口环境中的光照变化、天气因素与拍摄角度差异导致模型泛化能力受限。Wang 等人^[2]采用基于卷积神经网络的迁移学习框架，通过在大规模数据集上预训练提升模型在少量集装箱样本上的特征提取能力。为满足港口边缘计算设备的部署需求，模型轻量化是关键环节。Han 等人^[27]提出的网络剪枝技术，“通过训练-剪枝-微调”的三步范式，系统性地移除了神经网络中的冗余连接，能够在保证模型预测精度的同时，显著降低其参数量与计算复杂度。该技术为实现集装箱破损检测模型在资源受限环境下的高效、实时推理提供了核心方法论支持。

基于上述分析，可以看出，集装箱破损检测技术经历了从传统手工特征与机器学习方法，到基于深度学习的端到端智能识别系统的快速发展。尤其是以 YOLO 系列和 ResNet 为代表的现代卷积神经网络及其改进模型，在多尺度特征融合、注意力机制、轻量化设计等方面取得了显著进展，有效提升了检测的精度、鲁棒性与实时性。然而，面对真实港口环境中复杂的光照变化、背景干扰、样本分布不均以及细微缺陷难以捕捉等挑战，现有方法在泛化能力、小目标检测精度与边缘部署效率方面仍有提升空间。研究应进一步聚焦于跨场景自适应学习、小样本缺陷识别、多模态数据融合以及轻量化模型优化等方向，以推动集装箱破损检测技术在实际工业场景中的全面落地与应用深化。本文研究流程见图1，贡献如下：

1. 基于 ResNet18 骨干网络，引入了双重注意力机制（全局注意力 GAB 与类别注意力 CAB），显著增强了对集装箱表面缺陷的特征判别能力，在复杂背景下实现了高精度的图像集二分类及四分类。
2. 针对多尺度、多类别的集装箱破损检测任务，优化了 YOLOv11 结构，提升了在复杂光照与背景干扰下对凹陷、破洞、锈蚀等缺陷的检测精度与鲁棒性。
3. 设计了一套完整的集装箱健康状态智能分析系统，从数据构建、模型设计到系统实现，形成了从算法创新到实际落地的闭环解决方案，为港口自动化检测提供了可靠的技术支撑。




图 1 本文研究流程图

二、问题一求解

2.1 问题一分析

本研究的目标是进行图像级二分类：给定一张集装箱外观图像，判定其是否存在任何形式的残损。原始数据以 3 分类格式提供，而本任务要求二分类语义，需要正负样本；但是通过脚本分析，所给数据集均是含有标签的破损图片，这带来样本不均衡与负样本缺失问题。此外，拍摄环境复杂、视角与尺度多样、箱体材质与油漆纹理差异显著，小缺陷在全图中像素占比极低，均会削弱分类器对有效区域的关注并放大背景偏差。除光照变化与成像噪声等环境因素外，数据样本的选取策略及标注设置亦带来显著挑战（见图），进一步加剧了训练与评测的一致性难题。基于上述考虑，我们在图像层面对实例级标注进行聚合与重述：只要图中存在任一缺陷实例，则记为“有损”；否则为“无损”。在这一界定下，关键难点转化为如何获得高质量且不引入偏差的负样本，以及如何避免模型学习到与缺陷无关的背景捷径特征。



图 2 样本选取与标注设置带来的挑战示例：重度损伤图像及其遮挡生成对照

为弥补原始数据中负样本缺失的问题，本文对每幅带有缺陷标注的图像按其矩形标注框进行区域性覆盖处理，生成与原图一一对应的合成图像（见图）。原图保留全部缺陷信息，标注为标签 1（故障）；合成图将缺陷区域以白色矩形覆盖，标注为标签 0（正常）。该操作在全集上统一执行，从而构建正负样本等量（1:1）的平衡数据集。覆盖处理严格受标注框约束，不对图像其余区域的光照、背景与成像参数做任何改动，因而在尽可能保持原始数据分布稳定的前提下，完成二分类所需的高质量负样本构建。



(a) 原始损伤图像



(b) 矩形遮挡生成的对照图

图 3 损伤场景的正负样本构建示例

2.2 模型建立

CABNet (Category Attention Block Network) 是一种以 ResNet-18 为骨干的图像分类模型。其设计的关键在于引入双重注意力机制以强化判别特征：一方面，通过全局注意力块 (Global Attention Block, GAB) 在空间维度上自适应地重加权特征，突出与判别相关的空间区域；另一方面，通过类别注意力块 (Category Attention Block, CAB) 显式引入类别语义，为每个类别学习特定的注意力图，使得模型能够在“为不同类别看不同区域”的机制下抑制背景干扰，并提升细粒度差异的可分性。与传统的单一注意力机制 (如仅关注空间或通道的注意力) 不同，CAB 通过将类别信息直接并入注意力学习过程，理论上有助于缓解类间不平衡问题或局部弱小缺陷带来的表示偏差。

此外，CABNet 在处理长尾分布数据上展现了优异的表现。由于类别注意力机制的引入，模型能够更好地关注那些在样本中较少出现的类别，从而有效提高少数类 (长尾类) 的识别精度，减少其在训练过程中可能出现的误分类现象。




图 4 CABNet 模型结构图^[28]

整体架构采用“特征提取—注意力增强—分类预测”的三级串联。首先，输入图像经 ResNet-18 主干提取中高层语义特征。GAB 依次执行通道选择与空间聚焦，得到全局增强特征；CAB 按类别数 K 与每类注意力图数量 k 生成类别敏感的语义注意力，并与特征逐元素交互以形成类别特异的增强表征。最后，经过全局池化与全连接分类头给出图像级预测。该设计在保留 ResNet 结构性优势与训练稳定性的同时，通过注意力机制在复杂光照、视角多样与小目标比例较低等条件下有望提升模型对关键区域与类别特异模式的精确捕获与解释性。

2.2.1 特征提取骨干网络

本文采用 ResNet18 作为特征提取的骨干网络。ResNet18 是残差网络家族中的轻量级版本，包含四个残差块组，总共 18 层卷积层。残差连接通过跳跃连接机制有效缓解深度网络训练中的梯度消失，使网络能够学习恒等映射，从而在保证模型深度的同时维持训练稳定性。

对于输入图像 $\mathbf{X} \in \mathbb{R}^{B \times 3 \times 640 \times 640}$ (B 为批次大小)，ResNet18 先经 7×7 卷积与最大池化完成初步下采样，随后通过四组残差块逐步提取多尺度特征。每个残差块由两个 3×3 卷积与一条跳跃连接组成，其形式化表示为

$$\mathbf{F}_{i+1} = \mathcal{H}(\mathbf{F}_i) + \mathbf{F}_i,$$

其中 $\mathcal{H}(\cdot)$ 表示残差块内的卷积变换。完整骨干网络输出特征为

$$\mathbf{F} \in \mathbb{R}^{B \times 512 \times 20 \times 20},$$

对应于总下采样步长 32 ($640 \rightarrow 320 \rightarrow 160 \rightarrow 160 \rightarrow 80 \rightarrow 40 \rightarrow 20$) 与通道维 512。为对接后续注意力模块，本文移除了 ResNet18 原结构中的全局平均池化层与全连接分类层，仅保留卷积特征提取部分。

2.2.2 注意力块

注意力块 (Attention Block) 的设计灵感源于人类视觉系统中的选择性注意机制。在观察图像时，人类并不会对所有区域给予同等关注，而是会聚焦于显著性区域和重要的特征通道。为了模拟这一过程，CABNet 引入了类别注意力块 (Category Attention Block, CAB) 和全局注意力块 (Global Attention Block, GAB)，通过自适应地加权特征图中的不同类别特征和空间区域，使得网络能够突出与判别任务相关的类别信息，并抑制背景或不重要区域的干扰。

全局注意力块主要通过空间维度上的自适应加权，使网络能够在不同空间位置上关注显著的区域。这种机制基于空间信息和类别信息的联合建模，在模型的特征表达中引入全局上下文信息，从而帮助模型更好地理解不同空间区域的重要性。而类别注意力机制的核心思想是显式引入类别语义，针对每个类别学习其专有的注意力图，从而使得模型能够在不同类别之间关注不同的区域。这种“为每个类别选择性地关注不同区域”的策略

略，可以有效提高细粒度分类任务的判别能力，特别是在处理不同类别间细微差异的场景下，展现出了显著的优势。

对于输入特征 $\mathbf{F} \in \mathbb{R}^{B \times C \times H \times W}$ ，类别注意力块首先通过卷积操作对输入特征进行处理，将特征图压缩至 1×1 大小，并通过全局平均池化（Global Mean Pooling, GMP）操作获得每个类别的全局统计信息：

$$\mathbf{z} = \text{GMP}(\mathbf{F}) \in \mathbb{R}^{B \times C \times 1 \times 1}$$

接着，使用多层感知机（MLP）进一步学习类别间的非线性依赖关系，并生成每个类别的注意力权重 $\mathbf{A}_c$ ：

$$\mathbf{A}_c = \sigma(\text{MLP}(\mathbf{z}))$$

通过广播机制，类别注意力权重 $\mathbf{A}_c$ 被应用于原始特征 $\mathbf{F}$ ，完成类别维度的加权操作：

$$\mathbf{F}_{ca} = \mathbf{A}_c \odot \mathbf{F}$$

这一步骤确保了不同类别的特征能够被有选择地强化，从而提升模型对每个类别的识别能力。

此外，类别注意力块还能够有效抑制类别间的干扰，并显著提高模型在长尾分布数据上的性能。通过类别信息的显式引入，CABNet 能够在不平衡数据集上更好地聚焦于少数类别的特征，减少类间不均衡带来的表示偏差。最终，类别加权后的特征 $\mathbf{F}_{ca}$ 通过进一步的卷积和全连接层，得到模型的最终输出，增强了模型对各类别的判别能力，并优化了细粒度缺陷的识别精度。

通过将全局注意力块与类别注意力块的结合，CABNet 在处理图像级任务时，能够有效地聚焦于相关类别的区域，并抑制其他干扰信息，进一步提高了模型在细粒度任务中的表现。

2.2.3 分类器模块

经过双重注意力增强后的特征 $\mathbf{F}_{cab}$ 包含了丰富的判别性信息，但仍为空间分布的特征图。分类器模块负责将这些空间特征聚合为全局表征，并映射到类别预测空间。

首先通过自适应平均池化将空间维度压缩，得到全局特征向量：

$$\mathbf{v} = \text{AdaptiveAvgPool2d}(\mathbf{F}_{cab}).\text{view}(B, -1) \in \mathbb{R}^{B \times 512}$$

随后采用多层感知机（MLP）结构进行分类。MLP 由三个全连接层组成，隐藏层维度逐渐递减，形成特征的层级抽象。在每个隐藏层后添加 Dropout 以防止过拟合，dropout 概率分别设置为 0.5 和 0.3：

$$\mathbf{h}_1 = \text{Dropout}(\text{ReLU}(\text{Linear}(\mathbf{v}, 512))), p = 0.5$$

$$\mathbf{h}_2 = \text{Dropout}(\text{ReLU}(\text{Linear}(\mathbf{h}_1, 256))), p = 0.3$$

$$\mathbf{y} = \text{Linear}(\mathbf{h}_2, C_{cls})$$

最终输出 $\mathbf{y} \in \mathbb{R}^{B \times C_{cls}}$ 为各类别的预测 logits，经过 Softmax 归一化后即可得到类别概率分布。这种渐进式的降维设计有助于模型学习更抽象的类别表征，同时通过 Dropout 机制增强模型的泛化能力。

2.3 模型求解

本研究采用端到端监督训练以最小化二分类交叉熵目标。设样本的原始输出为 z_i (logit)，经 Sigmoid 激活得到概率 $\hat{y}_i = \sigma(z_i) = 1/(1 + e^{-z_i})$ ，对应真实标签 $y_i \in \{0, 1\}$ ，批大小为 N ，则损失定义为

$$L = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)].$$

该目标函数通过最小化预测分布与真实分布之间的交叉熵距离，引导模型在正负样本判别上实现最优分界。

训练在 Windows 11 环境下完成，使用 PyTorch 框架实现。系统在运行时自动检测 CUDA 可用性，优先使用 GPU 加速；图像在输入网络前统一为 640×640 像素，并按 ImageNet 统计量进行标准化，

$$I' = \frac{I - [0.485, 0.456, 0.406]}{[0.229, 0.224, 0.225]},$$

随后由数据加载器完成批量读取与张量转换 (PIL 图像 $\rightarrow$ Tensor)，训练集在每个 epoch 打乱顺序，验证集保持固定以保证评估一致性。

优化器采用 Adam，初始学习率设为 1×10^{-3} ，权重衰减系数为 1×10^{-4} 以抑制过拟合。学习率调度策略采用 ReduceLROnPlateau，当验证损失在连续 10 个 epoch 内未改善时，学习率按 0.5 倍比例衰减。训练总轮数为 100；每 10 轮保存一次检查点，并额外保存验证集性能最优的模型权重。主要超参数设置见表 1。

表 1 训练超参数与策略

参数	数值/策略
批次大小 (Batch Size)	32
训练轮数 (Epochs)	100
优化器	Adam
初始学习率	0.001
权重衰减	1e-4
学习率调度	ReduceLROnPlateau (耐心 10, 衰减因子 0.5)
检查点保存	每 10 轮保存一次，另保存验证集最佳模型

模型性能在验证集上通过多种分类指标进行评估。设 TP 、 FP 、 TN 、 FN 分别表示真阳性、假阳性、真阴性与假阴性样本数，则：

$$\begin{aligned} \text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN}, \\ \text{Precision} &= \frac{TP}{TP + FP}, \\ \text{Recall} &= \frac{TP}{TP + FN}, \end{aligned}$$

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}.$$

上述训练与评估流程保证了损失函数的稳定收敛与性能结果的可复现性。通过学习率自适应衰减与权重正则化策略，模型在验证集上表现出良好的泛化能力。流程图如5所示。




图 5 CABNet 模型训练与评估流程图

2.4 结果分析




图 6 准确率和损失曲线

训练准确率和验证准确率曲线呈现出高度一致的上升趋势。训练准确率从初始的约 65% 快速攀升，在第 15 个 epoch 达到 90% 以上，随后持续振荡上升至 95% 左右并保持稳定。验证准确率的变化轨迹与训练准确率基本同步，最终收敛至 94%-96% 区间。

验证准确率曲线同样表现出与损失曲线相对应的周期性波动特征，在第 50、80 和 95 个 epoch 附近分别出现显著下降，最低点分别降至约 63%、70% 和 72%。这些波动点与验证损失的峰值位置高度吻合，进一步印证了模型在特定训练阶段经历了暂时性的性能波动。然而，模型在每次波动后均能迅速恢复至高准确率水平，说明网络具备较强的鲁棒性和自我修正能力。

在第 100 个 epoch，模型最终的验证准确率稳定在约 95%，与训练准确率基本持平，两者之间的差距小于 1 个百分点。这种训练集与验证集性能的高度一致性表明模型具备良好的泛化能力，能够有效应用于未见数据的分类任务。




图 7 混淆矩阵

混淆矩阵清晰展示了模型在两个类别（Normal 和 Fault）上的详细分类表现。从原始计数混淆矩阵可以看出，模型对两类样本的识别能力高度均衡：对于 Normal 类别，模型正确识别 409 个样本，仅有 4 个样本被误分类为 Fault 类别，对应的类内准确率为 99.0%。对于 Fault 类别，模型正确识别 400 个样本，有 13 个样本被误分类为 Normal 类别，对应的类内准确率为 96.9%。

归一化混淆矩阵进一步量化了分类性能：Normal 类别的真阳性率（True Positive Rate）为 0.990，假阴性率（False Negative Rate）为 0.010；Fault 类别的真阳性率为 0.969，假阴性率为 0.031。从预测角度来看，当模型预测为 Normal 时，有 0.969 的概率是正确的；当模型预测为 Fault 时，有 0.990 的概率是正确的。

分类报告提供了精确率（Precision）、召回率（Recall）和 F1 分数三个关键指标，全面评估了模型的分类性能：

Normal 类别表现：精确率为 0.969，召回率为 0.990，F1 分数为 0.980。高召回率表明模型对 Normal 类别具有出色的识别敏感性，能够捕获绝大多数正常样本；精确率为 0.969 表明在模型预测为 Normal 的样本中，仅有 3.1% 为误判。F1 分数作为精确率和召回率的调和平均，达到 0.980，表明模型在两个指标上取得了良好的平衡。

Fault 类别表现：精确率为 0.990，召回率为 0.969，F1 分数为 0.979。精确率达到 0.990 表明模型在预测 Fault 类别时具有极高的置信度，误报率仅为 1.0%；召回率为 0.969 表




图 8 分类性能指标

明模型能够识别出 96.9% 的故障样本，漏检率为 3.1%。F1 分数为 0.979，与 Normal 类别基本持平，说明模型在两个类别上的整体性能高度均衡。

两个类别的 F1 分数均接近 0.98，这一结果充分证明了 CABNet 架构的有效性。全局注意力块（GAB）通过通道和空间双重注意力机制，成功捕获了区分 Normal 和 Fault 的关键特征；类别注意力块（CAB）为两个类别学习了专门的语义表征，使得模型能够精准定位判别性区域。双重注意力机制的协同作用使得网络在处理二分类任务时展现出卓越的判别能力。

总体而言，模型在二分类任务中取得了优异的性能，总体准确率达到 98%。其中 Normal 类别的精确率和召回率分别达到 97% 和 99%，Fault 类别的精确率和召回率分别达到 99% 和 97%，F1 分数均达到 98%。实验结果充分验证了 CABNet 架构在二分类任务中的有效性和鲁棒性，双重注意力机制的设计显著提升了模型的特征判别能力，为解决实际工程中的分类问题提供了可靠的技术方案。

三、问题二求解

3.1 问题二分析

问题二要求在存在残损的集装箱图像中，自动定位出残损区域并识别其类型。该任务实质上属于计算机视觉领域中的目标检测与实例分割问题，核心目标是对输入图像进行像素级或区域级的缺陷识别。

从赛题数据来看，数据集共包含 3713 张图像，其中训练集 3300 张、测试集 413 张，标注格式为 YOLO 标准格式。共有三类破损类型：凹陷（*dent*）、破洞（*hole*）与锈蚀（*rusty*）。每个标签文件均记录了目标框的中心坐标与宽高比例信息，因此该任务可建模为一个多类别目标检测问题。然而，问题二存在多重挑战：如图9所示，首先，图像背




图 9 赛题原始数据

景复杂，包含港口机械、地面、天空等干扰信息；其次，光照条件、反光与污渍会造成显著噪声；第三，不同类型缺陷的尺寸差异较大，既有微小裂纹，也有大面积锈蚀，导致模型需具备多尺度特征提取能力；最后，类别分布不均衡，如“裂缝”或“破洞”等小样本类别可能被主导类别“凹陷”所掩盖，造成检测偏差。

综上，问题二的核心任务是构建一个在复杂背景下具备多尺度检测能力、能有效区分不同类型破损的视觉检测模型。该模型应能在保持检测精度的同时，兼顾轻量化与实时性，以满足港口自动化场景中的部署需求。

3.2 模型建立

为解决集装箱图像中残损区域的自动检测与分类问题，本文构建了基于改进型 YOLO 架构的目标检测模型，骨干网络为 YOLOv11^[29]。该模型旨在实现多尺度特征提取、复杂背景抑制与轻量化推理的平衡，以应对港口环境中光照变化、阴影反射及结构差异显著等问题。

模型整体结构由三部分组成：特征提取网络、特征融合模块与检测头。主干网络采用改进的 CSPDarknet 结构，其通过跨阶段部分连接机制（Cross Stage Partial, CSP）在保持特征表达能力的同时显著降低冗余计算量。设输入图像为 $I \in \mathbb{R}^{H \times W \times 3}$ ，则经卷积与归一化操作后得到多尺度特征映射

$$F = \{f_1, f_2, f_3, f_4, f_5\},$$

其中 f_i 表示第 i 层的特征输出。浅层特征保留纹理信息，深层特征包含语义信息，为后续多尺度融合奠定基础。

为增强模型对不同尺度破损的响应能力，本文引入 FPN（Feature Pyramid Network）与 PAN（Path Aggregation Network）相结合的特征融合结构，实现由底向上与自顶向下的双向信息流传递。经融合后的多层特征可表示为

$$F' = \phi_{\text{PAN}}(\phi_{\text{FPN}}(F)),$$

其中 ϕ_{FPN} 与 ϕ_{PAN} 分别表示特征金字塔与路径聚合变换算子。该结构强化了高层语义与低层细节之间的互补性，使模型在检测微小裂缝与大面积锈蚀时均具备稳定性能。

考虑到复杂背景与噪声干扰可能削弱特征判别性，模型在特征融合阶段嵌入通道-空间注意力机制（CBAM），通过显式建模通道权重与空间权重，实现显著区域的自适应强化。设输入特征为 X ，则注意力权重矩阵计算形式为

$$M(X) = \sigma(W_s(\delta(W_c(X))))),$$

其中 W_c 与 W_s 分别为通道与空间权重映射， $\delta(\cdot)$ 表示非线性激活， $\sigma(\cdot)$ 为 Sigmoid 函数。经加权后的特征表示为 $\hat{X} = M(X) \odot X$ ，从而提升模型在复杂环境下的鲁棒性。

检测头采用解耦式结构，将分类分支与回归分支分离，以提高损失优化的独立性与收敛效率。定位任务采用 Complete IoU（CIoU）损失函数

$$L_{\text{CIoU}} = 1 - \text{IoU} + \frac{\rho^2(b, b^*)}{c^2} + \alpha v,$$

其中 ρ 表示预测框与真实框中心点距离， c 为最小外接框对角线长度， v 表示长宽比一致性项。分类任务采用二元交叉熵（BCE）损失函数

$$L_{\text{cls}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)],$$

两者联合构成总损失

$$L = \lambda_1 L_{\text{CIoU}} + \lambda_2 L_{\text{cls}},$$

其中 λ_1 与 λ_2 为权重系数。优化器采用 AdamW，结合余弦退火学习率策略以实现稳定收敛。

通过上述结构设计，模型在保证检测精度的同时，具备较高的特征表达与环境适应能力，为复杂背景下多类型残损的智能识别提供了有效建模基础。

3.3 模型求解

模型训练过程旨在最小化前述综合损失函数 L ，以实现检测精度与定位精度的协同最优。实验在 NVIDIA RTX A6000 GPU（48 GB 显存）环境下完成，利用其大显存优势将批大小（batch size）设置为 96，从而在保持显存可控的前提下提高梯度估计稳定性并加速模型收敛。

为充分利用大规模通用视觉特征，模型初始化采用基于 COCO 数据集的 YOLOv11 预训练权重。该预训练模型在多类自然场景目标上学习到丰富的结构与纹理特征，能够为集装箱破损检测提供良好的特征迁移基础。通过迁移学习机制，模型在少量任务特定样本下即可获得较高的初始识别能力，显著缩短训练时间并提升检测性能。

训练数据来源于官方提供的 3713 张集装箱图像数据集，其中训练集 3300 张、测试集 413 张。数据采用 YOLO 标准格式，每个样本包含类别编号及相对坐标信息。由于各类破损样本数量差异显著，训练阶段采用分层采样策略以平衡不同类别比例，缓解模型对主类“凹陷（dent）”的偏置。

为增强模型的泛化性能与鲁棒性，训练阶段引入多样化数据增强策略，包括随机水平翻转、亮度与对比度扰动、高斯模糊及仿雨污渍叠加。设原始图像为 I ，增强算子为 $\mathcal{A}(\cdot)$ ，则增强后样本表示为：

$$\tilde{I} = \mathcal{A}(I),$$

其中 $\mathcal{A}$ 服从随机组合分布，以模拟港口环境中不同光照与背景条件。进一步采用 Mosaic 与 MixUp 等复合增强机制，将多图拼接与线性混合策略结合，扩展特征分布的多样性，提升跨尺度目标检测能力。

优化器选用 AdamW，其权重衰减项有效抑制梯度震荡与过拟合。动量参数设定为 $(\beta_1, \beta_2) = (0.9, 0.999)$ ，权重衰减系数 1×10^{-4} 。初始学习率 $lr_0 = 1 \times 10^{-3}$ ，采用余弦退火学习率衰减策略：

$$lr_t = lr_{\min} + \frac{1}{2}(lr_0 - lr_{\min}) \left(1 + \cos \frac{t}{T_{\max}} \pi \right),$$

其中 $lr_{\min}$ 为最小学习率， t 为当前迭代步数， $T_{\max}$ 为总迭代轮数。模型训练共进行 300 轮（epochs），前期以较大学习率加速特征学习，后期逐步降低以实现参数稳定收敛。

损失函数按照

$$L_{\text{total}} = \lambda_1 L_{\text{CIoU}} + \lambda_2 L_{\text{cls}},$$

进行端到端反向传播与梯度更新，其中 $\lambda_1 = 1.0$ ， $\lambda_2 = 0.5$ 。验证阶段采用 mAP（mean Average Precision）作为主要指标，辅以 Precision、Recall 与 F1-score 进行综合评估。如图10所示，实验结果显示，模型在验证集上获得较高的 mAP_{50} 与 $\text{mAP}_{50:95}$ ，检测性能稳定，收敛曲线平滑。




图 10 训练过程中的损失与 mAP 曲线

总体而言，YOLOv11 模型在 COCO 预训练权重的迁移基础上，经针对性数据增强与优化策略调优后，能够在复杂背景下准确识别集装箱表面破损位置，对“凹陷”“破洞”“锈蚀”三类缺陷均表现出良好的判别能力与泛化性能。

3.4 结果分析

为进一步验证所构建模型在多类别破损检测任务中的性能，对各类缺陷的检测精度与判别能力进行了综合评估。图 11 展示了各类别的 Precision-Recall 曲线。模型在整体检测任务中的 $mAP@0.5$ 达到 0.810，其中“rusty”类性能最优（0.833），“dent”类次之（0.804），“hole”类相对较低（0.794）。从曲线走势可见，三类曲线整体平滑且高位延展，说明模型在不同召回率下均能保持较高检测精度。锈蚀类破损因纹理特征明显，模型在此类目标上的识别稳定性更强；而小尺度破洞受限于边缘噪声与样本不足，召回率略有下降。

为分析模型在类别区分方面的表现，绘制了混淆矩阵（图 12）。从结果可见，三类破损的主对角元素均接近 0.8，表明分类准确率较高。部分“dent”与“rusty”样本存在交叉误判，主要由于两者在局部光照与表面反光条件下纹理特征相似；“hole”类存在少量误检，主要原因是孔洞边缘与背景阴影的亮度梯度近似。整体矩阵呈明显对角分布，非对角元素占比较低，表明模型在复杂背景下仍具较强判别能力。

综合来看，基于 YOLOv11 的改进检测模型在迁移学习与多尺度特征融合的共同作用下，能够有效提取集装箱表面缺陷的空间与语义特征。模型在复杂光照与多背景条件下保持较高的 mAP 、Precision 与 Recall 值，表现出良好的泛化性能与鲁棒性。尤其在锈蚀与凹陷类破损识别中，模型具有稳定的响应能力与较低的误检率，为后续分割与状态评估任务提供了可靠基础。




图 11 各类别的 Precision-Recall 曲线




图 12 模型预测结果的混淆矩阵


四、问题三求解

4.1 多分类集装箱缺陷检测模型

由于现实情况当中，存在不同缺陷实际上对集装箱的状态会有不同的影响，针对集装箱表面缺陷的多分类检测任务，本文设计并实现了一个多分类的集装箱缺陷检测模型。该模型旨在准确识别并分类集装箱表面的多种缺陷类型，包括凹痕（Dent）、孔洞（Hole）、锈蚀（Rusty）及正常（Normal）状态。本节详细介绍一下具体实现过程。

4.1.1 数据处理

我们基于问题 1 的思路，扩展并构建了一个四分类数据集，标签分别为 0-Dent 凹痕、1-Hole 孔洞、2-Rusty 锈蚀、3-Normal 正常。首先，从原始的多标签数据集中提取包含不同缺陷类型的图像样本，通过分析每个图像中存在的缺陷类别，为每张包含多种缺陷的图像生成多个单标签训练样本。具体实现上，对于包含多种缺陷类别的图像，采用目标遮蔽技术：在为特定缺陷类别生成样本时，使用白色矩形标签区域遮盖其他所有类别的缺陷区域，仅保留目标缺陷类别作为学习对象。这种处理方式既保留了图像的背景上下文信息，又消除了其他缺陷类型的干扰，确保模型能够专注于学习特定缺陷的特征表达。在数据组织和类别映射方面，研究构建了一个层次化的目录结构，按照训练集和测试集分别组织，每个类别拥有独立的图像和标签存储目录。对于原始数据中的正常样本，进行了基于问题 1 的类别重映射将其转换为类别 3，以构建完整的四分类体系。通过这种数据转换策略，原始的多标签检测问题被转化为一个更加适合分类任务的单标签问题，每个训练样本都具有明确的类别标签和对应的边界标注信息。这种方法不仅提高了数据利用率，还通过遮蔽处理增强了模型对特定缺陷的敏感性和识别能力，为工业表面缺陷的自动检测提供了高质量的数据基础。



(a) 原始损伤图像

(b) 矩形遮挡生成的对照图

图 13 损伤场景的正负样本构建示例

如上图13所示, 原始 828 号图像包含复杂的多类别缺陷标注信息, 涉及类别 1 (Hole 孔洞) 的两个目标实例以及类别 0 (Dent 凹痕) 的三个目标实例, 具体坐标参数精确描述了各缺陷的空间位置和几何特征。在应用本研究提出的遮蔽转换策略后, 系统针对类别 1 生成专门的训练样本: 通过白色矩形遮蔽技术完全覆盖所有类别 0 的缺陷区域(坐标分别为 $[0.544531, 0.657813, 0.092188, 0.056250]$ 、 $[0.418750, 0.700781, 0.075000, 0.035938]$ 和 $[0.241406, 0.764844, 0.085938, 0.048438]$), 同时完整保留目标类别 1 的两个孔洞实例(坐标 $[0.416406, 0.396094, 0.048438, 0.026563]$ 和 $[0.409375, 0.447656, 0.025000, 0.020313]$)。转换后的样本被归类至标签 1 专属目录中, 其对应的标注文件仅包含孔洞类别的边界框信息, 实现了从多标签复杂场景到单一类别专注学习任务的精确转换。这种针对性的样本生成机制不仅消除了类别间干扰, 还确保了模型能够专注于特定缺陷类型的特征学习, 显著提升了分类任务的准确性和泛化能力。

4.1.2 模型求解

本研究采用 CABNet 作为四分类任务的深度学习模型, 通过监督学习的方式优化模型参数。给定训练数据集 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, 其中 $x_i \in \mathbb{R}^{3 \times 640 \times 640}$ 表示输入图像(固定尺寸 640×640), $y_i \in \{0, 1, 2, 3\}$ 对应四个类别。模型的优化目标是 minimized 交叉熵损失函数:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N \mathcal{L}_{CE}(f(x_i; \theta), y_i)$$

其中 θ 表示模型参数, $f(x_i; \theta)$ 为 CABNet 的前向传播输出, $\mathcal{L}_{CE}$ 为标准交叉熵损失函数。由于代码中未使用正则化项, 因此损失函数仅为交叉熵损失, 具体定义为:

$$\mathcal{L}_{CE} = - \sum_{c=0}^3 y_{i,c} \log(p_{i,c})$$

其中 $y_{i,c}$ 为样本 i 在类别 c 上的真实标签, $p_{i,c}$ 为模型预测的属于类别 c 的概率。

本研究实验环境配置如下: 操作系统为 Windows11, 编程语言为 Python 3.8。硬件方面采用 NVIDIA RTX 5070 GPU。批次大小设置为 32, 模型训练共进行 100 个 epoch 的迭代优化。本研究采用 Adam 优化器进行模型参数更新。

为了提升模型的泛化能力和鲁棒性, 本研究在训练过程中在训练集应用了多种数据增强技术。图像首先被调整为固定尺寸 640×640 像素, 并进行随机水平翻转(翻转概率为 0.5)和随机旋转(旋转角度范围为 ± 10 度)。在像素级的增强方面, 采用了颜色抖动技术, 调整图像的亮度、对比度和饱和度, 调整幅度均为 0.2。此外, 所有图像都使用 ImageNet 标准化参数进行归一化处理, 均值为 $[0.485, 0.456, 0.406]$, 标准差为 $[0.229, 0.224, 0.225]$ 。上述增强策略有助于提升模型对不同数据分布和环境变化的适应性, 从而增强模型的鲁棒性。

4.1.3 结果分析

本研究基于 CABNet 架构进行四分类任务，旨在对工业表面缺陷进行精确分类。实验结果通过多个评价指标进行分析，包括训练过程中的准确率与损失曲线、混淆矩阵、分类报告等。




图 14 训练和验证损失及准确率曲线

根据图14的表现，我们可以得出以下分析结论：模型在 100 个训练周期内稳定收敛，训练损失从约 1.2 下降至 0.5 以下并保持平稳，同时验证损失也表现出下降的趋势，未出现明显的波动，表明模型没有发生过拟合问题。训练准确率从约 50% 上升至约 80%，验证准确率也稳定增长至约 70%，表明 CABNet 能够有效捕捉到四分类任务中的集装箱损伤特征，且分类效果较为均衡。整体上，损失的平稳下降和准确率的持续上升验证了模型的鲁棒性和泛化能力，为后续的细节度分析和应用提供了坚实的基础。




图 15 原始和标准化混淆矩阵对比

根据图15所示的混淆矩阵对比图，我们可以得出以下分析结论：模型在四分类任务中，针对每一类的识别效果有了较为明显的提升。从原始混淆矩阵来看，类别“Normal”表现出显著的正确分类比例，达到近 95%。相比之下，类别“Rusty”和“Hole”则存在一定的混淆，分别在预测为“Rusty”时有约 10% 的错误分类为“Dent”或“Normal”。尤其是“Hole”类，在预测时有相对较多的误分类为“Rusty”，其召回率为 0.291，显示出模型在这一类别的识别能力有待进一步提升。

在标准化后的混淆矩阵中，各类别的预测概率分布更加均衡。对于“Dent”类别，模型成功地将大部分真实标签正确分类，达到 81.3% 的精度，表现优异。而“Rusty”类别的

精度相对较低，尽管其召回率较高，但在精度上有所欠缺，表现出较高的假阳性率。对比这两幅矩阵，可以看出标准化矩阵有助于对模型输出的更细致的区分，并能为进一步调整和优化模型提供指导。总的来说，CABNet 模型在四分类任务中的表现是较为稳定且有效的，但某些类别的分类精度仍需进一步优化，尤其是在处理复杂背景和多类别特征交叉的情境下。




图 16 各类别性能表现对比

根据图16所示的各类别性能表现图，我们可以得出以下分析结论：模型在四分类任务中的表现存在一定的类别差异。首先，“Dent”类别的精度（Precision）为 0.875，召回率（Recall）为 0.813，F1 分数为 0.843，表明该类别的检测效果相对较好，模型能够较为准确地识别出凹痕缺陷。与此相比，“Hole”类别的表现稍逊，精度为 0.735，召回率为 0.291，F1 分数为 0.417，显示出该类别在预测过程中容易受到其他类别干扰，导致其分类效果较为不稳定。

对于“Rusty”类别，精度为 0.733，召回率为 0.539，F1 分数为 0.621，虽然精度较高，但召回率较低，表明模型在该类别的识别上存在一定的漏检问题。最后，“Normal”类别表现最佳，其精度为 0.952，召回率为 0.848，F1 分数为 0.848，反映出模型能够高效地识别出正常区域，并且对于这一类别的预测具有较强的鲁棒性。

综合来看，本研究提出的四分类缺陷检测模型在测试集上总体准确率达到 80%。其中，Dent 类别的精确率达到 88%，Hole 类别为 74%，Rusty 类别为 73%，Normal 类别为 76%。证明 CABNet 模型不仅在二分类任务中表现出优异的特征判别能力，在更具挑战性的四分类任务中依然能够保持较高的分类精度与稳定性，体现出良好的泛化性能与鲁棒性。

4.2 集装箱健康状态分析系统

在完成集装箱表面破损的检测与分类后，仍需进一步量化集装箱整体的健康状态，以实现从“检测”向“诊断”的转变。单纯依靠缺陷检测结果无法直接反映容器的结构安全

性和服役可靠性，因此需引入综合评估指标，将多类型缺陷的空间分布、面积比例及叠加效应进行量化。为此，本文设计了基于检测结果的集装箱健康识别与评估系统，对容器的综合健康指数（Health Index, HI）进行建模与分级判定，实现集装箱从缺陷识别到健康评估的全流程自动化。

4.2.1 系统设计

系统采用基于 Python 的模块化实现，核心类为 `ContainerHealthMetrics`，其功能包括缺陷严重度量化、位置权重计算、复合缺陷识别及健康等级分类。总体流程如图 17 所示，系统主要由三部分组成：

(1) **损伤量化模型**：首先基于 YOLOv11 检测结果中每个缺陷的位置信息与尺寸，计算归一化面积比：

$$A_r = \frac{w \times h}{W \times H},$$

其中 w, h 为缺陷宽高， W, H 为整幅图像宽高。针对不同类型缺陷，赋予不同的严重度权重与面积放大系数，如孔洞（hole）权重 0.5、凹陷（dent）权重 0.3、锈蚀（rusty）权重 0.05，并引入尺度放大系数以反映其工程危害程度。同时根据缺陷位置（中心、边缘、角部）设置不同的影响权重，以体现结构应力分布的差异性。

(2) **复合损伤判定**：若检测结果中出现孔洞与凹陷共存、或孔洞与锈蚀叠加等情况，系统自动标记为“结构危险”状态（Critical Combination）。在此情况下，模型对损伤得分施加额外惩罚系数 $p = 1.5$ ，以放大潜在结构失效的风险。每张图像的综合损伤得分计算为：

$$S_d = \sum_{i=1}^N \omega_{t_i} \cdot s_{a_i} \cdot \omega_{l_i} \cdot p_i,$$

其中 ω_{t_i} 为缺陷类型权重， s_{a_i} 为面积放大比例， ω_{l_i} 为位置权重， p_i 为复合惩罚系数。

(3) **健康指数计算与状态判定**：根据总损伤得分计算健康指数：

$$HI = 1 - S_d,$$

并设定分级阈值进行健康状态划分：*Excellent* ($HI \geq 0.9$)、*Good* ($0.75 \leq HI < 0.9$)、*Fair* ($0.5 \leq HI < 0.75$)、*Poor* ($0.3 \leq HI < 0.5$)、*Critical* ($HI < 0.3$)。系统同时生成对应的维护建议，例如“表面锈蚀应进行防腐涂层修复”或“孔洞需立即停用检修”。

4.2.2 结果分析

系统在验证集检测结果上进行了批量评估，共生成 413 个集装箱样本的健康报告。图 18 展示了健康指数分布与状态占比。其中，*Excellent* 占比 29.8%，*Good* 占比 21.2%，*Fair* 占比 18.9%，*Critical* 占比 28.3%，平均健康指数为 0.749。可见样本总体健康状态偏良好，但存在部分高危容器。健康指数直方图显示，高健康值样本分布集中于 0.7–1.0 区间，而低于 0.3 的样本集中于重度破损容器，主要由“hole”缺陷导致。

在进一步的个体分析中，系统对健康指数最低的容器绘制雷达图（图 19），从结构完整性、表面状况、抗腐蚀性、整体安全性与使用寿命五个维度进行评估。结果显示，




图 17 集装箱健康识别系统总体流程图

编号为 `test/5.jpg` 的容器在结构完整性与表面状况方面分数较低，推测存在孔洞与多处凹陷的复合破损特征。系统自动给出“立即停用检修”的维护建议，验证了该方法在危险容器筛查中的可行性。

综上所述，该健康识别系统在检测模型输出的基础上实现了结构级安全状态量化，具备自动化、解释性与可扩展性。通过综合考虑缺陷类型、位置与面积影响，能够准确反映容器整体服役状态，为后续的安全预警与维护决策提供可靠依据。




图 18 集装箱健康指数与状态分布仪表盘




图 19 典型容器健康评估雷达图（示例：test/5.jpg）

五、总结与展望

5.1 研究总结

本文围绕“基于计算机视觉的集装箱智能破损检测”任务，针对复杂港口场景下集装箱外表面损伤的自动识别与健康评估问题，构建了一个完整的智能检测与状态评估体系。

在问题一中，结合集装箱图像级标注数据，建立了基于深度卷积特征的二分类模型，实现了对是否存在残损的快速判定，为后续精细检测提供先验筛选。

在问题二中，以 YOLOv11 为核心框架，利用 COCO 预训练权重进行迁移学习，结合多尺度特征融合与注意力机制设计，提出了改进的集装箱缺陷检测模型。模型在验证集上取得了 $mAP_{50} = 0.809$ 、 $mAP_{50:95} = 0.628$ ，各类缺陷的 Precision 均超过 0.80，表现出较好的检测精度与稳定性。同时，通过独立 IoU 匹配脚本验证了检测框与真实标签框的空间一致性，平均 IoU 达到 0.86，证明模型在定位精度方面的可靠性。

在问题三中，本文基于检测结果提出了集装箱健康识别系统（Container Health Metrics System）。该系统引入缺陷类型权重、面积放大系数与位置权重，构建综合损伤得分模型；同时通过健康指数（Health Index, HI）实现容器整体状态的量化评估。系统实现了从缺陷识别到结构健康诊断的自动化流程，并通过批量评估、可视化报表与雷达图展示，实现了对集装箱群体状态的智能统计与高风险容器的精准预警。综合实验结果表明，本研究提出的检测与评估体系在复杂背景、光照变化及多尺度破损场景下均表现出良好的鲁棒性与可解释性，为港口自动化检测与安全运维提供了技术支持。

总体而言，本文的主要创新点包括：

1. 构建了端到端的集装箱破损检测与健康评估流程，实现了从视觉识别到结构量化的闭环分析；
2. 在检测阶段引入注意力机制与多尺度特征融合结构，显著提升了小目标识别能力；
3. 提出了融合缺陷类型、面积与位置的健康指数模型，为容器结构健康的定量评估提供了可扩展框架；
4. 实现了可视化评估与智能报告生成，具备工程落地价值。

5.2 研究展望

尽管本研究实现了较为完整的检测与评估体系，但仍存在若干可进一步优化与拓展的方向。首先，在数据层面，现有数据集仍以静态图像为主，缺乏时间序列或多角度观测信息。未来可通过多视角摄像机或无人机巡检系统采集连续影像，利用时空建模方法（如时序卷积网络、Transformer-based Video Detector）实现动态破损跟踪与演化分析，从而更精确地评估容器疲劳与老化过程。

其次，在模型层面，可进一步探索轻量化与硬件适配优化，以实现端侧部署与实时检测。当前的 YOLOv11 模型虽然精度较高，但计算开销较大，不利于在边缘设备上

长时运行。未来可结合网络剪枝 (Pruning)、低秩分解 (LoRA/SVD)、混合精度推理 (FP16/INT8) 等技术, 构建针对国产 NPU、Jetson Orin 等硬件平台的轻量化检测模型, 实现 10ms 级实时推理, 从而满足港口现场自动化检测与无人巡检需求。

第三, 在系统层面, 健康指数模型仍以经验权重为主, 未来可引入多模态学习与物理约束优化, 将视觉缺陷与传感器数据 (如震动、温度、应变等) 融合, 通过多源信息交叉验证实现结构状态的精准评估。结合数字孪生 (Digital Twin) 技术, 可构建集装箱全生命周期的虚拟健康档案, 实现“检测—诊断—预测—维护”一体化闭环。

最后, 在应用层面, 系统具有较强的可扩展性, 可推广至铁路货厢、船体外板、桥梁面板等其他工业结构领域, 特别适用于边缘计算场景下的安全巡检任务。未来结合 5G 边缘计算与云端协同推理, 可构建多终端协同检测架构, 实现港口、码头与仓储系统的智能互联, 为智慧物流与智能制造提供支撑。

综上所述, 本研究不仅为集装箱智能检测提供了可行的技术路径, 也为结构健康评估领域提供了可扩展的计算框架。随着边缘 AI、传感融合与自监督学习等技术的持续发展, 基于视觉的集装箱健康评估系统有望在未来实现更高的智能化、自适应化与部署灵活性。

参考文献

- [1] KALUZA P, KOELZSCH A, GASTNER M, et al. The complex network of global cargo ship movements[J/OL]. *Journal of the Royal Society Interface*, 2010, 7(48): 1093-1103. DOI: 10.1098/rsif.2009.0495.
- [2] WANG Z, GAO J, ZENG Q, et al. Multitype damage detection of container using cnn based on transfer learning[J/OL]. *Mathematical Problems in Engineering*, 2021, 2021: 1-12. DOI: 10.1155/2021/5395494.
- [3] BONNÍN-PASCUAL F, ORTIZ A. Detection of cracks and corrosion for automated vessels visual inspection[C/OL]//ALQUÉZAR R, MORENO A, AGUILAR-MARTIN J. *Frontiers in Artificial Intelligence and Applications: Vol. 210 Artificial Intelligence Research and Development - Proceedings of the 13th International Conference of the Catalan Association for Artificial Intelligence, l'Espluga de Francolí, Tarragona, Spain, 20-22 October 2010*. IOS Press, 2010: 111-120. <https://doi.org/10.3233/978-1-60750-643-0-111>.
- [4] ORTIZ A, BONNIN-PASCUAL F, GARCIA-FIDALGO E, et al. Vision-based corrosion detection assisted by a micro-aerial vehicle in a vessel inspection application[J/OL]. *Sensors*, 2016, 16(12): 2118. <https://www.mdpi.com/1424-8220/16/12/2118>. DOI: 10.3390/s16122118.
- [5] AIJAZI A K, MALATERRE L, TAZIR M L, et al. Detecting and analyzing corrosion spots on the hull of large marine vessels using colored 3D LiDAR point clouds[J/OL]. *ISPRS Ann. Photogramm. Remote Sens. Spatial Inf. Sci.*, 2016, III-3: 153-160. <https://doi.org/10.5194/isprs-annals-III-3-153-2016>.
- [6] LI Y, ZHANG C. Automated vision system for fabric defect inspection using gabor filters and pcnn[J/OL]. *SpringerPlus*, 2016, 5(1): 765. <https://springerplus.springeropen.com/articles/10.1186/s40064-016-2452-6>.
- [7] DING S, LIU Z, LI C. Adaboost learning for fabric defect detection based on hog and svm[C/OL]//*Proc. Int. Conf. Multimedia Technology (ICMT)*. 2011: 2903-2906. DOI: 10.1109/ICMT.2011.6001937.
- [8] VALAVANIS I, KOSMOPOULOS D. Multiclass defect detection and classification in weld radiographic images using geometric and texture features[J/OL]. *Expert Systems with Applications*, 2010, 37(12): 7606-7614. <https://www.sciencedirect.com/science/article/pii/S0957417410003829>. DOI: <https://doi.org/10.1016/j.eswa.2010.04.082>.
- [9] KASBAN H, ZAHRAN O, ARAFA H, et al. Welding defect detection from radiography images with a cepstral approach[J/OL]. *NDT & E Int.*, 2011, 44(2): 226-231. <https://doi.org/10.1016/j.ndteint.2010.10.005>.

- [10] İMAMOĞLU Z, TUĞLULAR T, BASTANLAR Y. Container damage detection and classification using container images[C/OL]//2020 28th Signal Processing and Communications Applications Conference (SIU). IEEE, 2020: 1-6. <https://ieeexplore.ieee.org/document/9302442>. DOI: 10.1109/SIU49456.2020.9302442.
- [11] REN S, HE K, GIRSHICK R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149. <https://arxiv.org/abs/1506.01497>. DOI: 10.1109/TPAMI.2016.2577031.
- [12] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: Unified, real-time object detection[C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 779-788. <https://arxiv.org/abs/1506.02640>. DOI: 10.1109/CVPR.2016.91.
- [13] REDMON J, FARHADI A. Yolov3: An incremental improvement[A/OL]. 2018. <https://arxiv.org/abs/1804.02767>.
- [14] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C/OL]//Lecture Notes in Computer Science: Vol. 9351 Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. Springer, Cham, 2015: 234-241. <https://arxiv.org/abs/1505.04597>. DOI: 10.1007/978-3-319-24574-4_28.
- [15] HE K, GKIOXARI G, DOLLÁR P, et al. Mask r-cnn[C/OL]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 2980-2988. <https://arxiv.org/abs/1703.06870>. DOI: 10.1109/ICCV.2017.322.
- [16] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. Yolov4: Optimal speed and accuracy of object detection[A]. 2020.
- [17] BENJUMEA A, TEETI I, CUZZOLIN F, et al. Yolo-z: Improving small object detection in yolov5 for autonomous vehicles[A]. 2021.
- [18] LIU Y, WANG J, YU H, et al. Surface defect detection of steel products based on improved yolov5[C]//2022 41st Chinese Control Conference (CCC). IEEE, 2022: 5794-5799.
- [19] LI C, LI L, GENG Y, et al. Yolov6 v3. 0: A full-scale reloading[A]. 2023.
- [20] WANG C Y, YEH I H, MARK LIAO H Y. Yolov9: Learning what you want to learn using programmable gradient information[C]//European conference on computer vision. Springer, 2024: 1-21.
- [21] WANG A, CHEN H, LIU L, et al. Yolov10: Real-time end-to-end object detection[J]. Advances in Neural Information Processing Systems, 2024, 37: 107984-108011.

- [22] ZHANG H, WU C, ZHANG Z, et al. Resnest: Split-attention networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 2736-2746.
- [23] CHEN L C, PAPANDREOU G, KOKKINOS I, et al. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(4): 834-848.
- [24] CHEN L C, PAPANDREOU G, SCHROFF F, et al. Rethinking atrous convolution for semantic image segmentation[A]. 2017.
- [25] SANDLER M, HOWARD A, ZHU M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4510-4520.
- [26] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.
- [27] HAN S, POOL J, TRAN J, et al. Learning both weights and connections for efficient neural network[J]. Advances in neural information processing systems, 2015, 28.
- [28] HE A, LI T, LIN, et al. Cabnet: Category attention block for imbalanced diabetic retinopathy grading[J/OL]. IEEE Transactions on Medical Imaging, 2020, 40(1): 143-153. DOI: 10.1109/TMI.2020.3023463.
- [29] KHANAMR, HUSSAIN M. Yolov11: An overview of the key architectural enhancements [A/OL]. 2024. arXiv: 2410.17725. <https://arxiv.org/abs/2410.17725>.