

队伍编号	MCB2500060
赛道	A

面向智慧港口的集装箱残损多维度视觉检测与评估模型

摘要

本文针对全球贸易中集装箱运输安全的关键需求，研究基于计算机视觉的集装箱外表面破损智能检测方法。传统人工检测方式效率低下且主观性强，难以适应现代化港口自动化与大规模作业的要求。随着深度学习与计算机视觉技术的发展，本文利用集装箱外表面图像数据，构建了一种融合分类、检测与分割的智能识别模型。该模型首先通过图像特征提取实现集装箱是否存在残损的自动分类；对于存在残损的图像，进一步定位其位置并识别具体类别，如裂纹、凹陷、锈蚀等；最后从多个维度对模型性能进行系统评估。研究中充分考虑了复杂背景、光照变化、尺度差异及样本不平衡等现实挑战，旨在为智慧港口建设与运输安全管理提供高效、可靠的视觉检测解决方案。

针对问题一：设计了基于深度迁移学习的二分类模型，通过解析 YOLO 格式标注文件构建训练样本，采用 ResNet 和 EfficientNet 等先进网络架构进行特征提取，结合数据增强和类别平衡策略，实现了对集装箱图像破损状况的准确判断。

针对问题二：构建了多任务学习框架，将目标检测与语义分割有机结合，采用 Faster R-CNN 与 U-Net 相结合的架构，在准确定位破损区域的同时实现像素级分类，有效提升了小目标检测和边界分割的精度。

针对问题三：建立了多维度评估体系，从准确率、精确率、召回率、F1 分数、mAP、IoU 等多个指标对模型性能进行全面量化分析，并通过分层评估和误差分析为模型优化提供明确方向。

关键词：集装箱破损检测、计算机视觉、深度学习、目标检测、语义分割、模型评估

目 录

一、问题重述.....	1
1.1 问题背景.....	1
1.2 数据介绍与建模目标.....	2
二、问题分析.....	3
2.1 针对问题一.....	3
2.2 针对问题二.....	3
2.3 针对问题三.....	4
三、模型假设及符号说明.....	5
3.1 模型假设	5
3.2 符号说明	5
四、数据预处理.....	7
4.1 数据质量分析.....	7
4.2 数据集预处理.....	7
五、任务一 图像分类.....	8
5.1 问题分析与输入输出.....	8
5.2 数据预处理与增强.....	8
5.3 特征提取模型设计.....	9
5.4 二分类输出与损失函数.....	9
5.5 处理类别不平衡.....	10
5.6 模型评估与调优.....	11
六、任务二 检测与分割任务.....	12
6.1 问题定义与任务目标.....	12
6.2 数据准备与标注.....	12
6.3 目标检测模型架构设计.....	12
6.5 多任务联合训练的策略与损失函数设计.....	13
6.6 类别不平衡与小目标检测的解决方法.....	14
6.7 模型训练与优化.....	14
6.8 结果解析.....	15
七、任务三 模型评估.....	15
7.1 任务目标.....	15
7.2 分类模型的评估指标.....	15

7.3 检测与分割模型的评估指标.....	16
7.4 多维度评估策略与分层分析.....	17
7.5 评估流程自动化与结果汇报.....	18
7.6 模型性能改进与优化.....	18
参考文献.....	18
附录.....	19

一、问题重述

1.1 问题背景

在当今全球贸易高度活跃的环境下，集装箱作为货物运输的主要载体，承担着将商品安全、高效地运送到世界各地的重任。无论是在海洋航运、陆路运输还是多式联运中，集装箱都是实现物流连贯性的关键环节。然而，频繁的装卸作业、运输颠簸以及恶劣天气等因素常使集装箱受到不同程度的损伤。这些损坏可能表现为表面裂痕、凹陷、穿孔和锈蚀等多种形态，不仅削弱了集装箱的结构强度，还可能破坏其密封效果，导致货物暴露于外界环境中，增加货物受损和丢失的风险。此外，损坏的集装箱还会引发运输过程中的安全隐患，给运营商和客户带来潜在的经济损失。

目前，集装箱损坏的检测方法多以人工目测为主。这种传统方式不仅耗时耗力，且检测人员的主观判断难免引入误差，导致检测结果的不稳定和不一致。同时，港口作业节奏加快，集装箱堆积量庞大，单靠人工巡查已难以满足高效检测的需求。部分借助简单图像技术的检测手段，在面对复杂环境与多变光照时，也显得力不从心，难以准确分辨细微和多样的损害类型。因此，提升检测过程的自动化和智能化水平，成为港口物流安全管理的迫切需求。

随着计算机视觉技术的迅猛发展，尤其是深度学习模型在图像处理领域的广泛应用，为集装箱损伤检测提供了新的解决思路。现代神经网络能够自动从大规模图像数据中提取多层次、多尺度的特征，准确识别并定位多种类型的破损，实现自动化且高精度的分析。通过在港口安装高分辨率的摄像设备，可持续采集集装箱的表面图像，配合目标检测和语义分割模型，打破传统人工检查的瓶颈，为集装箱状态监测带来显著提升。这些技术不仅可以实现实时异常检测，还能通过对损伤范围及类别的精确判别，为后续维修决策提供科学依据，助力港口向智能化方向升级。

尽管自动检测技术前景广阔，但现实中仍面临诸多挑战。首要难题源于图像采集的复杂环境：集装箱所在的港口背景复杂多变，环境光线会出现强烈的阴影、反光以及污渍覆盖，图像质量时常受到影响。其次，不同破损的尺寸跨度极大，部分破损区块可能只占据极少像素，给模型的感知能力带来了考验。此外，数据集中正常无损的图像数量通常远多于损伤图像，造成样本不平衡，对模型训练的效果产生不利影响。更为棘手的是，某些损伤类型之间具有较高的视觉相似度，如何区分细微差别成为模型设计中的重

要考量。此外，由于某些破损类别样本相对稀缺，模型在这些类别上的表现可能较弱，影响整体检测的准确率和鲁棒性。

结合上述背景，本论文聚焦构建针对集装箱外表面图像的智能识别系统，设计并实现能够自动判断图像是否包含任何形式破损的分类模型，进一步完成损伤的位置检测和具体类别的识别，最后对模型的多维度性能进行评估。通过分析实际港口环境中复杂、动态的视觉数据，提升算法的普适性与稳定性，助力实现自动化、快速和可靠的集装箱破损检测和监控。

有效识别和管理集装箱破损，不仅能提升运输安全，减少货物损失，还能优化港口运营效率，促进智慧物流体系建设。未来，依靠人工智能驱动的破损检测技术，有望广泛应用于全球各大型港口和物流中心，促进全球贸易的高效与安全运转。

1.2 数据介绍与建模目标

本文主要包含 3713 幅图像，其中共包含“dent”凹陷、“hole”破洞、“rusty”锈蚀 3 类。存放图片数据的文件夹为 JPEGImages，由代码生成的数据集划分后的标签文件夹为 labels。题目所给数据集中的图像背景涵盖港口机械、天空、地面等，成分复杂；存在光照变化、反光、阴影、雨水、污渍等干扰；残损大小不一，大的如大面积锈蚀，小的如细微裂缝，对模型的多尺度特征提取能力要求高。

本文建模目标主要：

①集装箱残损的分类识别：通过分析集装箱外表面的图像信息，建立一个分类模型，能够判断输入的图像是否存在任何形式的破损或损伤。这一步骤的目标是快速识别集装箱是否完好，达成初步的损伤筛查。

②破损位置的检测与类别识别：对于确认存在破损的图像，需进一步设计检测与分割模型，准确定位破损的具体区域，并对残损类型进行精细分类。该任务强调不仅能发现损伤，还能明确损伤的具体性质和所在位置，便于后续维修决策。

③多维度模型性能评估：在模型训练和测试阶段，对建立的分类和检测模型进行全面评估，包括准确率、召回率、定位精度及对不同类别破损的识别能力等多个维度，确保模型在真实应用环境中的稳健性和有效性。

通过实现上述目标，使构建的模型能应对来自复杂环境、多样损伤及数据不平衡等实际应用挑战，推动集装箱破损检测技术向智能化、自动化方向发展，为港口物流的安全运营和高效管理提供技术支持。

二、问题分析

2.1 针对问题一

判断集装箱图像是否存在破损是一个典型的图像分类问题。首先，需要对数据集中的图像进行预处理，包括清洗异常样本和针对性的增强，以增强模型对复杂背景和光照变化的适应性。接着，选用预训练的卷积神经网络作为骨干，进行迁移学习或微调，提取有效的图像特征，从而完成破损与非破损的区分。

由于破损样本数量通常较少，训练过程中还需采取数据平衡策略和改进损失函数，避免模型偏向无损类别。最终通过准确率、召回率等多指标综合评估模型性能，并结合模型解释方法排查潜在问题，实现分类模型的稳定应用。模型训练完成后，对测试集图片运行推理，输出集装箱是否破损的判定结果。具体流程见图 2.1。




图 2.1 问题一流程图

2.2 针对问题二

针对问题二“检测与分割任务”，目标是在确认集装箱图像存在破损的前提下，准确定位破损区域并识别破损的具体类别。这是一个典型的目标检测和语义分割结合的多任务问题，难度较大，需要既精确识别破损位置，也要区分破损类别。由于集装箱损伤多样且形态复杂，加之图像环境杂乱、多光照和遮挡影响，模型需要具备强大的特征表达和多尺度感知能力。

具体完成流程首先需要构建一个目标检测模型，如 YOLO、Faster R-CNN 等，负责从集装箱图像中框选出破损位置的候选区域；随后，可采用语义分割方法对检测到的区域进行像素级分类，实现对破损边界的精细描绘和类别区分。训练过程需充分利用带有标注的破损框和分割掩码数据，采用多尺度增强和类别平衡策略来提升模型在小目标和样本少类别上的表现。同时，结合多任务学习方法优化检测和分割模块的联合训练效果，增强整个系统的鲁棒性。

最终通过衡量检测的准确率和分割的重叠指标，综合评估模型性能。测试时对所有图像逐一执行检测与分割流程，输出每张图对应的破损类别和精确位置，方便后续的保护和安全评估。针对模型训练和优化，可以采用迁移学习、模型融合以及后处理技术进一步提升实用性。具体流程见图 2.2。




图 2.2 问题二流程图

2.3 针对问题三

针对问题三“模型评估”，核心是对前面构建的分类和检测分割模型进行全面、多维度的性能评价，确保模型不仅在数值指标上表现优秀，同时能满足实际应用环境中的准确性、鲁棒性和稳定性要求。模型评估不仅是验证模型训练效果的关键环节，也是发现模型不足、指导后续优化的重要依据。

具体而言，对于分类模型，应关注准确率、召回率、精确率、F1 分数等指标，特别强调在不平衡数据中破损类别的检测能力，避免出现大量漏判或误判。混淆矩阵可直观反映模型对不同类别的分类情况，辅助判定偏差方向。对于检测与分割模型，则需侧重区域定位的准确度指标，如平均精度均值（mAP）、框的定位误差，以及分割质量指标如

交并比（IoU）、Dice 系数等，以衡量模型对于破损区域的识别和边界提取的能力。评估过程中应结合召回率和精度曲线（PR 曲线）、受试者工作特征曲线（ROC 曲线）、模型推理速度和资源占用等多维度指标，系统评判模型综合性能。此外，建议设计针对不同破损类别、不同破损严重程度的分层评估，分析模型在各种条件下的表现差异，确保模型的稳健性和泛化能力。对模型进行跨场景测试（如不同光照与背景环境）也有助于验证其实用性。

完成评估后，整理分析结果，形成报告，明确各项指标现状和优化方向，为团队后续迭代奠定基础。同时，评估流程应具备自动化能力，便于快速复现和持续监控模型表现，确保在真实应用中持续稳定运行。具体流程见图 2.3。




图 2.3 问题三流程图

三、模型假设及符号说明

3.1 模型假设

- 假设一：数据集的数据真实可靠。
- 假设二：假设测试设备在测试过程中性能稳定，不会引入额外的误差。
- 假设三：部分数据缺失不会对整体数据产生影响。
- 假设四：假设数据集中的任何异常值或离群点被处理后，不会产生显著影响。

3.2 符号说明

表 3.1 符号与符号说明

符号	意义
X	输入图片张数
H	图像高度

W	图像宽度
C	RGB 通道数量
$\hat{y}$	二值标签
η	学习率
c_i	第 i 个检测框的类别标签
θ	网络参数
p_i	第 i 个锚框是目标的概率
$\{p_{ij}\}_{j=1}^K$	第 i 个 RoI 属于第 j 类的概率
α	类别加权因子
γ	调节参数
p_t	预测的目标类别概率
TP, TN, FP, FN	分类模型预测结果中的真阳性、真阴性、假阳性、假阴性
B_{gt}	真实标注的边界框
M_{pred}	平均精度均值
s_i	检测框第 i 个类别的置信度分数
FPS	模型推理速度指标，衡量实时性能
$\mathcal{L}$	联合损失函数
$\mathcal{L}_{det}$	检测任务的损失函数
λ_{det}	分割任务的损失函数
$\mathcal{L}_{bbox}$	边框回归损失
$\mathcal{L}_{focal}$	Focal Loss 的损失值
$\hat{p}$	模型预测的破损概率（输出概率）
w	权重向量（参数）
b	偏置标量
$\mathcal{L}_w$	加权交叉熵损失
∇_{θ}	损失函数对参数的梯度
F1	调和平均数（精确率和召回率的平衡指标）
$f_{\theta}(X)$	特征提取函数（网络）
F	输出的特征图
$\hat{M}_{h,w,k}$	相应预测概率
Dice	衡量掩码重叠

四、数据预处理

4.1 数据质量分析

问题一的核心挑战在于：图像背景复杂(港口机械、天空、地面)，存在光照变化、反光、阴影等干扰;破损形态多样，尺度差异大(从大面积锈蚀到细微裂缝);数据可能存在类别不平衡，即无破损图像远多于有破损图像。输入数据为 RGB 图像，因此数据预处理是提升模型泛化能力和收敛速度的关键。

数据集预处理方案如图 3.1 所示。首先对题目给出的数据集进行数据质量分析与整理，内容包括标注完整性（空标注、错误格式、越界、面积过小等）、每类目标数量与出现图片数、每图目标数分布以及 bbox 面积分布与小/中/大目标比例等，以评估数据集质量并为后续模型优化提供依据。经过计算，得到的结果如下：共检测到 3300 个标注文件，Dent 、Hole 、Rusty 的数量分布分别是 3158、3934、946（Hole 显著较少），平均每图目标数为 3 个，小、中、大目标的比例分别为 45%、40%、14%，大目标占比较少。

4.2 数据集预处理

从类别分布来看，Hole 类样本数量明显少于 Dent 与 Rusty 类，为了平衡各类别样本数量，防止模型偏向多数类，我们采用旋转和高斯模糊的方式，将 Hole 类样本进行数据增强，这种针对性的数据增强策略确保了模型在所有破损类别上都能达到较好的性能，而不是只擅长识别样本数量多的类别。从尺度分布来看，小目标比例约占 45%，我们后续需要在模型中强化小目标检测能力，引入多尺度特征融合或注意力机制模块等。该数据集在类别平衡和目标尺度分布方面仍有优化空间，可结合样本均衡策略与模型结构改进共同提升检测性能，对图片进行分析的结果如下表 4.1、图 4.1 和图 4.2 所示。

表 4.1 尺度分布结果

尺度	计数	比率(%)
小(<0.01)	3637	45.24757402
中(0.01-0.1)	3261	40.56979348
大(>=0.1)	1140	14.1826325




图 4.1 目标对象数量图




图 4.2 类别图像数量图

五、任务一 图像分类

5.1 问题分析与输入输出

本问题实质是一个二分类任务，目标是判定输入的集装箱图像是否存在任何形式的破损。输入的彩色图像尺寸为 $H \times W$ ，通常具有 3 个颜色通道（RGB），可以表示为张量 $X \in R^{H \times W \times 3}$ 。输出是一个二值标签 $\hat{y}$ ，其中 0 代表图像无破损，1 代表存在破损。只有明确了任务类型（分类问题）、输入数据格式和期望输出，才能合理设计对应的机器学习模型、损失函数和评估指标。同时，二分类的定义简化了后续模型结构，使得整个训练过程更加清晰，明确地反映模型的目标。

5.2 数据预处理与增强

训练深度学习模型前，需对图像进行预处理。常规做法是对像素值进行归一化或者

标准化，目的是让所有输入数据在数值范围内保持一致，避免某些特征数值过大扰乱模型训练，促进神经网络更快更稳定地学习。图像尺寸统一调整成固定大小（如 224×224 ）是因为大部分深度卷积网络需要固定输入尺寸才能批量训练。此外，真实采集的图片大小不一，直接输入可能导致模型不能正常前进。

数据增强的目的在于增强模型的泛化能力。集装箱图像可能受到拍摄角度、光照、遮挡等影响，单一原始数据难以覆盖所有情况。随机翻转、裁剪、旋转、色彩扰动等数据增强方法增加了样本多样性，使模型学到更鲁棒的特征，能更好地适应现实中各种复杂场景，有效防止过拟合现象。

5.3 特征提取模型设计

卷积神经网络（CNN）因其强大的图像特征表达能力，被广泛用于视觉任务。通过多层卷积层，CNN 能够自动提取图像的边缘、纹理、形状乃至更抽象的语义特征。我们采用预训练模型 ResNet 做迁移学习，因为这些模型在大规模数据集（ImageNet）上已学会丰富的通用视觉表达，能够加速训练过程并提高最终准确率。相比从零训练，迁移学习减少了对大量标注数据的依赖，尤其在工业领域标注难度大时优势明显。




图 5.1 ResNet 模型残差块

模型设计中将最后的全连接层替换成符合当前任务输出的层，实现针对集装箱破损检测的专用分类，既保留了原网络优秀的通用特征提取能力，又能精准输出破损概率。

5.4 二分类输出与损失函数

为判断数据集中集装箱图像是否存在任何形式的残损，本文建立了基于深度迁移学

习的集装箱图像破损智能检测系统。我们采用经典的卷积神经网络架构（ResNet50 或 EfficientNetB0）作为特征提取主干网络，通过解析 YOLO 格式的标注文件构建二分类标签，利用 ImageNet 预训练权重进行参数初始化，有效解决了小样本数据下的模型训练难题。

系统采用多层次特征融合策略，在基础网络后接入全局平均池化层、批归一化层和 Dropout 正则化层，最终通过 Sigmoid 激活函数输出破损概率。系统还实现了端到端的 YOLO 标签解析机制，通过检测标注文件的存在性构建弱监督二分类标签。数据处理模块集成了多重图像增强技术，包括仿射变换（旋转、平移、缩放）、光度失真（亮度、对比度调整）以及弹性形变，这些增强策略有效模拟了实际港口环境中的视角变化、光照条件和物理形变，显著提升了模型的域适应能力。在 backbone 特征提取后，通过全局平均池化层替代全连接层，大幅减少参数量的同时增强了空间平移不变性。后续的深度可分离全连接层配合批归一化和 Dropout 正则化，形成了强大的特征蒸馏管道，有效防止过拟合并促进特征解耦。最终通过 Sigmoid 激活函数将连续特征映射为破损概率估计。

训练策略方面，系统实现了多目标优化框架：使用带类别权重的二元交叉熵损失函数，动态调整少数类样本的梯度贡献；配合自适应学习率调度器（ReduceLROnPlateau）和早停机制，在保证收敛性的同时避免过拟合。这种组合策略在类别不平衡场景下显著改善了模型对破损样本的敏感性。

评估体系构建了多维度的性能度量矩阵：除了基础的准确率指标，更强调精确率-召回率的平衡（F1 分数），特别是在高风险的应用场景中，避免漏检（低召回率）比减少误报（低精确率）具有更高的业务价值。AUC-ROC 指标提供了模型在不同决策阈值下的整体 discriminative power 评估，而混淆矩阵则直观呈现了分类错误的分布模式。模型最终输出破损概率是通过一个全连接层得到的实数 s ，再通过 Sigmoid 函数映射到 0 到 1 之间，形成概率 $\hat{p}$ 。Sigmoid 函数公式为：

$$\hat{p} = \frac{1}{1 + e^{-s}}$$

概率值可以直接反映模型对这张图片有无破损的信心程度。

采用交叉熵损失函数衡量了模型预测概率分布与真实分布之间的差异，是分类问题中的标准选择。交叉熵越小，说明模型预测值越接近真实标签，模型训练的目标是最小化该损失函数。该损失函数能够促使模型提升对正负样本的区分能力，在二分类任务中表现出色，能够有效驱动训练过程。

5.5 处理类别不平衡

现实数据集中，未破损的集装箱图片大幅多于破损图片，造成类别不平衡。若不处理，模型会倾向于预测无破损类别以获得高准确率，从而忽视破损样本。为解决该问题，一种简单方式是加权交叉熵，用加权因子提升破损样本在损失中的比重，让模型更加关注少数类别。具体形式：

$$\mathcal{L}_w = -(\alpha y \log \hat{p} + (1 - \alpha)(1 - y) \log (1 - \hat{p}))$$

其中权重 α 与类别样本比例相关。

更进一步，**Focal Loss** 通过动态调整样本权重，减少对简单样本（模型已学好的大多数类样本）的关注，专注难分类样本，提升模型对边界模糊的破损样本识别能力，有助于缓解训练过程中的类别偏差和过拟合。

5.6 模型评估与调优

训练神经网络本质是利用梯度下降算法不断调整模型参数，使损失函数最小化。反向传播通过链式法则计算损失对所有参数的梯度，指导每一步参数的更新公式为：

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}$$

学习率 η 调节参数更新步幅，平衡收敛速度和稳定性。

训练时选择合适的优化器（如 **Adam**、**SGD**）通过不同策略调整梯度步长与方向，确保训练过程平稳且高效。分批训练（**batch training**）加速计算，每个 **epoch** 训练完全部数据后，参数逐步趋于最优点。合理设置批量大小、学习率调度及早停策略，是避免模型陷入局部最优或过拟合的重要手段。

训练完模型后需评估其泛化性能，关键指标包括准确率、精确率（**Precision**）、召回率（**Recall**）和 **F1** 分数。准确率衡量整体正确预测比例，但在不平衡数据集上易被多数类主导，误导评价。召回率度量检测出所有破损样本的能力，低召回表示漏判；精确率衡量预测为破损样本中真实破损比例，低精确率意味着误报率高。**F1** 分数作为精确率和召回率的调和平均，更公平地评价模型综合性能。分析混淆矩阵可以找到模型具体的误分类场景，帮助针对性改进模型，如加大数据增强、调整损失权重等。

将训练验证完成后的模型部署到测试集上，对每张测试图像计算破损概率 $\hat{p}$ ，根据阈值 τ 做最终分类判定。阈值选择通过验证集调节，使召回率和精确率达到平衡。模型预测结果规范输出成指定格式，包含图片 ID 及对应判定类别，保证信息完整准确。

六、任务二 检测与分割任务

6.1 问题定义与任务目标

本问题旨在从集装箱表面图像中自动定位所有残损区域，并准确识别每个破损区域的具体类别。模型输入是一张图像 $X \in R^{H \times W \times 3}$ ，输出包括破损区域的边界框集合 $\{b_i\}$ 、对应的类别标签 $\{c_i\}$ 以及可选的语义分割掩码 $M_i \in \{0,1\}^{H \times W}$ ，完成像素级细化。

明确问题目标的核心是区分检测（定位+粗略分类）和分割（像素级分类），并为模型构建指明方向。准确的定位与分类直接影响后续维护决策，分割能提供更精细和直观的破损形态信息，有利于评估破损范围和严重程度。

6.2 数据准备与标注

高质量带有完整框标记和类别标签的训练数据是构建有效模型的基石。对于检测任务，标注包含每处破损的边界框 $b_i = (x_i, y_i, w_i, h_i)$ 和类别标签 c_i ，分割任务还需对应的像素级掩码 M_i 。现实中图像环境复杂（光照、遮挡、反光等），为提升模型鲁棒性，需采用多样化数据增强方法如随机裁剪、旋转、颜色变换等，增加数据多样性。此外，若类别分布严重不均，需通过过采样稀有类别、欠采样常见类别或生成合成样本平衡数据，确保模型训练时不过度偏向多数类。

精准的标注帮助模型学习有效的空间和类别特征，数据增强和均衡则提升模型对现实复杂环境的泛化能力。

6.3 目标检测模型架构设计

目标检测需同时解决物体定位和分类，典型且成熟的两阶段检测器 **Faster R-CNN** 被广泛采用。它包含：特征提取网络（**Backbone**），如 **ResNet**，提取图像高维语义特征；区域建议网络（**RPN**），基于特征图生成一系列候选边界框（锚框 **Anchor**）并判断其是否含破损目标；**RoI Align** 层，准确采样候选框对应的特征区域，为后续分类和回归做准备；分类与边框回归头，分别输出每个候选框属于各破损类别的概率分布和精细框位置调整。

在本章节专为集装箱残损检测任务设计了一个集成了 **CBAM**（**Convolutional Block Attention Module**）注意力机制的残差模块。该模块的核心组件有 **Bottleneck**、**CBAM** 注意力机制和残差连接等。其工作过程首先通过一个由三个卷积层构成的“瓶颈”结构对输入特征进行降维、空间卷积和升维的核心特征提取；随后，提取的特征被送入 **CBAM**

注意力机制，该机制会依次通过通道注意力子模块和空间注意力子模块，自适应地计算特征图在各个通道和空间位置上的重要性权重并进行加权，从而显著增强对关键信息的关注并抑制无关背景；最后，经过注意力调制的特征与通过快捷路径（如需下采样则通过 1×1 卷积进行维度匹配）的原始输入进行残差相加，再通过 ReLU 激活函数输出。该模块的作用在于，它通过残差结构确保了梯度流畅、缓解了网络退化问题，同时利用 CBAM 机制使网络能像“视觉注意力”一样聚焦于图像中的关键区域（如集装箱的损伤部位），从而在集装箱残损检测等复杂视觉任务中实现更精准、更鲁棒的特征表示。

选择两阶段检测架构主要因为它能在复杂背景和多样目标大小下保持较高的召回率和定位精度，特别适合集装箱破损这类大小不一、形态复杂的检测对象。分阶段流程对检测质量的提升显著，有助于降低误检和漏检率。

目标检测能给出位置和粗略类别，但有时边界不够精准，无法满足实际维修需求，因此结合语义分割，实现像素级破损区域识别。以 U-Net 为典型结构，编码器部分有效提取语义信息，解码器借助跳跃连接恢复细节，保持空间分辨率。模型输出一个像素分类概率图：

$$\hat{M} = g_{\phi}(\mathbf{X}) \in \mathbb{R}^{H \times W \times K}$$

表示每像素属于不同破损类别的概率。语义分割结合像素级交叉熵损失与 Dice 损失，提升模型对细小破损和边界的敏感度。这样不仅可以获得更具体的破损范围，还能辅助定位模块提升准确率，是实现工业级破损评估的关键。

6.5 多任务联合训练的策略与损失函数设计

联合训练检测和分割模块共用特征提取层，既节省算力，又能共享信息，互补强化。整体损失函数设计为：

$$\mathcal{L} = \lambda_{det} \mathcal{L}_{det} + \lambda_{seg} \mathcal{L}_{seg}$$

其中，检测损失一般包括目标分类的交叉熵损失和边框回归的 Smooth L1 损失：

$$\mathcal{L}_{det} = \mathcal{L}_{cls} + \mathcal{L}_{bbox}$$

分割部分使用像素交叉熵与 Dice 损失相结合，以面对严重类别不均衡：

$$\mathcal{L}_{seg} = \mathcal{L}_{ce} + (1 - \text{Dice coefficient})$$

调整权重 λ_{det} 和 λ_{seg} 平衡不同任务学习速度，避免某一任务主导训练。

多任务学习使模型具备更丰富和全面的破损特征表达能力，提高整体准确率和鲁棒性，满足工业场景多样化的检测需求。各种情况下的损失函数如下图 4.所示。




图 6.1 各情况下损失函数变化图

6.6 类别不平衡与小目标检测的解决方法

在实际场景中，某些破损类别非常罕见且尺寸较小，训练时易被忽略或难以学习，导致漏检。为解决此问题，利用 **Focal Loss** 调整样本权重，降低对简单负样本的关注，聚焦困难样本：

$$\mathcal{L}_{focal} = -\alpha(1 - p_t)^\gamma \log(p_t)$$

其中， p_t 是正样本预测概率， α 、 γ 控制关注难易样本度。

多尺度训练和特征金字塔网络（FPN）融合不同层级特征，使网络具备高分辨率特征，有效捕捉小 **target**。采样策略平衡类别数据，过采样少数类且加大其权重。

通过这些方法有效缓解类别和目标尺寸不均衡，使模型更全面精准识别各种破损。

6.7 模型训练与优化

模型训练应用反向传播，通过最小化联合损失函数不断调整参数：

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}$$

选用 **Adam** 或 **SGD** 优化器以自适应学习率提升训练效率。训练过程中引入学习率衰减、正则化（如权重衰减、**Dropout**）技术防止过拟合。

采用早停机制根据验证集性能自动终止训练，保证模型泛化力。

持续监控多个指标（准确率、**mAP**、**IoU** 等），定期调整超参数、增强策略，确保训练稳定有效，尤其在目标检测和分割任务中平衡性能。

6.8 结果解析

测试时，模型先通过检测模块输出所有破损候选框及其类别置信度，利用非极大值抑制（NMS）过滤重叠过大且置信度低的框，提高最终框的准确性和唯一性。随后，在每个检测框区域执行语义分割，得到更精确的破损掩码。结合位置与掩码信息，将坐标、类别和分割结果整理输出，满足竞赛及实际应用标准格式。模型最终的识别结果如图 4 所示。




图 6.2 检测结果图

七、任务三 模型评估

7.1 任务目标

模型评估的核心目的是科学、全面地衡量问题一（分类模型）和问题二（检测与分割模型）构建的算法性能，判断其能否满足实际应用需求。单纯依靠准确率不能全面反映模型优劣，尤其面对不平衡的数据和多类别、多任务场景。

因此必须从多个维度评估模型的分类能力、检测定位精度、分割细节准确性及推理效率，发现模型优缺点，有针对性地推动模型迭代与优化。全面评估保障模型在工业实际使用中的稳健性和可靠性，是将算法推向生产环节的关键一步。

7.2 分类模型的评估指标

对于问题一的二分类模型，关键评估指标包括：准确率： $Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$,

表示模型预测正确的比例，适用于类别基本均衡场景，但数据严重不平衡时不够敏感；
 精确率（Precision）： $\text{Precision} = \frac{TP}{TP+FP}$ ，衡量模型预测为正（破损）样本中实际正确的比例，高精确率意味着误报率低；召回率（Recall）： $\text{Recall} = \frac{TP}{TP+FN}$ ，体现模型查全率，即能够发现破损样本的能力，召回率低代表漏判严重；F1 分数： $F1 = 2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$ ，作为精确率与召回率的调和平均，更全面衡量模型性能。

计算这些指标的原因在于，破损图像往往少且关键，漏检会带来安全隐患，误检则浪费人工资源，需平衡两者。通过这些指标，可以准确判断模型在这一权衡上的表现。

7.3 检测与分割模型的评估指标

问题二模型复杂，需评估定位和分割两个方面性能：

①检测部分的平均精度均值（mAP）：

mAP 综合评价不同类别、不同 IoU 阈值下的检测性能。IoU（Intersection over Union）定义为检测框与真实框的交并比：

$$IoU = \frac{|B_{pred} \cap B_{gt}|}{|B_{pred} \cup B_{gt}|}$$

检测被认为正确是当 IoU 超过阈值（如 0.5）。mAP 计算为每个类别的平均精确率，综合反映检测质量。使用本文所提出的模型将赛题给出的 val 数据集进行测试，得到的 mAP50 结果如图 7.1 所示。




图 7.1 准确率与召回率曲线

②分割部分的交并比（IoU）和 Dice 系数：

分割评估重点度量预测掩码与真实掩码重叠度：

$$IoU_{seg} = \frac{|M_{pred} \cap M_{gt}|}{|M_{pred} \cup M_{gt}|}$$

$$Dice = \frac{2|M_{pred} \cap M_{gt}|}{|M_{pred}| + |M_{gt}|}$$

Dice 系数对小目标更敏感，IoU 更为常用。使用本文所提出的模型将赛题给出的 val 数据集进行测试，得到的坐标值已导出为 excel 表格上传至大赛官网。

这些指标从空间位置和像素级视角考察模型的破损检测及边界提取能力， ensuring 模型能在实际复杂环境下提供准确定位和细致分割，支持运维决策。




图 7.2 测试结果图

7.4 多维度评估策略与分层分析

除基础指标外，应对模型性能进行更细致的多维度分析：

类别分层评估：不同破损类别影响程度和样本量差异较大，对每个类别分别计算指标，确保模型不会忽视某些关键类别。

严重程度分层评估：按破损大小或严重度划分样本，评估模型对不同损伤程度的识别能力，保证关键破损不被遗漏。

环境影响分析：光照、遮挡等环境因素会影响表现，分组考察效果，确定模型在真实场景中的稳定性。

推理时间与资源消耗：模型实际部署时需要满足效率要求，评估推理时间（FPS）、

内存占用，平衡精度与实时性。这类分析帮助识别模型薄弱环节，指导定向优化，提升模型发布的可靠保障。

7.5 评估流程自动化与结果汇报

为了保证评估标准一致且可复现，应设计自动化评估流程，包括：

- ①测试数据统一加载和预处理。
- ②模型推理批量执行，输出预测结果。
- ③各项指标标准化计算，实现批量统计。
- ④生成综合报告，包含各指标值、曲线图（如 PR 曲线、ROC 曲线）、误判案例分析。

自动化减少人为误差，提高评估效率，方便在模型迭代过程中迅速反馈效果。评估报告为模型团队提供决策依据，明确提升方向。

7.6 模型性能改进与优化

通过评估得到的详细指标和问题分析，指导模型的后续优化。针对分类模型漏检多，可尝试调整阈值、改进损失函数；检测模型定位不准，则优先调整锚框设计或引入更强特征；分割质量差则增加数据增强或加入边界平滑损失。

建立评估-改进-再评估的闭环，使模型不断进化，最终在实际场景中表现稳健可靠。良好的评估体系和反馈机制是产业应用模型得以长期稳定运行的保障。

参考文献

- [1] 张晔,王作栋,朱海东,等.基于计算机视觉的敞车车厢破损检测系统[J].轨道交通装备与技术,2025,33(03):51-54.DOI:10.13711/j.cnki.cn32-1836/u.2025.03.011.
- [2] 朱景昊 , 曹立波 , 陈凯 , 等 . 基于 OpenCV-Python 的高速公路车辆识别与计数功能研究 [J]. 汽车工程师 , 2023, (06):14-19.
- [3] 王紫媛.基于深度学习的敞车厢体缺陷识别与定位研究 [D] . 成都: 电子科技大学, 2022.
- [4] 史洪斌, 刘文胜, 陈永东, 等. 铁路敞车车体耐腐蚀性与检修周期适应性分析 [J] . 机械工程与自动化, 2021 (10): 158-160.
- [5] Chethan Y D, Ravindra H V, Kumar S B. Machine vision for tool status monitoring in turning Inconel 718 using blob analysis[J]. Materials Today: Proceedings, 2015,

2(4-5):

- [6] 金鑫,王通,程园龙. 基于深度学习的 TFDS 货车故障图像智能识别算法研究 [J] . 铁道车辆, 2024, 62 (1): 138-144.
- [7] 颜为朗. 基于计算机视觉的铁路棚车车窗开闭状态检测算法研究 [D] . 武汉: 武汉理工大学, 2018.
- [8] 赵永强,饶元,董世鹏,等.深度学习目标检测方法综述[J].中国图象图形学报 2020:629-654.
- [9] 冷睿轩. 基于YOLOv8 的输电线路异物识别算法应用[D]. 东北农业大学,2023.DOI:10.27010/d.cnki.gdbnu.2023.000410.
- [10] 目标检测网络 YOLOv8.<https://www.cnblogs.com/makefile/p/YOLOv8.html>.
- [11] 王宪保,朱啸咏,姚明海. 基于改进FasterRCNN的目标检测方法[J]. 高技术通讯,2021,31(05):489-499.
- [12] Huang Zhanchao,Wang Jianlin,Fu Xuesong,et al. Dc-spp-yolo: DenseConnection and SpatialPyramid Pooling Based Yolo for Object Detection[J].Information Sciences, 2020(prepublish).
- [13] 陈建勋.基于计算机视觉的沥青路面裂缝与破损检测方法研究[D].华南理工大学,2023.DOI:10.27151/d.cnki.ghnlu.2023.001574.
- [14] 陈建勋.基于计算机视觉的沥青路面裂缝与破损检测方法研究[D].华南理工大学,2023.DOI:10.27151/d.cnki.ghnlu.2023.001574.

附录

数据预处理:

```
import os
import glob
import yaml
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# ===== 自动路径识别 =====
root = r"E:\project\yolov8-Cup\dataset\run"
data_yaml = r"E:\project\yolov8-Cup\ultralytics\cfg\datasets\run.yaml"
split = "train" # 可改为 "val" 做验证集统计
```