

队伍编号	MCB2500488
赛道	B

物流理赔风险标注分类及运单赔付预测研究

摘 要

现代物流业快速发展的同时，货损理赔问题日益凸显，本研究通过构建物流理赔风险评估双阈值模型与 XGBoost 模型，深入研究物流理赔风险识别及服务升级路径。

针对问题 1，首先，进行数据预处理，剔除数据异常值，计算“理赔差额”数据列；其次，基于**分位数理论**，以第一和第三四分位数为边界划分低、中、高三层金额层，并分别将每层金额层按照 0.03 和 0.85 的阈值进行初步分类划分，得到“合理诉求”、“诉求偏高”、“严重超额”三类风险分类集；再次，对三类风险分类集分别进行**线性拟合、指数函数和幂函数拟合**，使用**最小二乘法**估计函数参数，并以决定系数 R^2 评估函数拟合效果，得出“合理诉求”**阈值中线性函数的最优参数 $a=2.7224$, $b=234.5745$** ；最后，依据决定系数 R^2 评估拟合效果，得出“合理诉求”**阈值最优函数为线性函数**、“严重超额”**阈值最优函数为幂函数**，分别作为划分风险标注分类的阈值。

针对问题 2，构建基于梯度提升树的 XGBoost 回归预测模型。首先，进行数据预处理，对数值型特征缺失值使用中位数进行填补，对分类型特征缺失值使用众数填补，并采用**取绝对值、变负数和四分位距 (IQR)**的方法处理异常值；其次，构造统计、比率、频率**特征工程**；再次，构建**基于梯度回归树的 XGBoost 回归模型**，使用所有特征进行训练，并通过**随机搜索法**优化模型参数；然后，基于第一阶段全量特征模型的特征重要性排序，**部分重要性排序：索赔金额>保价金额>进线人身份>进线渠道>妥投到进线时长**，选取前 15 个较为重要的特征，并使用筛选后的特征重新训练模型；最终，得出附件 2 运单的实际赔付金额预测结果，部分结果举例：**实际赔付金额为 243.88，索赔金额为 436.69 时，标注为合理诉求。**

针对问题 3，首先，使用问题 1 的风险标注规则，在保证逻辑一致性、密集性和稀疏性的分类原则情况下，基于**四分位距 (IQR)**将运单数据的实际赔付金额分为低、中、高三级金额层；其次，选用线性函数、指数函数和幂函数进行阈值拟合，依据决定系数选择最优拟合函数，并对附件 2 的运单进行风险标注预测；再次，构建 XGBoost 模型，预测附件 2 的运单风险标注分类；最后，比较双阈值函数模型和 XGBoost 模型对运单风险标注分类的优劣势，得出结论：**双阈值函数模型的优点是解释性强，计算简单。**

关键词：双阈值函数模型；XGBoost 回归模型；特征工程


目 录

一、问题重述.....	1
1.1 问题背景.....	1
1.2 问题提出.....	1
二、问题分析.....	2
2.1 针对问题 1 的分析.....	2
2.2 针对问题 2 的分析.....	2
2.3 针对问题 3 的分析.....	2
三、模型假设.....	2
四、符号说明.....	3
五、模型的建立与求解.....	3
5.1 问题 1 的模型与求解.....	3
5.1.1 数据预处理.....	3
5.1.2 基于分位数的分层方法.....	3
5.1.3 双阈值函数拟合模型.....	5
5.1.4 风险分类模型.....	8
5.2 问题 2 模型的建立与求解.....	9
5.2.1 数据预处理.....	10
5.2.2 特征工程.....	10
5.2.3 XGBoost 回归模型.....	11
5.2.4 参数优化.....	12
5.2.5 特征重要性评估.....	12
5.2.6 特征筛选与重训练.....	13
5.2.7 预测结果.....	14
5.3 问题 3 的模型与求解.....	14
5.3.1 风险标注模型.....	14
5.3.2 基于机器学习的风险预测模型.....	16
5.3.3 优劣势.....	18
六、模型评价.....	18
6.1 优点.....	18
6.2 缺点.....	18
七、参考文献.....	18

一、问题重述

1.1 问题背景

现代物流业是我国基础性、战略性产业。目前，我国物流市场规模已连续 9 年位居世界第一，2025 年前三季度社会物流总额达 263.2 万亿元，同比增长 5.4%^{[1][2]}。然而，货损理赔问题日益凸显，现已成为制约行业高质量发展的重要瓶颈，2024 年货损率平均达 7.8%，远高于发达国家 3%~5% 的水平^[3]。传统理赔模式效率低下，从货损发现到最终赔付平均耗时 18 个工作日，45% 的案件存在责任争议，实际赔付金额仅为损失金额的 50% 左右^{[3][4]}。更值得关注的是，在数字化转型背景下，仅有 35% 的物流企业采用自动化理赔系统，理赔环节的数字化滞后严重制约了产业链协同发展^[3]。



《“十四五”现代物流发展规划》明确提出推进物流提质增效，“十五五”规划进一步强化智慧物流发展要求^{[5][6]}。在此背景下，研究物流理赔风险识别及服务升级具有重要意义：理论上可丰富物流风险管理理论体系；实践中能有效降低企业运营成本，提高客户满意度；社会层面有助于减少资源浪费，促进绿色低碳发展，为构建现代流通体系提供有力支撑。物流理赔风险识别及服务升级已成为行业亟待解决的重要课题。

1.2 问题提出

为研究物流理赔风险识别及服务升级路径，本研究需解决以下问题：

针对问题 1：基于附件 1 中的各项数据，分析“理赔差额”与“实际赔付金额”存在的变化规律，并构建风险标注模型，阐述风险标注的原理与规则，将附件 1 中各运单的物流理赔交易行为分别标注为“合理诉求”、“诉求偏高”、“严重超额”三类风险类型。

针对问题 2：构建运单实际赔付金额的预测模型，使用附件 1 中的部分数据进行模型训练，筛选出影响实际赔付金额预测结果的评估指标，得出附件 2 中运单实际赔付金额的预测结果，并使用附件 1 中的剩余数据进行验证，得出最终优化后的预测结果。

针对问题 3：基于问题 1 设置的风险标注规则，使用附件 1 中的数据构建风险标注分类模型，并根据构建的风险标注分类模型预测附件 2 运单的理赔风险程度；处理“严重超额”样本占比严重不均衡的问题，并分析此方法与问题 2 预测方法的优劣势。

二、问题分析

2.1 针对问题 1 的分析

针对问题 1，要构建风险标注模型，对附件 1 中的运单进行风险标注。首先，进行数据预处理，剔除数据异常值，增加“理赔差额”数据列；其次，基于分位数理论，以第一和第三四分位数为边界划分低、中、高三层金额层，并分别将每层金额层按照 0.03 和 0.85 的阈值进行初步分类划分，得到“合理诉求”、“诉求偏高”、“严重超额”三类风险分类集；再次，对三类风险分类集分别进行线性拟合、指数函数和幂函数拟合，使用最小二乘法估计函数参数，并以决定系数 R^2 评估函数拟合效果；最后，依据决定系数 R^2 评估拟合效果，选择最优函数作为划分风险标注分类的阈值。

2.2 针对问题 2 的分析

针对问题 2 中物流货损的实际赔付金额预测问题，构建基于梯度提升树的 XGBoost 回归预测模型。首先，进行数据预处理，对数值型特征缺失值使用中位数进行填补，对分类型特征缺失值使用众数填补，并采用取绝对值、变负数和四分位距（IQR）的方法处理异常值；其次，构造统计、比率、频率特征工程；再次，构建基于梯度回归树的 XGBoost 回归模型，使用所有特征进行训练，并通过随机搜索优化模型参数；然后，基于第一阶段全量特征模型的特征重要性排序，选取前 N 个较为重要的特征，并使用筛选后的特征重新训练模型；最终，得出附件 2 运单的实际赔付金额预测结果。

2.3 针对问题 3 的分析

针对问题三，首先，使用问题 1 的风险标注规则，在保证逻辑一致性、密集性和稀疏性的分类原则情况下，基于四分位距（IQR）将运单数据的实际赔付金额分为低、中、高三级金额层；其次，选用线性函数、指数函数和幂函数进行阈值拟合，依据决定系数选择最优拟合函数，并对附件 2 的运单进行风险标注预测；再次，构建 XGBoost 模型，预测附件 2 的运单风险标注分类；最后，比较双阈值函数模型和 XGBoost 模型对运单风险标注分类的优劣势。

三、模型假设

假设一：附件中“始发网点万单理赔率”出现的负值、“目的网点万单理赔率”出现的正值均为数据统计输入错误，可通过数据预处理进行修正。

假设二：模型迭代过程中因机器计算导致的误差可以忽略不计，且对最终的预测结果不产生实质性影响。

假设三：训练数据样本间相互独立，且服从同一概率分布。

四、符号说明

符号	说明
Q_1	第一四分位数
Q_3	第三四分位数
R^2	决定系数
f_1^*	合理诉求阈值最优拟合参数
f_2^*	严重超额阈值最优拟合参数
$frequency$	实体活跃度
l	损失函数
Ω	正则化项
T	树的叶子节点数
$\gamma、\lambda$	正则化参数
μ	理赔差额均值
σ	标准差

五、模型的建立与求解

5.1 问题 1 的模型与求解

针对问题 1，本研究构建物流理赔风险评估双阈值模型，将分层分析与函数拟合相结合，通过双阈值函数动态划分不同的风险标注等级，实现对物流理赔风险的精准分类。

5.1.1 数据预处理

首先，考虑到寄件人和收件人一般为不同人的现实情况，使用 Excel 软件的筛选功能，将附件 1 中“寄件人 id”和“收件人 id”相同的运单剔除；其次，由于保价金额均大于 0，因此剔除附件 1 中保价金额小于 0 的运单数据；最后，依据“理赔差额=索赔金额-实际赔付金额”的计算方式，增加“理赔差额”数据列。

5.1.2 基于分位数的分层方法

对预处理后的附件 1 中的运单数据按照“实际赔付金额”的数值大小升序排序，基于分位数理论，以第一和第三四分位数为边界划分为三层金额层，并分别将每层金额层按照 0.03 和 0.85 的阈值进行初步分类划分，即三层金额层分别得到“合理诉求”、“诉求偏高”、“严重超额”的风险分类集。

(1) 分位数理论

由于附件 1 中的数据均为离散数据，因此，分位数的计算采用线性插值法：

$$Q_p = x_{(k)} + \frac{p(n+1)-k}{k+1-k} (x_{(k+1)} - x_{(k)}) \tag{1}$$

其中， $k = \text{floor}(p(n+1))$, $x_{\{(k)\}}$ 表示第 k 个顺序统计量。

(2) 确定分层边界

根据实际赔付金额的描述性统计分析，得出其整体集中分布在中部区域，两端差异较为显著。因此，将“实际赔付金额”使用四分位数划分为三个层次：低金额层为 $y \leq Q_1$ ；中金额层为 $Q_1 < y \leq Q_3$ ；高金额层为 $y > Q_3$ 。其中 Q_1 和 Q_3 分别为第一四分位数和第三四分位数，即 25%分位数和 75%分位数。

经过计算，得出实际赔付金额的 25%分位数为 96.86，75%分位数为 426.74。

(3) 计算分层阈值

根据 (2) 中分得的三个层次的数据，计算每层的双阈值 (X_1, X_2)。其中，第一层阈值 X_1 控制“合理诉求”占比，第二层阈值 X_2 控制“严重超额”占比。

$$\begin{cases} X_1 = F_x^{-1}(p_{\text{合理}}) \\ X_2 = F_x^{-1}(1 - p_{\text{严重}}) \end{cases} \quad (2)$$

其中， $p_{\text{合理}}=0.85$ 为目标合理占比； $p_{\text{严重}}=0.03$ 为目标严重超额占比； F_x^{-1} 为理赔差额的累积分布函数的反函数。

最终，三层金额层分别得到“合理诉求”、“诉求偏高”、“严重超额”的风险分类范围。

表 1 低、中、高金额层最终阈值

	合理诉求	诉求偏高	严重超额
低金额层	≤ 363.33	$(363.33, 809.85]$	> 809.85
中金额层	≤ 363.33	$(843.32, 1650.27]$	> 1650.27
高金额层	≤ 1950.36	$(1950.36, 3211.88]$	> 3211.88

将低、中、高金额层三级风险标注可视化处理，见图 2。




图 2 基于原始分层的风险标注

由图 2 可知，绿色区域为“合理诉求”风险标注区，黄色区域为“诉求偏高”风险

标注区，红色区域为“严重超额”风险标注区；三类风险标注区分层标注，满足“实际赔付金额越高，则需要更高的索赔差额才会标注为‘诉求偏高’或‘严重超额’”的风险标注原则。且“合理诉求”标注区占比最高，“严重超额”标注区占比最低，符合不同赔付风险运单数量的分布要求。

（4）阈值检验

为检验阈值的密集性和稀疏性是否符合“‘合理诉求’的运单索赔差额相对密集，‘严重超额’的运单索赔差额相对稀疏，且不同类型的运单索赔差额密集程度之间存在明显差别”的要求，对原始分层标注的三层索赔金额进行核密度估计（KDE），并进行可视化分析。可视化见图 3。




图 3 原始分层核密度估计

由图 3 可得，合理区间数据的标准差均不超过阈值、严重超额区间数据的标准差均不低于阈值，阈值的密集性和稀疏性符合要求。

5.1.3 双阈值函数拟合模型

首先，针对分位数分层后初步划分的三类风险标注分类集，分别进行线性拟合、指数函数和幂函数拟合；其次，使用最小二乘法估计函数参数，并以决定系数 R^2 评估函数拟合效果；最后，依据决定系数 R^2 评估拟合效果，选择最优函数作为划分风险标注分类的阈值。

（1）候选函数

为选取拟合效果较好的拟合函数，候选了线性拟合、指数函数、幂函数三种函数形式进行拟合：

线性函数：

$$f(y) = a \cdot y + b \tag{3}$$

指数函数：

$$f(y) = a \cdot e^{b \cdot y / y_{\max}} \quad (4)$$

其中, $y_{\max} = \max(y)$ 为实际赔付金额的最大值。

幂函数:

$$f(y) = a \cdot y^b \quad (5)$$

(2) 参数估计

使用最小二乘法估计函数参数:

$$\min_{a,b} \sum_{i=1}^m (f(y_i) - x_i)^2 \quad (6)$$

其中, m 为分层数量, (y_i, x_i) 为各层的中位数和阈值。

(3) 拟合优度评估

使用决定系数 R^2 评估拟合效果:

$$\begin{cases} R^2 = 1 - \frac{\sum_{i=1}^m (x_i - \hat{x}_i)^2}{\sum_{i=1}^m (x_i - \bar{x})^2} \\ \hat{x}_i = f(y_i) \\ \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i \end{cases} \quad (7)$$

其中, $\hat{x}_i$ 为拟合值, $\bar{x}$ 为阈值均值。

(4) 选择最优函数

经过函数拟合, 最小二乘法求参数, 得到合理诉求阈值 X_1 候选函数拟合结果:

表 2 合理诉求阈值 X_1 候选函数拟合结果

	函数	决定系数 R^2	参数
线性函数	$f(y) = a \cdot y + b$	0.9994	a=2.7224 b=234.5745
指数函数	$f(y) = a \cdot e^{b \cdot y / y_{\max}}$	0.9769	a=431.8817 b=1.5139
幂函数	$f(y) = a \cdot y^b$	0.9971	a=17.2508 b=0.7322

同理, 可得严重超额阈值 X_2 候选函数拟合结果:

表 3 严重超额阈值 X_2 候选函数拟合结果

	函数	决定系数 R^2	参数
线性函数	$f(y) = a \cdot y + b$	0.9942	a=4.0665 b=669.1786
指数函数	$f(y) = a \cdot e^{b \cdot y / y_{\max}}$	0.9657	a=931.1027 b=1.2469
幂函数	$f(y) = a \cdot y^b$	0.9978	a=74.6561 b=0.5824

由表 2、表 3 可知, 合理诉求阈值 X_1 候选函数中, 线性函数的决定系数 $R^2=0.9994$ 最大, 严重超额阈值 X_2 候选函数中, 幂函数的决定系数 $R^2=0.9978$ 最大。

(4) 阈值检验

对双函数分层标注的三层索赔金额进行核密度估计 (KDE), 并进行可视化分析。可视化见图 4。




图 4 双函数标注核密度估计

由图 4 可得，合理区间数据的标准差均不超过阈值、严重超额区间数据的标准差均不低于阈值，阈值的密集性和稀疏性符合要求。

将候选函数进行可视化处理，详见图 5。




图 5 候选函数拟合对比图

由图 5 可知，“合理诉求”与“诉求偏高”边界阈值的三条候选函数中，线性函数的决定系数 $R^2=0.9994$ ，高于其他候选函数，说明该函数对 X_1 与实际赔付金额的关系解释能力最强，拟合效果最好；呈现单调递增趋势，符合“实际赔付金额越高，合理诉求阈值应适度提高”的分类规则；且相比其他函数，该函数趋势更平稳，避免对极端值过度敏感。“严重超额”与“诉求偏高”边界阈值的三条候选函数中，幂函数的决定系数

$R^2=0.9978$ ，高于其他候选函数，对 X_2 与实际赔付金额的关系刻画更准确，拟合效果最好；函数增长速率较快，符合“高金额案件需更高超额才判定为严重”的风险控制需求。因此，分别选用线性函数、幂函数作为三级风险标注分类的边界拟合曲线：

“合理诉求”与“诉求偏高”风险标注分界函数：

$$f(y) = a_1 \cdot y + b_1 \quad (8)$$

其中， $a_1=2.7224$ ， $b_1=234.5745$ 。

“诉求偏高”与“严重超额”风险标注分界函数：

$$f(y) = a_2 \cdot y^{b_2} \quad (9)$$

其中， $a_1=74.6561$ ， $b_1=0.5824$ 。

最终，得到实际赔付金额与双阈值的函数关系图：




图 6 实际赔付金额与双阈值得函数关系拟合

5.1.4 风险分类模型

(1) 动态阈值计算

对于任意实际赔付金额 y ，计算动态双阈值：

$$\begin{cases} X_1(y) = f_1^*(y) \\ X_2(y) = f_2^*(y) \end{cases} \quad (10)$$

其中， f_1^* 和 f_2^* 分别为“合理诉求”阈值和“严重超额”阈值的最优拟合函数。

(2) 风险等级划分

根据理赔差额 x 与动态阈值的关系进行风险分类： $x \leq X_1(y)$ 划分为“合理诉求”风险分类； $X_1(y) < x \leq X_2(y)$ 划分为“诉求偏高”风险分类； $x > X_2(y)$ 划分为“严重超额”风险分类。可视化见图 7。




图 7 基于双函数动态阈值的风险标注

由图 7 可知，绿色区域为“合理诉求”风险标注区，黄色区域为“诉求偏高”风险标注区，红色区域为“严重超额”风险标注区；“合理诉求”风险标注区与“诉求偏高”风险标注区。

部分风险标注结果展示如下：

表 4 部分风险标注结果

实际赔付金额	理赔差额	风险标注	风险标注_双函数拟合
336.47	454.27	合理诉求	合理诉求
55.7	93.47	合理诉求	合理诉求
136.18	127.56	合理诉求	合理诉求
97.29	291.27	合理诉求	合理诉求
457.81	15.96	诉求偏高	严重超额
1094.63	396.53	诉求偏高	合理诉求
590.86	126.16	合理诉求	诉求偏高
128.2	1.79	合理诉求	诉求偏高
1600.35	472.61	合理诉求	诉求偏高
1440.21	432.28	合理诉求	诉求偏高
571.18	101.81	合理诉求	诉求偏高
351.43	8.06	合理诉求	严重超额
3715.57	1172.64	严重超额	诉求偏高

5.2 问题 2 模型的建立与求解

针对问题 2 中物流货损的实际赔付金额预测问题，构建了基于梯度提升树的回归预

测模型。研究基于附件 2 所给运单数据，即包含物流订单特征的数据集 $D = \{(x_i, y_i)\}_{i=1}^n$ ，其中， $x_i \in R^d$ 为 d 维特征向量， $y_i \in R^+$ 为对应的实际赔付金额，以学习映射函数 $f: R^d \rightarrow R^+$ 为目标，使得对于新的样本 x ，能够准确预测其赔付金额。

5.2.1 数据预处理

首先，进行缺失值处理，对于数值型特征缺失值，使用中位数进行填补；对于分类型特征，使用众数填补。

其次，采用取绝对值、变负数和四分位距（IQR）的方法处理异常值。对“始发网点万单理赔率”出现的负值取绝对值；对“目的网点万单理赔率”出现的正值“变正为负”；对“配送超时时长”、“妥投到线时长”、“始发网点发单量”、“目的网点发单量”等特征中数值过大的特征值进行截断：

$$x_{ij}^{clipped} = \begin{cases} Q_1 - 1.5 \times IQR, & x_{ij} < Q_1 - 1.5 \times IQR \\ x_{ij}, & Q_1 - 1.5 \times IQR \leq x_{ij} \leq Q_3 + 1.5 \times IQR \\ Q_3 + 1.5 \times IQR, & x_{ij} > Q_3 + 1.5 \times IQR \end{cases} \quad (11)$$

其中， Q_1 和 Q_3 分别为第一和第三四分位数， $IQR = Q_3 - Q_1$ 。

再次，对“始发网点发单量”和“目的网点发单量”等特征进行可视化处理，将离群的异常值剔除，以“始发网点发单量”和“目的网点发单量”为例，详见图 8、图 9。




图 8 始发网点发单量分布图




图 9 目的网点发单量分布

最后，对数值型特征进行标准化处理：

$$x_{ij}^{norm} = \frac{x_{ij} - \mu_j}{\sigma_j} \quad (12)$$

其中， μ_j 为特征 j 的均值， σ_j 为特征 j 的标准差。

5.2.2 特征工程

针对“商品类型”、“寄件 B/C”、“进线人身份”等非数值型数据，通过构造特征工程进行特征编码处理。

(1) 统计特征构造

构造网点指标均值特征：

$$\begin{cases} \text{avg_claim_rate} = \frac{\text{origin_claim_rate} + \text{dest_claim_rate}}{2} \\ \text{avg_payout_ratio} = \frac{\text{origin_payout_ratio} + \text{dest_payout_ratio}}{2} \end{cases} \quad (13)$$

(2) 比率特征构造

构造时长比率特征，反映进线效率：

$$\text{efficiency_ratio} = \frac{\text{claim_response_time}}{\text{delivery_delay_time} + \varepsilon} \quad (14)$$

其中， ε 为极小值，防止分母为零。

(3) 频率特征构造

构造频率特征，反映实体的活跃度：

$$\text{frequency}(v) = \frac{\text{count}(x_j = v)}{n} \quad (15)$$

其中， v 为特征 j 的某个取值， n 为总样本数。

5.2.3 XGBoost 回归模型

首先，构建基于梯度回归树的 XGBoost 回归模型，使用所有特征进行训练，并通过随机搜索优化模型参数；其次，基于第一阶段全量特征模型的特征重要性排序，选取前 N 个较为重要的特征，并使用筛选后的特征重新训练模型；最终，得出预测结果。

(1) 模型原理

XGBoost 模型为基于梯度提升的集成学习算法，通过迭代训练多颗决策树并组合成强学习器，可以进行精准预测。其预测函数为：

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i) \quad (16)$$

其中， $f_k(x_i)$ 表示第 k 颗决策树对样本 x_i 的预测值， K 为决策树的数量。

(2) 目标函数

模型使用加法训练策略，第 t 轮的目标函数为：

$$\tau^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (17)$$

其中， $\hat{y}_i^{(t-1)}$ 为第 $t-1$ 轮的预测值， l 为损失函数， Ω 为正则化项。

对于回归问题，采用平方误差损失函数：

$$l(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2 \quad (18)$$

正则化项定义为：

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T \omega_j^2 \quad (19)$$

其中， T 为树的叶子节点数， ω_j 为第 j 个叶子节点的权重， γ 和 λ 为正则化参数。

(3) 梯度提升算法

对目标函数进行二阶泰勒展开：

$$\begin{cases} \tau^{(t)} \approx \sum_{i=1}^n \left[l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t) \\ g_i = \frac{\partial l(y_i, \hat{y}_i^{(t-1)})}{\partial \hat{y}_i^{(t-1)}} h_i = \frac{\partial^2 l(y_i, \hat{y}_i^{(t-1)})}{\partial (\hat{y}_i^{(t-1)})^2} \end{cases} \quad (20)$$

(4) 树结构学习

对于给定的树结构，叶子节点的最优权重为：

$$\omega_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda} \quad (21)$$

其中， I_j 表示属于第 j 个叶子节点的样本集合。

对应的目标函数值为：

$$\tau(\omega^*) = -\frac{1}{2} \sum_{j=1}^T \frac{\left(\sum_{i \in I_j} g_i \right)^2}{\sum_{i \in I_j} h_i + \lambda} + \gamma T \quad (22)$$

5.2.4 参数优化

使用随机搜索法进行参数优化：

$$\theta^* = \arg \max_{\theta} CV_score(X_{all}, y, \theta) \quad (23)$$

首先，定义搜索空间：

表 5 搜索空间定义

搜索空间	定义
树深度	max_depth~Uniform(3,8)
子节点最小权重	min_child_weight~Uniform(1,4)
样本采样率	subsample~Uniform(0.7,1.0)
特征采样率	colsample_bytree~Uniform(0.7,1.0)
剪枝阈值	γ ~Uniform(0,0.2)
学习率	learning_rate~Uniform(0.03,0.1)
树数量	n_estimators~Uniform(150,500)

其次，采用 5 折交叉验证评估模型性能：

$$CV_{score} = \frac{1}{5} \sum_{k=1}^5 score(D_k^{val}, \hat{y}_k) \quad (24)$$

其中， D_k^{val} 为第 k 折的验证集， $\hat{y}_k$ 为对应的预测值。

5.2.5 特征重要性评估

XGBoost 模型评估特征重要性主要有权重重要值、增益重要性、覆盖重要性三种计算方法，本研究选用增益重要性作为特征选择的依据，即特征在分裂时带来的增益：

$$gain(j) = \sum_{k=1}^K \sum_{splits \text{ on } j \text{ in } f_k} \Delta \tau \quad (25)$$

经过计算，得出 30 个特征值的重要性排序，前 15 项重要性指标见表 6。

表 6 部分特征重要值排序

	feature	importance
1	索赔金额	0.396410

2	保价金额	0.060308
3	进线人身份	0.037980
4	是否 c2c	0.037533
5	进线渠道	0.036139
6	妥投到进线时长	0.035418
7	配送超时时长	0.035349
8	始发网点发单量	0.030370
9	商品类型	0.026864
10	目的网点发单量	0.026061
11	收件人 id_频率	0.026021
12	异常原因	0.022917
13	始发城市	0.022587
14	目的网点赔付比例	0.021485
15	进线时长/配送时长	0.021088

将特征重要值可视化处理，见图 10。




图 10 XGBoost 模型特征重要性前 15 项特征

由图 10 可得，索赔金额对实际赔付金额的影响最大，其次是保价金额和进线人身份。最终筛选出“索赔金额”、“保价金额”、“进线人身份”、“进线渠道”、“妥投到进线时长”、“配送超时时长”、“是否 c2c”、“始发网点发单量”、“商品类型”、“收件人 id_频率”、“目的网点发单量”、“目的网点赔付比例”、“异常原因”、“始发城市”、“进线时长/配送时长”等 15 项特征，用于后续模型的再训练。

5.2.6 特征筛选与重训练

基于第一阶段模型的特征重要性，选择前 15 个最重要的特征：

$$S = \{j | \text{rank}(\text{gain}(j)) \leq N\} \quad (26)$$

使用筛选后的特征重新训练模型：

$$f^* = \arg \min_f \tau(f(X_s), y) + \Omega(f) \quad (27)$$

其中， X_s 为筛选后的特征矩阵。

5.2.7 预测结果

(1) 实际值与预测值对比




图 11 实际值与预测值对比图

由图 11 可知，蓝色实点为实际值、黄色叉点位预测值，预测值与实际值变化趋势基本一致，由此可得，模型预测效果良好。

(2) 部分预测结果展示

表 7 部分实际赔付金额预测结果

运单号	实际赔付金额
1	243.8800049
2	265.3099976
3	697.5499878
4	261.5400085
5	50.95999908
6	171.8399963
7	247.8399963
8	272
9	212.9600067
10	304.7200012
11	314.7099915
12	229.3600006
13	58.06000137

5.3 问题 3 的模型与求解

5.3.1 风险标注模型

(1) 数据分层策略

基于实际赔付金额的分位数将数据分为三层：低金额层： $y_i \leq Q_1$ ；中金额层： $Q_1 < y_i \leq Q_3$ ；高金额层： $y_i > Q_3$ 。

(2) 分层阈值计算

首先，设定初始阈值。对于每个分层，基于目标占比计算初始阈值：合理诉求占比 85%，严重超额占比 3%。

$$X_1^{(0)} = x_{(\lfloor n\alpha \rfloor)} \quad X_2^{(0)} = x_{(\lceil n(1-\beta) \rceil)} \quad (28)$$

其中， $x_{(k)}$ 表示排序后的第 k 个观测值， n 为样本数量。

其次，设置阈值调整机制：

①**逻辑一致性调整**： $X_1 < X_2$ 。若 $X_1^{(0)} \geq X_2^{(0)}$ ，则 $X_1^{(1)} = \mu - 0.5\sigma$ ， $X_2^{(1)} = \mu + 1.5\sigma$ 。其中， μ 为理赔差额均值， σ 为标准差。

②**密集性调整**：优化合理区间的密集程度。计算合理区间数据的标准差： $\sigma_1 = std(x_i | x_i \leq X_1)$ 。若 $\sigma_1 > \max_{\text{合理标准差}}$ ，则迭代调整 X_1 。

③**稀疏性调整**：优化严重超额区间的稀疏程度。计算严重超额区间数据的标准差： $\sigma_2 = std(x_i | x_i > X_2)$ 。若 $\sigma_2 < \min_{\text{严重标准差}}$ ，则迭代调整 X_2 。

(3) 模型拟合

基于问题 1 的研究方法，这里仍采用线性函数、指数函数和幂函数作为候选函数，进行阈值函数拟合；使用最小二乘法估计参数值；选用决定系数 R^2 作为模型选择的评价指标，选择决定系数 R^2 最大的函数作为最优拟合函数。

(4) 新数据预测

对于附件 2 中新的理赔运单，应用拟合的双阈值函数进行风险等级预测：

$$\hat{C}_i = f(x_i, y_i, X_1^*, X_2^*) \quad (29)$$

其中， X_1^* 和 X_2^* 为最优拟合函数。

(5) 预测风险标注结果




图 12 预测分组结果拟合图

由图 12 可知，使用问题 1 风险标注规则预测附件 2 运单风险标注结果，红色部分标注为“严重超额”，黄色部分标注为“诉求偏高”，绿色部分标注为“合理诉求”；“严重超额”部分占比最少、“诉求偏高”部分占比适中、“合理诉求”部分占比最多。

(6) 阈值检验




图 13 不同预测分组的理赔差额核密度分布图

表 8 预测分组结果表

运单号	实际赔付金额	理赔差额	预测分组
1	243.8800049	436.6899951	合理诉求
2	265.3099976	457.9400024	合理诉求
3	697.5499878	853.9500122	合理诉求
4	261.5400085	465.7699915	合理诉求
5	50.95999908	49.17000092	合理诉求
6	243.8800049	436.6899951	合理诉求
7	265.3099976	457.9400024	合理诉求
40	791.3400269	2449.029973	诉求偏高
119	525.3599854	2114.110015	诉求偏高
121	638.5499878	2239.510012	诉求偏高
178	171.25	727.32	诉求偏高
283	270.2099915	992.9200085	诉求偏高
301	710.460022	4714.329978	严重超额
481	310.8099976	1323.990002	诉求偏高

5.3.2 基于机器学习的风险预测模型

(1) 特征工程

首先，对“实际赔付金额”、“保价金额”、“配送超时时长”等数值特征进行标准化处理，对“线路类型”、“是否生鲜妥投及时”、“商品类型”等分类特征进行编码处理。其次，进行特征值变换。对“始发网点万单理赔率”出现的负值取绝对值；对“目

的网点万单理赔率”出现的正值“变正为负”；构造比例特征和频率特征。

(2) XGBoost 分类模型

使用问题 2 使用的模型对附件 2 运单的风险等级进行预测。对于三分类问题，使用 softmax 目标函数：

$$p_{ik} = \frac{e^{f_k(x_i)}}{\sum_{c=1}^3 e^{f_c(x_i)}} \hat{y}_i = \arg \max_k p_{ik} \quad (30)$$

采用随机搜索法优化超参数：树深度 3-7；学习率 0.03-0.1；子样本比例 0.7-1.0；列样本比例 0.7-1.0。优化目标为宏平均 F1 分数：

$$F_1^{macro} = \frac{1}{3} \sum_{k=1}^3 F_1(k) F_1(k) = 2 \cdot \frac{precision(k) \cdot recall(k)}{precision(k) + recall(k)} \quad (31)$$

(3) 特征重要性分析

首先，计算基于树模型的特征重要性：

$$importance(j) = \sum_{k=1}^t gain(j, k) \quad (32)$$

其中， $gain(j, k)$ 表示第 k 颗树中特征的信息增益。

其次，筛选出重要性排名前 15 的特征： $S^* = \{j \mid rank(importance(j)) \leq N\}$ 。

(4) 模型的评估与验证

首先，采用 5 折交叉验证评估模型性能：

$$CV(k) = \frac{1}{5} \sum_{i=1}^5 F_1^{(i)}(k) \quad (33)$$

其次，通过混淆矩阵分析模型在不同类别上的表现：

$$CM = \begin{bmatrix} TP_1 & FN_{12} & FN_{13} \\ FN_{21} & TP_2 & FN_{23} \\ FN_{31} & FN_{32} & TP_3 \end{bmatrix} \quad (34)$$

(5) 预测结果

表 9 问题 3 预测结果表

运单号	实际赔付金额	理赔差额	预测分组
1	243.8800049	436.6899951	合理诉求
2	265.3099976	457.9400024	合理诉求
3	697.5499878	853.9500122	诉求偏高
4	261.5400085	465.7699915	合理诉求
5	50.95999908	49.17000092	合理诉求
6	243.8800049	436.6899951	合理诉求
7	265.3099976	457.9400024	合理诉求
40	791.3400269	2449.029973	合理诉求
119	525.3599854	2114.110015	严重超额
121	638.5499878	2239.510012	严重超额
178	171.25	727.32	诉求偏高
283	270.2099915	992.9200085	诉求偏高
301	710.460022	4714.329978	严重超额

481	310.8099976	1323.990002	诉求偏高
-----	-------------	-------------	------

5.3.3 优劣势

双阈值函数模型的优点是解释性强，计算简单；缺点是对数据分布假设较强；XGBoost 模型的优点是预测精度高，适应性强；缺点是解释性较差，计算复杂。

六、模型评价

6.1 优点

- ①双阈值函数模型对于特征分布清晰、类别边界明确的数据，双阈值模型能够提供较好的分类效果。
- ②双阈值函数模型相比单阈值模型，双阈值模型能够更好地处理类别之间的过渡区域，减少误分类。
- ③XGBoost 模型能够输出每个特征的重要性得分，有助于理解模型决策过程和特征选择。

6.2 缺点

- ①双阈值模型分类精度通常低于更复杂的模型。
- ②XGBoost 模型对极端异常值较为敏感，可能影响模型性能。

七、参考文献

[1]中国物流与采购联合会.前三季度中国社会物流总额同比增长 5.4%[EB/OL].2025-10-29.

[2]中国物流与采购联合会.“物畅其流”!透过亮眼数据看“十四五”期间我国现代物流发展重要成就[EB/OL].2025-08-27.

[3]人人文库.货损理赔通道 2025 年物流行业风险管理案例分析报告[R].2025-09-10.

[4]安壹保险律师.2024 年物流保险诉讼事由分析[EB/OL].2024-12-24.

[5]国务院办公厅.关于印发“十四五”现代物流发展规划的通知[Z].2024-12-10.

[6]政策快讯."十五五"规划物流专项解读[EB/OL].2025-10-26.

[7]张李明,洪蕾.基于双阈值函数的音符检测旋律时间序列化分析[J].电子技术,2022,51(09):22-25.

[8]杨晓南,刘佳明,艾恒雨,等.XGBoost 模型驱动的 MOFs 吸附重金属性能预测[J/OL].哈尔滨理工大学学报,1-10[2025-10-31].

[9]李鸿霄,张怀念,杨洁,等.基于 XGBoost 对大数据驱动地形气候交互模型的构建与暴雨灾害预测[J/OL].数学的实践与认识,1-11[2025-10-31].

[10]Haoyuan F ,Xuebin Z ,Peiji S , et al.Environmental interpretation of spatial heterogeneity in the trade-offs and synergies of land use functions: A study based on the XGBoost-SHAP model[J].Journal of Arid Land,2025,17(10):1378-1401.