

队伍编号	MCB2501209
赛道	B

基于多模型集成的运单风险标注策略

摘要

当前，物流理赔如何减少人工，提高服务效率成为物流服务商所需解决的问题。为减少物流理赔人工环节，本文基于题目所提供的数据信息，建立数学模型，为运单数据进行风险标注，实现运单风险的自动化识别，降低物流服务商理赔成本、提高服务质量。

针对问题一，首先对附件 1 进行数据预处理，通过结合指标实际含义确定取值范围，剔除了 2482 条数据；随后进行探索性分析初步讨论特征分布及关联。在问题一中，本文进行**两阶段风险标注**，在第一阶段中，按实际赔付金额对附件 1 数据进行**四分位数分层**，通过统计异常对不同层设定不同的自适应系数，对每层的索赔差额序列进行划分为“严重超额区”、“合理诉求区”以及“模糊区”；在第二阶段中，利用“**中心距离法**”“**KNN 近邻加权分类**”以及“**随机森林分类**”三种方法对各层的“模糊区”投票判定运单风险类型，划分得到附件 1 的运单共 **91%**为“合理诉求”，**6%**为“诉求偏高”，**2.9%**为“严重超额”，接着再对不同风险类型样本**密集程度**进行验证，发现合理诉求的索赔差额最密集，严重超额最稀疏，偏高介于两者之间。最后，对附件 1 类别特征进行**交叉分析**，标注出严重超额率最高的 10 个**风险组合**。

针对问题二，首先对运单数据进行预处理，利用中位数填充法以及读热编码对缺失值进行填充，以规避右偏分布下极端值的干扰，同时将分类型特征缺失值标记为“Unknown”并通过标签编码转换为数值型。考虑到数据非线性、高维度及极端值敏感的特点，本文选择构建了 LightGBM、随机森林、梯度提升树三类**集成树回归模型**加权集成的实际赔付金额预测模型，将附件 1 数据作为训练集、附件 2 数据作为测试集。通过评价指标 MAE、RMSE、 R^2 、MAPE 对预测结果进行评估，结果显示集成模型的 MAE=**100.41**、RMSE=**141.54**、 R^2 =**0.7770**、MAPE=**86.68%**，其中 MAPE 偏高源于小额与零赔付样本放大百分比误差，聚焦有效赔付场景可显著降低预测，详细结果见 result 文件。

针对问题三，因“严重超额”样本占比严重不均衡，不利于后续模型训练。本文采用 **SMOTE 过采样法**，基于**近邻关系**生成虚拟样本提高少数类的样本占比；接着调整**类权重**，提高少数类样本的错分惩罚。在初步处理后，本文基于附件 1 每个运单标签化后的数据作为训练集，以附件 2 作为测试集，为减少单一模型的偶然错误，本文训练了“随机森林”“XGBoost”“LightGBM”“CatBoost”四种分类模型对附件 2 的运单独立分类，得到 LightGBM 分类模型性能最佳。接着以各模型在验证集上“严重超额”类的 F1 得分进行加权，以**软投票**方式确定最终附件 2 中运单的风险分类，整体准确率达到 **0.973**，Cohen's Kappa 系数达到 **0.939**，“严重超额”类各评估指标均达到 **0.85**，模型泛化较优。

关键词：物流理赔； 两阶段风险标注； 多模型集成； 加权投票；

目录

- 一、问题重述 1
 - 1.1 问题背景 1
 - 1.2 问题重述 1
- 二、问题分析 2
 - 2.1 问题一的分析 2
 - 2.2 问题二的分析 2
 - 2.3 问题三的分析 2
- 三、模型假设 2
- 四、符号说明 3
- 五、问题一模型建立与求解 3
 - 5.1 数据预处理 4
 - 5.1.1 异常数据处理 4
 - 5.1.2 探索性数据分析 4
 - 5.1.3 数据分层 6
 - 5.2 实际赔付与理赔差额特征 6
 - 5.3 基于自适应阈值与集成学习的分层风险标注模型 7
 - 5.3.1 一阶段风险标注 8
 - 5.3.2 二阶段风险标注 9
 - 5.3.3. 风险类型样本密集程度验证 13
 - 5.4 交叉特征分析 14
- 六、问题二模型建立与求解 15
 - 6.1 数据预处理与特征工程 15
 - 6.1.1 缺失值处理 16
 - 6.1.2 分类特征编码 16
 - 6.2 实际赔付金额预测模型 16
 - 6.2.1 LightGBM 回归 16
 - 6.2.2 随机森林回归 17
 - 6.2.3 梯度提升树回归 19
 - 6.2.4 多模型集成策略 19
 - 6.3 模型评估与分析 19
 - 6.3.1 评估指标计算 19

6.3.2 结果分析	20
七、问题三模型建立与求解	21
7.1 数据预处理	21
7.2 类别不均衡处理	22
7.2.1 SMOTE 过采样	22
7.2.2 类权重调整	22
7.2.3 分类模型的权重调整	23
7.3 风险标注的分类模型	23
7.3.1 随机森林分类	23
7.3.2 XGBoost 分类	24
7.3.3 LightGBM 分类	25
7.3.4 CatBoost 分类	25
7.4 模型求解与结果分析	26
7.5 问题二、三方法优劣势	28
7.5.1 问题二方法优势	28
7.5.2 问题二方法劣势	29
7.5.3 问题三方法优势	29
7.5.4 问题三方法劣势	29
八、模型评价与推广	30
8.1 模型评价	30
8.2 模型推广	30
参 考 文 献	30
附录	31

一、问题重述

1.1 问题背景

在数字经济与电子商务的驱动下，物流行业经历了数年的快速扩张，其业务规模与服务范围持续扩大^[1]。伴随着运单量的指数级增长，履约过程中包裹丢失、破损等问题难以避免，由此引发的理赔纠纷已成为影响客户体验与企业成本的核心痛点。一方面，合理高效的理赔服务是物流企业维护品牌信誉、提升客户忠诚度的核心抓手；另一方面，超额赔付、恶意索赔等问题导致的成本攀升又对企业盈利水平与健康运营构成直接威胁，如何平衡“服务质量”与“成本控制”成为了物流行业普遍面临的核心挑战。

当前物流理赔服务主要分为售前与售后两部分：售前需基于客户的历史寄件行为、以及货物特性等信息提前识别高风险运单，为客户推荐适配的物流保障方案；而售后则需在客户提交索赔诉求后，快速判断其诉求合理性并采取差异化处理策略，对合理诉求实施快速理赔以提升体验，对偏高或严重超额诉求启动人工审核以控制成本。行业数据显示，理赔运单中“合理诉求”占比通常不低于 85%， “严重超额”占比不超过 3%，该样本分布特征既为数据驱动的风险管控提供了基础，也对模型的精准性与鲁棒性提出了更高要求。

智能供应链技术发展与多维度运单数据积累为理赔智能化升级提供了可能。依托历史运单数据中运单、客诉、行为等多维度特征建立科学的风险标注以及预测模型，不仅能降低人工审核压力、控制理赔成本，还能反向优化售前服务推荐，实现理赔流程的智能化升级，形成“售前预判-售后优化”的闭环管理体系。

1.2 问题重述

该研究问题围绕物流理赔风险识别及服务升级展开，基于附件 1 提供的历史运单数据与附件 2 的待预测运单数据，需解决以下三个核心问题：

问题一：根据附件 1 中“理赔差额”与“实际赔付金额”两大核心指标进行分析，明确类别划分的标准与算法，将运单划分为“合理诉求”“诉求偏高”“严重超额”三类，构建科学的风险标注模型对其运单进行风险标注，同时得出附件 1 所有运单的风险标注结果及相应分析。

问题二：结合附件 1 中的历史运单数据，根据其运单、客诉、行为等多维度特征，建立预测模型以预测附件 2 中运单的实际赔付金额，并说明预测结果的评估指标，同时在不改变表格运单号的前提下，将所有运单的预测结果填写至 result 文件中。

问题三：运用问题一确定的风险标注规则，结合附件 1 数据构建风险标注分类模型，从而预测附件 2 中运单的风险标注结果，将其与问题二的结果一并填写到 result 文件中提交。同时，我们仍需要详细描述对于“严重超额”样本占比严重不均衡的处理方法，并对比与论述该方法与问题 2 预测风险标注结果方法的优劣势。

二、问题分析

2.1 问题一的分析

问题一要求我们根据附件 1 的信息对“理赔差额”与“实际赔付金额”进行分析，且建立一风险标注模型对运单进行划分，并给出标注结果与分析。首先需要根据附件 1 的数据指标，根据实际背景及指标含义去判断数据范围，如理赔率指标应为正数，对不合理的数据进行剔除，且对缺失值进行填补。因题目说明实际赔付金额越高，对索赔差额的容忍度会越高，本题难点在于如何界定“诉求偏高”，故可以建立两阶段风险标注模型。在一阶段中，可对附件 1 根据实际赔付金额进行四分位数划分为四层，在每层内依据“索赔差额”指标对运单进行划分，根据“严重超额”的运单占比小于 3%及“合理诉求”的运单占比不低于 85%的约束，将每层的运单划分为“严重超额”、“合理诉求”及“模糊区”；在第二阶段中，将“模糊区”进一步划分为“合理诉求”及“诉求偏高”。最后，再根据交叉特征分析组合的“严重超额”率，单独标记出来，优化物流公司售前准备环节。

2.2 问题二的分析

问题二要求我们基于附件 1 历史运单数据集训练一个预测模型，最终用于预测附件 2 测试集的实际赔付金额，输出结果并给出相应评级指标检验预测模型的准确性。由于附件 1、2 中存在数值型与分类型特征混合、目标变量右偏分布及部分缺失值等问题，需先通过差异化预处理以保障数据质量。由于数据之间存在的非线性关联、高纬度及极端值敏感等特点，传统线性模型难以满足需求，因此本题的难点在于如何选取合适的模型，最终测试集数据实现实际赔付金额的预测，同时为了更好的评估模型与结果的，需采用 MAE、RMSE、 R^2 、MAPE 四类回归指标全面验证模型性能，同时其输出结果将为问题三的风险标注分类提供关键量化支撑，助力物流企业实现理赔服务效率提升与成本控制的双重目标。

2.3 问题三的分析

对于问题三，需要基于问题一的风险标注规则，利用附件 1 的数据训练风险标注分类模型，将训练后的分类模型用于预测附件 2 中运单的风险标注结果。本题难点在于“严重超额”类样本占比不足 3%，该类样本严重不均衡，在模型训练过程中会产生较大的影响。故在模型训练之前，应对数据进行相应的处理，可以通过生成新的占比低的类别样本来平衡类别样本分布，但简单复制样本会导致模型过拟合，应采用“重采样”法生成新样本提高模型在少数类的训练性能，并可以提高严重超额类别的惩罚权重。虽然这两种方法能够有效改善“严重超额”占比严重不均衡的问题，但避免依赖单一模型，可以采用“多模型”+“概率投票”方法进行决策。

三、模型假设

1. 题目所提供的数据，其特征分布具有稳定性，保价金额、商品类型、网点事故率等核心特征与实际赔付金额、风险类型的关联机制在预测期内保持不变；

2. 数据集中的缺失值无系统性偏差，不会因“严重超额”“合理诉求”等类别差异导致关键信息缺失，且异常值已通过预处理有效控制，不影响模型核心规律捕捉。
3. 物流理赔的核心业务约束（合理诉求占比 $\geq 85\%$ 、严重超额占比 $< 3\%$ ）在模型应用周期内保持稳定，不会因政策调整或企业规则更新发生根本性变化；
4. 实际赔付金额的计算逻辑与索赔差额的风险映射关系具有一致性，跨区域、跨商品类型的赔付标准差异可通过特征量化消除。

四、符号说明

表 1 符号说明表

符号	含义
D_i	第 i 层的差额序列
S_i	第 i 层的严重超额区域
R_i	第 i 层的合理诉求区域
k	自适应系数
k_{i1}	严重超额系数
k_{i2}	合理诉求系数
Y_{i-high}	第 i 层的“严重超额”区域中心
Y_{i-low}	第 i 层的“合理诉求”区域中心
P_c	当前节点中类别 c 的样本占比
$weight_i$	类权重
$h_k(x)$	第 k 棵决策树对样本 x 的预测值
$\hat{p}_{ik}$	样本 i 被预测为第 k 类风险的概率
$y_{pred,i}$	样本 i 的预测风险类别

五、问题一模型建立与求解

在问题一的处理中，首先对附件 1 进行数据预处理，随后进行探索性分析初步讨论特征分布及关联。问题一可以通过两阶段风险标注求解，在第一阶段中，先按实际赔付金额对附件 1 数据进行四分位数分层，对每层的索赔差额序列进行划分为“严重超额区”、“合理诉求区”以及“模糊区”；在第二阶段中，通过三种方法对各层的“模糊区”投票判定运单风险类型，再对不同风险类型样本密集程度进行验证。最后，对附件 1 类别特征进行交叉分析，标注出严重超额率最高的 10 个风险组合。

问题一的思路框架图如图 1 所示。




图 1 问题一框架图

5.1 数据预处理

5.1.1 异常数据处理

对于附件 1 及题目对数据文件的信息解释，初步根据以下指标对数据进行剔除处理：始发网点发单量与目的网点发单量指标数值应大于 0；始发网点万单理赔率与目的网点万单理赔率指标数值应大于 0；始发网点赔付比例与目的网点赔付比例指标数值应在[0,1]区间；保价金额应大于 0。根据以上筛选规则，本文对附件 1 共剔除了 2482 条数据，剩余 8685 条数据进行后续分析。


5.1.2 探索性数据分析

附件 1 数据有中英文列名，为方便后续建模分析，只保留中文列名。题目没给出索赔差额，故我们需要根据所给的公式进行计算：

索赔差额 = 实际赔付金额-索赔金额 (1)

计算出索赔差额后将其命名为“claim_diff”。

接着对附件 1 中的如进线渠道、进线人身份等类别指标与索赔差额进行交互分析可视化如图 2 所示。






图 2 类别指标&索赔差额交互分析图

这四张图表分别从进线渠道、异常原因、进线人身份、寄件 B/C 四个维度，分析“索赔差额”的分布差异。整体可见各维度下索赔差额均集中在“实际赔付低于索赔金额”的区间，但不同类别在“大额负向差额”“小额负向差额”的频数存在明显分化。

再分别初步探讨事故率、商品类型与索赔差额的数据分布特征如图 3 所示。




图 3 数据分布特征可视化

左图每个数据点的颜色深度对应“索赔差额”的绝对值。从分布可见，多数运单集中在“始发事故率 ≤ 100 、目的事故率 ≤ 150 ”的低风险区域（红色密集区），而当始发或目的事故率超过 200 时，数据点颜色明显向深色调（索赔差额 ≤ -3000 ）倾斜，直观揭示高事故率节点的运单存在显著严重超额索赔风险。右图显示杂项、家具等商品严重超额风险突出；二者结合可帮助物流公司从运输节点和商品属性维度精准识别高风险场景，针对性优化运输监控、包装要求等策略，实现理赔风险的分层管控与资源高效分配。

最后，总体分析各指标之间的相关关联，进行斯皮尔曼相关性分析，其热力图如图 4 所示。



图 4 斯皮尔曼相关分析热力图

由此图可见，始发 / 目的网点的运单量、事故率、理赔率等特征间也存在不同程度的相关性，这些关联可助力挖掘理赔风险的关键影响因素，为后续风险标注与模型构建的特征选择提供依据。

通过以上探索性数据分析，为后续进一步深入探究交互特征提供方向。

5.1.3 数据分层

由于实际赔付金额越高时需要更高的索赔差额才会标注为“诉求偏高”或“严重超额”，即对于不同实际赔付金额需要有不同的分析讨论其阈值划分，故本文先对原始数据文件附件 1 按照实际赔付金额的 25%分位数、50%分位数与 75%分位数进行四等分，使得每层都有 2172 条数据。

5.2 实际赔付与理赔差额特征

首先先对索赔差额的分布及其概率密度进行可视化，初步观察其特征如图 5 所示。




图 5 索赔差额分布及概率密度可视化

由左图可知，数据呈左偏分布，存在少量“极端索赔差额”的运单，这类运单实际赔付远低于客户索赔金额，是理赔风险的核心关注点；而多数运单集中在-1000 至 0 区间，体现“合理诉求或轻微偏高诉求”占比高的业务现状。右图的曲线在 0 附近形成尖锐峰值，说明“索赔差额接近 0”的运单出现概率极高，而在-6000 至 0 区间，密度随索赔差额的绝对值增大呈指数级降低，体现“严重超额运单的发生概率随差额绝对值增大急剧下降”的规律。

接着对实际赔付金额与理赔差额分布特征进行可视化如图 6 所示。




图 6 实际赔付金额&理赔差额分布特征图

由图 6 可知，红色虚线为理想线，表示实际赔付=索赔差额，对远离红色虚线的运单，后续需重点关注分析。绝大多数点位于红色虚线下方为核心特征——说明实际赔付金额普遍低于客户索赔金额。随着索赔金额增加，实际赔付金额也呈上升趋势，但上升幅度小于索赔金额的增长幅度。数据点在“低索赔金额(0-2000)”区间高度聚集,说明小额索赔的运单数量占比极高;而“高索赔金额(3000+)”区间点相对稀疏,大额索赔为少数场景。

5.3 基于自适应阈值与集成学习的分层风险标注模型

在数据处理中我们按实际赔付金额将原始数据划分了四层，需要我们在每层内分别标注运单风险类型，且最终整合应满足“严重超额”运单占比小于 3%，“合理诉求”运单占比不低于 85%。由于“合理诉求”与“诉求偏高”不好界定，故本文分为两阶段进行风险标注，在此阶段是对每层进行“严

重超额”与“合理诉求”的阈值判定，通过统计阈值将每层划分为三段，分别为“严重超额”、“合理诉求”及以外的“模糊区”。

5.3.1 一阶段风险标注

1. 划分规则

首先，对第*i*层的差额序列设为*D_i*，第*i*层的严重超额区域为*S_i*，第*i*层的合理诉求区域为*R_i*，分别计算每层差额序列的均值 μ 与标准差 σ ，采用统计异常检测四项，计算“均值 - *k**标准差”对每层差额序列进行划分，公式如下：

$$S_i = \mu_i \pm k_{i1}\sigma \tag{2}$$

$$R_i = \mu_i \pm k_{i2}\sigma \tag{3}$$

其中， k_{i1} 为严重超额系数； k_{i2} 为合理诉求系数。

2. 自适应系数 *k* 值调整策略

自适应系数 *k* 越大，则差额容忍度越低（越严格），反之容忍度越大（越宽松），即在实际赔付金额越大时，应给予更高的差额容忍度，在赔付金额越小时，容忍度应降低^[2]。

a. *D₁*层（P0-25）系数选取策略

作为低赔付层，对差额容忍度极低（需严格控制严重超额），因此选取较大的严重超额系数*k₁₁*=2.9、适中的合理诉求系数*k₁₂*=0.9，贴合“实际赔付金额小，对差额容忍度低”。通过以下公式划分区间：

$$S_1 = \mu_1 \pm k_{11}\sigma \tag{4}$$

$$R_1 = \mu_1 \pm k_{12}\sigma \tag{5}$$

b. *D₂*层（P25-50）系数选取策略

赔付水平中等偏低，系数较*D₁*层略宽松，选取*k₂₁*=2.8、*k₂₂*=0.86，既不过度限制客户诉求，也能控制理赔成本。通过以下公式划分区间：

$$S_2 = \mu_2 \pm k_{21}\sigma \tag{6}$$

$$R_2 = \mu_2 \pm k_{22}\sigma \tag{7}$$

c. *D₃*层（P50-75）系数选取策略

赔付水平中等偏高，给予一定差额容忍度，选取*k₃₁*=2.7、*k₃₂*=0.84，实际赔付较高，可对差额容忍度适度提升，同时为全局严重率控制预留空间。通过以下公式划分区间：

$$S_3 = \mu_3 \pm k_{31}\sigma \tag{8}$$

$$R_3 = \mu_3 \pm k_{32}\sigma \tag{9}$$

d. *D₄*层（P75-100）系数选取策略

作为高赔付层，对差额容忍度最大（实际赔付高，需更高差额才判定为严重超额），因此选取较小的严重超额系数*k₄₁*=2.5、略宽松的合理诉求系数*k₄₂*=0.8，贴合实际赔付越高容忍度越大的实际情况，又通过全局加权平均确保整体严重率 < 3%。通过以下公式划分区间：

$$S_4 = \mu_4 \pm k_{41}\sigma \tag{10}$$

$$R_4 = \mu_4 \pm k_{42}\sigma \tag{11}$$

3.求解结果

通过以上规则运算，得到四个层的区域划分如表 2 所示。

表 2 区域划分指标表

分层	严重系数 k_{i1}	合理系数 k_{i2}	严重阈值	合理阈值	严重率	模糊率	合理率
$D_1(P0-25)$	2.9	0.9	-908.53	-435.25	2.67%	11.88%	85.45%
$D_2(P25-50)$	2.8	0.86	-1489.51	-720.8	2.58%	13.68%	83.74%
$D_3(P50-75)$	2.7	0.84	-1932.34	-975.13	3.27%	11.56%	85.17%
$D_4(P75-100)$	2.5	0.8	-3259.84	-1761.97	2.95%	15.43%	81.62%

此时，整体的严重超额率为 2.8%，合理诉求占比 84%，模糊区域占比 13%。由于在此阶段中对严重超额的阈值设置的最严格，且 $D < S$ 的样本占比 $<3\%$ ，属于极端尾部，模糊区域的区间为 $[S, R]$ ，与严重超额区域始终隔着阈值 S ，故后续在第二阶段进一步将模糊区域界定出“合理诉求”与“诉求偏高”即可，无需界定“严重超额”。

5.3.2 二阶段风险标注

在第一阶段中，我们将每层划分出了“严重超额”区域、“合理诉求”区域以及“模糊区域”，此阶段用于将“模糊区域”进一步的界定诉求偏高或是合理诉求。本文在第二阶段通过利用“中心距离法”、“KNN 近邻加权分类”、“随机森林分类”三种方法^[3]，对各层的模糊区以“投票”判定运单的类型。

1. 特征选取

在这第二阶段中，本文从 4 个维度选取了题目所提供的 11 个连续型变量作为指标，并增 8 个连续性指标，新增指标均基于原始指标进行计算，原始指标跟随以下新增指标进行划分维度，新增指标有：

- a. 索赔合理性 1：索赔金额与保价金额比例，衡量索赔合理性；
 - b. 索赔合理性 2：实际赔付与保价金额比例，衡量赔付对保价的覆盖度；
 - c. 索赔合理性 3：差额绝对值与实际赔付金额比例，衡量赔付与诉求的相对差距；
 - d. 网点运营风险 1：始发网点和目的网点万单理赔率的均值，衡量始发-目的网点理赔风险密度；
 - e. 网点运营风险 2：始发网点和目的网点万单赔付比例的均值，衡量始发-目的网点的实际赔付对客户诉求的覆盖程度；
 - f. 网点运营风险 3：始发网点万单理赔率 - 目的网点万单理赔率，体现始发--目的网点理赔风险差异程度及差异方向；
 - g. 物流时效：配送超时市场 + 妥投到进线时长，反映时效延误对理赔的影响；
 - h. 网点规模：始发网点和目的网点发单量的均值，关联网点规模与运营风险的关系
- 为避免分数指标分母为零的情况，对每个计算指标+1 后进行计算。

2. 数据处理

为便于后续风险标注模型建立，在此先对以上共 19 个指标进行标准化处理，公式如下：

$$x_{scaled} = \frac{x - \mu}{\sigma} \tag{12}$$

此处数据处理是对全体数据进行标准化处理，再分别转换三类数据，确保训练 / 测试数据同分布。

对数值指标标准化能够消除特征量纲差异，确保后续距离计算或分类模型中各特征的权重公平。其中， μ 为全体数据中的均值， σ 为标准差。

3. 中心距离法

中心距离法是通过计算“模糊区样本到两类已知区域中心的欧氏距离”，将样本归为距离更近的区域，根据“相似样本在特征空间中更接近”的原则，由数据分布决定模糊区域样本分类结果。

首先，计算每层中两类区域的特征中心，即“严重超额”区域与“合理诉求”区域的标准化特征均值，代表该类样本的“平均特征模式”。令第*i*层的“严重超额”区域中心为 Y_{i-high} ，“合理诉求”区域中心为 Y_{i-low} ，计算公式如下：

$$Y_{i-high} = \frac{1}{n_{i-high}} \sum_{j=1}^{n_{i-high}} X_{i,j-high} \quad (13)$$

$$Y_{i-low} = \frac{1}{n_{i-low}} \sum_{j=1}^{n_{i-low}} X_{i,j-low} \quad (14)$$

其中， n_{i-high} 表示每层中“严重超额”区域的样本量， n_{i-low} 同理； $X_{i,j-high}$ 表示每层中“严重超额”区域的第*j*个特征标准化后的值， $X_{i,j-low}$ 同理。

接着，计算模糊区样本到中心的欧式距离，欧氏距离即衡量高维空间中两点的直线距离，距离越小，样本与区域的相似度越高。对第*i*层模糊区的第*j*个样本 $x_{i,j}$ ，到两个中心的距离公式为：

$$dist_{high-i} = \sqrt{\sum_{z=1}^m (x_{i,j,z} - Y_{i-high})^2} \quad (15)$$

$$dist_{low-i} = \sqrt{\sum_{z=1}^m (x_{i,j,z} - Y_{i-low})^2} \quad (16)$$

其中，*m*为特征总数，*z*为第*z*个特征。

最后，若 $dist_{high-i} < dist_{low-i}$ ，则样本归为“诉求偏高”，反之归为“合理诉求”。

4. KNN 近邻加权分类

KNN 算法通过衡量样本与“邻居”的相似度来判定其类别，该算法不预先训练模型，而是在预测时直接利用训练集数据，即对于待分类的模糊区样本，找到其在特征空间中最最近的*K*个训练样本，再根据这些“邻居”的多数类别来判定模糊区样本的类别。

首先将“严重超额”和“合理诉求”的运单特征合并为训练集 X_{train} ，并标注对应类别 Y_{train} 。其中，标签类别 Y_{train} 中“严重超额”区域样本标签为“偏高”，“合理诉求”区域样本标签为“合理”。

接着，设定*K*值，即“邻居”数量，为保证邻居数量足够反映整体分布，又避免过多邻居引入异类样本，本文在代码中设定 $K = \min(50, \text{len}(X_{train})/2)$ ，且为避免远邻样本对分类的干扰，我们设定距离越近的“邻居”，投票权重越大，最终通过加权投票将模糊区样本进行归类，计算公式如下：

$$w_{i,k} = \frac{1}{dist_{i,k} + \epsilon} \quad (17)$$

$$score_{high-i} = \sum_{y_k='偏高'} w_{i,k} \quad (18)$$

$$score_{low-i} = \sum_{y_k='合理'} w_{i,k} \quad (19)$$

其中，公式 的 $dist_{i,k}$ 表示欧式距离，同前文中心距离法计算一致， ϵ 设为 1e-06，保证分母不为 0；公式 与 分别表示第 i 个样本的偏高类别权重与合理类别权重。

若 $score_{high-i} > score_{low-i}$ ，则样本归为“偏高”，否则归为“合理”。

5. 随机森林分类

随机森林分类法通过构建多棵独立的决策树，每棵树基于训练集的“随机特征子集+ 随机样本子集”训练；对模糊区样本，每棵树输出一个分类结果，最终按“多数票”决定样本类别即通过多树投票降低单棵树的过拟合风险，同时能自动学习特征重要性^[4]。

首先，通过样本随机+特征随机保证树之间的独立性。样本随机即 Bootstrap 抽样，通过对训练集进行有放回抽样，生成每棵树的训练子集；特征随机即在每棵树分裂时，仅从 $\sqrt{m}$ 个特征(m 为特征总数)中选择最优分裂特征，进一步强化树的多样性

接着进行分裂，决策树分裂逻辑为：每棵树在训练时，对每个特征的每个可能阈值，计算分裂后的“子节点 Gini 系数加权和”，选择使 Gini 系数下降最大的特征-阈值组合，递归分裂直到满足停止条件。其中，Gini 系数用于衡量节点样本的纯度，值越小则纯度越高，类别越集中，Gini 系数公式为：

$$Gini = 1 - \sum_{c=1}^C p_c^2 \quad (20)$$

其中，C 为类别总数， P_c 为当前节点中类别 c 的样本占比。

在计算中，随机森林可自动输出特征对分类结果的贡献度，通过特征分裂时 Gini 系数的总下降量衡量，公式为：

$$Importance_j = \sum_{tree=1}^T \Delta Gini_{tree,j} \quad (21)$$

在该方法中，本文代码设置了 200 棵决策树，对模糊区的每个待分类样本，每棵树输出一个分类结果，最终按多数票决定样本类别。

6. 分类结果说明

在一阶段划分中， $D_1(P0-25)$ 层模糊区样本量为 258， $D_2(P25-50)$ 层模糊区样本量为 297， $D_3(P50-75)$ 层模糊区样本量为 251， $D_4(P75-100)$ 层模糊区样本量为 335。在前文三种方法中，避免了通过人为主观分类带来的偏差，每个方法均独立计算对模糊区中的样本进行类别划分，最终以三个方法分类结果再进行投票，若三个方法划分出来都为“合理”，则一致性得分为 1，最终分类结果为“合理”，若

划分结果有差异，有两种方法划分为“偏高”，一种为“合理”，则一致性得分为 0.667，最终分类结果为“偏高”。

在此取每层模糊区的前三个样本展示分类结果，具体如表 3 所示。

表 3 模糊区分类结果

层	中心距离法分类	KNN 法分类	随机森林分类	最终分类	一致性得分
D ₁ (P0-25)	合理	合理	合理	合理	1
	合理	合理	合理	合理	1
	偏高	合理	偏高	偏高	0.667
D ₂ (P25-50)	偏高	偏高	偏高	偏高	1
	偏高	偏高	偏高	偏高	1
	偏高	合理	偏高	偏高	0.667
D ₃ (P50-75)	偏高	偏高	偏高	偏高	1
	偏高	偏高	偏高	偏高	1
	合理	合理	合理	合理	1
D ₄ (P75-100)	偏高	偏高	偏高	偏高	1
	偏高	偏高	偏高	偏高	1
	合理	合理	合理	合理	1

在D₁(P0-25)层中，一致性得分为 1 的样本占比 85%；D₂(P25-50)层中，一致性得分为 1 的样本占比 80%；D₃(P50-75)层中，一致性得分为 1 的样本占比 81%；D₄(P75-100)层中，一致性得分为 1 的样本占比 64%。可以看到，三种方法独立投票结果全部一致的样本占大多数，本文方法具有合理性。

在二阶段风险标注后，已将附件 1 的运单全部划分，接下来对结果进行直观可视化如图 7 所示。




图 7 划分结果可视化

在对每层中各类型区域运单数直观可视化如图 8 所示。




图 8 各层各类型区域运单数可视化

其中，红线为严重超额阈值线，黄线为合理诉求阈值线，中间则为诉求偏高区域。

再对以上两阶段结果进行统计，划分得到附件 1 中的所有运单共 91%为“合理诉求”，6%为“诉求偏高”，2.9%为“严重超额”，满足实际中“严重超额”运单占比通常小于 3%，“合理诉求”的运单不低于 85%的现实约束。

5.3.3. 风险类型样本密集程度验证

一般来说“合理诉求”的运单索赔差额相对密集，“严重超额”的运单索赔差额相对稀疏，且不同类型的运单索赔差额密集程度之间存在明显差别。

本文通过计算各风险类别标准差，以散点、小提琴图可视化索赔差额分布，与对索赔差额密度曲线可视化，进行验证不同风险类型的样本分布密集程度是否存在明显差别。

计算得到合理诉求的标准差为 418.22；诉求偏高的标准差为 743.48；严重超额的标准差为 961.03。标准差越小表示越密集。进一步通过三个图来说明不同风险类型的密集程度差异，可视化如图 9 所示。




图 9 密集程度差异可视化

左图小提琴图中，合理诉求的形状最窄、偏高次之、严重超额最宽；中图散点图里，合理诉求点最聚集、偏高次之、严重超额最分散；右图核密度曲线中，合理诉求峰值最高且曲线最窄、偏高次之、严重超额峰值最低且曲线最宽。整体而言，合理诉求的索赔差额最密集，严重超额最稀疏，偏高介于两者之间，明确体现了三类风险在密集程度上的梯度差异，表明本文风险标注模型对运单划分符合实际场景分布约束。

5.4 交叉特征分析

在前文建立了本题所要求的风险标注模型，并详细说明了标注规则对运单划分的机制，且给出了风险标注结果并对风险类型的样本量分布进行了验证，满足实际业务约束。进一步地，我们在本节通过风险标注后的结果数据，进行交叉特征分析，深入研究不同特征组合的历史运单严重超额率，优化物流企业的售前预警环节。

首先，对每个运单的风险标注进行标签化，0 表示合理诉求、1 表示诉求偏高、2 表示严重超额。基于业务经验从运单数据中筛选与“风险标注”相关的类别特征，如进线渠道、进线人身份等类别特征，通过筛选二维类别特征组合的运单，计算该类别特征组合的严重超额率，公式为：

严重超额率 =
$$\frac{\sum_{i=1}^n I(y_i = 2)}{n}$$
 (22)

其中，n 为该特征组合的总运单数量； y_i 为第 i 个运单的风险标签，当 $y_i = 2$ 时表示严重超额； $I(\cdot)$ 为指示函数，当括号内 $y_i = 2$ 成立时取 1，否则取 0。

剔除掉特征中未知量后，严重超额率排名前 10 的类别特征组合如表 4 所示。

表 4 严重超额率排名前 10 的类别特征组合

特征组合	最高风险组合	样本数	严重超额数	严重超额率
商品类型×线路类型	母婴用品×线路 1	10	2	20.00%
进线渠道×线路类型	小程序×线路 5	17	2	11.76%
进线渠道×进线人身份	供应商咨询×工作人员	10	1	10.00%
异常原因×商品类型	疑似丢失×家居用品	43	4	9.30%
进线人身份×商品类型	工作人员×药品	12	1	8.33%

续表 4 严重超额率排名前 10 的类别特征组合

特征组合	最高风险组合	样本数	严重超额数	严重超额率
进线渠道×异常原因	客诉×疑似丢失	14	1	7.14%
进线人身份×线路类型	收件人×线路 1	65	4	6.15%
进线人身份×异常原因	工作人员×疑似丢失	17	1	5.88%
异常原因×线路类型	疑似丢失×线路 1	34	2	5.88%
寄件 B/C×线路类型	寄件 C×线路 5	200	8	4.00%

通过类别特征交叉计算严重超额率，精准定位了“母婴用品 × 线路 1”、“小程序 × 线路 5”等高风险特征组合，其中母婴用品走线路 1 的严重超额率达 20%，风险尤为突出。建议企业针对这些高风险组合的运单加强人工审核，优化母婴用品在特定线路的运输保障措施，并对小程序进线且走线路 5 的运单提前介入风险管控，从而有效降低严重超额理赔的成本。

六、问题二模型建立与求解

对于问题二，应对运单数据进行缺失值填充，以规避右偏分布下极端值的干扰，同时将分类型特征通过标签编码转换为数值型。考虑到数据非线性、高维度及极端值敏感的特点，本文构建了LightGBM、随机森林、梯度提升树三类**集成树回归模型**加权集成的实际赔付金额预测模型，聚焦有效赔付场景可显著降低预测。

问题二思路框架如图 10 所示。




图 10 问题二框架图

6.1 数据预处理与特征工程

实际赔付金额的预测是判断客户诉求合理性、实现理赔流程的智能化升级重要前提，为了更加精准地预测附件 2 的实际赔付金额，我们对于附件 1 和附件 2 的数据进行了与问题一相同的数据预处理，同时对于问题二我们进行了以下额外的处理。

6.1.1 缺失值处理

针对附件数据中数值型与分类特征的缺失值，我们采用了采用不同的处理方法。由于实际赔付金额等数值特征呈右偏分布，其均值受极端值干扰较大，中位数可以更好的保留数据集中趋势，因此我们采用中位数填充法，具体公式如下：

$$x_{fill} = \text{median}(x_{non-null}) \quad (23)$$

其中 $x_{non-null}$ 表示特征的非缺失值集合。

而对于商品类型等分类型数据的缺失值，我们将其标记为“Unknown”，使其独立类别，通过独热编码转换为二进制特征，避免信息的丢失。

6.1.2 分类特征编码

对“商品类型”、“线路类型”、“进线渠道”等分类特征数据，我们采用标签编码使其转换为数值型，用 $0 \sim C - 1$ 的整数将 C 个类别的特征进行映射，具体公式如下：

$$x_{encoded} = Le(x_{raw}) \quad (24)$$

其中 $Le(\cdot)$ 表示标签编辑器， x_{raw} 表示原始分类值， $x_{encoded}$ 为编码后的数值，为了保障数据的一致性，避免编码偏差，我们将测试集出现而训练集不存在的类别映射为-1。

6.2 实际赔付金额预测模型

由于题目给定的物流理赔的运单数据存在非线性、高纬度以及极端值敏感等特点，因此我们选择 LightGBM、随机森林、梯度提升树三类集成树回归模型作为基础模型，并通过集成策略融合模型优势，最终实现实际赔付金额的预测。其中我们将训练集的 80% 作为训练子集，最终用于模型拟合，20% 作为验证子集，最终用于评估模型预测的性能，并根据其结果调整模型参数。

6.2.1 LightGBM 回归

LightGBM 可凭借直方图优化与 Leaf-wise 生长等核心创新，在保证预测精度的同时大幅提升训练效率^[5]，尤其适用于该高维度、大规模的结构化数据场景的物流理赔问题，我们将根据其算法原理和创新优化部分对其在实际赔付金额预测中的应用展开分析。

1. 核心算法原理

LightGBM 基于梯度提升决策树（GBDT）框架，通过迭代生成一系列弱决策树并加权融合，最终构建而成的强预测模型。其核心逻辑包括拟合残差、逐步优化，具体步骤如下：

a. 初始预测

在模型训练初期，通常取目标变量实际赔付金额的均值为所有样本的初始预测值，其公式如下：

$$\hat{y}_0 = \bar{y} = \frac{1}{N} \sum_{i=1}^N y_i \quad (25)$$

其中 N 为训练集总数； y_i 为第 i 个样本的真实赔付金额； $\hat{y}_0$ 为初始预测值。

b. 残差计算

在第 t 轮迭代中，通过计算模型预测值与真实值的残差来量化模型的未解释误差：

$$r_{t,i} = y_i - \hat{y}_{t-1,i} \quad (26)$$

其中 $r_{t,i}$ 为第 i 个样本在第 t 轮的残差； $\hat{y}_{t-1,i}$ 为第 $t-1$ 轮模型对第 i 的样本的预测值。

c. 拟合残差的决策树训练

令每轮迭代训练一棵二叉决策树的目标为**最小化残差的均方误差**（MSE），使其树的预测值尽可能接近残差：

$$h_t(x) = \underset{h}{\operatorname{argmin}} \sum_{i=1}^N (r_{t,i} - h(x_i))^2 \quad (27)$$

其中决策树的构建采用**二叉分裂策略**，每个节点分裂时选择最优特征与阈值,树的结点分裂以“**最大化均方误差减小量**”为标准，具体公式如下：

$$Gain = MSE_{parent} - \left(\frac{N_L}{N} \cdot MSE_L + \frac{N_R}{N} \cdot MSE_R \right) \quad (28)$$

其中 MSE_{parent} 为父节点的均方误差；

N_L 与 N_R 分别为左、右子节点的样本数 $N = N_L + N_R$ ；

MSE_L 与 MSE_R 分别为左右子节点的均方误差。

d. 模型更新

将新训练的决策树 $h_t(x)$ 纳入到集成模型中，在本题中，我们引入学习率 $\eta=0.05$ （收缩因子）来控制单棵树的贡献权重，避免过度拟合：

$$\hat{y}_{t,i} = \hat{y}_{t-1,i} + \eta \cdot h_t(x_i) \quad (29)$$

其中 $\hat{y}_{t,i}$ 为第 t 轮模型对第 i 个样本的预测值。

e. 迭代终止

重复步骤(2)~(4)，直到迭代次数达到最大或着达到早停条件，最终得到模型为 T 棵树决策树的加权和为：

$$\hat{y}_i = \bar{y} + \sum_{t=1}^T \eta \cdot h_t(x_i) \quad (30)$$

2. 核心创新优化

通过与传统的 GBDT 方法的比较，LightGBM 实现了效率与精度的双重提升，使得其也更适配物流理赔数据的特征。

a. 直方图优化

通过将其连续特征离散化为 255 个直方图 bin,我们可以发现其分裂增益计算复杂度从 $O(n)$ 降低至 $O(255)$ ，并且其训练速度提升了 10 倍。

b. Leaf-wise 生长策略

每次迭代仅扩展当前增益最高的叶节点，使其在相同迭代次数下可获得更高精度。

6.2.2 随机森林回归

随机森林（Random Forest）是一种集成学习算法，通过构建多棵独立的决策树并融合其预测结果，

最终实现了对复杂数据模式的精准捕捉。与单一决策树相比，随机森林通过“多样性集成”有效降低了过拟合风险，在该物流理赔问题中体现出了其卓越效果。

核心算法原理

随机森林是通过 Bootstrap 独立的决策树“投票”从而生成最终预测，其相应的构建过程如下：

1. Bootstrap 抽样

为了确保各决策树的独立性，我们采用了有放回抽样（Bootstrap 抽样），在原始训练数据集中样本随机选择 N 个样本，生成了 k 个不同的子训练集 D_k ：

$$D_k = \{x_{i_1}, x_{i_2}, \dots, x_{i_N}\}, \quad i_j \sim \text{Uniform}(1, N) \quad (31)$$

其中 N 为原始训练集的样本数。

2. 随机特征选择

在构建单棵决策树时，我们并非使用其所有 p 个特征，而是通过随机选择部分特征参与节点分裂，从而进一步增强树间的多样性。在本题中我们不难发现 p 等于 17，即 $\sqrt{17} \approx 4.12$ 因此我们的每棵树需要选取 4~5 个特征，并且其特征选取需要在每个节点分裂时独立进行，即同一棵树在不同的节点可以使用不同的特征子集。最终避免了“保价金额”、“索赔金额”等强特征在所有树中主导分裂，使“配送线路类型”“进线渠道”等弱特征也有机会贡献信息。

3. CART 回归树算法

每个子训练集上训练一棵分类与回归树（CART），其核心是通过递归二分分裂生成树结构：

a. 分裂标准：对于当前节点的样本集合 S ，可选择候选特征与阈值中使分裂后“均方误差（MSE）减少量最大”的特征与阈值：

$$\text{Gain}(s, t) = \text{MSE}(S) - \left(\frac{|S_L|}{|S|} \cdot \text{MSE}(S_L) + \frac{|S_R|}{|S|} \cdot \text{MSE}(S_R) \right) \quad (32)$$

$$\text{MSE}(S) = \frac{1}{|S|} \sum_{i \in S} (y_i - \bar{y}_S)^2 \quad (33)$$

其中： s 为候选特征， t 为该特征的分裂阈值； S_L 、 S_R 分别表示分裂后左右子节点的样本集， $|S| = |S_L| + |S_R|$ ； $\text{MSE}(S)$ 为节点 S 的均方误差； $\bar{y}_S$ 为节点 S 中样本的均值。

b. 终止条件：当节点样本数小于 10 或分裂增益小于阈值时停止分裂，该节点成为叶节点，其预测值则为节点内样本的均值：

$$h_k(x) = \bar{y}_L \quad \text{若 } x \in S_L \quad (34)$$

4. 多棵树均值融合

随机森林的最终预测为 K 棵决策树预测值的算术平均，其通过“方差平均效应”降低单棵树的预测波动：

$$\hat{y}_{rf}(x) = \frac{1}{K} \sum_{k=1}^K h_k(x) \quad (35)$$

其中 K 为决策树总数; $h_k(x)$ 为第 k 棵决策树对样本 x 的预测值。

6.2.3 梯度提升树回归

梯度提升树回归^[6]与 LightGBM 回归同属于梯度提升框架，传统的梯度提升决策树的具体实现，其与 LightGBM 存在一下两点核心差异：

1.树生长策略：梯度提升树采用 Level-wise 生长，其在每轮迭代为所有叶节点增加子节点，最终结构更规整但训练效率较低。

2.正则化机制：通过样本抽样在每轮使用 80%的训练集来构建树，引入随机性从而增强模型的泛化能力。

6.2.4 多模型集成策略

最后我们以验证集 RMSE 最小化为目标，求解三类基础模型的最优权重 (w_1, w_2, w_3)，约束条件：

$$w_1 + w_2 + w_3 = 1 \text{ 且 } w_i \geq 0 (i = 1, 2, 3) \quad (36)$$

优化目标函数：

$$\min_{w_1, w_2, w_3} \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - (w_1 \hat{y}_{1i} + w_2 \hat{y}_{2i} + w_3 \hat{y}_{3i}))^2} \quad (37)$$

其中 $\hat{y}_{1i}$ 为 LightGBM 对第 i 个样本的预测值； $\hat{y}_{2i}$ 为随机森林的预测值 $\hat{y}_{3i}$ 为梯度提升树的预测值； n 为验证集样本总数。

经过验证集 RMSE 最小化确定我们得到最优权重为 $w_1 = 0.5, w_2 = 0.3, w_3 = 0.2$ 。

6.3 模型评估与分析

6.3.1 评估指标计算

MAE（平均绝对误差）：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (38)$$

RMSE（均方根误差）：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (39)$$

R^2 （决定系数）：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (40)$$

MAPE（平均绝对百分比误差）：

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\%$$

(41)

其中n为样本量; y_i 为真实值; $\bar{y}$ 为真实值的均值; $\hat{y}_i$ 为预测值;当 R^2 越接近 1 则说明模型对数据的拟合效果越好

6.3.2 结果分析

表 5 模型评估指标表

评估指标	具体数值
平均绝对误差 MAE	100.41
均方根误差 RMSE	141.54
决定系数 R ²	0.7770
平均绝对百分比误差 MAPE	86.68%

由该模型评估指标表,首先我们可以得到其评估指标 MAE 为 100.41、RMSE 为 141.54、R² 为 0.7770、MAPE 为 86.68%, 这表明模型在整体上对实际赔付金额具备一定解释力, 其中 MAPE 较高可能是因为其实际赔付中存在大量小额甚至零赔付情况, 会放大百分比误差, 若我们聚焦有效赔付场景其精度将会有显著提升。




图 11 问题二结果可视化

根据 Predicted vs Actual Payment Amount 散点图,可以得到其拟合线 $y=0.79x+72.43$, 当实际赔付金额 x 较小时,其截距 72.43 的影响相对预测值较为明显,最终会导致预测值略高于真实值;当实际金额 x 较大时,拟合线的斜率 0.79 小于 1 会使得预测值略低于真实值。从总体上看拟合线与最优预测线较为贴合,同时我们也不难发现其多数样本集中在低误差区域,证明该模型在整体趋势上拟合较好,仅在低额赔付时模型轻微过度预测,在高额赔付时模型轻微低估。

模型性能对比图显示 LightGBM、随机森林、梯度提升树与集成模型的 MAE 差异极小，体现了其基础模型同质性较高。

由残差分布图我们可以发现，其均值接近 0 证明了该模型无系统性偏差，其左偏态则体现了在部分场景下预测值可能会低于真实值。

在误差百分比分布图中，超过 80%的样本处于 20-50%及以上的误差区间，其同样是小额赔付放大百分比误差所致，若聚焦有效业务场景，精度会明显改善。

根据特征重要性图可知，特征“payment_contract_money”和“insured_amount”占比遥遥领先，并且其符合业务逻辑，后续可基于此构建衍生特征，同时我们也保留其他辅助特征以维持模型完整性。

七、问题三模型建立与求解

本题将在问题一给出的风险标注规则基础上进行优化建立风险标注的分类模型，预测附件 2 中运单的风险标注结果。由于严重超额样本占比较低，本文将给出占比严重不均衡的处理方法，最终对当前方法与问题二所使用的方法进行优劣势说明。问题三框架如图 12 所示。




图 12 问题三框架图

7.1 数据预处理

在问题一中，我们已经将附件 1 各个运单进行类型标注，本文将以附件 1 作为训练集，附件 2 作为测试集。首先，对于附件 2 中数值特征的缺失值，用附件 1 相应特征的中位数进行填充，；对于类别特征，则通过附件 1 的众数进行填充。在进行模型分析前，需要将附件 2 中的类别特征采用 LabelEncoder 方法将类别映射为整数，为每个类别分配一个从 0 开始的连续整数。

为增强模型对关键信息的捕捉能力，本文基于原始特征衍生新的特征如下：

$$\text{索赔/保价比例} = \frac{\text{索赔金额}}{\text{保价金额} + 1} \tag{42}$$

$$\text{网点风险评分} = \text{始发（目的）网点万单理赔率} \times \text{始发（目的）网点赔付比例} \tag{43}$$

且为避免极端值对模型训练的干扰，需同时统一不同量级特征的权重，故对数值特征进行标准化。

7.2 类别不均衡处理

由于在实际场景中，“严重超额”类样本的占比通常低于 3%，若直接采用常规分类模型训练，模型会因“合理诉求”与“诉求偏高”样本占比过高而产生偏向性，导致“严重超额”的识别精度、召回率严重不足。因此，需要类别不均衡的针对性处理方法平衡模型对各类别样本的学习能力，故本文将采用 SMOTE 过采样与类权重结合策略进行处理。

7.2.1 SMOTE 过采样

SMOTE 通过合成新的少数类样本来平衡类别分布，其核心思想是在少数类样本的特征空间中，基于近邻关系生成“虚拟样本”，避免简单复制少数类样本导致的过拟合^[7]。实现步骤如下：

- 1. 近邻搜索：对每个少数类样本 x_i ，在特征空间中找到其 k 个近邻样本，本文取 k=3；
- 2. 样本合成：在 x_i 与近邻样本 $x_j \in N_k(x_i)$ 之间随机生成新样本，公式为：
$$x_{new} = x_i + \lambda(x_j - x_i) \tag{44}$$

其中， $\lambda \in [0,1]$ 为随机数，通过线性插值在 x_i 和 x_j 的特征向量间生成新样本，保证新样本在少数类的特征分布范围内。

- 3. 采样策略：结合实际与数据分布，对“严重超额”类样本，将其数量提升至“合理诉求”的 10%；对“诉求偏高”样本，提升至“合理诉求”的 30%，公式为：

$$\text{sampling} = \begin{cases} \min\left(\text{int}(\text{count}_{\text{合理诉求}} \times 0.1), 5 \times \text{count}_{\text{严重超额}}\right) & \text{类别} = \text{严重超额} \\ \text{int}(\text{count}_{\text{合理诉求}} \times 0.3) & \text{类别} = \text{诉求偏高} \end{cases} \tag{45}$$

通过以上 SMOTE 过采样法，最终用于后续模型训练的各类样本数如表 6 所示。

表 6 采样前后的数据分布

原始分布			重采样后分布		
合理诉求	诉求偏高	严重超额	合理诉求	诉求偏高	严重超额
7894（90.89%）	542（6.24%）	249（2.87%）	7,894（71.43%）	2,368（21.43%）	789（7.14%）
31.7 : 2.2 : 1			10 : 3 : 1		

7.2.2 类权重调整

类权重通过在损失函数中为少数类分配更高权重，强制模型关注少数类样本的错分代价。其计算公式为：

$$weight_i = \frac{\text{总样本数}}{\text{类别数} \times \text{第 i 类样本数}} \tag{46}$$

对物流理赔的三类样本（合理诉求、诉求偏高、严重超额），“严重超额”类因样本数最少，权重最高；“合理诉求”类样本数最多，权重最低。模型在训练时，对少数类样本的错分惩罚会被放大，从而提升少数类的识别性能。

通过计算得到“合理诉求”权重为 0.467；“诉求偏高”权重为 1.556；“严重超额”权重为 4.670。

此时“严重超额”权重最高，惩罚力度最高，从而引导模型更关注少数类的学习。

7.2.3 分类模型的权重调整

在后续风险标注的分类模型训练中，随机森林通过样本随机采样 + 特征随机选择，以随机性避免单一特征主导分类，并且降低对少数类样本的误判；XGBoost 则是通过正则化避免“严重超额”类样本量太小，过拟合导致误判的问题；LightGBM 通过三大优化进行决策，对低梯度采样样本的梯度进行修正，不丢失“严重超额”等关键样本的信息；CatBoost 分类若使用全量样本计算目标编码，会导致某样本的编码值包含自身信息，尤其对“严重超额”这类少数类，泄露会严重影响泛化能力，本文通过 Ordered Boosting 避免数据泄露，有效保障“严重超额”少数类训练。

在最后训练四种分类模型后，通过“严重超额”类的 F1 得分进行加权投票，能够有效注意“严重超额”类样本，避免因该类样本占比严重不均衡所导致的模型对“严重超额”类识别不足、分类偏倚等问题，提升对少数类的预测性能。具体调整详见下文模型部分。

7.3 风险标注的分类模型

为能够较好的处理结构化数据和类别不均衡问题，本文基于对附件 1 每个运单标签化后的数据作为训练集，以附件 2 作为测试集，通过 python 训练了四种强分类器^[8]，对附件 2 的运单以软投票方式进行分类，能够有效降低预测方差，减少单一模型的偶然错误，并且保留了不确定性信息，提高鲁棒性。具体模型方法原理下面具体介绍。

7.3.1 随机森林分类

随机森林通过“样本随机采样 + 特征随机选择”构建多棵独立决策树，最终以多数投票输出风险标注结果。由于“严重超额”样本占比较低，随机森林的随机性可避免单一特征主导分类，同时降低对少数类样本的误判风险。

1. 样本随机采样

对附件 1 的标注数据进行有放回采样，生成 $T=200$ 个子训练集。单个样本有 63.2% 概率被选入子训练集，未选中的“袋外样本”可用于无验证集评估模型对“严重超额”类的识别精度，避免“少数类误判导致超额赔付”的问题

2. 特征随机选择与节点分裂

设 M 为总特征数，构建每棵树时，从全部特征中随机选择 $\sqrt{M}$ 个特征，随后采用 Gini 系数衡量分裂纯度，节点纯度公式为：

$$Gini(D) = 1 - \sum_{k=1}^3 p_k^2 \quad (47)$$

其中， D 为当前节点样本集， p_1 、 p_2 、 p_3 分别为合理诉求、诉求偏高、严重超额的样本占比。Gini 系数越小，节点内风险类别越集中，分裂则越有效。分裂增益公式为：

$$Gini(f, t) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2) \quad (48)$$

其中， f 为分裂特征， t 为分裂阈值， D_1 、 D_2 为分裂后的子节点，通过该公式筛选出对“严重超额”识别最有效的特征组合。

最终预测结果为 200 棵树的多数投票，公式为：

$$y_{pred} = \arg \max_{k=1}^3 \sum_{t=1}^{200} I(h_t(x) = k) \quad (49)$$

其中， $h_t(x)$ 为第 t 棵树的预测类别， $I(\cdot)$ 为指示函数，该机制能够有效降低单棵树对“严重超额”少数类的漏判风险。

7.3.2 XGBoost 分类

XGBoost 通过“串行迭代拟合残差”优化模型，同时引入正则化项控制树复杂度，XGBoost 的二阶泰勒展开可精准捕捉这种量化关联，且正则化能避免过拟合导致的“严重超额”误判

1. 含正则化的目标函数

目标函数由训练损失与正则化损失构成，能够有效保障合理理赔与控制成本的目标，表示式为：

$$\mathcal{L}(t) = \sum_{i=1}^N l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (50)$$

其中，训练损失 $l(\cdot)$ 采用对数损失，衡量模型对“索赔差额 $\rightarrow$ 风险类型”的拟合精度；正则化项有“叶子节点数惩罚” γT 与“权重平方惩罚” $\lambda \sum_{j=1}^T w_j^2$ ，能够有效避免树结构过复杂。

2. 二阶泰勒展开

对训练损失在前期预测 $\hat{y}_i^{(t-1)}$ 处进行二阶泰勒展开，简化优化过程，表达式为：

$$\mathcal{L}(t) \approx \sum_{i=1}^N l\left(g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)\right) + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (51)$$

其中，一阶导数 $g_i = \frac{\partial l}{\partial \hat{y}_i^{(t-1)}}$ 反映当前预测与真实风险的残差梯度；二阶导数 $h_i = \frac{\partial^2 l}{\partial (\hat{y}_i^{(t-1)})^2}$ 反映梯度变化率。

3. 叶子节点权重优化

为提升少数类的识别，且优化“严重超额”样本占比低导致的学习不足的问题，在将样本分配到叶子节点后，设置最优权重公式为：

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda} \quad (52)$$

其中， I_j 为叶子节点 j 的样本集，对 g_i 绝对值大的“严重超额”样本，会被赋予更大的权重，确保模型优先训练少数类的样本。

4. 风险类别预测

最终，经过 T 轮训练后，模型输出一长度为 3 的实数向量，为得到直观的风险概率，通过 Softmax

函数进行归一化，公式为：

$$\hat{p}_{ik} = \frac{\exp(\hat{y}_{ik}^{(T)})}{\sum_{k'=1}^3 \exp(\hat{y}_{ik'}^{(T)})} \quad (53)$$

其中， $\hat{p}_{ik}$ 是样本 i 被预测为第 k 类风险的概率。

在得到三类风险概率后，通过取概率最大值对应的类别确定最终风险标注，公式为：

$$y_{pred,i} = \arg \max_{k=1}^3 p_{ik} \quad (54)$$

其中， $y_{pred,i}$ 为样本 i 的预测风险类别。

7.3.3 LightGBM 分类

LightGBM 通过直方图分箱、GOSS 采样、Leaf-wise 生长三大优化，适配每天上千万运单的大规模数据场景，同时保持对“严重超额”少数类的识别精度。该模型的核心在于在处理附件 1 和附件 2 的数据时，大幅提升训练速度，且不损失风险分类精度。

1. 直方图分箱

将连续特征划分为 B=255 个离散区间，用“区间索引”替代原始值，减少计算量。首先，按特征值等频划分统计每个区间内样本的梯度 $G = \sum g_i$ 与二阶导数和 $H = \sum h_i$

2. GOSS 采样

对样本按“梯度绝对值”采样，优先保留对风险分类关键的样本，保留梯度绝对值前 20% 的样本；对剩余 80% 低梯度样本随机采样 10%。

随后对其梯度乘以补偿权重，低梯度采样样本的梯度修正公式为：

$$\tilde{g}_i = g_i \cdot \frac{1-a}{b} \quad (55)$$

其中， $\tilde{g}_i$ 为修正后的梯度，确保采样后整体梯度分布与原分布一致，在减少计算量的同时，不丢失“严重超额”等关键样本的信息。

3. Leaf-wise 生长

每次迭代时，遍历所有叶子节点，计算每个节点的分裂增益，选择增益最大的节点进行分裂，直到树深度达到预设阈值。对节点分裂为左子节点 L 和右子节点 R，增益公式为：

$$Gain = \frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} - \gamma \quad (56)$$

其中， G_L 、 H_L 分别为左子节点的梯度和二阶导数和， λ 为正则化系数， γ 为叶子节点惩罚习俗，该策略避免为“合理诉求”样本生成冗余节点，提升模型对少数类的识别精度。

最终分类预测与 XGBoost 模型一致，在此不再赘述。

7.3.4 CatBoost 分类

CatBoost 能自动处理类别特征，并通过 Ordered Boosting 避免数据泄露，传统 LabelEncoder 会引入“假顺序”，而 CatBoost 可精准编码类别特征，提升风险分类精度。

1. 目标编码

对类别特征 C 的取值 c，编码值为该类别下样本的风险类别均值，公式为：

$$\hat{c} = \frac{\alpha \cdot \mu + \sum_{i:C_i=c} y_i}{\alpha + n_c} \quad (57)$$

其中， μ 为全局风险类别均值； $\sum_{i:C_i=c} y_i$ 表示类别 c 下样本的目标值之和； n_c 为类别 c 的样本数； α 为平滑系数，用于控制全局均值与类别均值的权重，本文设定 $\alpha=30$ ，避免小类别过拟合。

2. Ordered Boosting

若直接用全量样本计算目标编码，会导致某样本的编码值包含自身信息，尤其对“严重超额”这类少数类，泄露会严重影响泛化能力。步骤如下：

- 将附件 1 的训练样本随机排序为 $x_1, x_2, \dots, x_N$ ；
- 用前 i-1 个样本的信息计算样本 x_i 的类别编码；
- 重复 K 次随机排序，本文设定 K=4，取 4 次编码的均值作为最终值，降低随机性影响。

3. 抗过拟合机制

针对“严重超额”样本少，易过拟合的问题，CatBoost 通过三重机制控制复杂度，具体如下：

- L2 正则化：**目标函数中加入叶子节点权重的平方惩罚，公式为：

$$\Omega(f_t) = \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (58)$$

其中， w_j^2 为叶子节点 j 的权重， λ 为正则化系数。

- 随机子空间：**每棵树训练时随机选择部分特征，减少特征相关性导致的过拟合。
- 学习率衰减：**每棵树的预测值乘以学习率，公式为：

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta \cdot f_t(x_i) \quad (59)$$

避免单棵树对“严重超额”的预测权重过大

最终，通过迭代预测风险分类同 XGBoost 模型一致，在此不再赘述。

7.4 模型求解与结果分析

通过前文对问题三风险类型分类的模型建立，通过 python 求解四种分类模型的结果并通过“软投票”形式预测最终的分类结果。现先给出各个分类模型的总体性能，以准确率、宏平均 F1 得分衡量模型优劣。其中，准确率指标计算公式为：

$$Accuracy = \frac{\sum_{k=1}^n TP_k}{\sum_{k=1}^n (TP_k + FP_k + TN_k + FN_k)} \quad (60)$$

其中， TP_k 为第 k 类的实际为 k 类且预测为 k 类的数量， FP_k 为实际非 k 类但预测为 k 类， TN_k 为实际非 k 类且预测为非 k 类， FN_k 为实际为 k 类但预测为非 k 类，n 为类别总数，即 n=3。

宏平均 F1 得分是平等评估所有类别的综合指标，需要先计算每个类别的 F1 分数，再对所有类别的 F1 分数取算术平均值。最终计算得到四种分类模型的评估指标如表 7 所示

表 7 分类模型评估指标表

LightGBM		XGBoost		CatBoost		RandomForest	
Accuracy	F1-Macro	Accuracy	F1-Macro	Accuracy	F1-Macro	Accuracy	F1-Macro
0.9724	0.9315	0.9715	0.9275	0.9602	0.8971	0.9616	0.8972

并给出各分类模型对各类别的性能，以精准率、召回率及 F1 得分作为评估指标，如表 8 所示。

表 8 各分类模型对各类别的性能评估

分类模型	评估指标	合理诉求	诉求偏高	严重超额
LightGBM	精准率	0.9981	0.9396	0.8284
	召回率	0.9873	0.9515	0.8861
	F1	0.9927	0.9455	0.8563
XGBoost	精准率	0.9968	0.9322	0.8428
	召回率	0.9880	0.9578	0.8481
	F1	0.9924	0.9448	0.8454
CatBoost	精准率	0.9994	0.9330	0.7083
	召回率	0.9848	0.9114	0.8608
	F1	0.9920	0.9221	0.7771
RandomForest	精准率	0.9981	0.8717	0.8871
	召回率	0.9842	0.9747	0.6962
	F1	0.9911	0.9203	0.7801

由表可知，LightGBM 分类模型性能最佳。为进一步提升“严重超额”类的识别精度与模型整体稳定性，采用“软投票”集成四大模型结果，利用各模型优势互补，通过概率加权实现更可靠的分类。对每个测试样本，先获取四大模型输出的三类风险概率，再通过加权求和得到最终概率，最终取概率最大的类别作为集成结果，避免单一模型的误判风险。

为确保权重分配合理，以附件 1 中划分的验证集，占训练集的 30%，采用“严重超额”类 F1 得分加权法确定各模型权重，求解得到各分类模型权重如表 9 所示。

表 9 各分类模型权重表

LightGBM	XGBoost	CatBoost	RandomForest
0.262	0.259	0.238	0.240

随后，对每类风险将各模型的三类风险概率乘以对应模型权重后求和，得到最终概率 p_m ，公式为：

$$P_k = \sum_{m=1}^4 \omega_m \cdot p_{mk} \tag{62}$$

通过 python 求解后，在此展示前 40 个运单的风险标注结果如表 10 所示。

表 10 运单的风险标注结果							
运单号	风险标注	运单号	风险标注	运单号	风险标注	运单号	风险标注
1	合理诉求	11	合理诉求	21	合理诉求	31	合理诉求
2	合理诉求	12	合理诉求	22	合理诉求	32	合理诉求
3	合理诉求	13	合理诉求	23	合理诉求	33	合理诉求
4	合理诉求	14	合理诉求	24	合理诉求	34	合理诉求
5	合理诉求	15	合理诉求	25	合理诉求	35	合理诉求
6	合理诉求	16	合理诉求	26	合理诉求	36	合理诉求
7	合理诉求	17	合理诉求	27	合理诉求	37	合理诉求
8	合理诉求	18	诉求偏高	28	合理诉求	38	合理诉求
9	合理诉求	19	合理诉求	29	合理诉求	39	诉求偏高
10	合理诉求	20	合理诉求	30	合理诉求	40	合理诉求

最终本文对附件 2 运单的风险类型预测结果分布如表 11 所示。

表 11 预测结果样本分布		
合理诉求	诉求偏高	严重超额
2533（90.72%）	195（6.98%）	64（2.29%）

四种模型软投票后，对各类别分类评估结果见表 12。

表 12 最终结果的各类别分类评估			
类别	精确率	召回率	F1 得分
严重超额	0.85	0.85	0.85
合理诉求	1.00	0.99	0.99
诉求偏高	0.93	0.96	0.95

软投票集成模型在运单风险标注中结果较优，“严重超额”类精确率、召回率、F1 得分均达 0.85，有效把控高风险；“合理诉求”类精确率 1.00、召回率 0.99，能确保多数正常运单高效处理；“诉求偏高”类精确率 0.93、召回率 0.96，中间风险识别也较为精准。

整体准确率达到 0.973，Cohen's Kappa 系数达到 0.939，该系数用于衡量“模型预测与真实标签的一致性”，真实捕捉了“运单特征 - 风险类型”的关联规律，泛化稳定性强。

7.5 问题二、三方法优劣势

7.5.1 问题二方法优势

1. 问题二方法以“索赔差额”为核心依据，结合问题一中“相似实际赔付金额下索赔差额的聚类阈值”。整个过程基于明确的指标推导，结果易被业务人员理解，便于后续人工审核环节追溯标注依据，降低跨部门沟通成本。
2. 多维度特征融合，适配复杂场景。问题二模型融合运单、客诉、商品、网点行为等 17 个多维

度特征，通过 LightGBM、随机森林等集成模型捕捉特征间的非线性关联，相比仅依赖少量指标的简单规则，更能适配物流理赔数据的复杂性，索赔差额的风险映射更贴合真实业务场景。

3. 对“严重超额”样本鲁棒性较优。问题二模型通过加权集成策略降低极端值干扰，尤其随机森林的 Bootstrap 抽样可保留更多高额赔付样本信息，对”严重超额“这类占比低（<3%）但影响大的样本，其实际赔付金额预测误差显著低于单一模型。基于该预测值计算的索赔差额，能更准确识别“严重超额”场景，避免因单一模型低估 / 高估赔付金额导致的风险误判，一定程度上缓解了样本不均衡带来的标注偏差。

7.5.2 问题二方法劣势

1. 两阶段误差传递，标注精度受制约。赔付金额预测误差可能会影响风险标注，低额赔付场景误差占比高，可能引发类别错分。

2. 依赖问题一规则，灵活性与泛化待提升。规则若存在地域、业务适配局限，标注结果同步受限；业务规则更新时需全流程调整，灵活性需改善。

3. 计算成本高，不适用于实时场景。多模型训练和预测耗时久，单运单标注超实时理赔的 0.1 秒要求，易导致响应延迟。

4. 小额 / 零赔付样本标注误差大。这类样本占比高，预测百分比误差被放大，易将合理诉求误标，增加人工审核压力。

7.5.3 问题三方法优势

问题三采用“SMOTE 过采样 + 类权重调整 + 多模型软投票集成”的风险标注分类方法，优势主要在以下几点：

1. 针对性解决“严重超额”类不均衡：SMOTE 过采样+ 类权重调整，使该类召回率达 88.61%，有效降低超额赔付风险。

2. 多模型适配结构化数据：LightGBM 高效处理大规模数据、CatBoost 自动处理类别特征，避免“假顺序”干扰、XGBoost 及随机森林保障基础稳定性，四个分类模型互补，软投票集成策略降低单一模型风险，提升预测鲁棒性，“严重超额”F1 得分达 0.8563。

3. 集成模型预测结果符合“严重超额 < 3%、合理诉求 ≥ 85%”的业务指标，能提供理赔审核流程的方向建议，减少人工误判，模型具有一定的泛化能力。

7.5.4 问题三方法劣势

1. 问题三采用四种强分类器 + 软投票集成，虽通过“F1 得分加权”保障了预测鲁棒性，但多模型并行训练、超参数调优需消耗一定算力；同时软投票需实时调用四模型的概率输出，对实时理赔场景，响应效率存在小幅优化空间，该局限在多数业务场景中可通过硬件资源补充或模型轻量化缓解。

2. 为优先保障“严重超额”类的识别，合理诉求类的权重被设定为 0.467，导致模型对多数类的错分惩罚力度相对较低，存在少量合理诉求被误判为“诉求偏高”的情况，需增加少量人工复核成本。

八、模型评价与推广

8.1 模型评价

本文在解决运单风险标注策略的问题上提出了多模型集成的解决方案，提出“分层自适应阈值 + 三模型投票”的集成方案用于解决在“模糊区”分类的问题。并通过建立多回归模型并施加弹性权重作为平衡赔付金额预测精度与模型分布外泛化能力的方案，在本次大数据训练的背景下表现出优秀的性能与鲁棒性。

但本文背景并不支撑其不同数据集上训练，模型在极其特殊场景下的性能仍待考究

8.2 模型推广

在少数类识别的场景中，我们提出了“SMOTE 过采样 + 四模型软投票”的模型集成方案，使得模型具有优秀的外泛化能力与稳定性，能在面对不同数据训练时体现出优秀的适应性。总体上，本模型能够在物流理赔售前预判、售后审核全链路中有可观的性能，也能迁移到金融风控等具有模糊阈值的场景。

参 考 文 献

- [1] 关晓宁.物流企业供应链金融服务与财务风控体系融合[J].中国航务周刊,2025,(42):84-86.
- [2] 陈友淦,周明昭,涂申奥,等.基于类别自适应动态阈值与参数迁移学习的小样本声呐图像分类方法[J/OL].信号处理,1-17[2025-10-30].<https://link.cnki.net/urlid/11.2406.TN.20251017.1452.006>.
- [3] 赵晓峰,王平水.基于组合加权 k 近邻分类的无线传感网络节点复制攻击检测方法[J].传感技术学报,2024,37(06):1056-1060.
- [4] 刘中业,侯金霄,纪汶龙,等.基于组合优选及随机森林算法的东营市湿地分类方法[J/OL].济南大学学报(自然科学版),1-8[2025-10-30].<https://doi.org/10.13349/j.cnki.jdxbn.20251011.001>.
- [5] 任重义,耿文博.融合机理模型与 LightGBM 残差补偿的大行程数控铣床加工误差预测方法[J/OL].机床与液压,1-11[2025-10-30].<https://link.cnki.net/urlid/44.1259.TH.20251011.1040.039>.
- [6] 倪荣雨,李春辉,欧阳逸云,等.地理加权梯度提升机模型在黑龙江省林火预测中的应用[J/OL].生态学报,2025,(22):1-11[2025-10-30].<https://doi.org/10.20103/j.stxb.202502220374>.
- [7] 宋媚,吕峰,赵礼,等.基于局部合力改进的 Borderline-SMOTE 过采样方法[J/OL].南京师大学报(自然科学版),1-10[2025-10-30].<https://link.cnki.net/urlid/32.1239.N.20250918.1538.002>.
- [8] 林小惠,汪余嘉,张玲玲,等.基于 MIMIC-IV 数据库的万古霉素血药谷浓度机器学习分类预测模型构建[J].中国药房,2025,36(19):2448-2453.