

队伍编号	MCB2501256
赛道	(B)

物流理赔中 MQBL 风险标注与 Stacking 预测模型研究及不平衡数据优化

摘要

随着全球电商持续扩张，物流行业正从规模驱动向质量驱动转型。理赔服务作为关键客户触点，其管理质量直接影响客户体验与品牌忠诚度。然而，传统的理赔服务管理方式依赖人工与固定规则，存在效率低、主观性强、成本递增等问题。为此，本文基于物流理赔场景，利用数据与智能算法构建从风险识别、金额预测到处理不平衡数据的完整智能解决方案，以实现理赔流程的自动化与智能化优化。

针对问题一，构建单调分位边界学习 (MQBL) 模型。其核心是基于历史数据学习两条随实际赔付金额单调递增的**动态边界**，从而将运单划分为“合理诉求”“诉求偏高”和“严重超额”三个风险等级。首先，构建关键风险指标并处理缺失值与异常值，为模型提供高质量的特征输入。其次，按“商品类型”“新旧程度”对运单分组后，采用**自适应建模**，样本充足组执行“等频分箱-局部分位数估计-保序回归修匀-线性插值”流程，生成符合业务逻辑的单调风险边界；样本不足组则**自动回退**至类别级或全局模型，确保所有分组标注稳健。最后，在“合理诉求占比 $\geq 85\%$ ”“严重超额占比 $\leq 3\%$ ”的业务约束下，完成附件 1 运单风险标注。结果显示，风险特征因商品类型和新旧程度的不同而有显著差异，如全新美妆、杂货“严重超额”占比较高，验证了模型精细化分组的必要性。

针对问题二，构建基于 Stacking 集成学习的预测模型。该模型融合 XGBoost、LightGBM 和随机森林三种基学习器，充分利用不同模型在捕捉数据非线性关系和处理类别特征上的优势。首先，在特征工程层面，对保价金额等高度右偏的数值特征进行对数变换以提升模型鲁棒性，并对类别特征采用**独热编码**以严格对齐特征空间，防止数据泄露。其次，在模型架构上，创新性地**融合 XGBoost、LightGBM 和随机森林**三类基学习器，通过分层 k 折交叉验证生成元特征，并采用**线性回归**作为元模型进行加权融合。最后，引入 **SHAP 框架**进行模型可解释性分析，明确索赔金额、保价金额等关键特征的影响程度与方向。结果显示，**堆叠集成模型综合性能最优**，均方根误差为 160.55，平均绝对误差为 108.75，90%分位数损失为 54.37，均低于任一单一模型，平均绝对百分比误差 88.28%显著领先。且该模型在高价值索赔样本 (Top 10%) 上保持最低均方根误差 292.34，展现出良好的风险控制能力，能为物流企业有效规避超额赔付风险。

针对问题三，在问题一、二基础上构建了基于不平衡数据自适应优化的风险预测模型，重点解决了“严重超额”类别占比极低导致的模型偏差。首先，系统引入三种技术策略：(1) **代价敏感学习**通过目标值分箱逆频率权重叠加少数类权重系数调整样本贡献度。(2) **SMOTE 方法**在特征空间对少数类样本及其近邻进行线性插值生成合成样本。(3) **随机欠采样**通过动态删除多数类样本实现均衡。其次，设计 k 折交叉验证框架，将上述方法与 Stacking 集成学习结合，在每一折独立处理训练集后生成基模型预测，并通过元模型融合输出最终结果。最后，构建**多维度评估体系**，综合考量整体预测精度与少数类识别能力。结果显示，SMOTE 的整体预测精度与基准接近，其均方根误差为 161.30，平均绝对误差为 108.95，且在识别“严重超额”任务上表现最佳，精确率-召回率曲线下面积为 0.332，显著优于代价敏感学习的 0.296。随机欠采样的精确率-召回率曲线下面积虽达 0.433，但整体预测误差显著增大。因此，**SMOTE 是解决该样本不均**

衡问题的最优策略，能在不过度牺牲全局精度的前提下，有效提升高风险案件识别敏感性。

综上所述，本文通过 MQBL 模型、Stacking 集成学习框架以及针对性的处理不平衡数据策略，为物流企业理赔服务的自动化与智能化提供了一套科学、有效且完整的解决方案。所提方法在风险标注精度、赔付金额预测准确性和对关键风险的识别能力上均优于传统方法，具有较高的理论价值与广阔的行业应用前景。

关键词：物流理赔；风险预测；单调分位边界学习；Stacking 集成学习；合成少数类过采样技术

目录

一、问题重述	1
1.1 问题背景	1
1.2 问题重述	1
1.3 问题分析	2
1.4 全文技术路线图	2
二、模型假设与符号说明	3
2.1 模型假设	3
2.2 符号说明	3
三、基于单调分位边界学习 (MQBL) 的自适应风险标注模型构建与求解	4
3.1 数据预处理与特征工程构建	4
3.2 多维特征探索性分析与挖掘	5
3.3 单调分位边界学习 (MQBL) 风险标注模型构建	6
3.3.1 风险分级规则体系设计	6
3.3.2 MQBL 动态边界学习算法框架	6
3.4 基于自适应分组优化的 MQBL 模型求解策略	7
3.5 问题一小结	11
四、基于 Stacking 集成学习的赔付金额预测模型构建与求解	11
4.1 面向预测任务的特征工程构建与数据预处理	11
4.2 Stacking 集成学习框架下的模型构建	11
4.2.1 XGBoost 基模型	11
4.2.2 LightGBM 基模型	12
4.2.3 随机森林基模型	13
4.2.4 二层堆叠 (Stacking) 集成模型	14
4.3 基于分层交叉验证的模型训练与优化求解	14
4.3.1 基于分层 k 折交叉验证的 OOF 预测求解策略	14
4.3.2 基模型性能的多维对比评估与优选分析	15
4.3.3 预测性能的多维深度评估与误差分析	17
4.3.4 SHAP 框架下的模型可解释性与特征重要性度量	19
4.4 问题二小结	20

五、基于不平衡数据的自适应风险标注模型构建与求解	20
5.1 面向不平衡数据的自适应风险标注模型构建	20
5.1.1 代价敏感学习策略	21
5.1.2 合成少数类过采样策略	21
5.1.3 随机欠采样策略	22
5.2 三种不平衡数据处理模型的优化求解与性能分析	23
5.3 不平衡数据优化前后的优劣势分析	25
5.4 问题三小结	26
六、模型评价与改进	26
6.1 模型优点	26
6.2 模型缺点	27
6.3 模型改进与推广	27
参考文献	28
附录	30

一、问题重述

1.1 问题背景

随着全球电子商务的持续深化发展，物流行业作为支撑现代流通体系的基础性产业，正经历着从规模扩张向质量提升的重要转型阶段。据 2024 年最新统计数据显示，我国社会物流总额首次突破 360 万亿元，全年物流业总收入达 13.8 万亿元，物流市场规模已连续 9 年稳居全球首位。在这一庞大体量的业务规模背景下，运营管理的精细化程度已成为决定企业市场竞争力的关键因素。在经历初期的高速扩张后，领先的物流企业纷纷将战略重点转向服务质量与运营效率的协同提升。其中，理赔服务作为连接企业与客户的重要触点，不仅直接影响到客户满意度和品牌忠诚度，更深刻关系到企业的成本结构和盈利水平。可以说，优质高效的理赔服务已成为衡量现代物流企业核心竞争力的关键指标。

从业务流程来看，物流理赔服务通常分为售前和售后两个关键环节。售前环节侧重于风险预防，通过深度挖掘用户历史行为数据，如寄件频次、物品类型偏好、历史理赔记录等多维度信息，构建客户风险画像，从而提供个性化的物流保障方案推荐，实现潜在风险的前瞻性规避。售后环节则聚焦于理赔成本的精益管控，当客户提交索赔申请后，系统需快速评估案件的合理性与风险等级，并实施差异化的处理策略，如对小额低风险案件实施快速理赔通道，对中等风险案件启动人工审核机制，对高风险案件执行严格风控流程。这种基于风险等级的分类处理机制，不仅优化了企业资源的配置效率，还能显著降低因超额赔付导致的财务损失。

然而，在大数据时代背景下，传统理赔管理模式的局限性日益凸显。目前大多数物流企业仍采用基于固定规则引擎和人工审核的理赔处理方式，这种方式在面对大规模、高并发的理赔案件时表现出明显的不适应性。随着业务量的指数级增长，传统理赔模式的运营成本呈现边际递增趋势，处理效率低下与主观判断偏差等问题日益突出，已成为制约企业可持续发展的重要瓶颈。面对这些挑战，数据驱动的智能理赔服务优化已成为物流企业转型升级的必然选择。通过整合数学建模理论与机器学习技术，企业能够对海量历史理赔数据进行多维度深度挖掘，构建精准的风险识别模型与赔付金额预测模型，从而实现理赔服务向自动化、智能化方向的根本性转变。

针对传统理赔模型在应对“严重超额”样本类别不平衡、模型泛化能力不足等方面的局限，本文构建了一套融合动态风险分级、集成学习与样本平衡策略的完整方法体系。该体系的核心在于：首先，通过引入单调分位边界学习（MQBL）模型，实现基于业务逻辑的动态阈值划分与稳健风险标注；其次，采用 Stacking 异构集成框架，融合多基学习器优势，显著提升赔付金额预测精度与稳定性；进而，针对极端不平衡问题，系统对比并优选 SMOTE 过采样策略，有效提升对关键少数类风险的识别敏感性。这一方法体系不仅在风险标注、金额预测和类别平衡等关键环节实现了协同优化，也为物流理赔的智能化管控提供了系统性的解决方案，具备良好的可扩展性与行业推广价值。

1.2 问题重述

问题一重述：

基于附件 1 所提供的数据集，针对核心变量“理赔差额”与“实际赔付金额”构建风险标注规则框架，依据该规则对运单进行“合理诉求”、“诉求偏高”和“严重超额”风险的等级划分。完成模型构建后，需输出附件 1 中各运单对应的风险标注结果，并针对所制定的标注规则展开合理性评估，同时分析标注结果的分布特征与内在规律。

问题二重述：

利用附件 1 中的历史数据，构建一个预测模型，旨在精准估计附件 2 中各运单的“实际赔付金额”。在模型构建的流程中，需要筛选适用于该预测任务的评估指标，以此对模型的性能表现进行量化评估与客观分析。并将预测所得的“实际赔付金额”结果输出至指定结果文件，同时确保运单编号与原始数据保持严格一致，保障数据的一致性与完整性。

问题三重述：

依据问题一中确立的风险标注规则体系，首先基于附件 1 的数据训练风险分类模型，并用该模型预测附件 2 中运单的风险标注结果。其次，完成预测后，将风险标注预测结果与问题二中“实际赔付金额”的预测结果整合至同一结果文件，且保证运单编号的对应性与一致性。在模型训练与预测过程中，需重点关注数据不平衡问题，尤其是“严重超额”样本占比极低这一特殊情况，详细阐述针对该问题所采取的有效处理方法。最后，探讨当前风险分类模型预测方法与问题二中预测方法在风险标注结果预测方面的优势与局限性。

1.3 问题分析

问题一分析：

问题一需在物流理赔场景中对风险等级进行精准划分。首先需要对数据进行预处理，计算索赔差额、偏差等核心指标后对数据进行可视化分析。其次构建基于商品类型-新旧程度的分组体系，采用自适应建模策略，即样本量充足的分组，利用 MQBL 方法先按实际赔付金额分箱、计算索赔偏差分位数，再经保序回归拟合单调边界；样本量不足时自动回退。通过合理性约束与风险控制约束评估模型，对不满足约束的分组实施自适应合并优化。最后输出附件 1 中各运单对应的风险标注结果。

问题二分析：

问题二旨在精准预测运单“实际赔付金额”，首先需要对历史数据的数值、类别、时间型特征清洗，解决缺失与异常值问题，对极度偏态特征做对数变换以提升模型鲁棒性。其次以 XGBoost、LightGBM、随机森林为基模型，通过堆叠集成融合优势，提升预测准确性与泛化能力，尤其在高赔付样本预测中表现更优。最后进行方法评估，选出表现突出的模型，并输出附件 2 中各运单的“实际赔付金额”。

问题三分析：

结合问题一、问题二的方法输出附件 2 中运单的风险标注结果后，问题三针对物流理赔预测中“严重超额”类别占比极低的数据不平衡问题，引入代价敏感学习、SMOTE（合成样本生成）、随机欠采样三种策略。基于五折交叉验证和 Stacking 集成学习评估后，实证显示 SMOTE 方法在 MAE、RMSE 接近基准的同时，AUC-PR 显著提升，对少数类识别能力强且预测稳定；另外两种方法分别存在权重失效和信息丢失局限。综上，SMOTE 是解决该数据不平衡问题的优选方案。

1.4 全文技术路线图

本文的技术路线图如下所示：




图 1-1 全文技术路线图

二、模型假设与符号说明

2.1 模型假设

为了简化问题分析的复杂性，同时也为了确保模型具有可解性，本文基于一系列审慎考虑的假设条件下进行模型构建和验证过程。这些假设旨在让模型更贴合实际情况，降低模型维度，避免过度拟合，并保证模型在特定边界条件下能够稳定运行。具体假设内容如下：

(1) 假设数据中的谈赔标准和操作流程是相对一致和稳定的。不同客服人员或在不同时间点，对相似情况的运单所做出的“实际赔付金额”决策是可比、可建模的，不会出现因内部规则巨变而导致的数据规律断裂。

(2) 假设附件 1 与附件 2 中的运单数据来自于同一个概率分布。这意味着在附件 1 上学习到的规律可以有效地推广到附件 2 上。

2.2 符号说明

表 2-1 符号说明

符号	符号说明
E	索赔差额
p	单条运单的实际赔付金
c	索赔金额
e	索赔偏差
$Q_\gamma(S)$	集合 S 的 γ 分位数
$z_{j,k}$	保序回归后的拟合值
R	元模型
$\hat{y}_m(x_i)$	第 m 个基学习器的预测结果
MAE	平均绝对误差
RMSE	均方根误差
r_s	斯皮尔曼相关系数
AUC-PR	精确率-召回率曲线下面积

三、基于单调分位边界学习（MQBL）的自适应风险标注模型构建与求解

3.1 数据预处理与特征工程构建

数据预处理是物流理赔风险识别模型的首要环节，在物流理赔场景中，原始数据往往包含冗余字段、缺失值或不符合逻辑的异常值，若直接用于建模，会导致风险边界失真、分类结果不可靠。所以首先通过算术运算定义风险分析指标，利用数值约束过滤无效数据，确保后续建模的准确性。

通过“实际赔付金额”和“索赔金额”的差值，构建两个关键分析指标，直观反映“索赔合理性”。首先，定义“索赔差额”：

$$E = p - c. \quad (1)$$

当 $E > 0$ 时，说明实际赔付金额高于索赔金额，属于“保险公司超额赔付”，无客户超额索赔风险；当 $E = 0$ 时，说明赔付与索赔完全一致，属于“完全合理”；当 $E < 0$ 时，说明索赔金额高于实际赔付金额，此时才存在“客户超额索赔”的风险。

但“索赔差额”仍存在局限性，其负值的绝对值虽能反映超额金额，但无法直接对应“风险等级”的判断逻辑。因此，进一步定义“索赔偏差”：

$$e = c - p, \quad (2)$$

其中， e 表示索赔偏差，当 $e \leq 0$ 时，无论差值大小，均表示无超额索赔风险；当 $e > 0$ 时，正值的大小直接对应“超额索赔的金额”，数值越大，风险等级越高。

原始数据中存在的缺失值和异常值会降低建模数据的质量，因此需要过滤掉这些无效数据，以保证剩余数据集的“完整性”与“合理性”。

首先，处理缺失值，即关键字段为空，导致无法判断风险。在风险识别模型中，如

果缺失会直接导致数据无法参与风险计算或分类，则利用随机森林插补方法将缺失的记录进行填补，避免因缺失值导致的建模误差。如果缺失的字段非数字类型，则将缺失部分统一补全空白信息。例如，缺失字段“异常原因”，则将 NA 部分填补为“未知”。

其次，处理异常值，即数值不符合财务常识或业务规则，如负的赔付金额、索赔金额为 0 但存在赔付等。在物流理赔场景中，实际赔付金额和索赔金额均不可能为负数，因此，需对这两个字段进行非负约束过滤。对于“新旧程度”字段，原始数据中存在-1 这样的特殊值，这类值虽非说明中的定义，即新旧程度为 0 表示未知、1 表示全新、2 表示二手，但属于业务上的有效分类，代表无法归入其他类别的特殊商品，因此不能作为异常值过滤，需保留并纳入后续分组建模。经过上述步骤，最终得到的有效数据集，既具备完整的核心字段，又符合现实逻辑，能够直接用于后续的数据分析和算法建模。

3.2 多维特征探索性分析与挖掘

首先，从第一问涉及的数据中筛选出商品类型、新旧程度、实际赔付金额和索赔金额这些特征信息。其次，通过数学统计与可视化手段，进行数据的探索性数据分析，深入挖掘数据的内在分布特征、变量间的关联规律，以及不同业务维度对风险指标的影响。




图 3-1 数据分析图

从图 3-1 中可以看出，对比“索赔金额分布”和“实际赔付金额对数分布”图，原始金额数据呈显著右偏，少数高额值拉长尾，但经对数变换后分布更趋对称。“索赔差额分布”图中多数样本索赔差额为负，即索赔金额小于实际赔付金额，说明整体存在客户超额索赔的趋势。同时，“不同商品类型的索赔偏差分布”箱线图显示，索赔偏差的个体差异极大，若对全量数据统一建模，会因极端值和组间差异导致边界失真。从“实

际赔付金额 vs 索赔偏差”“不同商品类型的索赔偏差分布”图可见，商品类型对索赔偏差的影响显著，如“Miscellane”“Jewelry”等商品类型，不仅平均索赔偏差高，且存在大量高额异常值，需为其单独设置严格边界。其他如部分日用品类商品，索赔偏差整体偏低且波动小，可设置相对宽松的边界。“索赔差额分布”“新旧程度与索赔偏差关系”图显示，新旧程度与索赔偏差存在明显关联，全新商品的平均索赔偏差更高，且波动更大；二手商品的平均索赔偏差和波动也高于非全新类，但整体低于全新商品。“各组合平均索赔偏差”“商品类型与新旧程度交叉分析”图明确了高风险的业务组合，如“Maternit-2”“Apparel,-2”等组合的平均索赔偏差远超其他，这类组合需设置更严格的分位数参数以控制严重超额比例。

3.3 单调分位边界学习（MQBL）风险标注模型构建

针对物流理赔场景中风险等级的精准划分问题，提出单调分位边界学习（Monotone Quantile Boundary Learning, MQBL）风险标注模型。该模型的核心思想是构建两条随实际赔付金额单调递增的分位边界函数，实现对“合理诉求”“诉求偏高”“严重超额”三类风险的系统性划分。其本质是通过整合分箱划分、分位估计、保序回归与约束校准等步骤，在满足单调性与业务比例约束的前提下，求解最优风险边界，为风险识别提供兼具统计严谨性与业务可解释性的解决方案。

3.3.1 风险分级规则体系设计

在物流理赔风险识别场景中，核心变量为“实际赔付金额”与“索赔超额金额”，当索赔金额低于实际赔付，无超额风险；反之存在超额索赔，需进一步划分风险等级。MQBL 框架通过两条边界函数实现风险分层。设 $b_1: \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}_{\geq 0}$ 与 $b_2: \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}_{\geq 0}$ 为两条非负函数，满足单调性约束，即对任意 $p_1 \leq p_2$ ，有 $b_1(p_1) \leq b_1(p_2)$ 且 $b_2(p_1) \leq b_2(p_2)$ ；边界非交叉约束，即对任意 $p \in \mathbb{R}_{\geq 0}$ ，有 $b_1(p) \leq b_2(p)$ 。其中， $b_1(p)$ 称为“合理-偏高边界”，用于区分“合理诉求”与“诉求偏高”； $b_2(p)$ 称为“偏高-严重边界”，用于区分“诉求偏高”与“严重超额”。

基于上述边界函数，风险等级的分类规则可表示为对任意样本 (p_i, e_i) ，风险标签 y_i 有：

$$y_i = \begin{cases} \text{合理诉求, } e_i < 0 \text{ 或 } 0 \leq e_i \leq b_1(p_i) \\ \text{诉求偏高, } b_1(p_i) < e_i \leq b_2(p_i). \\ \text{严重超额, } e_i > b_2(p_i) \end{cases} \quad (3)$$

为使分类结果符合运营目标，MQBL 模型还需满足预设的业务比例约束，合理诉求的样本占比 $\hat{r}_{\text{合理}} = \frac{1}{N} \sum_{i=1}^N I\{y_i = \text{合理诉求}\}$ 需不低于阈值 $\alpha \in (0,1)$ ；严重超额的样本占比 $\hat{r}_{\text{严重}} = \frac{1}{N} \sum_{i=1}^N I\{y_i = \text{严重超额}\}$ 需不高于阈值 $\beta \in (0,1)$ 。因此，MQBL 模型的核心目标可概括为在单调性、非交叉性与业务比例约束下，求解最优边界函数 (b_1^*, b_2^*) ，实现风险等级的精准划分。

3.3.2 MQBL 动态边界学习算法框架

MQBL 模型通过“局部分位估计-保序回归修匀-连续函数构建”的三阶流程求解边界函数，能捕捉数据分布特征的同时，严格满足单调性约束。

首先，为构建边界函数 b_1 与 b_2 ，需首先捕捉在给定实际赔付金额 p 时，超额金额 e 的条件分布 $P(e|p)$ 的尾部特征。由于 e 与 p 的关系可能是非线性的，直接建模全局分布会

因数据异质性导致偏差。所以采用分箱策略将 p 的取值空间划分为若干子区间，在每个子区间内估计局部阈值，以近似条件分布。

将实际赔付金额 p 的样本集合 $\{p_1, p_1, \dots, p_N\}$ 按升序排序，划分为 K 个等频区间。记第 k 个箱的左边界为 L_k ，右边界为 R_k ，则区间定义为 $[L_k, R_k)$ 。每个箱的中心作为局部特征的代表点，定义为区间中点 $m_k = (L_k + R_k) / 2, (k=1, 2, \dots, K)$ 。对第 k 个箱，提取其包含的样本索引集 $I_k = \{i | p_i \in [L_k, R_k)\}$ ，筛选其中的超额金额样本 $\{e_i | i \in I_k, e_i \geq 0\}$ ，设 $Q_\gamma(S)$ 表示集合 S 的 γ 分位数，分别估计 γ_1 分位数与 γ_2 分位数 ($\gamma_1 < \gamma_2$) 作为初始局部阈值：

$$\hat{q}_1(m_k) = Q_{\gamma_1}(\{e_i : i \in I_k, e_i \geq 0\}), \quad \hat{q}_2(m_k) = Q_{\gamma_2}(\{e_i : i \in I_k, e_i \geq 0\}).$$

其次，局部分位数仅能反映各箱的局部特征，可能因噪声或样本波动出现非单调现象，违反函数定义中的单调性约束。为此，MQBL 引入保序回归 (Isotonic Regression) 对离散估计进行调整，在保留数据趋势的同时强制满足单调性。对边界 $b_j (j=1, 2)$ ，保序回归的目标是找到一组单调非递减的拟合值 $\{z_{j,k}\}_{k=1}^K$ ，使拟合值与局部分位数估计的加权平方误差最小，即：

$$\min_{\{z_{j,k}\}} \sum_{k=1}^K \omega_k (z_{j,k} - \hat{q}_j(m_k))^2 \quad \text{s.t.} \quad z_{j,1} \leq z_{j,2} \leq \dots \leq z_{j,K}, \quad (4)$$

其中， $\omega_k > 0$ 为第 k 个箱的权重。该模型属于凸二次规划问题，目标函数为凸函数，约束条件为凸集，因此存在唯一全局最优解。

保序回归问题通过 PAV 算法 (Pool Adjacent Violators Algorithm) [1] 求解，时间复杂度为 $O(K)$ ，远低于一般二次规划算法。PAV 算法的核心思想是合并违反单调性的相邻箱，用合并后区间的加权均值作为拟合值，直至所有区间满足单调性，得到满足单调性的离散拟合序列 $\{\tilde{q}_j(m_k)\}_{k=1}^K$ 。

最后，采用线性插值将离散拟合值扩展为覆盖全域 $p \in \mathbb{R}_{\geq 0}$ 的连续边界函数。对任意 $p \in [L_k, R_k]$ ，边界函数的取值通过相邻区间中心的拟合值线性过渡得到，即

$$\hat{b}_j(p) = \tilde{q}_j(m_k) + \frac{\tilde{q}_j(m_{k+1}) - \tilde{q}_j(m_k)}{m_{k+1} - m_k} (p - m_k).$$

线性插值的优势是能保持单调性，若 $\{\tilde{q}_j(m_k)\}$ 单调，则插值后的 $\hat{b}_j(p)$ 在全域上仍单调。对于超出样本范围的 p 值，采用常数外推确保边界函数在极端值区域的稳定性，即 $\hat{b}_j(p) = \tilde{q}_j(m_1)$ ($p < L_1$) 或 $\hat{b}_j(p) = \tilde{q}_j(m_K)$ ($p > R_K$)。

3.4 基于自适应分组优化的 MQBL 模型求解策略

根据 MQBL 模型搭建对应的局部分位数-保序回归-连续函数的 MQBL 算法，通过 MQBL 算法求解问题一风险标注问题。算法的流程图如下图所示：




图 3-2 MQBL 算法流程图

由图 3-2 可知，MQBL 算法首先读取数据并进行预处理得到有效数据集。其次，定义 MQBL 风险标注模型类，初始化业务约束与分箱参数，通过二分搜索确定最优分位参数，调用核心方法执行等频分箱、局部分位数计算、保序回归与线性插值，并构建单调非递减风险边界函数，实现样本分类与标签输出。分别训练全局、类别级、分组级 MQBL 模型，样本量不足时组合回退使用更高层级模型，并评估各模型分类效果，保存模型来源映，通过迭代优化不满足约束的模型，替换为更高层级模型直至达标。最后，应用优化后的 MQBL 模型获取每条数据的风险标签。

选取商品类型、新旧程度、实际赔付金额和索赔金额四种运单相关特征信息，代入 MQBL 算法流程对附件一中的数据进行风险标注，并绘制三类风险标注的可视化结果分析图。选取附件一中部分运单信息的风险标注结果进行展示：

表 3-1 部分运单信息的风险标注结果

风险 标签	风险 类别	实际赔付 金额	索赔 金额	索赔差额	索赔 偏差	商品类型	新旧 程度
2	诉求 偏高	144.51	947.97	-803.46	803.46	Apparel, Footwear & Accessories	0
1	合理 诉求	135.98	992.87	-856.89	856.89	Jewelry	1
1	合理 诉求	119.35	352.65	-233.3	233.3	Alcohol	1
1	合理 诉求	74.85	264.29	-189.44	189.44	Household Goods	1
1	合理	22.14	157.58	-135.44	135.44	Household Goods	0

1	诉求合理	13.53	214.52	-200.99	200.99	Household Goods	0
1	诉求合理	29.26	133.24	-103.98	103.98	Hardware	-1
2	诉求偏高	220.55	1786.95	-1566.4	1566.4	Alcohol	-1
2	诉求偏高	275.97	1981.78	-1705.81	1705.81	Pharmaceuticals	0
1	诉求合理	70.29	334.37	-264.08	264.08	Dried Groceries	0




图 3-3 各商品类型-新旧程度的严重超额占比图

从图 3-3 中可以看出，每个单元格的数值和颜色，对应“某商品类型-某新旧程度”组合下的严重超额占比。新旧程度为 1 时，美妆及日常必需品、文件及账单和杂货三类商品的严重超额占比明显突出，分别为 0.059、0.053 和 0.029，反映消费者对全新的这类商品存在较高过度预期，诉求严重超额明显。新旧程度为 0 时，多数商品严重超额占比处于较低水平，但母婴产品、服饰鞋包占比相对稍高，为 0.030、0.026。体现消费者对未知新旧的母婴产品、服饰鞋包有一定过度预期。新旧程度为-1 时，药品、家装建材、家居用品、等占比偏高，说明消费者对这类商品的预期过高，诉求严重超额。




图 3-4 各商品类型-新旧程度的诉求偏高占比图

从图 3-4 中可以看出，新旧程度为 1 时多数商品诉求偏高占比极低，仅生鲜因对新鲜度预期过高，诉求偏高占比达 0.214。新旧程度为 0 时，五金、干货等品类诉求偏高占比明显，反映消费者对其品质预期过高，而电子、珠宝类消费者预期相对理性。新旧程度为-1 时，票据文件、干货等品类诉求偏高占比较高，说明消费者对这类较旧二手商品的品质预期过高，酒精、服饰鞋包等也有一定比例偏高诉求。




图 3-5 各商品类型-新旧程度的合理诉求占比图

从图 3-5 中可以看出，在全新时，多数商品如酒精、服饰鞋包、家装建材等合理诉求占比达 1.000，五金、药品等也接近 1，表明消费者对新旧程度为 1 的商品的诉求几乎都合理，仅美妆日用、生鲜因包装保质期或新鲜度问题合理诉求占比稍低。新旧程度为 0 时，家具、珠宝、生鲜等合理诉求占比处于中高水平，电子类、家电类对未知新旧商品的性能外观合理诉求也较高。新旧程度为-1 时，药品、美妆日用、家具等合理诉求占比仍高，说明消费者对这类商品的使用价值合理诉求为主。

3.5 问题一小结

通过系统性的数据处理与模型构建，实现了“合理诉求”“诉求偏高”“严重超额”三类风险的精准标注。首先，完成核心指标定义与数据预处理后进行探索性数据分析。发现原始金额数据呈右偏分布，经对数变换后更趋对称；多数样本存在客户超额索赔趋势，且商品类型、新旧程度对索赔偏差影响显著，如“Miscellane”“Jewelry”等商品及全新商品的索赔偏差更高，需针对性设置风险边界。其次，构建单调分位边界学习（MQBL）风险标注模型，通过“等频分箱-局部分位估计-保序回归修匀-线性插值”流程，生成两条单调递增的风险边界函数，结合业务比例约束实现风险分层。最后，运用 MQBL 算法进行模型求解并输出附件 1 中各运单风险标注结果。

四、基于 Stacking 集成学习的赔付金额预测模型构建与求解

4.1 面向预测任务的特征工程构建与数据预处理

在问题二中，要求基于附件 1 的历史运单建立稳健的模型以预测单条运单的“实际赔付金额”，训练数据来自历史运单记录，包含数值型、类别型、时间型等多类变量，并伴随典型的数据质量问题，如一部分类别特征存在缺失、若干数值特征呈显著右偏且存在极端值等等。为此，在建模前应对历史运单数据实施系统化的预处理。与问题一的基础清洗不同，模型训练对特征的分布形态、类别编码的一致性及极端值的处理更为敏感。因此在问题一基础上，针对建模需要进一步进行以下数据预处理，并使得评估更具可靠性。

根据对数据的分析，选择与目标变量“实际赔付金额”最相关的特征，包括“保价金额”“配送超时时长”“异常原因”“商品类型”“新旧程度”“目的网点赔付比例”“始发网点赔付比例”“索赔金额”等。在特征工程中，为降低数值特征的偏态影响，对“保价金额”“配送超时时长”等高度右偏的变量构造了对数变换特征，以此削弱长尾分布对回归模型的拉动作用，增强其鲁棒性与表达能力：

$$x' = \log(1+x), \quad (5)$$

其中， x 为原始变量， x' 为经过对数变换后的变量。该变换有助于减少数据的偏态分布，尤其是当数据中存在极大值时，通过对数变换在保留数值顺序信息的同时压缩极端值对损失的影响，可以使数据更符合模型假设，进而提升模型的稳定性。

为保证训练及测试阶段特征空间一致，在数据预处理中对所有类别变量均采用 One-Hot 编码进行转换，将其拆分为多个二元特征，以便模型能够处理非数值型数据。具体流程为：首先在训练集上重新拟合 One-Hot 编码器以确定虚拟变量空间，其次以此编码器转换测试集数据，最后对所有列名进行规范化处理并采用列对齐策略，消除了训练集与测试集因样本分布差异导致的特征空间不一致问题，从而避免运行时错误与潜在的数据泄露，确保模型在训练与预测阶段特征维度的统一。

4.2 Stacking 集成学习框架下的模型构建

4.2.1 XGBoost 基模型

XGBoost(Extreme Gradient Boosting)是一种基于梯度提升树(Gradient Boosting Tree, GBT)的高效实现，广泛应用于回归和分类问题^[2]。其基本思想是将模型表示为若干回归树的加法组合并通过迭代地拟合残差或损失的负梯度逐步逼近目标函数。在问题二中，将其应用于快递赔付金额的预测任务，旨在通过序列化构建多棵决策树来逐步逼近真实的赔付金额函数。

采用 XGBoost 作为一阶基学习器之一。设模型由 M 棵回归树组成, 第 m 棵树记为 f_m , 总体预测表示为:

$$\hat{f}(x) = \sum_{m=1}^M f_m(x). \quad (6)$$

为兼顾样本重要性与模型复杂度, 在训练中对每个样本引入由目标分箱的逆频率归一化得到的权重 w_i , 并以带权的正则化目标进行优化:

$$Obj(f_m) = \sum_{i=1}^n w_i \ell(y_i, \hat{f}(x_i)) + \sum_{m=1}^M \Omega(f_m),$$

其中, 损失函数在回归任务中采用平方损失 $\ell(y, \hat{y}) = \frac{1}{2}(y - \hat{y})^2$ 。为了避免过拟合, XGBoost 在目标函数中加入了正则化项 $\Omega(f_k)$, 用于控制模型复杂度。单棵树的正则化项取叶级别的形式:

$$\Omega(f_m) = \gamma J_m + \frac{1}{2} \lambda \sum_{j=1}^{J_m} w_{m,j}^2,$$

其中, J_m 为第 m 棵树的叶节点数, $w_{m,j}$ 为叶节点权重, (γ, λ) 为正则化超参数。

在第 m 轮拟合新增树时, 基于损失的二阶泰勒展开并引入带权梯度与二阶导, 可写为:

$$\sum_{i=1}^n w_i \ell(y_i, \hat{y}_i^{(m-1)} + f_m(x_i)) \approx \text{const} + \sum_{i=1}^n g_i f_m(x_i) + \frac{1}{2} \sum_{i=1}^n h_i f_m(x_i)^2,$$

其中, 带权的一阶、二阶项定义为 $g_i = w_i \frac{\partial \ell(y_i, \hat{y})}{\partial \hat{y}} \Big|_{\hat{y} = \hat{y}_i^{(m-1)}}$, $h_i = w_i \frac{\partial^2 \ell(y_i, \hat{y})}{\partial \hat{y}^2} \Big|_{\hat{y} = \hat{y}_i^{(m-1)}}$ 。

若样本按叶 $I_{m,j}$ 划分, 叶 j 上的目标化简为关于该叶权重 $w_{m,j}$ 的二次函数, 其解析最优解为:

$$w_{m,j}^* = -\frac{G_{m,j}}{H_{m,j} + \lambda}, \text{ 其中 } G_{m,j} = \sum_{i \in I_{m,j}} g_i, H_{m,j} = \sum_{i \in I_{m,j}} h_i. \quad (7)$$

分裂增益按二阶增益公式计算:

$$\text{Gain} = \frac{1}{2} \left(\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right) - \gamma, \quad (8)$$

其中, (R_L, R_R, H_L, H_R) 分别为左右子叶的带权梯度与带权二阶和。

4.2.2 LightGBM 基模型

与 XGBoost 类似, LightGBM 通过构建一系列决策树来逐步提升预测准确性, 但它采用了直方图方法 (Histogram-based approach) 来加速计算, 并有效减少内存使用。在本题中, LightGBM 被用于预测实际赔付金额, 旨在处理由多种特征组成的复杂数据集, 并通过高效的训练过程来提升模型的预测能力^[3]。

LightGBM 基于梯度提升框架, 其目标函数由损失函数和正则化项组成。对于包含 n 个样本的训练集, 模型在第 t 次迭代的目标函数为:

$$Obj^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \sum_{k=1}^t \Omega(f_k), \quad (9)$$

其中, $l(\cdot)$ 为损失函数 (采用平方损失函数 $l(y, \hat{y}) = \frac{1}{2}(y - \hat{y})^2$), f_k 为第 t 棵决策树,

$\Omega(f_k) = \gamma T + \frac{1}{2} \lambda \|w\|^2$ 为正则化项， T 为叶子节点数， w 为叶子权重。

传统梯度提升算法需要对所有样本计算梯度，计算开销大。相较于传统 GBDT 算法，LightGBM 在保持预测精度的同时，通过多项创新技术大幅提升了训练效率，特别适合处理如快递赔付预测这类包含大量数据且特征维度较高的回归问题。LightGBM 的核心优化体现在单边梯度采样（GOSS）以及互斥特征捆绑（EFB）两个方面^[4]。

GOSS 技术基于一个关键观察：**不同训练样本对信息增益的贡献是不同的，梯度绝对值越大的样本，其信息增益通常也越大。**GOSS 通过一种智能的采样策略来近似全数据梯度，其步骤为：首先，保留梯度绝对值最大的前 $a \times 100\%$ 的样本，这些样本携带了最多的信息；其次，从剩余的 $(1-a) \times 100\%$ 样本中，随机选取 $b \times 100\%$ 的样本；最后，为了弥补采样对数据分布的扰动，在计算信息增益时，对随机采样的低梯度样本引入一个常数权重放大因子 $\frac{1-a}{b}$ 。

设训练实例集合为 X ，其梯度绝对值为 g ，采样后的样本集合为 X^s ，则信息增益的近似计算为：

$$\tilde{g} \approx \frac{1}{n} \left(\sum_{x_i \in A} g_i + \frac{1-a}{b} \sum_{x_i \in B} g_i \right), \quad (10)$$

其中， A 表示高梯度样本集合， B 表示从低梯度样本中随机采样的集合。通过此策略，LightGBM 能够在几乎不损失精度的情况下，将数据量减少到原来的 $(a + b(1-a))$ 倍，显著加快了训练速度。

高维特征数据通常是稀疏的，即许多特征是互斥的。例如，在 One-Hot 编码后，一个样本在同一时刻只有一个特征为非零值。EFB 技术旨在**通过合并互斥的特征来降低特征维度**，从而减少寻找最优分裂点的计算复杂度。EFB 将特征捆绑问题转化为图着色问题，即首先将每个特征视为图中的一个顶点；其次如果两个特征不是互斥的，则在它们之间添加一条边；最后用图着色算法对顶点进行着色，颜色相同的特征可以被捆绑成一个新的“超级特征”。在分裂点查找时，算法不再需要在 d 个原始特征上遍历，而只需要在 d' 个捆绑特征上遍历，且 $d' \ll d$ 。这使得计算复杂度有所降低。

GOSS 通过对样本的智能筛选减少了数据量，EFB 通过对特征的智能合并降低了特征维度。这两项技术共同作用，使 LightGBM 在处理快递赔付数据时，相比 XGBoost 获得了数量级上的训练速度提升，同时保持了相当的预测精度。

4.2.3 随机森林基模型

随机森林（Random Forest）是一种基于 Bagging 集成学习思想的强大算法，通过构建多棵决策树并综合其预测结果来提升模型泛化能力^[5]。随机森林被用作基模型之一以预测运单的实际赔付金额。考虑到目标变量具有明显右偏分布与若干高赔付（“严重超额”）样本，随机森林的稳健性使其成为合适的候选。

对于包含 n 个样本的训练集，通过 Bootstrap 采样生成 B 个自助样本集，基于每个样本集独立训练决策树 $T_b(x)$ ，最终预测为所有树预测的平均值：

$$\hat{y}_{RF} = \frac{1}{B} \sum_{b=1}^B T_b(x), \quad (11)$$

其中，设置的树的数量为 $B = 200$ 。每棵决策树在生长过程中，分裂点的选择基于特征子集的信息增益最大化，其特征采样数 m 通常取总特征数 M 的平方根 $m = \lfloor \sqrt{M} \rfloor$ 。

在回归问题中，随机森林采用方差减少作为分裂准则。设节点 t 包含样本集 S_t ，其

方差为:

$$Var(S_i) = \frac{1}{|S_i|} \sum_{i \in S_i} (y_i - \bar{y}_i)^2. \quad (12)$$

对于特征 j 在值 s 处的分裂, 将 S_i 划分为左子节点 S_L 和右子节点 S_R , 分裂的质量通过方差减少量衡量。

$$\Delta Var(j, s) = Var(S_i) - \frac{|S_L|}{|S_i|} Var(S_L) - \frac{|S_R|}{|S_i|} Var(S_R). \quad (13)$$

算法遍历特征子集中的所有可能分裂, 选择使 $\Delta Var(j, s)$ 最大的特征和分裂点。

4.2.4 二层堆叠 (Stacking) 集成模型

为综合不同基学习器的互补优势并提升对实际赔付金额预测的泛化性能, 采用二层堆叠 (Stacking) 集成策略。第一层由三类基模型构成: 基于二阶近似的梯度提升树 (XGBoost)、高效直方图与采样优化的梯度提升树 (LightGBM) 以及基于 Bagging 的随机森林 (Random Forest); 第二层采用简单线性回归作为元学习器对第一层输出进行融合。堆叠的核心思想是: 第一层模型分别从不同角度逼近目标函数, 第二层元模型在不引入原始特征的情况下学习如何加权这些不同来源的预测, 从而在偏差-方差权衡上取得更优解。

在堆叠集成模型中, 基于多个学习器的预测结果进行加权组合, 通过不同基模型对不同数据特征的适应性, 提供更为精确的预测, 有效降低模型的**偏差和方差**, 提升整体预测的鲁棒性。此外, 元模型的选择至关重要。在问题二中, 选择简单的**线性回归**模型作为元模型。其原因在于线性回归能够通过最小化预测误差的方式, 自动调整每个基学习器预测结果的权重, 从而有效合并不同模型的优点。元模型 R 的具体形式为线性组合:

$$R(\hat{y}_1(x_i), \dots, \hat{y}_M(x_i)) = \beta_0 + \beta_1 \hat{y}_1(x_i) + \beta_2 \hat{y}_2(x_i) + \dots + \beta_M \hat{y}_M(x_i), \quad (14)$$

其中, β_0 为截距项, $\beta_1, \dots, \beta_M$ 为赋予各基学习器的权重。

在模型训练过程中, 首先对每个基学习器进行训练, 通过 k 折交叉验证获得每个基学习器的 **OOF 预测** (Out-Of-Fold 预测) [6]。这些预测结果将作为元模型的输入特征, 用于训练一个线性回归模型。通过最小化以下损失函数来优化元模型的参数:

$$Loss = \sum_{i=1}^n (y_i - g(\hat{y}_1(x_i), \hat{y}_2(x_i), \dots, \hat{y}_M(x_i)))^2, \quad (15)$$

其中, R 为元模型, $\hat{y}_m(x_i)$ 为第 m 个基学习器的预测结果, y_i 为实际值。

4.3 基于分层交叉验证的模型训练与优化求解

4.3.1 基于分层 k 折交叉验证的 OOF 预测求解策略

在交叉验证与模型选择方面, 采用分层 k 折的 OOF (Out-Of-Fold) 流程以获得稳健的泛化误差估计并为二阶段融合提供无泄露的元特征。在每一折的训练过程中, 基模型在验证集上会产生一个“最佳训练轮数”的估计值; 为了在全量数据上得到用于可解释性分析的稳定模型, 最终在完成所有折的 OOF 评估后, 将各折得到的最佳轮数指标汇总作为在全量训练时采用的训练轮次。这样可以既保证模型性能报告以 OOF 估计为准、避免评估泄露, 又能在全量数据上得到一个相对稳健的解释性模型, 便于将模型输出与业务规则或人工复核流程对接。

堆叠集成通过将基学习器的输出作为元特征输入元学习器, 实现对原始预测结果的智能融合。设第一层包含 K 个基学习器 $\{M_1, M_2, \dots, M_K\}$, $K = 3$ 。为避免信息泄露并保证

元模型的训练仅使用“真实的泛化预测”，选择在第一层采用分层 k 折交叉验证生成袋外预测作为元特征。

设训练集样本索引为 $\{1, \dots, n\}$ ，将其划分为 k 个互不相交的验证折 $\mathcal{V}_1, \dots, \mathcal{V}_k$ ，划分时对目标变量进行分箱以实现分层抽样，确保高赔付样本在每一折中都具有代表性。对于第 m 个基模型（ $m=1, \dots, M$ ， $M=3$ ），在第 k 折中使用除 $\mathcal{V}_k$ 外的样本训练基模型并对 $\mathcal{V}_k$ 给出预测，从而得到该模型对所有训练样本的 OOF 预测向量 $\{z_{i,m}\}_{i=1}^n$ 。

令 $\hat{f}_m^{(-k)}$ 表示在第 k 折的训练子集上得到的第 m 个基模型，则对于 $i \in \mathcal{V}_k$ 有：

$$z_{i,m} = \hat{f}_m^{(-k)}(x_i). \quad (16)$$

完成所有折后，得到训练集上 M 个 OOF 预测列，构成堆叠设计矩阵：

$$Z = \begin{bmatrix} 1 & z_{1,1} & z_{1,2} & \cdots & z_{1,M} \\ 1 & z_{2,1} & z_{2,2} & \cdots & z_{2,M} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & z_{n,1} & z_{n,2} & \cdots & z_{n,M} \end{bmatrix} \in \mathbb{R}^{n \times (M+1)},$$

其中，第一列为常数项。以 $\mathbf{y} = (y_1, \dots, y_n)^\top$ 表示实际赔付金额，则元模型采用线性最小二乘拟合：

$$\beta^* = \arg \min_{\beta} \|\mathbf{y} - Z\beta\|_2^2.$$

由于 $Z^\top Z$ 可逆，其解析解为：

$$\hat{\beta} = (Z^\top Z)^{-1} Z^\top \mathbf{y}.$$

因此元模型输出的训练阶段预测为 $\hat{\mathbf{y}}_{\text{stack}} = Z\hat{\beta}$ ，并可据此计算 OOF 的 RMSE 以与各基模型的 OOF RMSE 进行比较。

对于测试集样本 x_{test} ，首先通过基学习器生成预测：

$$z_{\text{test},m} = \frac{1}{K} \sum_{k=1}^K \hat{f}_m^{(-k)}(x_{\text{test}}).$$

最终预测为：

$$\hat{y}_{\text{test}} = \hat{\beta}_0 + \sum_{m=1}^M \hat{\beta}_m z_{\text{test},m}. \quad (17)$$

基于上述结果，可计算得到 OOF RMSE，并将其与各基模型的 OOF RMSE 进行量化比较。在线性元模型的构建过程中，为缓解基模型间可能存在的多重共线性问题及模型过拟合风险，可根据实际需求引入正则化方法；然而，为实现对各基模型权重系数的直接解释、强化模型的可解释性，最终确定选用无惩罚项的线性回归模型。

4.3.2 基模型性能的多维对比评估与优选分析

为客观评估各模型的泛化性能，基于 Out-of-Fold 预测计算了多项评估指标，结果如表 4-1 所示。在评估指标中，平均绝对百分比误差 MAPE 对于业务解释尤为重要，它衡量了预测的相对误差水平，其计算公式为：

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{\max(|y_i|, \epsilon)} \right|, \quad (18)$$

其中，引入 ϵ 是为防止分母为零。

由表 4-1 可知，堆叠集成模型的 MAPE 为 88.28%，显著低于所有基模型，其绝对误差率相较于基模型降低了 3.8 至 9.95 个百分点。这一结果意味着堆叠模型对单个样本

的预测相对准确度有了实质性提升，在物流企业的实际理赔成本预估中更具实用价值。

此外，为专门评估模型在高赔付金额运单上的表现，计算了 90%分位数损失。该指标通过不对称加权，重点惩罚可能造成“企业超额赔付”的预测误差，即预测值低估真实赔付金额，其计算公式为：

$$L_{90\%}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n \max(0.9 \cdot (y_i - \hat{y}_i), (0.9 - 1) \cdot (y_i - \hat{y}_i)). \quad (19)$$

由表 4-1 可知，堆叠模型的 90%分位数损失最低为 54.37，这表明其在控制企业超额赔付风险方面表现最优，对物流企业的成本控制与风控管理价值突出。对于其他指标，均方根误差 RMSE 和平均绝对误差 MAE 分别从不同角度衡量了绝对误差，堆叠模型在此二者上也均取得了最小值，分别为 160.55 和 108.75。同时，决定系数 R^2 最高为 0.675，说明该模型对赔付金额波动的解释能力最强。综上所述，堆叠集成模型在预测精度、风险控制 and 解释能力等多个关键维度上均表现出显著优势，验证了该集成学习策略在解决物流企业赔付金额预测问题上的有效性与实用性。

表 4-1 OOF 总体评估指标

model	RMSE	MAE	MedAE	MAPE_pct	R^2	90%分位数损失
XGBoost	161.00	108.91	71.59	92.08	0.67	54.89
LightGBM	161.78	109.50	72.90	96.27	0.67	54.65
随机森林	164.88	111.58	73.96	98.23	0.66	55.23
集成模型	160.55	108.75	71.63	88.28	0.68	54.37

在完成全样本集的模型性能评估后，为深入考察各模型在关键业务样本上的预测稳健性，进一步针对训练集中索赔金额最高的 10%样本，即 $n = 1117$ ，进行了专项分析。高价值索赔样本虽然数量占比有限，但通常涉及物流企业的大部分理赔成本，其预测准确性直接关系到企业的财务风险控制水平。专项评估结果如表 4-2 所示。

表 4-2 高价值索赔样本（Top-10%）评估指标

model	RMSE	MAE	MAPE_pct	R^2
XGBoost	293.26	211.23	34.77	0.34
LightGBM	296.77	214.60	34.86	0.33
随机森林	304.77	221.02	37.04	0.29
集成模型	292.34	212.28	35.40	0.35

由表 4-2 可知，在高价值样本集上，堆叠集成模型的均方根误差 RMSE 保持最低，为 292.34，这表明其在处理关键的高额赔案时，能最有效地避免产生极端预测偏差。同时，其决定系数 R^2 在所有模型中最高为 0.347，说明即使在高价值样本上，该模型对赔付金额波动的解释能力仍然最强。




图 4-1 RMSE 按索赔金额分箱图

在完成整体性能评估后，为深入考察模型在不同业务规模下的预测稳健性，进一步将训练集按索赔金额等分为 10 个分组，并分别计算各分组内的 RMSE。该分析旨在验证模型是否仅对特定规模的赔案有效，以及其性能是否随业务规模扩大而出现显著波动。

表 4-3 RMSE 按索赔金额分箱表

n	分组	索赔金额		RMSE			
		最小值	最大值	XGBoost	LightGBM	随机森林	集成模型
1117	1	100.00	129.98	31.22	35.15	33.45	30.86
	2	129.99	195.88	44.05	44.61	43.82	43.63
	3	195.89	291.49	61.21	60.85	60.82	60.75
	4	291.61	402.78	85.75	85.94	86.81	85.59
	5	402.84	546.41	107.72	107.71	107.10	107.40
	6	546.54	709.88	139.84	139.33	137.62	139.22
	7	709.88	929.48	175.35	175.62	178.52	175.12
1116	8	929.74	1236.53	208.44	208.38	213.02	208.14
	9	1237.46	1872.14	233.11	233.61	239.70	232.38
	10	1872.49	5498.77	292.57	296.05	304.23	291.67

由表 4-3 可知，所有模型的 RMSE 均随索赔金额分位数的上升而单调递增，这与业务逻辑相符，即金额越高的赔案，其不确定性和潜在波动性越大，预测绝对误差随之增加属正常现象。然而，堆叠集成模型在全部 10 个分组中，有 8 个分组的 RMSE 值为最低，尤其在索赔金额最高的第 10 分位最高为 5498.77，其 RMSE 为 291.67，显著低于其他基模型。从图 4-1 中可以看出，蓝色相对 RMSE 曲线进一步揭示，尽管绝对误差在增长，但堆叠模型在高价值区间的相对预测精度保持领先。综上所述，堆叠集成策略不仅提升了整体精度，更关键的是在物流企业最为关注的高价值货件赔付预测上，提供了最优且最稳定的性能保障，为差异化风险管理提供了可靠依据。

4.3.3 预测性能的多维深度评估与误差分析

经过对模型的求解，得到附件 2 中运单的实际赔付金额的预测结果。部分预测结果如表 4-4 所示。

表 4-4 运单实际赔付金额预测结果（前 30 条）

运单号	实际赔付金额	运单号	实际赔付金额	运单号	实际赔付金额
1	241.98	11	315.68	21	231.72
2	295.48	12	232.14	22	94.24
3	810.50	13	53.90	23	183.97
4	224.37	14	421.62	24	209.26
5	36.42	15	259.30	25	256.81
6	179.56	16	97.94	26	120.77
7	252.98	17	304.75	27	35.92
8	302.68	18	405.49	28	573.93
9	238.87	19	304.92	29	174.97
10	288.90	20	114.18	30	87.40

为了深入了解模型的预测性能，除了关注传统的如 RMSE、MAE 等回归误差指标，还对模型在不同赔偿金额区间的表现进行了进一步分析。图 4-2 展示了堆叠集成模型的残差分布诊断结果。左图展示了全量残差分布，呈现典型的单峰形态，峰值密集于零点附近，且分布曲线对称，符合正态分布特征。右图聚焦于 1%-99%分位数区间，密度峰值约为 0.005，残差集中在 $[-200,200]$ 区间。这表明模型没有明显的系统性偏差，绝大多数预测误差都在合理范围内；堆叠集成模型在大部分样本上的误差较小，且残差集中，未出现明显的偏差，证明了模型的稳定性和预测精度。




图 4-2 残差分布对比图

图 4-3 通过二维密度散点图展示了索赔金额与实际赔付金额的关系，并对样本的密度进行了颜色映射。散点图中的红色线条代表模型的预测趋势线，而绿色线条代表实际赔付金额与索赔金额的关系。颜色梯度显示出明显的正相关趋势，黄色区域表示高密度样本。从图 4-3 中可以看出，图中堆叠集成模型的预测趋势线与实际赔付金额的关系较为吻合，尽管在高赔付区域数据点较为稀疏，趋势线依然稳定，表明模型有效捕捉了极端案例的赔付规律。堆叠集成模型能够更好地拟合实际赔付金额与索赔金额之间的关系，

尤其在高赔偿金额区间仍然能够保持较高的预测准确度。




图 4-3 索赔金额与实际赔付金额散点对比图

4.3.4 SHAP 框架下的模型可解释性与特征重要性度量

在完成传统性能指标评估后，进一步引入 SHAP（SHapley Additiveex Planations）方法进行模型可解释性分析。虽然 RMSE、MAE 等指标能够有效衡量模型的整体预测精度，但无法揭示模型内部的决策机制。SHAP 是一种基于博弈论的特征重要性解释方法，可以为每个特征提供量化的贡献度，从而揭示模型预测的决策过程，可解答“哪些特征影响最大”及“特征如何影响预测”两大核心问题。能够清楚地了解该特征对模型预测结果的正向或负向影响，并且 SHAP 的加性特性保证了各特征贡献的叠加结果等于模型的输出。




图 4-4 SHAP 值对比图

从图 4-4 中可以看出，左图中“索赔金额”是影响赔付金额预测的最重要特征，其 SHAP 值显著高于其他特征。这一发现与快递赔付业务的底层逻辑完全一致，即客户申报的索赔金额直接反映了损失规模的基本面。值得注意的是，经过对数变换的“保价金额”和“配送超时时长”分别位列第二、三位，分别为 26.41 和 22.18，这表明在同等索赔金额下，高价值货件和延误严重的订单往往对应更高的最终赔付额，体现了物流行业特有的风险定价规律。右图显示各特征对预测结果的影响方向存在显著差异。数值型特征如“索赔金额”为 158.32 呈现明确的正向影响，表明这些特征的数值增大会推高预测赔付金额。特别是“配送超时时长”的正向影响，印证了物流行业中时效延误与赔付成本的正相关关系。类别型特征的影响则呈现出更复杂的模式，如“商品类型 Hardware”的 SHAP 值分布在零值两侧，表明该特征在不同样本中既可能产生正向也可能产生负向影响。

综上所述，数值型特征在赔付金额预测中起主导作用，其中“索赔金额”“保价金额”和“配送超时时长”是最重要的三个影响因素，这一特征重要性排序充分体现了物流行业风险定价的内在规律。同时，不同类型特征对预测结果的影响模式存在显著差异，数值型特征呈现明确的正向影响，而类别型特征的影响则更为复杂。

4.4 问题二小结

在问题二中，建立了一个精确预测运单“实际赔付金额”的模型。通过数据预处理，对历史数据中的数值型、分类型和时间型特征进行了有效清洗，解决了数据缺失、异常值及偏态分布的问题。在模型构建方面，采用了 XGBoost、LightGBM 和随机森林三种强大算法作为基模型，旨在捕捉运单赔付金额的复杂模式。通过堆叠集成方法，将这三种基学习器的优势融合，以提高预测的准确性和泛化能力。堆叠集成模型的表现优于单一基模型，特别是在高赔付金额样本的预测上展现出优异的稳定性和准确度。最终的模型在多个评估指标上表现出色，堆叠集成模型的 MAPE 显著低于其他模型，表明其在实际应用中对于赔付金额的预测具有较高的实际价值。同时，针对高赔付金额的风险控制能力尤为突出，这使得模型能够有效支持物流企业实际运营中的理赔成本控制与风险管理。总体而言，提出的模型在处理大规模、复杂数据集的赔付金额预测任务时，展现了强大的预测能力与稳定性，为物流企业提供了有效的风险评估工具，并为进一步的优化与改进奠定了坚实的基础。

五、基于不平衡数据的自适应风险标注模型构建与求解

5.1 面向不平衡数据的自适应风险标注模型构建

在问题二中，首先通过构建混合模型对附件 2 的运单实际赔付金额进行预测，得到预测结果后，调用第一问构建的 MQBL 模型对附件 2 样本进行风险标注，并将风险标注结果与第二问的预测金额一同存入 Result.xlsx。

观察附件 1 与附件 2 的风险标注结果可以得出，无论是从样本总体维度，还是按不同商品类型拆分后、不同新旧程度的子维度来看，“严重超额”类别的样本占比均存在显著不平衡问题。这种样本分布失衡会导致模型训练产生系统性偏差，使算法过度拟合多数类样本的分布特征，进而严重削弱对少数类样本的识别能力。此类偏差不仅会造成关键少数类样本的漏检，还会导致准确率等传统评估指标失效，无法真实反映模型的泛化性能；更会降低模型在真实场景中的决策可靠性，尤其在高风险识别、异常检测等核心任务中，可能引发严重的运营后果。

因此，为提升模型对少数类样本的敏感度、确保评估结果的有效性，必须针对性处理样本不平衡问题。基于此，引入三种优化方法，分别为代价敏感学习策略、合成少数

类过采样策略（SMOTE）及随机欠采样策略，来处理不平衡数据问题。

5.1.1 代价敏感学习策略

代价敏感学习（Cost-Sensitive Learning），又称样本加权法，是解决样本不平衡问题的基础策略^[7]。其核心逻辑是通过为不同样本分配差异化训练权重，调整样本在损失函数中的贡献度。具体而言，对少数类样本赋予更高权重，对多数类样本赋予更低权重，以此引导模型重点关注不平衡场景中的关键样本，进而优化模型预测偏倚。从本质上看，该方法通过“权重调整”而非“样本数量调整”平衡样本对模型训练的影响，无需改变原始样本分布，可最大程度保留数据原始特征。

第三问对传统样本加权法进行了适应性改进，摒弃单一少数类加权模式，设计“基础权重+少数类增强权重”的双层混合加权策略，相比传统单一加权方式更适配此回归任务。具体改进体现在以下两点：

改进一：基础权重基于“目标值分箱”而非“类别”设定。传统加权多直接按样本类别分配权重，而这里需先将目标值按分位数划分为 K 个箱，再计算“分箱逆频率权重”，即样本数量越少的分箱，对应权重越高。该改进可有效解决回归任务中“同类别样本目标值差异大”的问题，避免同类别内数值极端的样本被模型忽略，提升对关键数值样本的关注。

改进二：少数类权重与基础权重采用“乘法叠加+归一化”融合方式。在基础权重的基础上，先对基础权重进行归一化处理，再叠加少数类增强权重。此改进既确保少数类样本在模型训练中保持高贡献度，又能避免因权重规模过大导致模型优化过程不稳定，保障训练过程的收敛性。

关于上述双层混合加权策略的具体计算逻辑，涉及的数学公式如下：

$$\omega_{base}(x) = \frac{n}{n_b}, \quad (20)$$

$$\omega_{base,norm}(x) = \frac{\omega_{base}(x)}{\frac{1}{n} \sum_{x \in X_{tr}} \omega_{base}(x)}, \quad (21)$$

$$\omega_{final}(x) = \omega_{base,norm}(x) \cdot [1 + (\omega_m - 1)I(x)], \quad (22)$$

其中，公式（20-22）分别表示计算基础权重、基础权重归一化、最终训练权重。 n 表示训练集总样本数， n_b 表示第 b 个分箱的样本数， ω_m 表示少数类权重增强系数， $I(x)$ 表示少数类指示函数， x 为少数类时 $I(x)=1$ ，否则 $I(x)=0$ ， ω_{base} 表示样本 x 的基础权重， $\omega_{base,norm}$ 表示归一化后的基础权重。

5.1.2 合成少数类过采样策略

合成少数类过采样技术（Synthetic Minority Oversampling Technique, SMOTE）是 Chawla 等人于 2002 年提出的经典过采样方法，是针对分类任务中少数类样本不足的问题，通过在少数类样本与其 k 近邻样本之间进行线性插值，生成新的合成少数类样本，从而平衡样本分布，避免模型偏向多数类。其本质是通过“插值生成”而非“重复采样”扩充少数类，保留少数类样本的分布特征，降低过拟合风险^[8]。

问题三中并非直接套用标准分类 SMOTE，而是针对实际赔付金额这一回归任务进行了 3 处关键改进，适配回归场景的特殊性。改进一：目标值从“标签复制”改为“插值生成”。标准 SMOTE 用于分类时，合成样本的标签直接复制“父样本”标签；而改

进后，合成样本的目标值与特征向量同步插值，确保生成的目标值符合少数类样本的数值分布规律，避免回归预测值的偏差。改进二：增加“目标值分箱权重继承”机制。在生成合成样本后，并未直接用于训练，而是让合成样本继承其“父样本”的基础权重。这一改进解决了“合成样本权重无依据”的问题，同时结合目标值分箱进一步平衡了不同数值区间的样本贡献。改进三：动态调整有效近邻数。标准 SMOTE 固定 k 近邻数，若少数类样本数小于 k ，会导致近邻选择失败；代码中动态调整近邻数，即当少数类样本数为 1 时，强制近邻数为 1，避免程序报错，同时保证极端情况下仍能生成合成样本。具体数学公式给出如下：

$$k_e = \min(k, \max(1, m-1)), \quad (23)$$

$$x_{syn} = x_i + \gamma(x_j - x_i), \quad (24)$$

$$y_{syn} = y_i + \gamma(y_j - y_i), \quad (25)$$

其中，公式 (23) 表示有效近邻数的计算方式，公式 (24)、(25) 分别表示合成特征与合成目标值的计算公式。 k 代表预设近邻数， m 代表少数类样本数，即“严重超额”的样本数， λ 是插值比例， x_i 代表少数类中随机选的“父样本”特征， x_j 是 x_i 的近邻样本特征， y_i 、 y_j 对应“父样本”、近邻样本的目标值。

5.1.3 随机欠采样策略

随机欠采样 (Random Undersampling) 是最简单的欠采样方法，该方法针对多数类样本过多的问题，通过无放回随机删除部分多数类样本，减少多数类样本数量，使多数类与少数类样本数量比例趋于平衡，从而降低模型对多数类的偏向性^[9]。其本质是通过“减少多数类规模”而非“扩充少数类”平衡样本分布，计算成本低、训练效率高，但可能丢失多数类中的关键信息。

同样问题三针对传统的“固定比例删除多数类”进行了两处改进，使其更适用于多类别不平衡场景。改进一：“保留全部少数类”+“多数类按目标数量动态采样”。传统欠采样常按固定比例删除多数类，若多数类含多个子类别，可能导致部分子类别样本被过度删除；改进中先确定少数类目标样本数，对每个多数类子类别，若样本数大于目标样本数，则随机采样至目标样本数；若样本数小于等于目标样本数，则全部保留。这一改进能避免多数类子类别信息丢失，同时保证整体样本平衡。改进二：下采样后增加“权重补偿”机制。传统欠采样后直接用平衡样本训练，未考虑下采样后“目标值分布偏移”的问题；而在欠采样后，可基于新样本集的目标值分箱重新计算“逆频率权重”，以此补偿下采样后可能出现的“数值区间样本不平衡”，进一步优化回归预测精度。

$$N_t = \begin{cases} \text{median}(\{n_i\}_{i=1}^K), & \text{中位数策略} \\ \max(\{n_i\}_{i=1}^K), & \text{最大值策略,} \\ sv, & \text{自定义策略} \end{cases} \quad (26)$$

$$n'_i = \begin{cases} n_i, & k \text{ 为少数类, 全部保留} \\ \min(n_i, N_t), & k \text{ 为多数类, 下采样} \end{cases}, \quad (27)$$

$$S_u = \bigcup_{i=1}^K \left\{ \text{RandomSample}(S_i, n'_i) \right\}. \quad (28)$$

其中，公式 (26) 表示确定目标采样数，公式 (27) 是定义的各类别采样规则，公式 (28) 表示欠采样后的数据集。 S_i 表示第 i 个类别的原始样本集合， N_i 表示目标采样数， n_i' 表示采样后的样本数， $RandomSample(S_i, n_i')$ 表示从集合 S_i 中随机无放回抽取 n_i' 个样本。

5.2 三种不平衡数据处理模型的优化求解与性能分析

在前面 5.1 章中，为解决样本占比严重不平衡问题引入了三种方法。为验证这三种方法处理样本占比严重不平衡的可行性，需将其与问题 2 中的模型结合，分析对实际赔付金额预测的影响，并通过观察评价指标，从包含原方法在内的四种方法中选出表现更优异的方案。其中，原方法指不针对“风险类别不平衡”做特殊处理，仅通过目标值分箱加权平衡不同数值区间样本贡献的方式。

验证过程采用“方法处理样本+模型训练预测”的流程思路，核心逻辑为“5 折交叉验证+方法处理训练集+基础模型训练+Stacking 集成”，具体操作如下：

首先，构建分层 5 折交叉验证框架，确保每折样本分布与整体训练集一致。优先基于风险类别分层划分，若风险类别列无效，则退化为基于“目标值分箱”分层，最终得到 5 组互不重叠的训练集-验证集对。针对每折训练集，分别用四种方法进行样本处理：原方法仅通过“目标值分箱逆频率加权”平衡不同数值区间样本贡献；SMOTE 方法通过少数类样本与其近邻的线性插值生成合成样本，将少数类规模扩充至目标数量；代价敏感学习方法在分箱加权基础上，对少数类样本叠加重增强系数；随机欠采样方法保留全部少数类样本，对各多数类样本无放回随机下采样，实现样本平衡。每折样本处理均独立进行，避免跨折数据泄露。

其次，进行基础模型训练并生成多维度预测。针对每折处理后的训练集及对应样本权重，同步训练 XGBoost、LightGBM、随机森林三种基础回归模型。训练过程中，以每折验证集作为独立测试集，生成各模型的 Out-Of-Fold (OOF) 预测值；同时对测试集生成预测值并按折累加。

最后，通过 Stacking 集成学习生成最终预测结果。5 折交叉验证完成后，先整合基础模型的 OOF 预测与测试集预测，将 5 折 OOF 预测按样本索引拼接，得到全量训练集的基础模型预测矩阵；将 5 折测试集预测累加值分别除以 5，得到各基础模型的测试集平均预测。随后构建 Stacking 集成模型，以 OOF 为元特征，训练集真实目标值为标签，采用线性回归作为元模型，学习基础模型预测与真实值的映射关系，生成集成后的全量训练集 OOF 预测；最后将基础模型的测试集平均预测矩阵输入元模型，得到最终测试集预测结果。

上述流程即为四种方法结合问题二模型，获取实际赔付金额预测结果的完整过程。为从定量角度对比样本不平衡处理方法与原方法的效果，需引入回归评价指标和分类相关指标，具体指标如下：

(1) 平均绝对误差 (MAE)

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|, \quad (29)$$

(2) 均方根误差 (RMSE)

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}, \quad (30)$$

(3) 斯皮尔曼相关系数 (Spearman)

$$r_s = 1 - \frac{6 \sum_{i=1}^N d_i^2}{N(N^2 - 1)}, \quad (31)$$

(4) 精确率-召回率曲线下面积 (AUC-PR)

$$\begin{cases} Precision = \frac{TP}{TP + FP} \\ Recall = \frac{TP}{TP + FN} \\ AUC-PR = \int_0^1 P(R) dR \end{cases}, \quad (32)$$

其中, N 表示样本数据量, y_i 和 $\hat{y}_i$ 表示真实数据和预测数据; d_i 为第 i 个样本的真实值秩次与预测值秩次的差值; TP 、 FP 、 FN 是分类问题中混淆矩阵的核心组成部分, TP 是实际为正例且被模型正确预测为正例的样本数量; FP 是实际为负例但被模型错误预测为正例的样本数量; FN 是实际为正例但被模型错误预测为负例的样本数量。在问题三中, 正例是“严重超额”的运单, 负例是非“严重超额”的运单。 MAE 和 $RMSE$ 衡量的是真实值与预测值的偏离的绝对大小; r_s 衡量预测值与真实值的“秩相关”程度, 而非数值大小; $AUC-PR$ 衡量“严重超额”的检测能力, 适合不平衡数据。相对而言, MAE 不易受极端值影响, $RMSE$ 则会放大预测误差。 MAE 与规模相关, 但不会像 $RMSE$ 那样惩罚大误差。另一方面, r_s 取值范围是 $[-1, 1]$, 越接近 1 表示排序一致性越高; $AUC-PR$ 的取值范围为 $[0, 1]$, 越接近 1 表示在不同召回率下, 精确率越高。

根据上述评价指标的计算公式, 将四种方法的评价指标计算结果整理如下表所示。

表 5-1 样本不平衡处理方法性能比较分析

	MAE	RMSE	Spearman	AUC-PR
Baseline	108.55	160.35	0.83	0.30
Weight	108.82	161.11	0.83	0.30
SMOTE	108.95	161.30	0.83	0.33
Undersample	117.70	171.87	0.80	0.43

其中, **Baseline** 代表基准方法、**Weight** 代表代价敏感学习、**SMOTE** 代表合成少数类过采样技术、**Undersample** 代表随机欠采样方法。上述四种样本不平衡处理方法在回归预测任务中展现出不同的性能特点, 各方法在整体预测精度与少数类识别能力之间呈现明显的权衡关系。在预测误差方面, 基准方法在 MAE 和 $RMSE$ 上表现最优, 表明其整体预测偏差最小。代价敏感学习与合成少数类过采样两种方法的预测误差与基准方法相近, 说明这两种方法在调整样本分布时未显著影响模型的全局预测性能。而随机欠采样方法因删减多数类样本导致信息损失, 其预测误差显著增大。就排序一致性而言, 合成少数类过采样方法的 **Spearman** 相关系数最高, 略优于基准方法和代价敏感学习方法, 表明其合成的少数类样本有助于提升预测值的秩相关性。随机欠采样方法在该指标上表现最弱, 进一步印证了样本删减对模型排序能力的负面影响。在少数类识别关键指标 $AUC-PR$ 上, 随机欠采样方法以约 0.4335 居于首位, 但这是以牺牲整体精度为代价; 合成少数类过采样方法虽低于随机欠采样方法, 但显著优于基准方法和代价敏感学习方法, 显示出其在不破坏全局预测性能的前提下, 有效提升了对少数类样本的检测能力。代价敏感学习方法的 $AUC-PR$ 反而低于基准方法, 说明简单的权重调整策略在此场景下未能有效改善少数类识别效果。

综合分析表明, 合成少数类过采样方法在整体预测精度、排序一致性和少数类识别

能力三者间实现了最佳平衡，是解决问题三中样本不平衡问题的优选方案。为了更直观清晰地展示四种方法的差异，给出四种样本不平衡处理方法的多指标性能对比图：




图 5-1 样本不平衡处理方法的多指标性能对比图

从图 5-1 中可以看出，在精度-召回曲线中，随机欠采样方法的曲线下面积最高，表明其对“严重超额”少数类的检测能力最强，但结合右上方柱状图可见，该方法以牺牲整体预测精度为代价，其 RMSE 和 MAE 均显著高于其他方法。相反，SMOTE 方法在 AUC-PR 上显著优于基准方法和代价敏感学习方法，同时 RMSE 和 MAE 与基准方法高度接近，说明 SMOTE 方法在保持全局预测精度的前提下有效提升了少数类识别能力。下方散点图显示，SMOTE 和代价敏感学习方法的预测值与实际值分布较集中，且趋势线斜率接近 1，印证了其预测一致性较好；而随机欠采样方法的散点离散度明显增大，与实际值的偏离程度较高。残差分布箱线图进一步验证了这一趋势：随机欠采样方法的残差波动范围最广，中位数偏移明显，而 SMOTE 方法的残差分布相对集中，异常值较少，反映出其预测稳定性更优。

综上，随机欠采样方法虽强化少数类识别，但导致整体回归性能下降；代价敏感学习方法未能有效平衡两类目标；SMOTE 方法则通过特征空间插值实现了预测精度与少数类敏感性的最优协同，是兼顾业务需求与模型鲁棒性的理想选择。

5.3 不平衡数据优化前后的优劣势分析

在 5.2 章中，已验证 5.1 章提出的三种样本不平衡处理方法的可行性，并从定量角度对比包含原方法（基准方法）在内的四种方法的评价指标数值，最终确定合成少数类过采样（SMOTE）方法是解决问题三样本不平衡问题的优选方案。但需注意，基准方法与 SMOTE 方法各有侧重，并非 SMOTE 方法在所有评价指标上均优于基准方法，因此在 5.3 章中进一步说明两种方法的优劣势。

基准方法作为样本不平衡处理的基准参照，未对“严重超额”少数类实施直接的样本平衡操作，核心逻辑是基于目标值分箱的逆频率权重策略：将训练集目标值按分位数划分为 5 个数值区间，依据“分箱样本数越少，样本权重越高”的逆频率规则生成基础权重，再对权重进行均值归一化，以此平衡不同数值区间样本对模型训练的贡献。流程上，该方法直接将原始训练集数据输入模型，仅通过权重调整间接影响训练过程，无样本生成或删除操作。

SMOTE 方法是合成少数类过采样技术的适配实现，核心思想是通过插值生成少数类样本以扩充少数类规模。具体流程为：先识别“严重超额”少数类样本集，计算需生

成的合成样本数量；再针对每个待生成样本，从少数类样本中随机选择“父样本”，并从其父样本的近邻中随机选择“邻居样本”，通过线性插值生成合成特征向量与合成目标值；最后将合成样本与原始样本合并形成扩充训练集，且合成样本继承父样本的目标值分箱权重，确保数值区间的平衡性。

通过 5.2 章中对基准方法与 SMOTE 方法的性能特征比较，可以得到基准方法通过保持原始数据分布，在整体预测精度方面表现优异，其 MAE 和 RMSE 均为最低值，且计算效率较高，无需额外的样本处理步骤。然而，该方法对少数类样本的识别能力有限，AUC-PR 值仅为 0.303，在需要重点关注高风险样本的业务场景下适用性不足。相比之下，SMOTE 方法通过特征空间插值生成合成样本，显著提升了对少数类别的检测能力，AUC-PR 提高至 0.332，且保持了与基线方法相近的整体预测精度。不过，该方法需要额外的计算资源进行样本生成和处理，在特征边界模糊的情况下可能产生不具代表性的合成样本，存在一定的噪声放大风险。在实际业务应用中，基准方法更适用于整体预测精度优先且计算资源受限的场景，特别是在各类别样本量差异不大、业务目标更关注全局预测准确性的情况下，基准方法能够提供最直接的解决方案。而 SMOTE 方法则适用于风险敏感型业务需求，当样本存在严重不均、且需要模型同时兼顾预测精度与高风险样本识别能力时，SMOTE 方法展现出明显优势。对于保险赔付预测这类既要求准确的金额预测又需要及时发现高风险保单的综合需求，推荐采用 SMOTE 方法，其在不过度牺牲整体精度的前提下，能有效提升模型对关键少数类的检测能力，更符合实际业务的风险管理需求。

5.4 问题三小结

针对物流理赔预测中存在的样本不平衡问题，引入了三种处理策略：（1）代价敏感学习通过权重调整平衡样本贡献；（2）SMOTE 方法通过特征和目标值插值生成合成样本；（3）随机欠采样则通过削减多数类样本实现平衡。这些方法的目的是为了解决“严重超额”类别占比极低导致的模型偏差问题，确保风险识别的准确性。基于五折交叉验证框架，结合 Stacking 集成学习，对方法有效性进行了量化评估。实证分析表明，SMOTE 方法在各项指标间取得了最佳平衡：其 MAE 和 RMSE 与基准方法高度接近，同时 AUC-PR 显著提升，显示出对少数类样本的增强识别能力。可视化结果进一步验证了 SMOTE 的预测稳定性和一致性，而代价敏感学习和欠采样方法分别存在权重失效或信息丢失的局限。综合来看，SMOTE 方法通过智能样本生成机制，在保持整体预测精度的前提下有效提升了对关键风险的敏感性，是解决样本不平衡问题的优选方案。

六、模型评价与改进

6.1 模型优点

1. 单调分位边界学习（MQBL）模型具有的“全局-类别-分组”三级建模策略，有效应对了数据稀疏性问题，保证了不同粒度业务场景的风险判断精度。
2. 所采用的核心技术均为成熟且开源的算法，模型框架不依赖特定软件或平台，具有较强的可移植性和可复现性。
3. 从数据预处理、特征工程到模型训练与评估，形成了完整的自动化流水线，能够适应大规模数据的处理需求，为持续学习和部署提供了便利。
4. 通过五折交叉验证框架生成 OOF 预测进行评估，有效防止模型过拟合，确保了性能评估结果的稳定性和对未知数据的泛化能力。
5. 模型支持便捷引入新特征，且能适应数据分布的变化，其整体设计具备模块化升级的特性，为未来的优化预留了充足空间。

6.2 模型缺点

1. MQBL 模型需对每个商品类型-新旧程度组合独立训练分位边界，当品类数量庞大时，模型训练与存储成本较高，难以满足实时理赔决策的毫秒级响应需求。
2. Stacking 集成学习需要多次交叉验证和基模型训练，计算资源消耗较大，不利于在资源受限的边缘设备上部署。

6.3 模型改进与推广

1. 技术层面改进方向

当前的模型基于历史静态数据训练，而实际的物流理赔规则、客户行为和市场环境处于持续变化中。为应对这一挑战，可引入在线学习或增量学习机制。模型无需完全重新训练，而是以流式数据的方式，定期或实时地吸收新的理赔案例，动态调整风险边界函数的参数。这能使模型具备持续进化的能力，及时捕捉风险模式的最新变化，避免因规则迭代而导致的模型性能衰减，从而构建一个具有韧性和适应性的智能风控系统。

2. 业务场景推广

模型的结果验证了数据驱动方法在理赔环节的价值，但其应用潜力远不止于此。可将其核心框架推广至物流的全链路风险管控。例如，在运输前，可利用历史数据预测货损高风险线路或品类，进行主动的包装加固或路由优化；在运输中，可结合实时轨迹与天气数据，对可能发生的延误或异常进行预警；在仓储环节，可预测库存周转风险。从而构建一个“事前预警、事中干预、事后分析”的全局风控体系，实现从单点理赔管理向全流程精细化运营的跨越。

3. 前瞻性探索

未来的风险预测不应局限于结构化的表格数据。应探索融合多模态数据，如客户的客服进线录音（通过语音情感识别分析客户情绪）、商品破损的图片（通过 CV 图像识别自动评估损伤程度）、历史交互文本记录（通过 NLP 分析投诉焦点）等。运用图神经网络（GNN）技术，可以挖掘用户、商品、网点、客服之间的复杂关系网络，从而更全面、更深度地捕捉潜在风险信号，实现认知层面的风险洞察。

参考文献

- [1] Lanza A, Di Stefano L. Statistical change detection by the pool adjacent violators algorithm[J]. IEEE transactions on pattern analysis and machine intelligence, 2011, 33(9): 1894-1910.
- [2] Chen T, Guestrin C. Xgboost: A scalable tree boosting system[C] Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining. 2016: 785-794.
- [3] Ke G, Meng Q, Finley T, et al. Lightgbm: A highly efficient gradient boosting decision tree[J]. Advances in neural information processing systems, 2017, 30.
- [4] Ponsam J G, Gracia S V J B, Geetha G, et al. Credit Risk Analysis using LightGBM and a comparative study of popular algorithms[C] International Conference on Computing and Communications Technologies (ICCT). IEEE, 2021: 634-641.
- [5] Biau G, Scornet E. A random forest guided tour[J]. Test, 2016, 25(2): 197-227.
- [6] Hong J K, Lee S J. Out-of-Fold Stacking Regression for Rapid Prediction of Time-to-Exploit in Newly Disclosed Vulnerabilities[J]. IEEE Access, 2025.
- [7] Wenquan C U I, Houying Y U, Xiaotian H O U. Focused loss-based for imbalanced data scenarios integrated classification methods for CGAN[J]. JUSTC, 2020, 50(7): 968-976.
- [8] Chawla N V, Bowyer K W, Hall L O, et al. SMOTE: synthetic minority over-sampling technique[J]. Journal of artificial intelligence research, 2002, 16: 321-357.
- [9] Mishra S. Handling imbalanced data: SMOTE vs. random undersampling[J]. International Research Journal of Engineering and Technology, 2017, 4(8): 317-320.
- [10] 吴烨凡.基于集成学习的智能化车险理赔风险预测[D].华中农业大学,2024.
- [11] 刘爽.具有相依结构的保险风险模型下的风险评估[D].南京审计大学,2022.
- [12] Pokrovskaya O, Reshetko N, Kirpicheva M, et al. The study of logistics risks in optimizing the company's transportation process[C] IOP conference series: Materials Science and Engineering. IOP Publishing, 2019, 698(6): 066060.
- [13] Barmuta K, Rusakova N, Malkhasyan A. Improving the method of analyzing risks of the company's logistics processes[J]. Transportation Research Procedia, 2022, 63: 737-745.
- [14] Yan Y, Suo B. Risks analysis of logistics financial business based on evidential Bayesian network[J]. Mathematical Problems in Engineering, 2013, 2013(1): 785218.
- [15] Batarlienè N, Meleniakas M. Claims solutions using a blockchain system in international logistics[J]. Sustainability, 2021, 13(7): 3710.
- [16] 陈韵如.基于 gcForest 算法的健康险理赔风险识别应用研究[D].上海财经大学,2022.
- [17] 王鑫之.具有复杂相依结构的连续时保险风险模型的渐近问题研究[D].南京审计大学,2021.
- [18] 荣庆川,马欣.基于 AHP-DEMATEL 分析方法的车险理赔风险评价研究[J].保险职业学院学报,2020,34(05):30-36.
- [19] Lu Y, Wang S, Wang H, et al. Fed-SCRIP: Federated Multi-View Learning for Seller Claim Risk Prediction in Logistics Scenarios[C] International Conference on High Performance Computing and Communications (HPCC). IEEE, 2024: 610-617.
- [20] Barczak A, Dembińska I, Marzantowicz Ł. Analysis of the risk impact of implementing digital innovations for logistics management[J]. Processes, 2019, 7(11): 815.
- [21] Oluwaferanmi A. Artificial Intelligence and Machine Learning in US Supply Chain Risk Financing: Enhancing Predictive Analytics for Disruption Forecasting, Credit Risk

- Evaluation, and Insurance Pricing Models[J]. 2025.
- [22]彭玮莹,黎跃勇,谭诗琪,等.基于降水因子的湖南省财货险理赔风险指数模型[J].应用气象学报,2025,36(01):14-23.
- [23]Choi T M. Risk analysis in logistics systems: A research agenda during and after the COVID-19 pandemic[J]. Transportation Research Part E: Logistics and Transportation Review, 2021, 145: 102190.
- [24]陶菊春,高金玲,张婷婷.考虑保险责任调整的精算风险模型与优化分析[J].西北师范大学学报(自然科学版),2014,50(03):9-13.