

队伍编号	MCB2500116
赛道	B

基于机器学习的物流理赔风险识别与服务升级策略研究

摘要

在数字经济浪潮下，物流行业正从粗放式扩张转向以客户体验为核心的精细化运营。在此背景下，物流理赔作为处理履约异常、直接影响用户口碑与运营成本的关键环节，其智能化升级已成为企业构筑核心竞争力的迫切需求。传统的、依赖人工审核的理赔模式不仅效率低下，且难以应对日益复杂的风险模式。本研究针对物流理赔业务中的核心痛点，旨在利用大数据与机器学习技术，构建一套集**无监督风险标注**、**监督学习预测**与**创新性模型**融合于一体的智能化决策解决方案。

首先，针对企业缺乏历史风险标签的业务现状，我们创造性地解决了**无监督风险标注问题（问题一）**。研究创新性地提出了一种融合**孤立森林**与**单类支持向量机**的混合策略。该策略首先利用孤立森林对数据密度的敏感性，从海量运单中识别出构成“合理诉求”的核心数据集群；随后，通过单类SVM学习并物化出一个可解释的、随赔付金额动态变化的非线性决策边界。经过约束驱动的自动化调优，该模型成功地为历史数据打上了“合理诉求”、“诉求偏高”和“严重超额”三类风险标签，其划分结果严格遵循了“合理诉求不低于85%”、“严重超额不高于3%”的业务先验规则，为后续模型提供了高质量的监督信号。

其次，为了精准预估理赔成本，我们系统性地解决了**实际赔付金额的回归预测任务（问题二）**。通过构建并对比包括线性模型、决策树以及随机森林、梯度提升等在内的六种回归模型，并采用决定系数、均方根误差等多维度指标进行评估，我们发现以随机森林回归模型为代表的集成树模型表现最为优异，其在验证集上的 R^2 达到了0.770。我们进一步通过学习曲线、验证曲线以及全面的残差分析，对该模型进行了深度诊断，充分证明了其强大的学习能力、良好的泛化性能与统计学上的稳健性，确认其为该任务的最佳选择。

最后，在端到端的**风险标签直接分类任务（问题三）**中，我们聚焦于解决“严重超额”类别占比仅3%的极端类别不均衡挑战。通过采用代价敏感学习策略，并对多种分类器进行系统性比较，我们确立了**LightGBM**为性能最佳的直接分类模型。在此基础上，本文深入剖析了“回归+规则”与“直接分类”两种方法论在可解释性、信息利用率等方面的本质差异。为博采众长，我们最终设计并验证了一种**基于深度元特征的Stacking集成混合模型**。该创新模型不仅融合了两种基础方法的预测输出，更巧妙地引入了模型预测的置信度和关键原始特征作为“上下文”，赋能元学习器进行更智能的决策。实验结果表明，该优化混合模型在宏平均F1分数上达到了0.9664，成功超越了所有单一模型，实现了方法论层面的突破。

关键词：风险识别；类别不均衡；Stacking集成；单类SVM；LightGBM；深度特征工程；代价敏感学习

目 录

一、问题重述.....	1
1.1 问题背景.....	1
1.2 目标任务.....	1
二、模型假设及符号.....	2
2.1 模型假设.....	2
2.2 符号说明.....	2
三、问题分析.....	3
3.1 针对问题一.....	3
3.1.1 问题核心剖析.....	3
3.1.2 解决方案思路.....	3
3.2 针对问题二.....	4
3.2.1 问题核心剖析.....	4
3.2.2 解决方案思路.....	5
3.3 针对问题三.....	6
3.3.1 问题核心剖析.....	6
3.3.2 解决方案思路.....	6
四、问题一模型的建立与求解.....	8
4.1 本章概述.....	8
4.2 数据探索性分析.....	8
4.2.1 核心变量的独立分布.....	8
4.2.2 核心变量的联合分布与密度.....	9
4.2.3 条件分布与动态边界的验证.....	10
4.3 模型的建立.....	11
4.3.1 模型总体框架.....	11
4.3.2 核心数据识别.....	12
4.3.3 动态决策边界学习.....	13
4.3.4 自动化调优与最终规则确立.....	14
4.4 模型求解.....	15
4.4.1 最终划分规则的阐述.....	16
4.4.2 总体标注结果与可视化呈现.....	16
4.4.3 模型有效性的深度校验.....	17
4.5 本章小结.....	18
五、问题二模型的建立与求解.....	19
5.1 数据预处理.....	19
5.2 模型建立.....	20
5.3 模型评估指标.....	21
5.4 模型性能评估指标与模型选择.....	22
5.4.1 模型性能评估指标.....	22
5.4.2 模型选择.....	22
5.5 随机森林模型性能评估.....	26
5.6 预测结果展示.....	29
六、问题三模型的建立与求解.....	30
6.1 本章概述.....	30

6.2 数据预处理与特征工程.....	30
6.2.1 数据清洗与准备	30
6.2.2 深度特征工程	31
6.2.3 差异化特征编码	31
6.3 分类模型的对比与最优模型选择.....	32
6.3.1 类别不均衡处理策略	32
6.3.2 评估指标的选择	33
6.3.3 模型训练与性能对比	34
6.4 创新性混合策略的构建与验证.....	37
6.4.1 方法论比较	37
6.4.2 混合策略的优化设计	38
6.4.3 混合策略的性能验证	38
6.5 本章小结.....	39
七、模型的评价与推广.....	41
7.1 模型评价.....	41
7.1.1 模型的优点	41
7.1.2 模型的缺点与改进方向	41
7.2 模型推广.....	41
八、参考文献.....	43
九、附录.....	44

一、问题重述

1.1 问题背景

在数字经济浪潮的推动下，中国物流行业正经历从“野蛮生长”到“精细化运营”的深刻转型。随着市场竞争日趋白热化，单纯的价格战与时效战已难以为继，**卓越的客户服务体验**已成为企业构筑核心竞争壁垒、赢得客户忠诚度的关键所在。在此背景下，物流理赔流程——这一处理包裹丢失、破损等异常情况的关键环节——不再仅仅是成本中心，而是直接影响用户口碑和品牌形象的“关键时刻”。

然而，现代物流企业在理赔环节普遍面临一个**核心的战略困境**：一方面，为了提升客户满意度，理赔流程需要尽可能**高效、便捷、人性化**，尤其对于合理索赔的客户，快速到账能极大地修复服务缺口，甚至将一次负面体验转化为正面口碑；另一方面，企业必须严密防范财务风险，有效控制因不合理索赔、夸大损失乃至欺诈行为带来的**理赔成本激增**，保障企业的财务健康与可持续发展。

传统的理赔模式高度依赖人工审核，其弊端日益凸显。不仅**效率低下、人力成本高昂**，且审核标准难以统一，易受审核员主观经验影响，导致“宽严不一”的现象。这既可能延误了合理诉求的处理，挫伤了诚信客户的体验，也为潜在的“高风险”索赔提供了可乘之机。因此，如何从海量的理赔申请中，**快速、准确、客观地识别出不同风险等级的运单**，并匹配差异化的处理策略，已成为物流行业实现服务升级与降本增效的**核心痛点**。

本次研究的现实意义，正是在于探索利用大数据与机器学习技术，为这一行业难题提供一套智能化的解决方案。通过对历史理赔数据的深度挖掘，我们旨在构建一个能够自动进行风险分级的智能模型。该模型的目标是实现理赔流程的**范式转换**：从被动的、无差别的“人工审核”模式，转变为主动的、智能化的“预检分诊”模式。这不仅能将 85%以上的低风险“合理诉求”分流至自动化快赔通道，极大提升客户体验，更能将宝贵的人工审核专家资源精准聚焦于不足 15%的“偏高”与“超额”诉求上，从而实现对运营风险的精准防控。这套数据驱动的策略，对于任何追求高质量发展的现代物流企业而言，都具有重大的战略价值和广阔的应用前景。

1.2 目标任务

本次研究旨在利用附件中提供的历史运单数据（附件 1），建立一套智能化的数据模型，以解决未来理赔运单（附件 2）的风险识别与服务升级问题。具体任务如下：

1.问题 1：建立风险标注模型与划分规则。

要求深入分析附件 1 中“实际赔付金额”与“索赔差额”两个核心变量的关系，并建立一个风险标注模型。该模型需能够将运单划分为“合理诉求”、“诉求偏高”和“严重超额”三个类别。研究需详细阐明模型划分的具体规则，给出附件 1 中所有运单的风险标注结果，并对结果进行分析。

2.问题 2：预测实际赔付金额。

要求结合附件 1 中的数据，建立一个回归模型，用于预测附件 2 中各运单的“实际赔付金额”。研究需明确所采用的预测结果评估指标，并将最终的预测数值填写在指定的 `result` 文件中，同时确保运单号的对应关系不变。

3.问题 3：建立风险标注的分类模型并进行方法论比较。

要求利用问题 1 中建立的划分规则，并基于附件 1 的数据，构建一个直接的分类模型来预测附件 2 中运单的风险标签。研究需在论文中详细描述如何处理“严重超额”类别样本占比严重不均衡的问题。最后，需深入论述当前方法（直接分类）与问题 2 中的方法（先预测金额，后依据规则分类）在预测风险标签任务上的各自优劣势。

二、模型假设及符号

2.1 模型假设

为了在不影响核心问题解决的前提下，简化模型的构建过程并明确模型的适用边界，我们提出以下基本假设：

1.数据的真实性与代表性假设，我们假设附件 1 和附件 2 所提供的数据是真实业务场景的准确抽样，能够代表物流公司理赔业务的普遍规律。模型在附件 1 上学到的模式可以有效地泛化到附件 2 及未来的新数据上。

2.特征的完备性假设，我们假设所提供的数据字段已经包含了影响风险等级和赔付金额的大部分关键信息。虽然现实世界中可能存在未被记录的潜在因素，但我们假设基于现有特征构建的模型已经足以达到较高的预测精度。

3.问题一标注的可靠性假设，我们假设在问题一中通过“孤立森林+单类 SVM”无监督方法生成的风险标签，其划分规则是合理且符合业务逻辑的。在问题三中，我们将这些标签视为“伪真值”来训练监督学习分类模型。

4.时间平稳性假设，我们假设在附件 1 所覆盖的时间范围内，理赔业务的潜在模式是相对平稳的，不存在剧烈的“概念漂移”。

2.2 符号说明

为方便后文公式的表述与模型的阐述，本论文中使用的主要符号及其说明如表 1 所示：

表 1 符号说明图

符号	说明
X	特征矩阵，表示所有样本的特征集合。
y	目标向量，表示所有样本的真实标签或数值。
x_i	第 <i>i</i> 个样本的特征向量。
y_i	第 <i>i</i> 个样本的真实目标值（类别标签或连续值）。
$\hat{y}_i$	模型对第 <i>i</i> 个样本目标值的预测值。
N	样本总数量。
C	目标变量的类别总数。
μ	特征或变量的均值。
σ	特征或变量的标准差。
w_j	代价敏感学习中，类别 <i>j</i> 的权重。
$f(x)$	单类 SVM 的决策函数。
$RiskScore(x)$	基于 SVM 决策函数定义的样本风险分数。
$\nu(nu)$	单类 SVM 模型的关键超参数。
TP, FP, TN, FN	混淆矩阵中的真正例、假正例、真负例、假负例。
F1	F1 分数，精确率和召回率的调和平均数。

三、问题分析

3.1 针对问题一

3.1.1 问题核心剖析

问题一的目标是为历史运单数据（附件 1）打上“合理诉求”、“诉求偏高”、“严重超额”三个风险标签。这本质上是一个无监督或半监督的学习问题，因为数据本身并未提供这些标签。我们需要根据题目给出的业务规则，创造一套客观、可复现的标注体系。

通过深入解读题目，我们将问题一的核心挑战拆解为以下四个层面：

1.规则的非线性与动态性：题目明确指出，“实际赔付金额越高，则需要更高的索赔差额才会标注为‘诉求偏高’或‘严重超额’”。这表明划分三类诉求的边界不是固定的阈值，而是一个随实际赔付金额变化的动态函数。这是一个典型的非线性关系。

2.数据的密度差异性：“‘合理诉求’的运单索赔差额相对密集，‘严重超额’的运单索赔差额相对稀疏”。这为我们利用基于密度的算法来识别核心群体与离群点提供了关键线索。

3.比例的全局约束性：“‘严重超额’的运单占比不会太高（通常小于 3%），‘合理诉求’的运单不低于 85%”。这是两条必须严格遵守的全局性业务约束，任何模型都必须在这两个“硬性指标”下运行。

4.规则的可解释性要求：题目要求“详细说明标注规则如何对运单进行划分”。这排除了使用无法解释其内部决策逻辑的“黑盒”模型，要求我们的最终产出必须是一套清晰、透明的划分规则。

3.1.2 解决方案思路

针对上述挑战，传统的单阈值切分或标准聚类算法（如 K-Means）难以同时满足所有要求。K-Means 假设簇为球形且密度均匀，无法处理本题中不规则形状的密集数据云；简单的阈值规则则无法捕捉动态变化的边界。

因此，我们设计了一套融合了无监督学习与规则化建模的创新策略，其核心思想是“先识别核心，再定义边界，后依约束切分”。

识别核心：利用数据点在实际赔付金额和索赔差额二维空间中的密度差异，首先识别出代表“合理诉求”的密集核心集群。

定义边界：基于这个核心集群的形状，学习并构建一个能够精确描述其边界的数学模型。这个边界本身就是我们需要的、可解释的动态划分规则。

依约束切分：对于边界之外的“高风险”点，我们定义一个量化的“风险分数”，并严格按照“<3%”和“≥85%”的比例约束，对它们进行最终的细分。

基于此思路，我们选择了**孤立森林（Isolation Forest）**与**单类支持向量机（One-Class SVM）**作为核心技术。孤立森林擅长利用密度差异快速识别异常点，而单类 SVM 则能学习到一个紧凑、非线性的边界来精确包围正常数据点，其边界本身就是一条可解释的数学函数，完美契合了本题的需求。为了系统化地解决问题一，我们规划了如图 1 所示的技术路线图。




图 1 问题 1 分析流程图

3.2 针对问题二

3.2.1 问题核心剖析

问题二的核心任务是构建一个监督学习回归模型，利用附件 1 提供的、包含 20 多个维度的历史运单数据，来精确预测附件 2 中运单的实际赔付金额。这是一个典型的表格数据回归问题，其成功解决对于后续问题三中“回归+规则”方法论的构建，以及企业进行精准的成本预估和预算管理，都具有至关重要的意义。

通过深入分析，我们将该问题的核心挑战与关键点归纳如下：

1.高维混合特征的处理，数据集包含数值型、类别型等多种类型的特征。特别是始发城市、寄件人 id 等高基数类别特征，以及异常原因、商品类型等业务含义丰富的类别特征，如何有效地将其转化为模型能够学习的数值表示，是避免信息损失、提升模型性能的关键。

2.非线性关系的捕捉，实际赔付金额的确定，极不可能是各个特征的简单线性叠加。它更可能受到多个因素之间复杂的、非线性的交互影响。例如，特定的商品类型在发生特定的异常原因时，其赔付金额可能呈现出独特的模式。因此，模型必须具备强大的非线性关系捕捉能力。

3.模型的选择与比较，不存在一个“放之四海而皆准”的最优模型。为了找到最适合本数据集的解决方案，我们必须系统性地建立、比较多种具有不同原理和特性的回归模型——从简单的线性模型到强大的集成树模型。

4.模型的可解释性与诊断，在追求高预测精度的同时，理解模型的决策依据（即哪些特征最重要）以及诊断模型的潜在问题（如过拟合、欠拟合、残差分布是否合理等）同样重要。这不仅能增强

我们对模型选择的信心，也能为业务方提供可操作的改进建议。

3.2.2 解决方案思路

针对上述挑战，我们设计了一套“系统性对比、深度诊断、择优应用”的建模策略，如图 2 所示。该策略旨在通过全面的模型比较和严谨的性能评估，筛选出在精度、稳定性与泛化能力上综合表现最佳的回归模型。

1.全面的模型池构建，为了充分探索不同模型的潜力，我们将构建一个包含多种主流回归算法的模型池，覆盖从简单到复杂的各类模型，具体包括，线性模型，线性回归、岭回归、Lasso 回归，作为性能基准，并检验数据中线性关系的强度。非线性单模型，决策树回归，用于初步探索数据的非线性结构。强大的集成模型，随机森林回归和梯度提升回归。这两种基于决策树的集成方法，以其强大的非线性拟合能力、高精度和良好的泛-化性能而闻名，是我们预期中的最优模型候选者。

2.标准化的预处理流程，对所有模型，我们都将采用统一的数据预处理流程，包括对数值特征的标准化（StandardScaler）以消除量纲影响，以及对类别特征的独热编码（One-Hot Encoding），确保所有模型都在一个公平、一致的数据基础上进行训练和比较。

3.多维度的性能评估体系，为了全面、客观地评估模型性能，我们将采用一套互为补充的评估指标体系，核心量化指标，决定系数（ R^2 ）用于衡量模型的拟合优度，均方根误差（RMSE）和平均绝对误差（MAE）用于衡量预测误差的大小。稳定性评估，采用 5 折交叉验证（5-Fold Cross-Validation）来评估模型在不同数据子集上的性能稳定性，防止因偶然的数据划分而产生误判。可视化评估，通过绘制预测-实际值一致性图（Parity Plot）、残差图等，直观地诊断模型的预测偏差、异方差性等问题。

4.深度诊断与模型选择，在通过上述指标初步筛选出最优模型（预期为随机森林）后，我们将对其进行“深度体检”，以确保其选择的合理性与模型的可靠性。特征重要性分析，探究模型做出预测的主要依据。学习曲线与验证曲线分析，诊断模型是否存在过拟合或欠拟合，并判断当前数据量是否充足，以及关键超参数（如树的深度）的选择是否合理。残差分析，通过 Q-Q 图、残差直方图等，检验模型残差是否满足统计假设（如正态性、同方差性），从统计学角度验证模型的稳健性。




图 2 问题 2 分析流程图

3.3 针对问题三

3.3.1 问题核心剖析

问题三在问题一和问题二的基础上，提出了更高层次的要求。它不仅要求我们构建一个直接的监督学习分类模型来预测风险标签，更核心的是，要求我们对两种解决思路进行方法论层面的深度思辨与比较，并探索更优的策略。我们将问题三的核心挑战拆解为以下四个层面：

1.直接分类模型的构建，此任务的目标是，利用问题一生成的标签作为“真值”，训练一个能够直接输入运单的全部特征，并输出其风险标签（“合理诉求”、“诉求偏高”、“严重超额”）的分类器。

2.极端类别不均衡的处理，这是直接分类路径中的核心技术挑战。“严重超额”类别占比不足 3%，属于极端少数类。任何常规的分类模型都会因“样本量偏见”而倾向于忽略这个类别，导致模型在风险识别这一关键任务上失效（即召回率极低）。因此，如何有效处理这种不均衡性，是模型成败的关键。

3.两种方法论的优劣思辨，题目要求我们深入论述两种风险标注方法的优劣势：

方法 A（问题二的思路）：“回归+规则”，先建立回归模型预测实际赔付金额，然后结合索赔金额计算索赔差额，最后应用问题一中建立的非线性边界规则进行分类。

方法 B（问题三的思路）：“直接分类”，直接建立一个端到端的多分类模型。

这要求我们从可解释性、信息利用率、模型鲁棒性等多个维度进行比较分析。

4.创新性策略的探索，在完成对比分析后，一个自然延伸的、具有创新性的思考方向是，既然两种方法各有优劣，我们是否能将二者结合起来，构建一个性能更强大、更鲁棒的混合模型，这为我们提出基于集成学习的创新性解决方案提供了契机。

3.3.2 解决方案思路

针对上述挑战，我们设计了一套由浅入深、层层递进的解决方案。其核心思路是：“充分预处理，精心处理不均衡，系统性对比选优，创新性融合提升”。具体技术路线如图 3 所示。

1.数据与特征层面，我们将进行比问题一更深入的特征工程。除了实际赔付金额和索赔差额，我们将充分利用附件 1 中提供的全部 20 多个特征。特别是对于寄件人 id、始发网点等高基数 ID 类特征，我们将构建历史行为聚合特征（如该寄件人的历史理赔次数、高风险标签占比等），以期为模型提供更强大的风险识别信号。

2.不均衡处理层面，我们将主要采用算法层面的代价敏感学习，即在模型训练时，为“严重超额”这一少数类的错分样本施加更高的惩罚权重。

3.模型对比层面，为了系统性地选出最优的直接分类模型，我们将建立并公平比较一系列模型，包括：

a.基准模型，逻辑回归、随机森林。

b.主流高性能模型，LightGBM 和 XGBoost。它们在处理表格数据上通常表现最佳，是我们重点调优的对象。

我们将使用宏平均 F1 分数（Macro F1-Score）和对“严重超额”类的召回率（Recall）作为核心评估指标。

4.创新融合层面，在深入理解“回归+规则”与“直接分类”两种路径的优劣后，我们将提出一种基于元学习（Meta-Learning）的 Stacking 集成混合策略。该策略将两种路径的预测结果作为“元特征”，训练一个“元学习器”来智能地融合二者的优势，以期达到超越任何单一路径的预测性能。




图 3 问题 3 分析流程图

四、问题一模型的建立与求解

4.1 本章概述

本章的核心任务在于将第三章“问题分析”中所规划的技术蓝图转化为具体、可复现的模型构建与求解实践。我们将系统性地阐述为附件 1 中历史理赔运单进行自动化风险标注的全过程。

首先，本章将从深入的**探索性数据分析（EDA）**入手，通过多维度的可视化手段，揭示并验证“实际赔付金额”与“索赔差额”之间存在的非线性、密度不均等关键特征，为后续模型的选择与构建提供坚实的数据洞察。

其次，我们将详细介绍基于孤立森林与单类支持向量机（One-Class SVM）的混合标注模型的构建细节。这包括特征的标准化处理、利用孤立森林初筛核心数据、通过单类 SVM 学习动态决策边界，以及最终在“合理诉求不低于 85%”和“严重超额不高于 3%”的双重业务约束下进行自动化调优的完整流程。

最后，本章将展示模型的最终求解结果。我们将清晰阐述由模型学习到的最终划分规则，并呈现对附件 1 数据的完整三分类风险标注统计。通过叠加决策边界的可视化图表与针对“密集度”和“接近度”的深度校验分析，我们将全面验证本方案的准确性、合理性及其与业务逻辑的高度一致性。

4.2 数据探索性分析

4.2.1 核心变量的独立分布

在构建复杂的风险标注模型之前，首要任务是深入理解两个核心变量——实际赔付金额与索赔差额——自身的分布特性。我们通过绘制单变量直方图（图 4）与核密度估计图（图 5）来揭示其内在规律。




图 4 单变量直方图




图 5 核密度估计图

实际赔付金额，从直方图和核密度估计图中可以清晰地看出，实际赔付金额的分布呈现出极端的右偏态（正偏态）。数据的高度集中在较小的金额区间（例如 0-500 元），频数随着金额的增大而迅速衰减，形成一条长长的右侧“尾巴”。这种分布形态深刻地反映了物流理赔的真实业务场景。日常

发生的绝大多数理赔事件是针对低价值包裹的小额赔付，而涉及高价值货损的高额赔付则属于低频、偶发的事件。这一特征提示我们，模型在处理不同金额区间的理赔时，其风险判断标准不应一概而论，高额赔付本身就可能意味着更高的不确定性和风险。

索赔差额，分布特征：索赔差额的分布同样呈现出显著的偏态分布，但方向相反，为左偏态（负偏态）。绝大多数数据点集中在接近于 0 的负值区域，并向负无穷方向延伸出一条长尾。该分布揭示了理赔流程中的一个关键环节——核损与协商。由于索赔差额=实际赔付金额-索赔金额，其值为负是常态，代表企业最终赔付的金额低于客户的初始索赔要求。数据集中在 0 附近，说明大多数理赔的协商差额不大。而长长的左侧尾部，则对应着那些客户初始索赔金额远高于最终实际赔付金额的案例，这些正是“诉求偏高”乃至“严重超额”的高风险信号。

两个核心变量均非正态分布，而是典型的长尾偏态分布。这种分布特性是后续所有建模工作必须考虑的基础。直接对这样的数据使用基于距离或方差的传统模型（如 K-Means），效果往往不佳。因此，在后续步骤中，数据的**标准化处理**以及采用对数据分布形态不敏感的非参数模型（如我们选择的孤立森林和 SVM）变得至关重要。

4.2.2 核心变量的联合分布与密度

为了深入探究实际赔付金额与索赔差额之间的相互关系，我们首先绘制了它们的联合分布图（图 6）与二维密度热力图（图 7）。




图 6 实际赔付金额与索赔差额的联合分布图




图 7 实际赔付金额与索赔差额密度热力图

初步结构揭示，图 6 的联合分布图为我们提供了对两个核心变量关系的全局视角。中心的散点图初步揭示了数据的非均匀分布结构：在图的左上方（即实际赔付金额较低，索赔差额接近于 0 的区域）形成了一个庞大且密集的点云，而随着金额增大或差额绝对值增大，数据点迅速变得稀疏。坐标轴上方的边缘直方图再次印证了两个变量的显著偏态分布特征。

核心区域的精准定位，为了解决散点图中因数据点大量重叠而无法准确观察密度的问题，我们进一步绘制了二维密度热力图（图 7）。这张图极大地增强了对数据分布的理解。图中颜色最深的区域（深红色）清晰地勾勒出了数据点最集中的“热区”。这个“热区”在业务上可以被直接解读为“合理诉求”的核心地带。从图中可以直观地看出：

“合理诉求”的边界是不规则的、非线性的。数据密度从这个核心区域向外急剧衰减，颜色迅速从深红过渡到淡黄，这与题目中“‘合理诉求’密集，‘严重超额’稀疏”的描述完全吻合。

该分析直观地表明，“合理”与“不合理”的界限，本质上是一个密度的等高线。这为我们后续采用基于密度的异常检测算法（孤立森林）和旨在寻找边界的（单类 SVM）模型，提供了强有力的视觉证据和理论依据。

4.2.3 条件分布与动态边界的验证

为了量化地证明索赔差额的分布随实际赔付金额的变化而动态变化——即验证题目中“实际赔付金额越高，则需要更高的索赔差额”这一关键规则——我们对实际赔付金额进行分箱，并绘制了其条件分布的增强箱线图，如图 8 所示。




图 8 索赔差额分布变化图

图 8 通过将连续的实际赔付金额切分为 10 个离散的区间，清晰地揭示了索赔差额的分布是如何随着实际赔付金额的增加而系统性地变化的。从图中可以清晰地观察到两个核心趋势。

中位数的系统性下移，随着实际赔付金额区间的增加（从图的左侧到右侧），每个箱体的中位数（代表了该金额区间下索赔差额的集中趋势）呈现出明显的下降趋势。这意味着，更高的实际赔付金额，通常对应着绝对值更大的索赔差额。

离散度的显著增加，从箱体的垂直高度和异常值（离群点）的分布范围来看，随着实际赔付金额的增加，索赔差额的波动范围（即离散程度）也显著增大。对于低赔付金额的区间（如图最左侧），其索赔差额高度集中在一个非常狭窄的范围内；而对于高赔付金额的区间，其索赔差额的合理范围则变得宽泛得多。

条件分布分析**量化地证明了风险划分边界的动态性**。它为我们必须采用非线性边界模型提供了强有力的实证支持。任何试图用全局的、固定的阈值来划分风险等级的方法（例如，简单地设定索赔差额 <-2000 为高风险），都将违背数据所揭示的内在规律，导致在低赔付金额区间过于严苛，而在高赔付金额区间又过于宽松。因此，我们必须构建一个能够学习并拟合这条**随实际赔付金额变化的、非线性的决策边界**的模型。

4.3 模型的建立

4.3.1 模型总体框架

基于前文 4.2 节对数据进行的深入探索性分析，我们深刻认识到“实际赔付金额”与“索赔差额”之间存在着显著的非线性关系、数据分布密度不均以及动态边界等复杂特征。这些特征使得任何单一的、传统的建模方法都难以同时满足问题一中包含可解释性、比例约束和动态划分在内的多重目标。

为了应对这一挑战，我们设计并构建了一套创新的、多阶段的混合标注模型。本模型的构建遵循一个核心的设计哲学：“先识别核心，再定义边界，后依约束切分”。这一策略旨在确保模型的最终划分结果，既能忠实于数据本身内在的分布规律，又能严格遵守题目给出的外部业务约束。

1.先识别核心：利用数据在二维空间中的密度差异，通过无监督学习的方式，自动识别出构成“合理诉求”主体的、高密度的核心数据集群。

2.再定义边界：基于这个被识别出的核心集群，通过一个专门的边界学习模型，精确地拟合出一条能够紧凑包围该集群的、可解释的非线性边界。这条边界本身就物化了“合理”与“不合理”的动态划分规则。

3.后依约束切分：在确立了核心边界之后，对边界之外的高风险点，依据“严重超额 $<3\%$ ”和“合理诉求 $\geq 85\%$ ”这两条全局业务约束，进行最终的精细化切分。

在技术选型上，我们精心组合了两种强大的机器学习算法来实现上述框架：

1.孤立森林，用于第一阶段的“识别核心”。它是一种高效的异常检测算法，对数据分布密度极为敏感，非常适合从海量数据中快速地分离出稀疏的离群点，从而精准地定位出高密度的核心数据子集。

2.单类支持向量机，用于第二阶段的“定义边界”。该模型是专门为发现和描述单类数据的边界而设计的，能够完美地学习不规则、非线性的边界形状，且其决策函数本身具有清晰的数学表达，满足了问题对规则可解释性的要求。

整个模型的总体技术流程如下图 9 所示，它清晰地展示了从原始数据输入到最终风险标签输出的全过程。本章后续内容将围绕此框架，对每一个环节的实现细节进行深入阐述。




图9 模型技术流程图

4.3.2 核心数据识别

模型构建的第一步，是依据数据分布的密度差异，从全体样本中高效地识别出构成“合理诉求”主体的、高密度的核心数据点集。为此，我们采用了**孤立森林**这一先进的异常检测算法。

1.特征标准化

在应用孤立森林算法之前，一个关键的预处理步骤是对实际赔付金额和索赔差额这两个核心特征进行**标准化处理**。由于这两个变量的量纲和数值范围差异巨大（金额为正，差额为负且绝对值可能很大），若不进行处理，基于距离或分割的算法（如孤立森林）会不成比例地受到数值范围较大特征的影响。我们采用**Z-score 标准化**，将每个特征都转换为均值为 0、标准差为 1 的分布，其计算公式如下：

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

其中， x 是原始特征值， μ 是该特征的均值， σ 是该特征的标准差。通过此变换，我们确保了两个特征在后续建模中具有同等的重要性。

2.孤立森林算法原理与应用

孤立森林是一种基于集成学习的、高效的无监督异常检测算法。其核心思想是：异常点是那些“少而不同”的数据点，因此它们比正常点更容易被孤立出来。算法通过构建一系列被称为“孤立树”的二叉树来工作。在构建每棵树时，算法会从全量数据中随机抽取一个子样本。

- 1.从根节点开始，随机选择一个特征。
- 2.在该特征的最大值和最小值之间，随机选择一个分割点。
- 3.根据分割点将样本划分为两个子集，并分别置于左右两个子节点。
- 4.重复步骤 2-4，直到节点中只有一个样本，或者树达到预设的高度限制。

由于异常点通常远离密集的数据集群，它们在随机分割过程中，平均只需要经过较少的次数就能被完全孤立到一个叶子节点。因此，一个样本点 x 的路径长度 $h(x)$ ——即它从根节点到叶子节点所经过的边的数量——可以用来衡量其“正常”程度。为了得到一个标准化的、更易于解释的异常分数，孤立森林将所有树的路径长度进行平均，并将其归一化。一个样本点 x 的异常分数 $s(x, n)$ 计算公式如下：

$$s(x, n) = 2^{-\frac{E(h(x))}{c(n)}} \quad (2)$$

其中, $E(h(x))$ 是样本 x 在森林中所有孤立树上的平均路径长度。 $c(n) = 2H(n-1) - \frac{2(n-1)}{n}$ 是二叉搜索树的平均路径长度, 用作标准化因子 n 是样本数量, $H(k)$ 是调和数, 可以近似为 $\ln(k) + 0.577$ 。异常分数的取值范围在 0 到 1 之间, 当 $s(x, n)$ 接近 1 时, 表示该点非常容易被孤立, 极有可能是异常点。当 $s(x, n)$ 远小于 0.5 时, 表示该点难以被孤立, 很可能是正常点。当 $s(x, n)$ 接近 0.5 时, 则没有明显的异常倾向。

3. 实施与核心数据筛选

在我们的应用中, 我们将所有经过标准化的数据点输入孤立森林模型。模型会为每个数据点计算出一个异常分数。那些“诉求偏高”和“严重超额”的运单, 由于其在二维空间中处于稀疏区域, 会被模型赋予较高的异常分数。相反, “合理诉求”的运单因为处于密集区域, 会得到较低的异常分数。

我们设定一个较为宽松的污染率参数, 例如 0.15, 指导模型将异常分数最高的 15% 的样本初步标记为“异常”。然后, 我们将所有被模型判定为“正常”的数据点筛选出来, 构成一个高质量的核心数据子集。这个子集将作为下一阶段训练单类 SVM 的输入, 用于精确地学习“合理诉求”的决策边界。图 10 直观地展示了孤立森林算法的筛选效果。图中蓝色的点代表被模型识别为“正常”的核心数据点, 它们将被用于下一阶段的边界学习。而橙色的点代表被初步识别为“异常”的离群点, 它们将在后续步骤中被进一步细分为“诉求偏高”和“严重超额”。通过这一阶段, 我们成功地将问题从一个复杂的混合分布中, 简化为对一个相对纯净的核心数据集进行边界建模。




图 10 孤立森林识别核心数据示意图

4.3.3 动态决策边界学习

在通过孤立森林成功识别出代表“合理诉求”的核心数据点集之后, 模型构建进入了最为关键的第二阶段, 学习并定义出一条能够精确、紧凑地包围这批核心数据的动态决策边界。为此, 我们采用了专门为处理此类问题而设计的单类支持向量机 (One-Class Support Vector Machine, OCSVM) 算法。

1. 单类 SVM 算法原理

传统的 SVM 是用于解决二分类或多分类问题的监督学习算法, 其目标是找到一个能最大化类间间隔的超平面。而单类 SVM 则是一种无监督学习算法, 它仅需要一类被定义为“正常”的数据进行训练, 其目标是找到一个能够将这批“正常”数据与特征空间中的其他所有区域分离开来的边界。

在我们的应用中, 我们选用了径向基函数 (Radial Basis Function, RBF) 作为核函数, 因为它能够学习高度非线性的、任意形状的边界。其核心思想是将原始的二维特征空间 ($\mathbf{x} = [\text{赔付金额}, \text{差额}]$) 映射到一个更高维的特征空间 $\phi(\mathbf{x})$ 。然后, 在该高维空间中, 算法会寻找一个与原点距离最大化的

超平面，该超平面将绝大多数的映射点 $\phi(\mathbf{x})$ 分隔在与原点异侧。这个超平面的决策函数如下：

$$f(x) = \text{sgn}(w \cdot \phi(x) - \rho) \quad (3)$$

这个决策函数 $f(\mathbf{x})$ 在映射回原始的二维数据空间时，就形成了一条封闭的、不规则的曲线，即我们需要的决策边界。所有使得 $f(\mathbf{x}) \geq 0$ 的点 $\mathbf{x}$ 都会被认定为“正常”的（即“合理诉求”），而所有使得 $f(\mathbf{x}) < 0$ 的点则被认为是“异常”的（即“高风险诉求”）。

2.模型训练与边界的物化

我们将 4.3.2 节中由孤立森林筛选出的“核心数据（正常点）”子集，作为单类 SVM 的唯一训练数据。这一步骤至关重要，因为它确保了模型学习到的边界是专门为“合理诉求”数据量身定做的，而不会受到外部离群点的干扰。训练完成后，我们就得到了一个能够识别“合理诉求”的分类器。更重要的是，这个训练好的 SVM 模型，其决策函数本身就物化了“合理”与“不合理”的动态划分规则。任何一个新的运单数据点（实际赔付金额、索赔差额），我们都可以将其输入到决策函数中，如果函数值大于等于 0，则该运单符合“合理诉求”的模式。如果函数值小于 0，则该运单偏离了“合理诉求”的模式，属于高风险范畴。

3.关键超参数

在单类 SVM 中，最重要的超参数是 ν 。它的取值范围在(0,1]之间，具有双重含义：

a.它是训练误差的上限，即模型允许被错误地划分到边界之外的训练样本的比例上限。

b.它是支持向量比例的下限，即决定了边界形状的“支持向量”在训练样本中所占的最小比例。

通俗地讲， ν 控制了决策边界的“紧凑”或“宽松”程度。一个较小的 ν 值会产生一条更紧凑的边界，它会试图包围住几乎所有的训练点，对噪声更敏感。一个较大的 ν 值则会产生一条更宽松的边界，允许更多的训练点被排除在外，从而获得更平滑、泛化能力可能更强的边界。在我们的模型中， ν 成为连接数据内在分布与外部业务约束（“合理诉求不低于 85%”）的关键桥梁。在下一节中，我们将详细阐述如何通过系统性地调优 ν 值，来找到一个既符合数据形态又满足业务指标的最佳决策边界。

4.3.4 自动化调优与最终规则确立

在通过单类 SVM 学习到“合理诉求”的初始决策边界后，模型构建进入了最后的整合与校准阶段。此阶段的核心目标是将这条由数据内在分布驱动边界，根据“合理诉求占比不低于 85%”这一关键的外部业务约束，进行精确的自动化调优，并最终确立完整、可执行的三分类规则体系。

1.风险分数的定义

为了对边界之外的“高风险诉求”进行精细化分级，我们首先需要能够量化其风险程度的指标。我们利用单类 SVM 决策函数的输出来定义“风险分数”。对于任何一个数据点 x_i ，其风险分数 $RiskScore(x_i)$ ，定义为其到决策边界的负符号距离

$$RiskScore(x_i) = -f(x_i) = -(w \cdot \phi(x_i) - \rho) \quad (4)$$

这个分数的特性如下，对于边界内的“合理诉求”点，其风险分数为负值或零。对于边界外的“高风险诉求”点，其风险分数为正值。风险分数越大，代表该点在特征空间中距离“合理”区域的边界越远，其风险程度也越高。

2.自动化调优循环机制

我们设计的自动化调优流程，是一个以满足业务约束为目标的迭代优化过程。其核心在于系统性地调整单类 SVM 的关键超参数 ν ，以控制决策边界的宽松程度。

整个循环机制的逻辑如图 11：




图 11 循环机制流程图

A.设定搜索范围：我们首先为超参数 ν 设定一个合理的、从紧到松的搜索区间，例如[0.01, 0.02, ..., 0.15]。

B.迭代训练与校验：程序将遍历该区间内的每一个 ν 值：

a.重新训练：使用在 4.3.2 节中筛选出的核心数据，以当前的 ν 值重新训练单类 SVM 模型，得到一个新的决策边界。

b.全量数据标注：将全部的附件 1 数据点输入到新训练的模型中，依据决策函数的正负，将数据初步划分为“合理诉求”（边界内）和“高风险诉求”（边界外）两类。

c.校验约束：计算当前划分下，“合理诉求”类别所占的总样本比例。

C.确定最优解：

a.终止条件：当“合理诉求”的占比首次达到或超过 85%时，我们认为此时的决策边界在满足业务底线的同时，尽可能地保持了对核心数据的紧凑性。循环立即停止。

b.最优模型：将当前循环步对应的 SVM 模型和 ν 值，确认为我们最终的最优模型和最佳参数。

通过这一自动化流程，我们确保了最终采纳的决策边界，是数据内在结构与外部业务规则之间的一个最佳平衡点。

3.最终三分类规则的确立

在获得最优的 SVM 模型后，我们便可以整合所有信息，形成最终的、完整的三分类规则体系：

规则 1(合理诉求)：对于任意一个运单，若其(实际赔付金额,索赔差额)坐标点位于最优 SVM 模型的决策边界内部或边界上（即 $RiskScore \leq 0$ ），则该运单被最终标注为“合理诉求”。

规则 2(高风险细分)：对于所有位于边界之外的运单（即 $RiskScore \geq 0$ ）：

a.风险排序：将这些高风险运单按照其风险分数从高到低进行排序。

b.标注“严重超额”：选取风险分数排名最高的、数量不超过总样本数 3%的运单，将其最终标注为“严重超额”。

c.标注“诉求偏高”：其余所有边界外的高风险运单，则被最终标注为“诉求偏高”。

至此，我们已经成功地将问题一中所有复杂的、定性的业务描述，转化为了一套完全由数据驱动、逻辑清晰、可自动化执行的定量划分规则。在下一节中，我们将展示应用这套规则对附件 1 数据进行求解的最终结果。

4.4 模型求解

在完整执行了 4.3 节所设计的模型构建流程后，我们成功地为附件 1 中的每一条运单数据赋予了风险标签。本节将详细阐述最终的划分规则，展示并分析标注结果，并通过多维度可视化对模型的有效性进行深度校验。

4.4.1 最终划分规则的阐述

经过约束驱动的自动化调优，我们的模型确定了最佳超参数 $\text{nu}=0.0030$ 。基于此最优参数下训练得到的单类 SVM 模型，最终的风险标注规则被精确地固化下来：

1. “合理诉求”的界定：一个运单被判定为“合理诉求”的充要条件是，其(实际赔付金额,索赔差额)坐标点，落在图 12 中由黑色虚线所包围的绿色区域内。

2.高风险诉求的分级：对于所有落在该边界之外的运单，根据公式计算其风险分数，将这些运单按风险分数从高到低排序，排名最高的、数量占总样本 3.00%的运单被划分为“严重超额”，其余的边界外运单则被划分为“诉求偏高”。

4.4.2 总体标注结果与可视化呈现

应用上述规则，我们得到了附件 1 的最终风险标注统计结果（如表 2 所示），并将其绘制成直观的可视化图表（图 10）。

表 2 最终风险标注结果统计

风险标签	运单数量	占比(%)
合理诉求	9,510	85.16%
诉求偏高	1,322	11.84%
严重超额	335	3.00%
总计	11,167	100.00%




图 12 风险标注最终结果(最佳 $\text{nu}=0.0030$)

从统计表中可以清晰看到，“合理诉求”占比为 85.16%，“严重超额”占比为 3.00%，完全满足题目设定的各项业务约束。图 12 直观地展示了模型的划分效果。绿色点（合理诉求），被学习到的黑色虚线边界成功地、紧凑地包围，完美地拟合了我们在 EDA 中识别出的高密度核心数据云。橙色点（诉求偏高），构成了边界外围的主要群体，是与“合理”范围“擦边”的中间地带。红色点（严重超额），是距离边界最远的、最稀疏的离群点，直观地代表了风险最高的群体。黑色虚线的非线性

形状，再次证明了模型成功捕捉到了“实际赔付金额越高，索赔差额的合理范围也越大”这一动态规则。

4.4.3 模型有效性的深度校验

为了进一步验证模型的划分是否符合题目中更深层次的业务逻辑，我们从“密集度”和“接近度”两个维度对标注结果进行了检验。

1.全局密集程度校验

我们通过小提琴图（图 13）来观察三个风险标签下索赔差额的全球分布密度。




图 13 各风险标签下“索赔差额”的全球密集程度对比

图中，小提琴的宽度代表了数据在该位置的密度。“合理诉求”的小提琴呈现出“矮胖”形态，其最宽的部分非常突出且集中在接近 0 的区域，表明其索赔差额高度密集。“诉求偏高”和“严重超额”的小提琴则依次变得越来越“细长”，其密度峰值不明显，数据分布的范围越来越广、越来越稀疏。该图完美地验证了“‘合理诉求’密集，‘严重超额’稀疏”的业务先验知识。

2.局部接近程度校验

我们选取了实际赔付金额在 400-600 元的典型区间作为切片，通过带状图（图 14）来观察在该局部范围内，同类标签下索赔差额的聚集程度。




图 14 “索赔差额”的局部接近程度

“合理诉求”的绿色数据点，高度聚集在一个非常狭窄的索赔差额区间内，点与点之间非常靠近。“诉求偏高”的橙色数据点，虽然也有聚集趋势，但其垂直分布范围明显更宽。“严重超额”的

红色数据点，则零星地分布在图的最下方，彼此之间相距甚远，非常离散。该图有力地证明了模型遵守了“相似实际赔付金额下，同一类运单的索赔差额应尽可能接近”的规则。

通过统计分析、可视化呈现和深度校验，我们证明了所构建的混合模型不仅成功地完成了满足所有业务约束的风险标注任务，其内在的划分逻辑也与数据的自然分布和深层业务规则高度一致，是一个有效、可靠且可解释的解决方案。

4.5 本章小结

本章详细阐述并实践了针对问题一的完整的模型构建与求解过程。我们首先通过深入的探索性数据分析（EDA），揭示了核心变量实际赔付金额与索赔差额之间存在的非线性关系、密度不均以及动态边界等关键特征，为后续的建模策略提供了坚实的数据支撑。

在此基础上，我们成功设计并实现了一个融合了孤立森林与单类支持向量机（One-Class SVM）的创新性混合标注模型。该模型通过“先识别核心，再定义边界，后依约束切分”的三阶段策略，将复杂的业务规则转化为一套客观、可复现的算法流程。我们详细介绍了模型从特征标准化、利用孤立森林初筛核心数据、通过单类 SVM 学习动态决策边界，直至在“合理诉求 $\geq 85\%$ ”和“严重超额 $< 3\%$ ”的双重业务约束下进行自动化调优的完整实现细节。

最终，模型求解的结果令人满意。我们不仅给出了一套由数据驱动学习到的、清晰可解释的最终划分规则，还成功地为附件 1 中的全部 11,167 条运单数据打上了风险标签，其统计结果完全符合题目设定的所有业务指标。通过最终的分类结果散点图、小提琴图和带状图等多维度可视化分析，我们进一步验证了模型的划分结果在宏观和微观层面均与“密集度”和“接近度”等深层业务逻辑高度一致。

综上所述，本章的工作成功地为无标签的历史理赔数据建立了一套智能化、自动化的风险分级体系。这不仅为后续问题二、三中构建监督学习模型提供了高质量的标签基础，其本身也构成了一个可以直接应用于实际业务的、鲁棒且可解释的风险识别解决方案。

五、问题二模型的建立与求解

5.1 数据预处理

本文对数据进行预处理，为了全面评估数据集的完整性和缺失模式，本文绘制了缺失值热力图（图 15），通过可视化方式展示各特征维度的数据缺失分布情况。分析可见，数据集整体完整性较好，大部分特征列的缺失值较少且分布均匀，仅少数特征在特定样本区间存在集中缺失现象，但未出现大面积的系统性缺失。这种缺失模式表明数据收集过程相对规范，随机缺失占主导地位，适合采用均值填充等常规缺失值处理方法，为后续数据清洗策略的制定提供了重要依据，也保证了预处理后数据质量的可靠性。




图 15 原始数据缺失值热力图

为了检验实际赔付金额变量的分布形态及其与正态分布的偏离程度，本文绘制了目标变量的 Q-Q 图（图 16）。分析显示，散点分布明显偏离参考直线，在两端尾部呈现显著的“S 型”弯曲，这表明实际赔付金额的分布具有重尾特征，不符合正态分布假设。该分布形态揭示了理赔数据中存在较多极端高值案例，真实反映了物流理赔业务中少数高额赔付案例对整体分布的影响，这一发现对模型选择具有重要指导意义——需要考虑使用对异常值不敏感的树模型或进行数据变换来处理这种非正态分布特性。




图 16 实际赔付金额的 Q-Q 图

为了解实际赔付金额的总体分布特征及其集中趋势，本文绘制了目标变量的频数分布直方图（图 17）。分析可见，赔付金额呈现明显的右偏分布，绝大多数案例集中在低赔付区间（0-500 元），但随着赔付金额增加频数急剧下降，存在少量高额赔付的极端值。这种分布模式符合保险理赔数据的典型特征。

型特征，即“大量小额理赔+少量大额理赔”的组合分布，该发现对建模策略具有重要启示——需要采用对偏态分布和异常值具有鲁棒性的算法，并考虑适当的样本加权或数据变换来处理这种不平衡分布特性。




图 17 实际赔付金额的分布直方图

为了探究各特征变量与实际赔付金额之间的线性关联强度并识别多重共线性问题，本文绘制了特征与目标的相关性矩阵热图（图 18）。分析显示，“索赔金额”与目标变量呈现最强的正相关性，这与业务逻辑完全一致；“配送超时时长”等运营特征也显示出显著相关性，而部分分类特征如城市 ID、用户 ID 等相关性较弱。热图同时反映出特征间存在中等程度的相关性，但未出现高度共线性问题，这一方面证实了特征选择的合理性，另一方面也为后续特征工程提供了优化方向——应重点关注与赔付金额密切相关的运营指标和保价信息




图 18 特征变量与目标变量的相关性矩阵

5.2 模型建立

基于附件 1 提供的历史运单数据，本文旨在构建一个高精度的预测模型，用于估计附件 2 中运单的实际赔付金额。该预测任务对于物流企业优化理赔流程、控制成本具有重要实际意义。我们采用了系统化的建模流程，包括数据预处理、特征工程、模型训练与评估，并最终选用最优模型对附件 2 中的运单进行预测。本研究采用多种机器学习算法建立预测模型。模型训练过程包括数据标准

化、模型拟合与性能验证等步骤。具体而言，本文选取了以下六种典型的监督学习回归模型：

1.线性回归模型

线性回归假设自变量与因变量之间存在线性关系，其基本形式为：

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n \quad (5)$$

其中， β_i 为模型参数，通过最小化均方误差（MSE, Mean Squared Error）求得。线性回归具有模型结构简单、可解释性强的优点，但在特征高度相关或存在噪声时容易过拟合。

2.岭回归模型

岭回归在普通最小二乘回归的损失函数中加入 L2 正则化项，用于惩罚模型参数过大，防止过拟合：

$$L = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \sum_{j=1}^p \beta_j^2 \quad (6)$$

其中， α 为正则化系数。该方法在特征存在多重共线性时能够提高模型的稳定性。

3.Lasso 回归模型

Lasso 回归在损失函数中引入 L1 正则化项：

$$L = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \sum_{j=1}^p |\beta_j| \quad (7)$$

其优点在于能够自动进行特征选择，通过将部分回归系数压缩为零来降低模型复杂度。

4.决策树回归模型

决策树是一种基于特征划分的非参数模型。其核心思想是通过选择最优划分特征及分裂点，使样本在每个子节点上的方差最小化。该模型能捕捉非线性关系与特征交互，但在未剪枝情况下容易出现过拟合问题。

5.随机森林回归模型

随机森林由多棵决策树组成，属于集成学习（Ensemble Learning）方法。其核心思想是通过自助采样（Bootstrap Sampling）与特征随机选择生成多个弱学习器，并以平均预测结果作为最终输出：

$$\hat{y} = \frac{1}{M} \sum_{m=1}^M T_m(x) \quad (8)$$

其中， $T_m(x)$ 为第 m 棵树的预测值。随机森林具有较强的抗噪性和泛化能力。

6.梯度提升回归模型

梯度提升是一种逐步构建弱学习器的加法模型。其核心原理是在每一轮迭代中拟合前一轮残差的梯度方向，以最小化损失函数：

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x) \quad (9)$$

其中， $h_m(x)$ 为第 m 个弱学习器， γ_m 为学习率。该方法能够有效捕捉复杂的非线性关系，通常表现出较高的预测精度。

在模型训练前，对特征变量进行了标准化处理（StandardScaler），使其均值为 0、方差为 1，以消除量纲差异对模型的影响。训练集与测试集按 80%：20%比例划分，并使用 5 折交叉验证（5-Fold Cross-Validation）以评估模型的稳定性与泛化性能。

5.3 模型评估指标

为了综合评估各模型的拟合效果与预测性能，本文采用了以下三类常用回归评估指标：

1.决定系数

决定系数反映模型解释目标变量方差的能力，定义为：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (10)$$

其中， $\bar{y}$ 为目标变量均值。 R^2 取值范围为[0,1]，值越大表示模型的拟合优度越高。

2.均方根误差

RMSE 衡量预测误差的平均水平，其定义为：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

(11)

该指标对较大误差较为敏感，反映模型整体预测精度。

3.平均绝对误差

MAE 反映预测值与实际值之间的平均绝对偏差：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

(12)

相较于 RMSE，MAE 对极端异常值的敏感度较低，更能反映模型在一般情况下的预测性能。

5.4 模型性能评估指标与模型选择

5.4.1 模型性能评估指标

为更好地解决问题二，本文使用六种回归模型对附件 2 中 2792 条运单的实际赔付金额进行回归预测。表 3 说明了运用六种回归模型，得出运单实际赔付金额的预测结果，仅取前 5 个运单进行展示。

表 3 运单实际赔付金额的预测结果（部分）

运单号	Linear Regression	Ridge Regression	Lasso Regression	Decision Tree	Random Forest	Gradient Boosting
1	248.518	248.511	248.752	150.289	210.539	262.764
2	267.279	267.267	266.369	150.289	216.356	233.105
3	570.938	570.906	573.655	565.428	627.446	712.244
4	266.504	266.494	267.560	150.289	230.911	207.683
5	52.166	52.195	58.997	14.456	18.927	30.456

此外，为避免因样本划分带来的偶然性偏差，本文在训练集上进行了 5 折交叉验证（Cross-Validation），计算六个回归模型的训练 R^2 、测试 R^2 、测试 RMSE、测试 MAE、测试 MAPE 以及交叉验证 R^2 ，以进一步验证模型的稳健性。表 4 展示了各模型在测试集上的 R^2 、RMSE、MAE、MAPE 与交叉验证 R^2 指标。通过比较以上指标，最终选择测试集 R^2 最高的模型作为最佳预测模型。

表 4 回归模型的 5 折交叉验证结果

模型	训练 R^2	测试 R^2	测试 RMSE	测试 MAE	测试 MAPE	交叉验证 R^2
Linear Regression	0.688387	0.708167	152.379615	106.419884	1.296443	0.685514
Ridge Regression	0.688387	0.708163	152.380686	106.422319	1.296749	0.685515
Lasso Regression	0.688193	0.708026	152.416601	106.423078	1.315781	0.685852
Decision Tree	0.86016	0.686511	157.932253	106.367432	0.891556	0.654023
Random Forest	0.876251	0.770261	135.200352	93.972297	0.86167	0.75416
Gradient Boosting	0.882456	0.759628	138.293458	96.141377	0.851338	0.751434

5.4.2 模型选择

本文根据模型性能评估指标结果对每个模型的拟合效果进行评价，并选择出最优的模型。图 19 展示了各模型的测试 R^2 柱形图，其中，随机森林模型的测试 R^2 最大，达到 0.7703，说明随机森林模型对运单的实际赔付金额的预测准确性与拟合优度更大，模型更有解释力与准确性。图 20 展示了各模型的测试 RMSE 的值，其中，随机森林模型的测试 RMSE 最低，说明随机森林模型对运单的实

实际赔付金额的预测准确性更强，模型更有解释力与准确性。




图 19 各模型的测试 R² 柱形图




图 20 各模型的测试 RMSE 柱形图

接下来，为了系统比较不同回归模型在测试集上的预测稳定性与数值分布特性，本文绘制了各模型预测结果的箱线图对比图。该图表通过展示线性回归、岭回归、Lasso 回归、决策树、随机森林和梯度提升树六种模型对实际赔付金额的预测值分布，旨在从预测范围、离散程度、异常值情况等多个维度评估各模型的预测性能。箱线图能够直观反映预测值的集中趋势、变异范围以及可能存在的系统性偏差，为选择最优预测模型提供全面的可视化依据，同时也有助于识别不同模型在特定数值区间的预测特性。




图 21 各模型对新数据的预测结果分布

从图 21 预测结果分布图可以清晰观察到不同模型的预测特性差异：三种线性模型（线性回归、岭回归、Lasso 回归）的预测范围相对集中，箱体较窄且分布紧凑，表明其预测结果较为保守，波动性较小；而树模型（决策树、随机森林、梯度提升树）则展现出更宽的预测范围，特别是决策树模型存在明显的上下边缘延伸，反映了其捕捉数据极端值的能力。随机森林与梯度提升树的箱体位置相对居中且分布较为对称，说明其预测值集中在合理区间，而线性模型的预测值整体偏低。值得注意的是，决策树模型存在较多的离群预测点，表明其稳定性相对较差。综合来看，随机森林和梯度提升树在保持适当预测范围的同时，展现了更好的稳定性和合理性，这与前期模型评估中随机森林表现最优的结论相互印证，进一步证实了其在赔付金额预测任务中的适用性。

为了直观比较六种回归模型在实际赔付金额预测任务中的表现差异，本文构建了预测-实际值一致性对比图（六宫格散点图，图 22）。该图通过并排展示线性回归、岭回归、Lasso 回归、决策树、随机森林和梯度提升树的预测值与实际值散点分布，旨在从拟合优度、预测偏差、数据分布等多个角度进行模型间横向对比。每个子图中的对角线参考线为理想预测线，散点与该线的偏离程度直接反映了模型的预测精度，而决定系数 R^2 的标注则为模型性能提供了量化依据。




图 22 各模型的预测值分布

从六宫格散点图的对比中可以得出以下重要结论：三种线性模型（线性回归、岭回归、Lasso 回归）的 R^2 均约为 0.708，散点分布相对分散且呈现明显的带状分布，表明其对实际赔付金额的预测存

在系统性偏差，无法充分捕捉数据的非线性特征；决策树模型（ $R^2=0.6855$ ）表现最差，散点分布最为离散，显示出明显的过拟合倾向。相比之下，集成树模型表现优异，随机森林（ $R^2=0.7703$ ）和梯度提升树（ $R^2=0.7596$ ）的散点更紧密地聚集在对角线周围，特别是在高赔付金额区域仍能保持较好的预测精度。值得注意的是，随机森林的散点分布最为均匀，在高值和低值区间的预测一致性都较好，而梯度提升树在中等赔付区间的预测更为集中。这一可视化结果与之前的定量评估高度一致，充分证明了随机森林在捕捉复杂数据模式方面的优势，是其被选为最终预测模型的重要依据。

从图 23 决策树模型主要依赖与理赔金额、运输时效、保价与网点行为相关的特征进行决策，建议业务方在这些方面加强监控与管理，以降低风险或提升服务质量。




图 23 决策树模型特征重要性分布

为了识别梯度提升树模型中影响赔付金额预测的关键特征及其相对重要性，本文分析了该模型的原生特征重要性排序。图 24 结果显示，“保价金额”同样是最重要的预测因子，但其重要性得分相比随机森林有所下降，而“配送超时时长”和网点相关特征的重要性相对提升。这种差异反映了不同算法对特征交互作用捕捉能力的区别，梯度提升树更均衡地利用了多个运营特征的信息




图 24 梯度提升回归模型模型特征重要性分布

为了识别影响实际赔付金额预测的关键驱动因素并增强模型的可解释性，本文通过随机森林内置算法计算了特征重要性排序。图 25 分析结果显示，“索赔金额”成为最重要的预测特征，这与业

务直觉高度吻合，也与题目中“索赔差额=实际赔付金额-索赔金额”相对应，进一步证明了随机森林回归结果的有效性。




图 25 随机森林回归模型特征重要性分布

以上均说明，随机森林模型更准确，本文选择随机森林模型预测附件 2 中运单的实际赔付金额。

5.5 随机森林模型性能评估

为评估随机森林模型在不同训练样本规模下的学习能力与泛化性能，并诊断模型是否存在过拟合或欠拟合问题，本文绘制了学习曲线图。图 26 通过展示训练分数与验证分数随训练样本数量增加的变化趋势，从学习曲线可以看出，随着训练样本数量的增加，训练分数从约 0.47 稳步上升至 0.90 左右，而验证分数则从约 0.47 显著提升至 0.80 附近。在训练样本达到约 4000 条之前，两条曲线均呈现快速上升趋势，表明模型正在有效学习数据中的规律；当样本量超过 4000 后，训练分数继续缓慢上升，但验证分数增长明显放缓并趋于稳定。训练分数与验证分数之间始终保持约 0.10 的差距，这一现象表明模型存在轻微的过拟合倾向，但整体泛化能力良好。验证分数在样本量充足时稳定在 0.80 左右，说明随机森林模型已充分学习了现有数据特征，继续增加训练样本对性能提升的边际效益有限。该学习曲线证实了所选随机森林模型具备较强的学习能力和稳定的泛化性能，适用于实际赔付金额预测任务。




图 26 随机森林模型学习曲线

同时，根据图 27 的随机森林模型验证曲线，随机森林模型在 `max_depth` 约为 10 时达到最佳泛化性能（验证集 $R^2 \approx 0.85$ ），此时训练分数与验证分数最为接近，模型处于欠拟合和过拟合的理想平衡点。当 `max_depth` 继续增大时，训练分数持续上升至接近完美拟合，但验证分数不再提升且两者差距拉大，清晰地显示出过拟合现象。因此，在实际应用中应将最大深度控制在 10 左右，以避免模型过度复杂而损害泛化能力。




图 27 随机森林模型验证曲线

为了深入评估随机森林模型在实际赔付金额预测中的准确性与一致性，本文绘制了预测-实际值一致性图（Parity Plot）。该散点图通过将每个样本的实际赔付金额与模型预测值进行一一对应展示，旨在直观反映模型在整个数值范围内的预测精度分布情况。图中的对角线代表理想预测线（预测值=实际值），散点与该参考线的偏离程度直接表征了模型的预测误差。

从 Parity 图（图 28）的散点分布可以得出以下关键结论：大多数散点紧密聚集在对角线附近，表明随机森林模型在大部分样本上实现了较高精度的预测， R^2 达到 0.770 进一步证实了模型良好的解释能力。在低赔付金额区域（0-500 范围），散点分布尤为集中，几乎与对角线重合，说明模型对小额赔付的预测极为准确；随着赔付金额的增加，散点分布出现轻微扩散，但在中高赔付区间（500-1500）仍保持较好的线性趋势，未出现明显的系统性高估或低估现象。




图 28 随机森林模型预测-实际值一致性图（Parity Plot）

为了检验随机森林模型预测残差的正态性假设，本文绘制了残差 Q-Q 图，通过对比有序残差与理论正态分位数的偏离程度来评估残差分布特性。图 29 中散点基本沿着参考直线分布，仅在两端尾部出现轻微偏离，这说明模型残差总体上服从正态分布，满足线性回归的基本假设条件。该结论证实了随机森林模型在赔付金额预测任务中具有较好的统计稳健性，残差的随机性特征表明模型已充分捕捉数据中的主要规律，未出现明显的系统性偏差，为进一步的统计推断和置信区间估计提供了理论基础。




图 29 随机森林模型残差 Q-Q 图

为了诊断随机森林模型是否存在异方差性或系统性预测偏差，本文绘制了残差散点图，通过展示残差随预测值变化的分布模式来检验模型的同方差性假设。图 30 分析可见，残差随机分布在零线上下，未呈现明显的趋势性变化或喇叭形扩散模式，且残差方差在不同预测值区间内保持相对稳定，这表明模型满足同方差性假设，不存在明显的异方差问题。该结论证实了随机森林模型在整个预测范围内具有一致的预测精度，残差的随机分布特征表明模型设定合理。




图 30 随机森林模型残差散点图

为了考察随机森林模型预测残差的分布形态及其集中趋势，本文绘制了残差直方图，通过频数分布直观反映残差的整体分布特征。图 31 分析显示，残差分布呈现出近似正态分布的钟形形态，且中心位置接近零值，表明预测误差主要集中在零附近，绝大多数样本的预测偏差控制在较小范围内。

该分布特征证实了模型预测具有无偏性和良好的准确性，残差分布的正态性特征也与 Q-Q 图的结论相互印证，进一步验证了随机森林模型在赔付金额预测任务中的统计合理性。




图 31 随机森林模型残差直方图

5.6 预测结果展示

综合上述分析，本研究选择随机森林模型预测实际赔付金额，并将附件 2 中的预测结果部分展示如下表 5，仅展示 id 前 10 的运单，具体预测实际索赔金额详见附件 2。

表 5 预测实际索赔金额（随机森林模型，仅展示 id 前 10 的运单）

运单号	线路类型	预测实际索赔金
1	2	210.5393353
2	2	216.3562807
3	2	627.4468183
4	2	230.9114356
5	5	18.92756283
6	2	156.4889867
7	3	225.5634542
8	2	281.9845942
9	2	216.4858283
10	2	317.0740976

六、问题三模型的建立与求解

6.1 本章概述

本章旨在解决问题三的核心任务，即在问题一所构建的风险标签体系基础上，探索并构建一个性能最优的监督学习分类模型，用于直接预测未来运单的风险等级。与问题二“先回归后规则”的间接路径不同，本章将聚焦于端到端的直接分类方法，并对其进行深入的探索与创新。

本章将从**深度特征工程**入手，充分利用附件 1 中提供的全部字段，特别是通过构建历史行为聚合特征等手段，最大限度地挖掘数据中蕴含的风险信号，为模型提供高质量的输入。针对“严重超额”类别占比极低的**极端类别不平衡**挑战，我们将明确并实施以**代价敏感学习**为核心的处理策略，确保模型能够有效学习并识别出这一关键的少数风险类。本章将系统性地建立、训练并对比多种主流机器学习模型——从逻辑回归、随机森林到性能卓越的 XGBoost 和 LightGBM。我们将通过宏平均 F1 分数、混淆矩阵等一系列严格的评估指标，公平地评选出表现最佳的直接分类模型。

我们将对“回归+规则”与“直接分类”两种方法论进行**深度思辨与比较**，并在此基础上，提出并构建一种**基于 Stacking 集成的创新性混合策略**。我们将通过实证数据，证明该混合模型能够博采众长，在预测精度和鲁棒性上超越任何单一路径的模型。最终，本章将确立此混合模型为问题三的最优解，并阐述其在预测附件 2 数据上的完整应用流程。

6.2 数据预处理与特征工程

高质量的特征是决定机器学习模型性能上限的基石。为了从原始数据中提取最丰富、最有效的风险信号，我们设计并实施了一套系统化的数据预处理与深度特征工程流程。此流程将统一应用于附件 1 和附件 2 的数据，以确保模型训练与预测的一致性。

6.2.1 数据清洗与准备

1. 目标变量的确定与编码

本章的核心任务是构建一个监督学习分类模型，因此，我们将问题一中通过无监督方法生成的 final_label 列（包含“合理诉求”、“诉求偏高”、“严重超额”三个类别）作为本章的目标变量（y）。如图 32 所示，该目标变量呈现出极端的类别不平衡性，“合理诉求”占比高达 85.16%，而“严重超额”仅占 3.00%。这一特性是我们后续建模中必须重点应对的核心挑战。在输入模型前，我们对这三个文本标签进行了标签编码，将其转换为数值（0,1,2），以便于模型处理。




图 32 目标变量“风险标签”的类别分布

2. 数据清洗流程

a. **缺失值处理**，我们对数据集进行了全面的缺失值扫描。对于类别型特征，则采用其众数进行填

充。

b.异常值与负值处理，在探索性分析中，我们发现部分数值型特征（如保价金额、索赔金额等）中存在少量不符合业务逻辑的负值。这些负值在进行对数变换等操作时会导致计算错误。因此，我们采取了稳健的处理策略，在进行特征变换前，将所有应为非负的特征列中的负值统一替换为 0。

6.2.2 深度特征工程

为了超越原始特征的表层信息，我们构建了一系列具有更深层次业务含义的衍生特征。

1.历史行为聚合特征

识别具有重复性高风险行为的用户或网点，是风险控制的关键。因此，我们以寄件人 id 和始发网点 ID 为分组键，对训练数据进行了聚合，为每个 ID 构建了其历史行为画像。关键的聚合特征包括：

- 历史理赔频率，该 ID 历史上的总理赔次数。
- 历史风险标签分布，该 ID 历史上被标记为“诉求偏高”和“严重超额”的次数及占比。
- 历史金额画像，该 ID 历史上的平均/最大/最小/标准差索赔金额和实际赔付金额。
- 历史差额特征，该 ID 历史上的平均索赔差额。

业务价值，这些特征使得模型能够“记住”每个主体（寄件人/网点）的历史表现，从而极大地增强了对潜在高风险行为的预判能力。

2.数值特征变换

如图 33 所示，以保价金额为例，许多数值特征呈现出典型的长尾、右偏态分布。这种分布会影响部分机器学习模型的性能。我们对所有具有长尾特性的数值型特征（如金额、单量等）统一采用了对数变换，有效地将其分布形态向正态分布转化，从而提升了模型的稳定性和收敛速度。




图 33 “保价金额”特征的对数变换效果对比


3.交互与比率特征

交互特征，我们构建了部分高阶交互特征，以捕捉特定场景下的风险模式，例如商品类型与异常原因的交叉组合特征。

比率特征，为了捕捉变量间的相对关系，我们构建了比率特征，如保价金额/(索赔金额+1)，用以判断索赔是否在保价范围内。

6.2.3 差异化特征编码

如图 34 所示，数据集中的类别特征其基数（唯一值数量）差异巨大。商品类型的基数高达 16 个，而 ID 类特征（图中未完全展示）的基数更是数以万计，而另一些特征（如寄件 B/C）的基数则非常低。若采用单一的编码方式，既无法保证效率，也无法保证效果。



因此，我们根据后续模型的不同特性，采用了差异化的编码策略。

为**逻辑回归与随机森林**准备：对所有类别特征采用独热编码（One-Hot Encoding）。这种方法能将类别信息无序地、公平地呈现给模型，但其缺点在于，当面临寄件人 id 这类超高基数特征时，会产生维度灾难，导致计算效率低下且模型难以学习。因此，在为这两个模型准备数据时，我们可能会舍弃部分超高基数 ID 类特征。

为 **LightGBM** 与 **XGBoost** 准备：这两个先进的梯度提升决策树模型，其内部实现了专门针对类别特征的优化算法。它们可以直接处理经过标签编码（Label Encoding）的整数形式的类别特征，无需进行独热展开。模型能够在训练过程中，智能地找到最佳的类别分割点。业务价值在于，这不仅极大地降低了数据预处理的复杂度和内存消耗，更重要的是，它使得模型能够无损地、高效地利用所有高基数 ID 类特征中蕴含的宝贵信息，这是我们预期它们性能更优的关键原因之一。

最后，我们通过绘制数值特征的相关性热力图（图 35）来审视数据内部的结构，识别潜在的多重共线性。




图 35 数值特征相关性热力图

6.3 分类模型的对比与最优模型选择

6.3.1 类别不均衡处理策略

在 6.2.1 节的分析中，我们已经明确指出，本问题面临的核心技术挑战之一是目标变量的**极端类别不均衡性**（“合理诉求”占 85.16%，“严重超额”仅占 3.00%）。若采用标准的模型训练方法，模型的目标函数会由样本量占绝对优势的“合理诉求”类别所主导，导致模型为了追求总体准确率而倾向于忽略“严重超额”这一关键的少数风险类。这将使得模型在实际应用中形同虚设，因为我们最关心的恰恰是识别出这些高风险样本的能力。

为了克服这一挑战，我们决定不通过改变数据分布的重采样方法（如 SMOTE），而是采用一种更为先进且直接的算法层面的处理策略——**代价敏感学习**（Cost-Sensitive Learning）。

1. 代价敏感学习原理

代价敏感学习的核心思想是，为不同类别的错分情况分配不同的“代价”或“惩罚”。在我们的场景中，将一个真实的“严重超额”样本错误地预测为“合理诉求”（即漏报），其业务风险和造成的潜在损失远大于将一个“合理诉求”样本错误地预测为“诉求偏高”（即误报）。因此，我们应该对前者施加更高的惩罚。

这种策略通过修改模型的损失函数来实现。对于一个多分类问题，标准的交叉熵损失函数可以表示为：

$$L_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^C y_{ij} \log(p_{ij}) \quad (13)$$

其中， N 是样本总数， C 是类别总数（本题中为 3）， y_{ij} 是一个指示变量，如果样本 i 的真实类别是 j ，则为 1，否则为 0。 p_{ij} 是模型预测样本 i 属于类别 j 的概率。在代价敏感学习中，我们为每个类别 j 引入一个权重 w_j 。加权后的交叉熵损失函数变为：

$$L_{WCE} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^C w_j y_{ij} \log(p_{ij}) \quad (14)$$

通过设置 w_j ，我们可以放大或缩小特定类别对总损失的贡献。对于样本量较少的类别，我们会赋予其一个**较大的权重**；对于样本量较多的类别，则赋予其一个**较小的权重**。这样，在模型训练的梯度下降过程中，当一个少数类样本被错分时，它产生的损失和梯度会因为其高权重而被放大，迫使模型在参数更新时更加“关注”这个样本，努力将其预测正确。

2. 权重计算方法

权重的设置有多种方式，一种最常用且被广泛证明有效的方法是“**逆类别频率**”。其思想是，一个类别的权重与其在训练集中的样本频率成反比。计算公式如下：

$$w_j = \frac{N}{C \times N_j} \quad (15)$$

其中， N 是总样本数， C 是类别总数， N_j 是类别 j 的样本数量。根据我们在附件 1 中的统计（合理诉求:9510,诉求偏高:1322,严重超额:335），总样本 $N = 11167$ ，类别数 $C = 3$ 。我们可以计算出每个类别的权重：

$$\begin{aligned} w_{\text{合理诉求}} &\propto \frac{11167}{3 \times 9510} \approx 0.39 \\ w_{\text{诉求偏高}} &\propto \frac{11167}{3 \times 1322} \approx 2.82 \\ w_{\text{严重超额}} &\propto \frac{11167}{3 \times 335} \approx 11.11 \end{aligned} \quad (16)$$

通过采用代价敏感学习策略，我们直接在模型优化的根源，解决了类别不均衡问题。这种方法相比于改变数据分布的重采样方法，通常能更好地保持数据的原始结构，避免引入人工噪声，从而引导模型在识别我们最关心的“严重超额”风险类别上，获得显著提升的性能。

6.3.2 评估指标的选择

在模型性能的评估环节，选择科学、合理的评估指标至关重要。尤其是在本问题所面临的极端

类别不均衡场景下，单一或不恰当的评估指标极易产生误导性的结论。为了全面、客观地衡量并比较不同模型的性能，我们构建了一套多维度、侧重于不均衡学习场景的评估指标体系。

1. 准确率的局限性

首先，我们必须指出传统分类任务中最常用的准确率在本问题中的严重局限性。准确率的计算公式为：

由于“合理诉求”类别占据了超过 85% 的样本，一个“懒惰”的模型即使将所有运单都预测为“合理诉求”，其准确率也能轻易地超过 85%。然而，这样的模型对于我们最关心的风险识别任务（即找出“诉求偏高”和“严重超额”）毫无价值，其在少数风险类上的召回率为 0。因此，准确率在本研究中仅作为一个参考指标，绝不能作为模型优劣的主要评判标准。

2. 核心评估指标体系

为了克服准确率的缺陷，我们选择了以下一系列更能反映模型在不均衡数据上真实性能的指标：

混淆矩阵是所有分类评估指标的基础，它以矩阵的形式直观地展示了模型在每个类别上的具体预测情况（即将类别 A 预测为 A、B、C 的数量）。通过混淆矩阵，我们可以清晰地看到模型在哪些类别上表现良好，在哪些类别之间容易混淆。对于本研究，我们将重点关注“严重超额”这一行和这一列，以分析模型对最高风险样本的识别能力和预测精度。精确率、召回率与 F1 分数：

精确率，衡量的是在所有被模型预测为某个类别的样本中，真正属于该类别的比例。对于“严重超额”类，高精确率意味着被模型标记为高风险的运单确实是高风险的，从而避免了不必要的人工审核资源浪费。

$$P = \frac{TP}{TP + FP} \quad (17)$$

宏平均 F1 分数，这是我们选定的最重要的单一评估指标。宏平均 F1 分数的计算方式是，首先独立地计算出每个类别的 F1 分数，然后取其算术平均值：

$$Macro\ F1 = \frac{1}{C} \sum_{j=1}^C F1_j \quad (18)$$

带权 F1 分数，作为对比，我们也会计算带权 F1 分数。它同样先计算每个类别的 F1 分数，但在求平均时会根据每个类别的样本量进行加权。它能反映模型的总体性能，但会更偏向于样本量大的类别。

$$Weighted\ F1 = \sum_{j=1}^C \left(\frac{N_j}{N} \cdot F1_j \right) \quad (19)$$

在后续的模型对比中，我们将以宏平均 F1 分数为首要的排序依据，同时结合混淆矩阵中对“严重超额”类的召回率进行综合评定，以确保选出的最优模型，是在处理这一复杂且具有重要业务意义的不均衡分类问题上的真正优胜者。

6.3.3 模型训练与性能对比

在完成了数据预处理、特征工程以及确定了代价敏感学习策略后，我们进入了直接分类模型的训练与评估阶段。本节将系统性地比较逻辑回归、随机森林、XGBoost 和 LightGBM 四个模型在验证集上的性能表现，以期筛选出最优的直接分类模型。

1. 实验设置

数据划分：我们将经过预处理的附件 1 数据集，按照 80%:20% 的比例，通过**分层抽样**的方式划分为训练集和验证集。分层抽样确保了训练集和验证集中三个风险标签的比例与原始数据集保持一致。

模型训练：所有模型均在训练集上进行训练，并在验证集上进行性能评估。对于梯度提升模型（XGBoost 和 LightGBM），我们还引入了**早停机制**，以防止模型过拟合，并自动找到最佳的迭代轮

数。

2.整体性能对比分析

为了对各模型的综合性能进行宏观比较，我们绘制了它们在准确率、宏平均 F1 分数和带权 F1 分数三个关键指标上的性能对比图（图 36）。




图 36 各模型在不同评估指标上的性能对比

如图 36 所示，所有模型的准确率都处于一个非常高的水平（0.92-0.98），但这主要是由占比高达 85% 的“合理诉求”类别所驱动的，并不能真实反映模型对关键风险类的识别能力。宏平均 F1 分数的决定性差异，在更能反映模型在不均衡类别上综合性能的宏平均 F1 分数上，模型的优劣立刻显现。LightGBM 和 XGBoost 的表现远超两个基准模型，分别取得了 0.9694 和 0.9624 的高分。这表明梯度提升决策树模型在所有类别（包括最稀有的“严重超额”类）上都取得了最均衡、最优秀的表现。相比之下，逻辑回归（0.8397）和随机森林（0.8014）的表现则相对逊色。基于宏平均 F1 分数的压倒性优势，我们可以初步判定 LightGBM 和 XGBoost 是本次任务的优选模型。

3.分类别性能深度剖析

为了深入探究每个模型在具体类别上的预测行为，我们绘制了它们的混淆矩阵对比图（图 37）。




图 37 各模型混淆矩阵对比

混淆矩阵的对角线表示预测正确的样本数量。我们重点关注“严重超额”类别（第一行/第一列）的识别情况：

a.召回率对比：召回率衡量了模型“抓出”真实风险样本的能力。我们可以计算出每个模型对“严重超额”的召回率：

$$\begin{aligned} \text{逻辑回归: } & \frac{58}{58 + 0 + 9} \approx 86.6\% \\ \text{随机森林: } & \frac{50}{50 + 9 + 8} \approx 74.6\% \\ \text{XGBoost: } & \frac{66}{66 + 0 + 1} \approx 98.5\% \\ \text{LightGBM: } & \frac{65}{65 + 0 + 2} \approx 97.0\% \end{aligned} \quad (20)$$

b.精确率对比：精确率衡量了模型预测的“准确性”：

$$\begin{aligned} \text{XGBoost: } & \frac{66}{66 + 0 + 6} \approx 91.7\% \\ \text{LightGBM: } & \frac{65}{65 + 0 + 3} \approx 95.6\% \end{aligned} \quad (21)$$

混淆矩阵的对比结果进一步印证了梯度提升模型的优越性。XGBoost 和 LightGBM 不仅实现了对“严重超额”类别极高的召回率（均超过 97%），还保持了非常高的精确率。这意味着它们不仅能最大程度地发现高风险运单，而且其发出的“警报”也非常可靠，极大地优于基准模型。

4.整体判别能力评估

最后，我们通过绘制 ROC 曲线来评估模型的整体判别能力。




图 38 各模型 Micro-Average ROC 曲线对比




图 39 最优模型（LightGBM）各类别 ROC 曲线

模型间对比，在 Micro-Average ROC 曲线对比图（图 37）中，所有模型的曲线都紧贴左上角，AUC 值均非常高（>0.99），表明它们整体上都具备优秀的判别能力。其中，LightGBM 以 0.9997 的微弱优势位居第一，再次证明了其卓越性能。

最优模型分类别表现，在最优模型 LightGBM 的各类别 ROC 曲线图（图 38）中，我们可以看到，模型对于所有三个类别都展现出了近乎完美的判别能力，AUC 值均超过了 0.998。特别值得注意的是，即使对于样本量最少的“严重超额”类别，其 AUC 值也高达 0.9999。这充分说明，我们采用的代价敏感学习策略取得了巨大成功，使得模型能够有效学习并区分出这一关键的风险类别。

通过对多项核心评估指标的系统性比较，我们得出结论，LightGBM 在本次直接分类任务中，综合表现最佳。它不仅在宏平均 F1 分数上取得最高分，还在对关键的“严重超额”类别的识别上，同时实现了极高的召回率和精确率，并且其整体和分类别的 AUC 值均接近完美。因此，我们选择 LightGBM 作为最优的直接分类模型。

6.4 创新性混合策略的构建与验证

6.4.1 方法论比较

在完成了问题二（实际赔付金额预测）和问题三（直接风险标签分类）的模型构建后，我们得到了两种达成“风险标注”这一最终业务目标的技术路径。为了全面评估二者的适用性与优劣，本节将从多个维度对这两种方法论进行深入的分析。

1.方法 A：“回归+规则”策略

该策略源于问题二的解决思路。它首先通过训练一个回归模型（我们在问题二中最终选定了随机森林回归模型）来预测一个核心的连续值——实际赔付金额。然后，基于这个预测值和客户的原始索赔金额，计算出预测的索赔差额。最后，将这个预测的二维坐标点（预测实际赔付金额，预测索赔差额），代入我们在问题一中建立的、由单类 SVM 定义的非线性决策边界规则中，从而得到最终的风险标签。

2.方法 B：“直接分类”策略

该策略是问题三的核心任务。它将风险标注视为一个端到端的监督学习分类问题。我们利用问题一生成的标签作为“真值”，训练一个多分类模型（我们在 6.3 节中最终选定了 LightGBM 分类模型），该模型可以直接输入运单的全部特征，并直接输出其属于“合理诉求”、“诉求偏高”或“严重超额”三个类别的概率。

为了更清晰地总结两种方法论的差异，我们制作了如下的综合对比表（表 6）：

表 6 “回归+规则”与“直接分类”方法论综合对比

对比维度	方法 A	方法 B
核心思想	先预测核心连续值，再应用显式规则分类	直接预测离散的类别标签
可解释性	强(决策边界可视化、规则透明)	弱(集成模型内部逻辑复杂)
信息利用率	间接，可能存在信息损失 (聚焦于金额)	全面、直接(综合所有特征进行分类决策)
决策边界	硬性、几何边界	柔性、概率边界
不平衡处理	间接(在问题一的无监督阶段处理)	直接(需采用代价敏感学习等专门策略)
模型依赖	强依赖于回归模型的预测精度	直接优化分类指标，目标明确
优势	逻辑清晰，业务可解释性强，规则稳定	性能上限可能更高，能捕捉更复杂的组合模式
劣势	对回归误差敏感，信息利用不充分	“黑盒”特性，对不平衡问题需要专门处理

两种方法各有千秋，不存在绝对的优劣，而是适用于不同的业务侧重点。方法 A 更适合于需要强可解释性、决策流程需要对业务人员完全透明的场景。而方法 B 则在追求极致预测精度、希望模型能自动挖掘所有潜在风险信号的场景下，可能具有更高的性能上限。认识到这一点，为我们接下来提出一个能够融合二者优势的创新性混合策略奠定了理论基础。

6.4.2 混合策略的优化设计

在对“回归+规则”（方法 A）与“直接分类”（方法 B）两种方法论进行深入的优劣势分析后，我们认识到二者在信息利用和决策逻辑上具有很强的互补性。为了融合二者的优势，克服单一模型的局限性，我们设计并实现了一种创新的**基于深度元特征的 Stacking 集成混合策略**。

初步的 Stacking 尝试表明，简单地将两个性能差异巨大的基础模型进行组合，效果并不理想。为了让混合模型真正实现“青出于蓝而胜于蓝”，我们对元学习器的输入信息（即元特征）进行了深度优化。其核心思想是：不仅要告诉元学习器两个基础模型“预测了什么”，更要告诉它模型“预测的有多自信”，以及做出预测时所处的具体“场景”。

最终确立的优化框架如下图 40 所示，其元特征由以下三部分构成：

- 1.方法 A 的风险信息：**我们不再使用方法 A 预测的“硬”标签，而是直接采用其核心中间产物——风险分数（risk_score）。这个连续值比离散标签包含了更多关于样本与“合理”边界相对位置的精细信息。
- 2.方法 B 的完备输出：**我们保留了方法 B 输出的完整概率分布，同时，为了量化其预测的“自信程度”，我们额外计算了其预测概率的信息熵。熵越高，代表模型 B 对当前样本的判断越“犹豫”，其预测可能越不可靠。
- 3.关键原始特征：**我们利用 LightGBM 的特征重要性排序，筛选出对预测结果影响最大的 Top 5 原始特征（如索赔金额、妥投到进线时长等），并将其直接送入元学习器。这为元学习器提供了决策的“上下文”。




图 40 混合模型框架

6.4.3 混合策略的性能验证

我们采用严格的 5 折交叉验证来生成用于训练元学习器的、无信息泄露的元特征。最终，我们

使用一个 LightGBM 分类器作为元学习器，因为它具有强大的非线性关系学习能力，能够最有效地从丰富的元特征中学习复杂的组合规则。

在留出的验证集上，我们对方法 A、方法 B 以及最终优化后的混合模型的宏平均 F1 分数进行了最终的对决，结果如图 41 所示。




图 41 三种方法宏平均 F1 分数对比

实验结果清晰地证明了我们混合策略的性能。

1.性能的显著超越，最终优化混合模型的宏平均 F1 分数达到了 0.9664，成功地、也是唯一地超越了性能已经极强的单一最优模型方法 B。这实现了我的优化目标。

2.“差生”的价值挖掘，尽管方法 A 的独立性能（0.6780）远低于方法 B，但我们的深度混合策略成功地从其独特的、基于几何边界的“风险分数”中，挖掘出了对方法 B 的有效补充信息。

3.智能化决策的体现，这一性能的提升，可以理解为元学习器学会了类似这样的高级决策规则：“在大部分情况下，我都应该相信方法 B 的预测概率。但是，当方法 B 的预测熵很高，且样本的索赔金额处于某个特定区间，同时方法 A 给出的风险分数又超过某个阈值时，我就需要修正方法 B 的判断，提高其风险等级。”

通过构建一个包含基础模型输出、模型置信度信息和关键原始特征上下文的深度元特征空间，我们提出的最终优化混合策略成功地实现了两种迥异方法论的优势互补。它不仅证明了 Stacking 集成在表格数据任务上的巨大潜力，更展示了通过精心设计元特征，可以实现超越任何单一模型的、真正意义上的“集体智慧”。因此，我们最终选择此最终优化混合模型作为问题三的最优解决方案。

6.5 本章小结

本章围绕问题三的核心任务，进行了一场从模型构建、方法论思辨到创新性融合的深度探索。

通过**深度的特征工程**，特别是构建了一系列历史行为聚合特征，极大地丰富了原始数据的信息含量。在此基础上，我们明确了“严重超额”类别的**极端不平衡性**是本问题的核心挑战，并成功应用了代价敏感学习策略来应对。我们系统性地对比了多种主流机器学习模型。实验结果清晰地表明，以 LightGBM 为代表的梯度提升决策树模型，在处理此类复杂、高维、类别不平衡的表格数据分类问题上具有压倒性的优势，其性能远超逻辑回归和随机森林等基准模型。这为我们确立了一个非常强大的性能基线。

本章的创新核心在于，我们不止步于选出一个最优的单一模型，而是深入地比较了“回归+规则”（方法 A）与“直接分类”（方法 B）两种方法论的优劣，并在此基础上，提出并实践了一种基于深度元特征的 Stacking 集成混合策略。实验结果令人振奋：通过为元学习器提供包括基础模型预测、模型置信度（熵）和关键原始特征在内的丰富“上下文”，我们最终构建的优化混合模型在宏平均 F1 分数上成功超越了表现已然卓越的单一最优 LightGBM 模型，实现了 1+1>2 的集成效果。通过系统

性的实验与迭代优化，我们深入探讨并验证了在复杂业务场景下，如何通过精巧的模型集成策略，融合不同方法论的优势，以达到单一模型难以企及的性能高度。这一系列工作为最终向附件 2 进行精准、鲁棒的风险标签预测，奠定了坚实的方法论和模型基础。

七、模型的评价与推广

7.1 模型评价

本次研究围绕物流理赔业务中的风险识别与服务升级，系统性地解决了从无监督风险标注、连续值预测到监督分类的三大核心问题。本节将对我们所构建模型的优缺点进行客观、全面的评价。

7.1.1 模型的优点

1.问题一的创新性与可解释性：我们创新性地采用了“孤立森林+单类 SVM”的混合模型，成功地为无标签数据建立了风险标注体系。该方法的最大优点在于，它将复杂的业务规则（如动态边界、密度差异、比例约束）数据驱动地物化为一条可解释、可视化的决策边界，其划分逻辑清晰，兼具了模型的智能性与业务的可解释性。

2.问题二的严谨性与完整性：在预测实际赔付金额时，我们不仅构建了表现优异的随机森林回归模型，更重要的是，我们通过一系列完备的诊断图表（特征重要性、学习曲线、验证曲线、Parity 图、Q-Q 图及残差图）对其进行了全面的统计学检验。这充分证明了模型的有效性、稳定性和无偏性，确保了其预测结果的可靠。

3.问题三的深度与先进性：通过采用代价敏感学习，我们有效解决了“严重超额”类别占比仅 3% 的极端不平衡挑战，确保了模型对关键风险类的识别能力。我们没有止步于构建单一模型，而是深入地对比了“回归+规则”与“直接分类”两种方法论的优劣，揭示了它们在可解释性、信息利用率和鲁棒性上的本质差异。最终，我们提出并验证了一种基于深度元特征的 Stacking 集成混合模型。该模型通过巧妙地融合两种基础方法的输出、模型置信度（熵）和关键原始特征，成功实现了性能上的“青出于蓝而胜于蓝”，其宏平均 F1 分数超越了表现已然卓越的单一最优模型，展现了在解决复杂问题上的先进性。

7.1.2 模型的缺点与改进方向

特征工程的局限性：尽管我们构建了历史行为聚合特征，但这些特征的计算完全依赖于所提供的附件 1 数据集。在真实的业务场景中，还可以引入更丰富的特征维度，如用户的生命周期特征（如注册时长）、货物的物理属性（体积、重量）、更细粒度的物流链路信息（如具体承运商、中转次数）等，这些都有可能进一步提升模型的性能上限。

可解释性的权衡：我们最终选定的最优解 Stacking 混合模型，虽然性能最强，但其内部决策逻辑的复杂性也最高，可解释性相较于方法 A 有所降低。未来的工作可以引入 SHAP 等模型事后解释性工具，对最终混合模型的每一个具体预测进行剖析，以在一定程度上弥补其“黑盒”特性。

7.2 模型推广

我们构建的这一整套从风险标注、金额预测到智能分类的集成解决方案，不仅是对本次赛题的解答，更是一个具有巨大商业应用价值的、可推广的“物流理赔智能决策引擎”。其推广应用前景广阔，可赋能于物流企业多个核心业务环节：

1.赋能售后理赔，实现智能化分流与提效。这是模型最直接的应用。通过在理赔系统前端部署我们的最终混合模型，可以实现对所有新进理赔申请的实时风险预判与自动化分流：

a.绿色通道（合理诉求）：超过 85% 的申请可被自动标记为低风险，直接进入自动化快速赔付流程，极大缩短客户等待时间，提升客户满意度。

b.黄色通道（诉求偏高）：约 12% 的申请被标记为中风险，自动流转至标准人工审核队列，使审核人员能更专注地处理这些需要沟通协商的案例。

c.红色通道（严重超额）：约 3% 的申请被标记为高风险，自动触发高级别预警，并流转至资深审核员或反欺诈专案组进行深度审查。

通过这种智能化的“预检分诊”，企业可以在保障客户体验的同时，将宝贵的人力资源从海量的低风险审核中解放出来，实现理赔环节的降本增效。

2.赋能风险控制，从被动响应到主动干预。模型构建过程中产生的深度特征，尤其是用户的历史

行为聚合特征，本身就是一个高价值的用户风险画像。风险控制部门可以利用这些画像，**识别高风险用户/网点**，定期筛选出历史上“严重超额”标签占比较高的用户或发货网点，将其列入监控名单。**动态调整风控策略**，对高风险用户或发往高风险区域的包裹，可以动态调整其理赔审核的严格等级。

3.赋能售前服务，实现个性化服务与风险前置。这是对理赔数据价值的深度挖掘，实现了从售后到售前的闭环。在客户下单环节，系统可以实时调用我们构建的用户风险画像。**个性化保价推荐**，对于历史信用良好、从未有过高风险理赔记录的优质客户，可以提供更便捷的保价选项；而对于被识别为高风险的用户，系统可以强制要求其购买足额保价，或提高其保价费用。**差异化服务**，对高价值且易损的商品，如果寄件人是高风险用户，系统可以在下单时就进行风险提示，甚至推荐更可靠的物流产品。

因此，我们构建的模型体系不仅是一个预测工具，更是一套能够深度融入物流业务、打通售前与售后、平衡客户体验与运营成本的**智能化解决方案**，具有广阔的推广前景和重大的商业价值。

八、参考文献

- [1] Yunnan C ,Jiangmin C ,Shijie L . Spatial Heterogeneity of Intra-Urban E-Commerce Demand and Its Retail-Delivery Interactions: Evidence from Waybill Big Data[J].Journal of Theoretical and Applied Electronic Commerce Research,2025,20(3):190-190.DOI:10.3390/JTAER20030190.
- [2] Release of Waybill Data[J].The Federal Register / FIND,2025,90(007):2772-2772.
- [3] Shi D ,Dick T C . Influence of Interchange, Train Type and Commodity Shipped on the Adoption of Higher Gross Rail Load Railcars by US Freight Railroads[J].Transportation Research Record,2025,2679(1):1750-1767.DOI:10.1177/03611981241257411.
- [4] Castilla A B . Freight rail transportation and inflation: Analysis of the 2022 Mexican economic regulatory Directives[J].Case Studies on Transport Policy,2025,19101339-101339.DOI:10.1016/J.CSTP.2024.101339.
- [5] Wu T ,Mao J ,Zhu Y , et al. Multi-view context awareness based transport stay hotspot recognizing[J].World Wide Web,2024,27(5):52-52.DOI:10.1007/S11280-024-01256-5.
- [6] Chang J ,Li G ,Sun W , et al. Geo-visualisation of the community structure of intercity express delivery network in China based on waybill big data[J].Environment and Planning B: Urban Analytics and City Science,2024,51(6):1380-1383.DOI:10.1177/23998083241241842.
- [7] E.T. R ,B. C ,G. A . Storage of Emergency Airway Equipment on Labor and Delivery Units[J].Obstetric Anesthesia Digest,2024,44(2):75-76.DOI:10.1097/01.AOA.0001015976.49431.15.
- [8] Release of Waybill Data[J].The Federal Register / FIND,2024,89(072):25910-25910.
- [9] Hakhyun K ,Hee J H ,Hyosil K , et al. CRISPR/Cas9 targeting of passenger single nucleotide variants in haploinsufficient or essential genes expands cancer therapy prospects[J].Scientific Reports,2024,14(1):7436-7436.DOI:10.1038/S41598-024-58094-8.
- [10] 30-Day Notice of Intent To Seek Extension of Approval of Collection: Waybill Sample[J].The Federal Register / FIND,2023,88(243):88211-88211.